

Aprendizado de Mundo Aberto em Poços de Petróleo

Da detecção baseada em regras à explicabilidade
por agentes de linguagem

Lucas Gouveia Omena Lopes

Thales Miranda de Almeida Vieira
Eduardo Toledo de Lima Junior
William Wagner Matos Lira

Pedro Esteves Aranha
Ricardo Emanuel Vaz Vargas

Laboratório de Computação Científica e Visualização
Universidade Federal de Alagoas

Petrobras

Maceió — 2026

Prefácio

Este livro conta a história de uma ideia.

A ideia é simples de enunciar e difícil de realizar: *um sistema de monitoramento industrial não deveria fingir que já viu tudo*. Quando um poço de petróleo a dois mil metros de lâmina d'água começa a se comportar de forma estranha, o classificador que o vigia tem duas escolhas honestas — dizer “isto é um fechamento espúrio da válvula de segurança” ou dizer “isto eu nunca vi”. O que ele não deveria fazer, e no entanto é exatamente o que a maioria dos classificadores faz, é forçar o evento desconhecido para dentro da categoria conhecida mais próxima e reportar alta confiança.

Essa patologia tem nome. Chama-se hipótese de mundo fechado (*closed-world assumption*), e é uma consequência direta da forma como treinamos modelos de classificação: apresentamos um conjunto finito de classes, otimizamos uma função de perda que exige que a soma das probabilidades seja igual a um, e obtemos um modelo que, por construção, é incapaz de responder “nenhuma das anteriores”. Em um laboratório isso é uma curiosidade metodológica. Em uma plataforma de produção, é um alarme que não toca.

De onde vem este livro

O material aqui reunido nasceu de uma linha de pesquisa desenvolvida no Laboratório de Computação Científica e Visualização da Universidade Federal de Alagoas, em cooperação com a Petrobras, e se organiza em cinco trabalhos encadeados:

1. Um **sistema dual** que combina um diagrama de decisão baseado em regras com um autoencoder recorrente, implantado em mais de vinte unidades flutuantes de produção e mais de duzentos e cinquenta poços submarinos. É a prova de que o problema é real e de que uma solução híbrida funciona em campo.
2. Um **ensemble de classificadores binários** um-contra-todos, que troca a pergunta “qual das nove classes é esta?” pela pergunta “esta é a classe k , sim ou não?”, repetida nove vezes. A mudança parece cosmética; não é. É o que permite a resposta “nenhuma das classes treinadas”.
3. Uma **estratégia completa de aprendizado de mundo aberto**, que fecha o ciclo: detectar, classificar o que é conhecido, agrupar o que não é, submeter os agrupamentos a um especialista e reincorporar as novas classes ao sistema.
4. Uma **evolução metodológica** em duas frentes — da detecção por erro de reconstrução para a segmentação temporal supervisionada, e da detecção de novidade por ensemble para a detecção por distância de Mahalanobis no espaço latente.
5. Uma **camada de agente de linguagem**, colocada a jusante de todo o restante, cuja função não é classificar melhor, mas explicar, questionar e nomear.

Cada um desses trabalhos existe como tese ou artigo. O que faltava era o fio que os liga — a narrativa que mostra por que cada passo foi dado, o que exatamente estava quebrado antes dele e o que continuou quebrado depois. Este livro é esse fio.

Para quem foi escrito

Escrevemos para estudantes de pós-graduação e engenheiros que precisam construir — e não apenas usar — sistemas de monitoramento inteligente. Isso impõe duas obrigações.

A primeira é **não pressupor conhecimento prévio**. Os Capítulos 1 a Capítulo 6 constroem, do zero, tudo o que é necessário: o vocabulário de poços e completação, a estrutura dos dados de séries temporais, as métricas de avaliação em cenários desbalanceados, as arquiteturas de redes recorrentes e convolucionais, os autoencoders e o conceito de espaço latente, os algoritmos de agrupamento e os fundamentos de reconhecimento em conjunto aberto. Quem já domina esse material pode saltar diretamente para a Parte II; quem não domina não ficará para trás.

A segunda obrigação é **mostrar os números**. Um livro sobre métodos aplicados que não apresenta resultados não é um livro sobre métodos aplicados. Todas as tabelas de desempenho dos trabalhos originais são reproduzidas aqui, com discussão crítica — inclusive, e sobretudo, dos casos em que o método falhou. A classe *Instabilidade de Fluxo* atravessa este livro inteiro como um problema não resolvido; a classe *Hidrato na Linha de Serviço* idem. Preferimos expor essas fronteiras a escondê-las.

Uma observação sobre linguagem

O livro é escrito em português. A terminologia técnica da área, contudo, é majoritariamente anglófona, e traduzir siglas consagradas seria um desserviço a quem precisa ler a literatura primária ou conversar com um fornecedor. Adotamos a seguinte convenção: conceitos são traduzidos, com o termo original em itálico entre parênteses na primeira ocorrência; siglas operacionais (PDG, TPT, DHSV, ICV, BSW) e nomes de arquiteturas (LSTM, U-Net) permanecem em inglês, expandidos na primeira ocorrência e listados na lista de siglas.

Números decimais usam vírgula, conforme a norma brasileira. Quando reproduzimos uma tabela de um trabalho original em inglês, os valores são convertidos, mas jamais alterados.

Os autores

Maceió, 2026

Como ler este livro

A arquitetura do argumento

O livro está organizado em cinco partes que correspondem a cinco momentos de uma mesma investigação, e a estrutura cabe em um parágrafo. A Parte I ensina o necessário. A Parte II apresenta a base — três estratégias que, juntas, constituem o primeiro sistema completo de aprendizado de mundo aberto para poços de petróleo. A Parte III mostra como essa base foi revista quando suas limitações ficaram claras. A Parte IV acrescenta a camada que faltava: explicação. A Parte V amarra tudo e discute o que falta.

Trilhas de leitura

Leitura completa (curso de um semestre).

Capítulos 1 a 18 na ordem. Os Capítulos 1 a 3 cobrem domínio e dados; Capítulos 4 a 6 cobrem método; os demais são aplicação. Uma disciplina de quinze semanas comporta um capítulo por semana com três semanas de folga para os projetos.

Leitura para quem já sabe aprendizado de máquina.

Comece pelo Capítulo 2 (o vocabulário de poços é indispensável e não é óbvio), leia o Capítulo 3 (o conjunto 3W tem particularidades que confundem quem chega de outros domínios), passe rapidamente pelo Capítulo 6 e vá para a Parte II.

Leitura para quem quer implantar.

Capítulo 2, Capítulo 7 (o sistema que efetivamente está em campo), Capítulo 16 (arquitetura de referência) e Capítulo 17 (implantação, deriva, governança). Volte aos demais conforme a necessidade.

Leitura para quem só quer os resultados.

Capítulo 7, Capítulo 8, Capítulo 9, Capítulo 11, Capítulo 12 e Capítulo 15 contêm todas as tabelas. O Capítulo 16 consolida.

Convenções tipográficas

Ao longo do texto você encontrará seis elementos recorrentes.

Objetivos de aprendizagem

Abre cada capítulo. Lista, em forma de verbos de ação, o que se espera que o leitor saiba fazer ao terminá-lo. Os verbos foram escolhidos para refletir o que o texto de fato entrega: este é um livro de argumentação e evidência, não um manual de implementação. Onde o objetivo é “descrever” ou “reconhecer”, o capítulo não pretende habilitar o leitor

a implementar o método do zero; para isso, o Capítulo E aponta código executável e o Capítulo D reúne os hiperparâmetros.

As **caixas de definição**, em azul, introduzem conceitos formais e são numeradas por capítulo (por exemplo, *Definição 6.2*), de modo que podem ser referenciadas cruzadamente. As **caixas de exemplo**, em verde, aplicam o conceito imediatamente anterior a um caso concreto, quase sempre extraído dos dados reais discutidos no livro, e seguem a mesma numeração.

Resultado-chave

Destaca um número ou achado que sustenta o argumento do capítulo. É o que você deve levar consigo se ler apenas as caixas.

Caixa de atenção

Marca uma armadilha conceitual, uma limitação relevante ou uma decisão de projeto cuja motivação não é evidente.

Cada capítulo termina com um **resumo**, uma lista de **exercícios** — mesclando questões conceituais, exercícios de cálculo e propostas de implementação — e sugestões de **leituras recomendadas**.

Nomenclatura das classes de anomalia

Todo o livro utiliza a numeração canônica do conjunto de dados 3W, apresentada em detalhe no Capítulo 3. Por conveniência, ela é reproduzida aqui:

Classe	Evento
0	Estado normal
1	Aumento abrupto de BSW
2	Fechamento espúrio da DHSV
3	Golfadas severas
4	Instabilidade de fluxo
5	Perda rápida de produtividade
6	Restrição rápida no PCK
7	Incrustação no PCK
8	Hidrato na linha de produção
9	Hidrato na linha de serviço
—	Falha de ICV (<i>dado proprietário; não pertence ao 3W</i>)
—	Operação de válvula (<i>dado proprietário; não pertence ao 3W</i>)

Sobre reprodutibilidade

O conjunto de dados 3W é público. Os dados proprietários de poços da Petrobras utilizados nos estudos de caso não o são, e portanto os resultados que dependem exclusivamente deles não podem ser reproduzidos por terceiros. Sempre que um resultado depende de dados fechados, isso é dito explicitamente. O Capítulo D reúne hiperparâmetros, ambiente computacional e procedimentos de avaliação de todos os experimentos discutidos.

O leitor que quiser executar código, e não apenas lê-lo, deve começar pelo Capítulo E. Ele descreve um recurso didático público, hospedado no próprio repositório do 3W (Petróleo

Brasileiro S.A. (Petrobras), 2026; Lopes, 2026), que percorre em cinco cadernos Jupyter todo o caminho da Parte I: tratamento de dados, visualização, autoencoders, classificadores supervisionados e agrupamento. As caixas de **prática** espalhadas pela Parte I apontam, capítulo a capítulo, qual caderno exercita qual conceito.

Sumário

Prefácio	iii
Como ler este livro	v
Lista de siglas	xxvii
Notação	xxxix
I Fundamentos	1
1 Por que vigiar um poço de petróleo	3
1.1 Um poço é um sistema que você não pode ver	3
1.1.1 A escala do problema	3
1.1.2 O que dá errado	4
1.2 O custo de não saber	4
1.3 Três problemas, não um	5
1.4 A hipótese de mundo fechado	6
1.5 O percurso deste livro	7
Resumo do capítulo	8
Exercícios	8
Leituras recomendadas	9
2 Anatomia de um poço submarino	11
2.1 Do reservatório à plataforma	11
2.1.1 A completação	12
2.1.2 A árvore de natal molhada	12
2.2 O que os sensores enxergam	13
2.2.1 Os quatro sinais fundamentais	14
2.2.2 Por que os sensores mentem	14
2.3 A taxonomia dos eventos indesejáveis	15
2.3.1 Classe 0 — Estado normal	15
2.3.2 Classe 1 — Aumento abrupto de BSW	15
2.3.3 Classe 2 — Fechamento espúrio da DHSV	15
2.3.4 Classe 3 — Golfadas severas	16
2.3.5 Classe 4 — Instabilidade de fluxo	16
2.3.6 Classe 5 — Perda rápida de produtividade	16
2.3.7 Classe 6 — Restrição rápida no PCK	16
2.3.8 Classe 7 — Incrustação no PCK	17
2.3.9 Classe 8 — Hidrato na linha de produção	17
2.3.10 Classe 9 — Hidrato na linha de serviço	17

2.4	Além do 3W: eventos de completção inteligente	17
2.5	Uma taxonomia por assinatura	18
	Resumo do capítulo	18
	Exercícios	18
	Leituras recomendadas	19
3	Os dados: séries temporais de poços e o conjunto 3W	21
3.1	Formalização	21
3.2	O conjunto 3W	22
3.2.1	Origem e propósito	22
3.2.2	Versão 1.0	22
3.2.3	Versão 2.0	22
3.2.4	Três procedências	23
3.3	A rotulação	23
3.3.1	Três estados por amostra	23
3.3.2	Rótulo por instância	24
3.4	As armadilhas	24
3.4.1	O estado das válvulas muda a estrutura de correlação	24
3.4.2	Desbalanceamento	25
3.4.3	Valores ausentes e sensores congelados	25
3.4.4	A correlação espúria mais perigosa do 3W	26
3.4.5	Vazamento temporal e vazamento entre poços	26
3.5	Pré-processamento	26
	Resumo do capítulo	27
	Exercícios	28
	Leituras recomendadas	28
4	Aprendizado de máquina e avaliação	29
4.1	As duas formulações	29
4.1.1	Supervisionada	29
4.1.2	Não supervisionada	29
4.2	A matriz de confusão e o que se extrai dela	30
4.3	Métricas de regressão e reconstrução	31
4.4	Avaliação de detecção de eventos	31
4.4.1	A métrica de sobreposição para segmentação	32
4.5	Métricas para <i>ranking</i> : acurácia top- <i>k</i>	32
4.6	Incerteza: intervalos de confiança para proporções	33
4.7	Validação	34
4.7.1	Validação cruzada estratificada	34
4.7.2	Divisão temporal	34
4.7.3	Avaliação por poço	34
	Resumo do capítulo	35
	Exercícios	35
	Leituras recomendadas	35
5	Aprendizado profundo para séries temporais	37
5.1	Da regressão à rede profunda	37
5.1.1	O perceptron de múltiplas camadas	37
5.1.2	Regularização	38
5.2	Redes recorrentes	38
5.2.1	O problema	38

5.2.2	A célula LSTM	38
5.2.3	GRU	39
5.3	Convoluções unidimensionais	39
5.3.1	Convolução <i>versus</i> recorrência	40
5.4	Autoencoders	40
5.4.1	Autoencoder variacional	42
5.4.2	Rede de agrupamento profundo	42
5.5	A U-Net unidimensional	43
5.6	Atenção e Transformers	44
	Resumo do capítulo	44
	Exercícios	44
	Leituras recomendadas	45
6	Detecção de novidade e mundo aberto	47
6.1	Três níveis de abertura	47
6.1.1	Risco de espaço aberto	48
6.2	Quatro escores de novidade	48
6.2.1	Erro de reconstrução	48
6.2.2	Máquina de vetores de suporte de uma classe	49
6.2.3	Distância de Mahalanobis	50
6.2.4	Rejeição por ensemble binário	51
6.2.5	Comparação	51
6.3	Agrupamento	51
6.3.1	K-means	52
6.3.2	MeanShift	52
6.3.3	DBSCAN	52
6.3.4	Combinação e refinamento	52
6.4	Avaliar agrupamentos sem rótulos	53
6.5	Visualização	54
6.6	O ciclo completo	54
	Resumo do capítulo	55
	Exercícios	56
	Leituras recomendadas	56
II	A base: da regra ao mundo aberto	57
7	O sistema dual: regra e reconstrução	59
7.1	O problema que este capítulo resolve	59
7.2	Arquitetura geral	60
7.3	O diagrama de decisão	60
7.3.1	O tratamento de manobras de válvula	62
7.4	O detector por autoencoder	62
7.4.1	Lógica de operação	62
7.4.2	Arquitetura da rede	64
7.4.3	Treinamento	64
7.4.4	Limiar e classificação de risco	64
7.5	Implantação	65
7.6	Resultados	66
7.6.1	Contribuição de cada componente	66
7.6.2	Comparação com a literatura	67

7.6.3	Estudos de caso em poços reais	67
7.7	Limitações	72
	Resumo do capítulo	72
	Exercícios	72
	Leituras recomendadas	73
8	Ensemble de classificadores binários	75
8.1	Uma mudança de pergunta	75
8.1.1	Três consequências adicionais	76
8.1.2	E os custos	76
8.2	Metodologia	76
8.2.1	Análise exploratória	76
8.2.2	Preparação dos dados	77
8.2.3	Arquitetura dos classificadores	77
8.2.4	Otimização de hiperparâmetros	77
8.3	Resultados por classe	78
8.3.1	Leitura global	79
8.3.2	Onde as duas abordagens divergem	79
8.3.3	A falha da OCSVM	80
8.3.4	As duas classes problemáticas	80
8.3.5	Sobre a comparação com a literatura	80
8.4	O que falta	81
	Resumo do capítulo	81
	Exercícios	81
	Leituras recomendadas	82
9	O ciclo de aprendizado de mundo aberto	83
9.1	A questão em aberto	83
9.2	As seis etapas	84
9.3	Etapas 1: a representação latente	84
9.3.1	Arquitetura	84
9.3.2	Por que não um VAE ou um DCN	84
9.4	Etapas 2 e 3: reconhecer e rejeitar	86
9.4.1	Classificadores binários no espaço latente	86
9.4.2	O voto ponderado	86
9.4.3	Desempenho dos classificadores binários latentes	87
9.5	O teste real: a anomalia de ICV	87
9.5.1	Como o ensemble reage	88
9.6	Etapas 4 e 5: agrupar, refinar, validar	89
9.6.1	Estimar o número de grupos	89
9.6.2	Interseção entre dois algoritmos	89
9.6.3	Refinamento por limiar adaptativo	91
9.6.4	Validação	92
9.6.5	O que o agrupamento acerta, quando acerta	92
9.7	Etapas 6: classes virtuais	93
9.8	Balanco	94
	Resumo do capítulo	95
	Exercícios	95
	Leituras recomendadas	96

III	A evolução	97
10	Superando o mundo fechado	99
10.1	Do princípio à evidência	99
10.2	O experimento da classe escondida	99
10.2.1	Protocolo	99
10.2.2	Resultado	100
10.2.3	Os onze por cento restantes	101
10.3	O comprimento da janela	101
10.3.1	Um compromisso que não é técnico	101
10.3.2	Três leituras da tabela	101
10.4	Validação contra um modelo físico	103
10.4.1	A ideia	103
10.4.2	O modelo de Motiee	103
10.4.3	Resultado da comparação	104
10.4.4	Interpretando a diferença	105
10.4.5	A complementaridade na tela do operador	105
10.5	Custo computacional	105
10.6	Limitações	107
	Resumo do capítulo	107
	Exercícios	108
	Leituras recomendadas	108
11	Da detecção à segmentação	109
11.1	A pergunta errada	109
11.2	A U-Net unidimensional	110
11.2.1	Por que esta arquitetura	110
11.2.2	Arquitetura	110
11.3	Protocolo experimental	110
11.4	Resultados	111
11.4.1	Autoencoder <i>versus</i> U-Net	111
11.4.2	O número que importa não é a média	111
11.4.3	Qualidade da delimitação	112
11.5	Avaliação por SoftED	113
11.5.1	O problema das métricas ponto a ponto	113
11.5.2	Resultados	113
11.5.3	Três leituras	113
11.5.4	O poço A3, ou como uma métrica revela um problema de dados	113
11.6	Os classificadores binários sobre segmentos	114
11.7	Limitações	115
	Resumo do capítulo	115
	Exercícios	115
	Leituras recomendadas	116
12	Novidade no espaço latente	117
12.1	Retomando um resultado incômodo	117
12.2	A distância de Mahalanobis como score	118
12.2.1	Definição	118
12.2.2	Calibração do limiar	118
12.3	Três espaços em competição	118
12.4	Resultados	119

12.4.1	Detecção de novidade	119
12.4.2	Três observações	119
12.4.3	Quanto o desconhecido se afasta	120
12.4.4	Por que o latente é melhor: a evidência direta	120
12.4.5	Efeito sobre a classificação	121
12.5	Balanço da evolução	122
12.6	Limitações	122
	Resumo do capítulo	123
	Exercícios	123
	Leituras recomendadas	124
IV	A explicabilidade	125
13	Modelos de linguagem como camada de raciocínio	127
13.1	A pergunta que sobrou	127
13.2	O <i>transformer</i>	128
13.2.1	Atenção	128
13.2.2	Da arquitetura ao modelo de linguagem	128
13.3	Mistura de especialistas	128
13.4	Como se instrui um modelo de linguagem	129
13.4.1	Prompt	129
13.4.2	Saída estruturada	129
13.4.3	Modo de raciocínio	130
13.5	Modos de falha	130
13.6	Infraestrutura	131
	Resumo do capítulo	131
	Exercícios	132
	Leituras recomendadas	132
14	A camada de agente	135
14.1	O problema de tradução	135
14.2	Pré-processamento	136
14.2.1	Seleção de instâncias	136
14.3	As treze métricas	137
14.3.1	Métricas de deslocamento	137
14.3.2	Métricas categóricas	137
14.3.3	Métricas de forma e variabilidade	138
14.3.4	Métricas entre sensores	138
14.4	Perfis de classe	139
14.4.1	Remoção de valores extremos em duas passagens	139
14.4.2	Composição do perfil	139
14.5	O prompt	140
14.6	A arquitetura completa	140
	Resumo do capítulo	141
	Exercícios	141
	Leituras recomendadas	141

15 O que o agente acerta e o que não acerta	143
15.1 Três estudos, três perguntas	143
15.2 Estudo 0: classificação	144
15.2.1 Protocolo	144
15.2.2 Resultados globais	144
15.2.3 Como não ler estes números	144
15.2.4 Por classe	144
15.3 Estudo 1: validação	146
15.3.1 Uma tarefa diferente	146
15.3.2 Resultados	146
15.3.3 Por que a precisão é o número que importa	146
15.3.4 Por classe	147
15.4 Estudo 2: detecção de novidade	147
15.4.1 Protocolo	147
15.4.2 Resultados	147
15.5 Os nomes gerados	148
15.5.1 O acerto notável	149
15.5.2 A não convergência	149
15.5.3 O achado incômodo	149
15.6 Limitações	150
Resumo do capítulo	150
Exercícios	151
Leituras recomendadas	151
 V Síntese e prática	 153
16 Síntese: uma arquitetura de referência	155
16.1 Onde chegamos	155
16.2 O que produziu cada ganho	156
16.3 Resultados consolidados	157
16.3.1 Detecção de novidade	157
16.3.2 Classificação	157
16.3.3 As duas assimetrias	158
16.4 Divisão de trabalho por classe	158
16.4.1 As classes sintomáticas	159
16.5 A arquitetura de referência	159
16.5.1 Estrutura em camadas	159
16.5.2 Fluxo	160
16.6 Sete princípios	160
Resumo do capítulo	161
Exercícios	161
Leituras recomendadas	162
 17 Da bancada à plataforma	 163
17.1 O que muda quando o sistema é ligado	163
17.2 Requisitos não funcionais	164
17.3 A interface	164
17.3.1 O que apresentar	164
17.3.2 Graduação em vez de binário	165
17.3.3 Validação de agrupamentos	165

17.4	O laço humano	166
17.4.1	Três papéis distintos	166
17.4.2	Governança de classes virtuais	166
17.5	Deriva	167
17.5.1	Três formas	167
17.5.2	O que monitorar	167
17.6	Custo	168
17.6.1	Custos que não aparecem na tabela	168
17.7	Uma lista de verificação	169
	Resumo do capítulo	169
	Exercícios	169
	Leituras recomendadas	170
18	O que ainda não sabemos	171
18.1	Uma advertência sobre o que foi medido	171
18.2	Limitações de dados	172
18.3	Limitações de método	172
18.3.1	Segmentação	172
18.3.2	Novidade	172
18.3.3	Agente	173
18.3.4	Reprodutibilidade do modelo de linguagem	173
18.4	Limitações de avaliação	174
18.5	Uma agenda	174
18.5.1	Ordenada por razão informação/custo	174
18.5.2	Quatro questões de pesquisa	175
18.6	Encerramento	175
	Resumo do capítulo	175
	Projetos de pesquisa	176
	Leituras recomendadas	176
A	Glossário	177
A.1	Operação de poços e escoamento	177
A.2	Aprendizado de máquina	178
A.3	Modelos de linguagem	180
A.4	Métricas e avaliação	181
B	Correspondência de notação	183
B.1	Séries temporais e janelas	183
B.2	Modelos e representações	184
B.3	Estatística e limiares	184
B.4	Métricas	185
B.5	Nomenclatura de classes	185
C	Formulário	187
C.1	Métricas de classificação	187
C.2	Erro de reconstrução e limiar	187
C.3	Deteção de novidade	188
C.4	Agrupamento	188
C.5	Formação de hidrato	189
C.6	As treze métricas do agente	189
C.7	Intervalo de confiança	189

C.8	Normalizações	190
D	Reprodução dos experimentos	191
D.1	Dados	191
D.1.1	O 3W	191
D.1.2	Dados operacionais	191
D.2	Ambiente computacional	192
D.3	Hiperparâmetros	192
D.3.1	Sistema dual (Capítulo 7)	192
D.3.2	Ensemble binário (Capítulo 8)	193
D.3.3	Ciclo de mundo aberto (Capítulo 9)	193
D.3.4	Segmentação (Capítulo 11)	193
D.3.5	Representação e Mahalanobis (Capítulo 12)	193
D.3.6	Camada de linguagem (Capítulos 13 e 14)	193
D.4	Protocolos de avaliação	195
D.5	Lista de verificação para reprodução	195
E	Roteiro prático com o repositório 3W	197
E.1	Estrutura do recurso	197
E.2	Instalação	197
E.3	Configuração central	198
E.4	Caderno 1: tratamento de dados	199
E.4.1	A separação entre real e simulado	199
E.5	Caderno 2: técnicas de visualização	199
E.6	Caderno 3: aprendizado não supervisionado	200
E.6.1	A arquitetura	200
E.6.2	O limiar	201
E.6.3	A alternativa geométrica	201
E.7	Caderno 4: aprendizado supervisionado	201
E.8	Caderno 5: métodos de agrupamento	202
E.9	Diferenças em relação às configurações do livro	203
E.10	Exercícios guiados	203
	Exercícios	203
	Leituras recomendadas	204
	Referências	205
	Índice remissivo	209

Lista de Figuras

2.1	Disposição típica de válvulas e sensores em um poço submarino. Os medidores PDG, TPT e PT ocupam posições fixas ao longo do caminho do fluido, e cada válvula — DHSV, M1, M2, W1, W2, XO, PXO e a reguladora — define um estado operacional distinto. Adaptado de Aranha et al. (2024a).	13
3.1	Matrizes de correlação entre os sinais de pressão e temperatura (PT, TPT e PDG), calculadas separadamente para dados do 3W e para dados de operação com a válvula M2 aberta e fechada. Vermelho indica correlação positiva; azul, negativa. Adaptado de Aranha et al. (2024a).	25
5.1	Estrutura de um autoencoder: o codificador comprime a entrada até uma representação latente de baixa dimensão e o decodificador tenta reconstruí-la. A restrição $d \ll T \cdot S$ força a rede a reter apenas os fatores de variação mais relevantes.	41
5.2	Projeção t-SNE do espaço latente produzido por uma DCN. Cada cor é uma classe conhecida; o polígono destaca a região ocupada pelas janelas da falha de ICV, uma classe que a rede nunca viu. Os pontos novos são absorvidos pelos agrupamentos existentes em vez de formar um agrupamento próprio.	42
6.1	Densidade interpolada do erro de reconstrução para dados normais e para janelas de falha de ICV, com o limiar probabilístico assinalado. A área sob cada curva soma um.	49
6.2	Fronteira de decisão de uma OCSVM treinada sobre o espaço latente, projetada por t-SNE. O gradiente representa o valor da função de decisão: regiões escuras são classificadas com confiança como conhecidas; regiões claras, como não-classe. Os pontos sobrepostos distinguem dados de validação, dados de ICV e amostras de não-classe.	50
6.3	O ciclo de aprendizado de mundo aberto aplicado à operação de poços. O fluxo é fechado: o conhecimento validado ao fim de uma volta passa a integrar a base de classificadores usada na volta seguinte.	55
7.1	Fluxo geral do sistema dual. Os dados do poço alimentam simultaneamente o diagrama de decisão e o módulo de detecção de anomalias por inteligência artificial. O diagrama de decisão encaminha ao módulo de aprendizado apenas os trechos que classifica como normais. Qualquer um dos dois componentes pode disparar o alerta ao operador. Adaptado de Aranha et al. (2024a). . . .	60
7.2	Estrutura do diagrama de decisão. O fluxo bifurca conforme o dado seja o primeiro do poço, siga uma mudança de estado de válvula ou dê continuidade a um regime já estabelecido, encaminhando cada caso para estabilização, análise de anomalia ou atualização da média móvel. Adaptado de Aranha et al. (2024a). . . .	61

7.3	Lógica operacional do módulo de detecção por inteligência artificial. Note os três estados possíveis: antes do treinamento, o sistema apenas acumula dados normais selecionados pelo diagrama de decisão; após o treinamento, ele prediz, compara com a tolerância e informa o estado do poço; uma mudança de válvula reinicia o ciclo. Dados julgados anômalos nunca retornam ao conjunto de treinamento. Adaptado de Aranha et al. (2024a).	63
7.4	Exemplo de detecção em dados reais. Nos dois painéis superiores, as pressões e as temperaturas medidas por PDG e TPT; no inferior, o escore de anomalia com a linha de tolerância da Equação (7.1). A ultrapassagem do limiar precede em várias horas o desvio que seria visível a olho nu nos sinais brutos. Adaptado de Aranha et al. (2024a).	65
7.5	Interface do sistema em operação. À esquerda, os valores instantâneos dos cinco sensores monitorados; ao centro, os registros de pressão e temperatura; à direita, os erros relativos de reconstrução por sensor e o erro agregado. O painel inferior direito mostra o escore de anomalia cruzando o limiar, indicado pela linha horizontal. Adaptado de Aranha et al. (2024a).	66
7.6	Poço 1, primeiro evento. De cima para baixo: os sensores PDG, PT e TPT, o estado das válvulas e a comparação entre a classificação dos dois modelos (<i>LSTM status</i> e <i>analytical status</i>) e a classificação humana posterior (<i>class</i>). Adaptado de Aranha et al. (2024a).	68
7.7	Poço 1, segundo evento, no mesmo dia. Adaptado de Aranha et al. (2024a).	69
7.8	Poço 2, retroanálise do evento de 6 de junho de 2018. Adaptado de Aranha et al. (2024a).	70
7.9	Poço 3, evento de 18 de outubro de 2022, com o ciclo completo: detecção, fechamento pelo operador, ciclagem, reabertura e retorno à normalidade. Adaptado de Aranha et al. (2024a).	71
8.1	Fluxo metodológico do desenvolvimento dos classificadores binários: análise exploratória, preparação dos dados, construção dos classificadores, otimização de hiperparâmetros e, por fim, verificação e validação — esta última incluindo a comparação com um modelo termodinâmico independente, discutida no Capítulo 10.	77
9.1	Projeção t-SNE do espaço latente do codificador. À esquerda, os pontos coloridos pelos oito rótulos originais do 3W; à direita, pelos agrupamentos obtidos com <i>K</i> -médias sobre a mesma representação. A correspondência entre as duas partições é parcial: alguns rótulos ocupam regiões bem definidas, outros se dispersam por vários agrupamentos. Adaptado de Lopes et al. (2025).	85
9.2	Distribuição dos escores dos nove classificadores binários quando apresentados a janelas da anomalia de ICV — uma classe que nenhum deles conhece. Seis dos nove (1, 3, 4, 6, 8 e 9) produzem escore identicamente nulo. O classificador da classe 2 concentra-se em torno do limiar 0,5, sem decidir. Os classificadores das classes 5 e 7 distribuem massa acima do limiar. A linha tracejada indica o limiar de decisão. Adaptado de Lopes et al. (2025).	88
9.3	Projeção t-SNE do espaço latente. Cada cor corresponde a um agrupamento identificado pelo K-means sobre as classes conhecidas; os círculos vermelhos são as janelas de ICV rejeitadas, e a região sombreada é o envoltório convexo que elas ocupam. Note que as janelas de ICV não formam um grupo compacto: elas se distribuem em subgrupos separados, no limite entre agrupamentos existentes. Adaptado de Lopes et al. (2025).	90

9.4	Agrupamento das janelas de ICV rejeitadas por MeanShift, projetado por t-SNE. O algoritmo identifica dois grupos e marca como ruído as amostras que não pertencem a nenhum deles — comportamento desejável, já que a rejeição inevitavelmente arrasta janelas de transição. Adaptado de Lopes et al. (2025).	90
9.5	Agrupamento das mesmas janelas por DBSCAN. O algoritmo não exige que se declare o número de grupos, mas transfere a dificuldade para os parâmetros ε e $minPts$: com a densidade heterogênea do espaço latente, ele ou funde os subgrupos ou classifica a maior parte das amostras como ruído. Adaptado de Lopes et al. (2025).	91
9.6	Ocultando as classes 3, 6 e 8 e tratando-as como desconhecidas. À esquerda, a distribuição original dos dados, colorida pelos rótulos verdadeiros; à direita, os três agrupamentos recuperados por K -médias sem acesso a esses rótulos. Adaptado de Lopes et al. (2025).	92
9.7	Matriz de confusão normalizada do agrupamento por K -médias, agregada sobre as $\binom{9}{3} = 168$ combinações possíveis de três classes ocultas. A diagonal domina, mas os erros não estão distribuídos de modo uniforme. Adaptado de Lopes et al. (2025).	93
9.8	O mesmo cenário da Figura 9.2, agora com dez classificadores. O décimo foi treinado exclusivamente sobre as janelas antes rejeitadas e reivindica a maior parte delas; as reivindicações espúrias das classes 2 e 5 retrocedem. Adaptado de Lopes et al. (2025).	94
10.1	Escores de um classificador multiclasse treinado em seis classes, quando apresentado às instâncias da classe 8 — que ele nunca viu. Note a concentração de massa próxima de 1,0 para as classes 3, 2 e 5: o modelo não hesita, ele afirma com convicção máxima que o hidrato é outra coisa. A restrição $\sum_k \hat{p}_k = 1$ não lhe permite outra resposta. Adaptado de Lopes et al. (2026c).	100
10.2	Arquitetura de validação cruzada entre modelo físico e modelo aprendido. Os mesmos valores de sensor alimentam dois caminhos independentes — a análise pressão–temperatura contra a envoltória de formação de hidrato e o classificador binário — cujos resultados são então confrontados antes de gerar o alerta. Adaptado de Lopes et al. (2026c).	103
10.3	Envoltória de formação de hidrato no plano temperatura–pressão. A curva separa a zona de operação normal da zona de formação: para uma dada pressão, temperaturas à esquerda da curva colocam o sistema em risco. Adaptado de Lopes et al. (2026c).	104
10.4	Painel operacional com os dois indicadores lado a lado. À direita, a curva de formação de hidrato com o ponto de operação atual; abaixo, os dois medidores de risco: o analítico (PVT), em 19,71 %, e o aprendido (IA), em 0,00 %. Os dois números respondem a perguntas diferentes e são apresentados sem tentativa de fundi-los em um só. Adaptado de Lopes et al. (2026c).	106
11.1	Classificador binário aplicado ao segmento identificado, com as dimensões efetivas de cada tensor de parâmetros: uma camada recorrente seguida de camadas densas decrescentes até uma única saída escalar. A figura mostra a variante com LSTM de 256 unidades; o número de unidades recorrentes é ajustado por classe. Adaptado de Lopes et al. (2026a).	114
12.1	Cabeça classificadora aplicada sobre a representação latente: duas camadas densas com ativação ReLU seguidas da camada de saída. É a mesma cabeça para os três espaços comparados, o que isola o efeito da representação.	118

- 17.1 Interface de validação de agrupamentos. O especialista inspeciona a projeção do espaço latente, seleciona um ponto e recebe as variações percentuais por sensor daquele segmento. Pode então reatribuir o ponto a outro agrupamento ou removê-lo da análise. 165

Lista de Tabelas

3.1	Parametrização de janela adotada em cada capítulo deste livro.	22
7.1	Desempenho do diagrama de decisão isolado e do sistema dual completo. . . .	66
7.2	Detecção de fechamento espúrio da DHSV: comparação com trabalhos anteriores.	67
7.3	Estudos de caso: características dos poços. WD é a lâmina d'água e TD a profundidade total.	67
7.4	Estudos de caso: eventos detectados e desempenho. O SMAPE indicado é o valor de pico do erro de reconstrução durante o evento.	68
8.1	Espaço de busca de hiperparâmetros e condições de treinamento dos classificadores binários.	78
8.2	Acurácia por classe. OVA é o ensemble um-contra-todos proposto; Multi. é o classificador multiclasse; OCSVM é a máquina de vetores de suporte de uma classe aplicada ao espaço bruto. As duas últimas colunas reproduzem Marins et al. (2021a) nas modalidades binária e multiclasse. Traços indicam classes não avaliadas naquele trabalho.	78
9.1	Acurácia do ciclo completo em função da arquitetura de representação. . . .	85
9.2	Pesos do voto ponderado por classe. $w^{(b)}$ é o peso do classificador binário e $w^{(o)}$ o da OCSVM.	86
9.3	Desempenho dos classificadores binários no espaço latente. As duas primeiras colunas referem-se ao experimento consolidado; as duas últimas, à média e ao desvio padrão entre execuções, por amostra e por instância.	87
9.4	Indicadores do estimador do número de agrupamentos reportados por Lopes et al. (2025).	89
10.1	Desempenho do classificador binário de hidrato em função do comprimento da janela T . FP e FN são as taxas de falso positivo e falso negativo.	102
10.2	Compromisso entre histórico mínimo e acurácia para três comprimentos de janela representativos; o atraso efetivo depende do passo e do alinhamento. .	102
10.3	Classificador binário de hidrato <i>versus</i> critério analítico baseado na correlação de Motiee.	104
10.4	Custo computacional por inferência, para janela de 900s.	106
11.1	Detecção por autoencoder <i>versus</i> segmentação por U-Net, avaliadas no nível de amostra, por poço.	111
11.2	Acurácia e interseção sobre união da segmentação por U-Net, por poço. . . .	112
11.3	Avaliação SoftED com tolerância $k = 1000$ amostras, por poço.	113
12.1	Acurácia de detecção de novidade (%) por classe tratada como desconhecida, sob três abordagens.	119

12.2	Razão de separação: distância de Mahalanobis média das amostras desconhecidas dividida pela das conhecidas, nos espaços bruto e latente.	120
12.3	Qualidade do espaço de representação segundo três índices internos. Para silhueta e Calinski-Harabasz, maior é melhor; para Davies-Bouldin, menor é melhor.	120
12.4	Desempenho dos classificadores binários em função do espaço de representação. Média e desvio padrão sobre as classes.	121
12.5	Evolução da detecção de novidade sobre a anomalia de ICV ao longo do livro.	122
13.1	Configuração de inferência do agente.	131
15.1	Acurácia global do agente na tarefa de classificação, com intervalos de confiança de Wilson a 95 %. As linhas de acaso correspondem a escolha aleatória entre nove classes.	144
15.2	Acurácia do agente por classe na tarefa de classificação (%).	145
15.3	Desempenho do agente na tarefa de validação.	146
15.4	Desempenho do agente na validação, por classe (%). “Val. OK” é a fração de decisões corretas julgadas válidas; “Val. Rej.” é a fração de decisões incorretas julgadas inválidas.	147
15.5	Taxa de reconhecimento de novidade pelo agente nas sete classes não sintomáticas avaliadas.	148
15.6	Nomes consolidados propostos pelo agente para cada classe apresentada como desconhecida.	148
16.1	Marcos de desempenho e a mudança conceitual responsável por cada um.	156
16.2	Detecção de novidade ao longo do livro. Valores em porcentagem. Traços indicam que a combinação não foi avaliada.	157
16.3	Acurácia de classificação por abordagem.	157
16.4	Divisão de trabalho derivada dos resultados. “Numérico” refere-se ao pipeline U-Net + latente do multiclasse + Mahalanobis.	158
17.1	Requisitos não funcionais e a resposta arquitetural correspondente.	164
17.2	Política de governança de classes virtuais.	166
17.3	Estrutura de custo por camada, em ordem de grandeza.	168
18.1	Alternativas para reprodutibilidade da camada de linguagem.	173
18.2	Agenda de trabalho, ordenada por razão entre informação obtida e custo.	174
B.1	Correspondência de notação para dados e janelas.	183
B.2	Correspondência de notação para modelos.	184
B.3	Correspondência de notação para estatística e limiares.	184
B.4	Correspondência de notação para métricas de avaliação.	185
B.5	Correspondência entre a numeração de classes do 3W e a designação usada no livro.	185
C.1	Categorizações das métricas do agente.	190
D.1	Procedência das instâncias do 3W e uso neste livro.	191
D.2	Ambiente computacional utilizado.	192
D.3	Configuração do autoencoder do sistema dual.	192
D.4	Configuração dos classificadores binários um-contra-todos.	193
D.5	Configuração do ciclo de mundo aberto.	193

D.6	Configuração da U-Net unidimensional.	194
D.7	Configuração dos espaços de representação avaliados.	194
D.8	Configuração da camada de linguagem.	194
E.1	Cadernos do recurso e sua correspondência com os capítulos do livro.	198
E.2	Configurações de projeção avaliadas no caderno 2.	199
E.3	Decisões de estabilidade numérica no autoencoder do caderno 3.	200
E.4	Modelos supervisionados do caderno 4.	201
E.5	Algoritmos de agrupamento do caderno 5.	202
E.6	Principais diferenças entre o recurso didático e os experimentos do livro. . . .	203

Lista de siglas

Operação de poços

ANM	Árvore de Natal Molhada — conjunto de válvulas instalado na cabeça do poço submarino (<i>wet christmas tree</i>).
BSW	<i>Basic Sediment and Water</i> — fração de água e sedimentos no fluido produzido.
CKGL	<i>Gas-Lift Choke</i> — válvula reguladora da injeção de gás de elevação.
CKP	<i>Production Choke</i> — válvula reguladora de produção.
DHSV	<i>Downhole Safety Valve</i> — válvula de segurança de subsuperfície.
FPSO	<i>Floating Production, Storage and Offloading</i> — unidade flutuante de produção, armazenamento e transferência.
GLV	<i>Gas-Lift Valve</i> — válvula de gás de elevação.
ICV	<i>Interval Control Valve</i> — válvula de controle de intervalo, usada em completação inteligente.
M1, M2	Válvulas mestre da árvore de natal.
NPT	<i>Non-Productive Time</i> — tempo não produtivo.
PCK	<i>Production Choke</i> — ver CKP. Nas classes do 3W, designa a região da válvula reguladora de produção.
PDG	<i>Permanent Downhole Gauge</i> — sensor permanente de fundo de poço.
PT	<i>Pressure Transducer</i> — transdutor de pressão.
PXO	<i>Production Cross-Over</i> — válvula de cruzamento de produção.
TPT	<i>Temperature and Pressure Transducer</i> — transdutor de temperatura e pressão.
WAG	<i>Water-Alternating-Gas</i> — injeção alternada de água e gás.
XO	<i>Cross-Over</i> — válvula de cruzamento.

Aprendizado de máquina e estatística

ACC	Acurácia (<i>accuracy</i>).
AE	Autoencoder (<i>autoencoder</i>).
ARI	<i>Adjusted Rand Index</i> — índice de Rand ajustado.
CNN	Rede neural convolucional (<i>convolutional neural network</i>).

DBSCAN	<i>Density-Based Spatial Clustering of Applications with Noise.</i>
DCN	<i>Deep Clustering Network</i> — rede de agrupamento profundo.
GRU	<i>Gated Recurrent Unit</i> — unidade recorrente com portas.
IOU	<i>Intersection over Union</i> — razão entre interseção e união.
LSTM	<i>Long Short-Term Memory</i> — memória de curto prazo longa.
MLP	<i>Multilayer Perceptron</i> — perceptron de múltiplas camadas.
MoE	<i>Mixture of Experts</i> — mistura de especialistas.
MTS	<i>Multivariate Time Series</i> — série temporal multivariada.
OCSVM	<i>One-Class Support Vector Machine</i> — máquina de vetores de suporte de uma classe.
OSR	<i>Open-Set Recognition</i> — reconhecimento em conjunto aberto.
OVA	<i>One-vs-All</i> — um-contra-todos.
OWL	<i>Open-World Learning</i> — aprendizado de mundo aberto.
PCA	<i>Principal Component Analysis</i> — análise de componentes principais.
RNN	Rede neural recorrente (<i>recurrent neural network</i>).
SMAPE	<i>Symmetric Mean Absolute Percentage Error</i> — erro percentual absoluto médio simétrico.
SoftED	<i>Soft Event Detection</i> — família de métricas com tolerância temporal para detecção de eventos.
SVM	<i>Support Vector Machine</i> — máquina de vetores de suporte.
t-SNE	<i>t-Distributed Stochastic Neighbor Embedding.</i>
UMAP	<i>Uniform Manifold Approximation and Projection.</i>
VAE	<i>Variational Autoencoder</i> — autoencoder variacional.

Modelos de linguagem

API	<i>Application Programming Interface</i> — interface de programação de aplicações.
CoT	<i>Chain-of-Thought</i> — cadeia de raciocínio.
JSON	<i>JavaScript Object Notation</i> — formato de intercâmbio de dados.
LLM	<i>Large Language Model</i> — modelo de linguagem de grande porte.
NIM	<i>NVIDIA Inference Microservice</i> — serviço de inferência da NVIDIA.
XAI	<i>Explainable Artificial Intelligence</i> — inteligência artificial explicável.

Conjuntos de dados e instituições

3W	Conjunto de dados público de eventos indesejáveis em poços (<i>wells</i>) de petróleo, mantido pela Petrobras. O “3” refere-se às três procedências das instâncias: reais, simuladas e desenhadas à mão.
-----------	--

LCCV	Laboratório de Computação Científica e Visualização, UFAL.
OTC	<i>Offshore Technology Conference.</i>
SPE	<i>Society of Petroleum Engineers.</i>
UFAL	Universidade Federal de Alagoas.

Notação

A notação a seguir é usada de forma consistente em todo o livro. Onde um trabalho original empregava símbolo diferente, ele foi harmonizado; a correspondência está registrada no Capítulo B.

Convenções gerais

Forma	Significado
x, α	escalar
$\mathbf{x}$	vetor (coluna, em negrito)
$\mathbf{X}, \mathbf{\Sigma}$	matriz (em negrito maiúsculo)
$\mathbf{x}^\top$	transposto
$\mathbf{\Sigma}^{-1}$	inversa
$\ \mathbf{x}\ $	norma euclidiana
$\hat{y}$	valor predito
$\bar{x}$	média amostral
$\mathbb{R}^d$	espaço euclidiano de dimensão d

Dados e séries temporais

Símbolo	Significado
T	número de passos de tempo de uma janela
S	número de sensores (canais)
$\mathbf{X} \in \mathbb{R}^{T \times S}$	janela multivariada de sensores
$\mathbf{x}_t \in \mathbb{R}^S$	leitura de todos os sensores no instante t
$y \in \{0, 1, \dots, 9\}$	rótulo de classe do 3W
$\mathcal{K}$	conjunto de classes conhecidas
$\mathcal{U}$	conjunto de classes desconhecidas (novidades)
$\mathbf{b}$	janela de linha de base, anterior ao evento
$\mathbf{e}$	janela de evento

Modelos

Símbolo	Significado
f_θ	modelo com parâmetros θ
g_ϕ	codificador (<i>encoder</i>) do autoencoder
h_ψ	decodificador (<i>decoder</i>) do autoencoder
$\mathbf{z} = g_\phi(\mathbf{X}) \in \mathbb{R}^d$	representação latente
d	dimensão do espaço latente
$\hat{\mathbf{X}} = h_\psi(\mathbf{z})$	reconstrução
c_k	classificador binário da classe k
$s_k \in [0, 1]$	escore do classificador binário c_k
τ	limiar de decisão

Estatística e avaliação

Símbolo	Significado
μ, σ	média e desvio-padrão
Σ	matriz de covariância
$d_M(\mathbf{x})$	distância de Mahalanobis
λ	parâmetro de regularização da covariância
k	multiplicador de desvio-padrão em limiares $\mu + k\sigma$
K	número de agrupamentos (<i>clusters</i>)
VP, VN	verdadeiros positivos e verdadeiros negativos
FP, FN	falsos positivos e falsos negativos
ACC, ACC _b	acurácia e acurácia balanceada
REC, PR, SP	revocação, precisão e especificidade
F_1	medida F1

Colisão de símbolos

Dois usos de k convivem no livro e não podem ser confundidos: o *multiplicador de desvio-padrão* em limiares da forma $\mu + k\sigma$ (Capítulo 7, Capítulo 9) e o *número de vizinhos ou de posições em um ranking* nas métricas “top- k ” (Capítulo 15). O contexto sempre desambigua; quando houver risco, o significado é repetido por extenso. Da mesma forma, K maiúsculo designa exclusivamente o número de agrupamentos.

Parte I

Fundamentos

Capítulo 1

Por que vigiar um poço de petróleo

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- explicar por que a operação de poços submarinos exige monitoramento contínuo e automatizado, em termos de segurança, integridade e economia;
- quantificar o impacto do tempo não produtivo (NPT) e relacioná-lo à detecção precoce de anomalias;
- distinguir os três problemas computacionais envolvidos — detecção, classificação e explicação — e enunciar por que eles não são o mesmo problema;
- enunciar a hipótese de mundo fechado e reconhecer suas manifestações práticas;
- descrever o percurso argumentativo do livro e escolher a trilha de leitura adequada ao seu objetivo.

1.1 Um poço é um sistema que você não pode ver

A engenharia costuma lidar com sistemas que podem ser inspecionados. Uma ponte pode ser percorrida a pé; um vaso de pressão pode ser ensaiado por ultrassom; uma turbina pode ser aberta. Um poço submarino de petróleo em lâmina d'água de dois mil metros não pode ser nada disso. Entre o operador na sala de controle e o reservatório a seis mil metros abaixo da linha d'água existem, no melhor dos casos, algumas dezenas de canais de telemetria — pressões, temperaturas, vazões — amostrados a cada poucos segundos.

Tudo o que se sabe sobre o estado do poço vem desses canais. Se um deles congela, se um transdutor deriva, se um evento se manifesta em uma escala temporal mais lenta do que a janela de observação do operador, a observação pode ficar ausente, enviesada ou insuficiente para identificar o estado. A consequência é direta: *o monitoramento de poços é, antes de tudo, um problema de inferência a partir de observação parcial*, uma das classes de problema em que o aprendizado de máquina pode ser útil.

1.1.1 A escala do problema

Uma única unidade flutuante de produção, armazenamento e transferência (FPSO) pode estar conectada a algumas dezenas de poços produtores e injetores. Uma operadora de porte médio opera dezenas de FPSOs. O sistema descrito no Capítulo 7 deste livro foi implantado, à época

de sua avaliação, em mais de vinte unidades e mais de duzentos e cinquenta poços submarinos nas bacias de Santos e de Campos.

Multiplique: se cada poço fornece cinco sinais amostrados a cada segundo, duzentos e cinquenta poços produzem mais de cem milhões de leituras por dia. Nenhuma equipe de operação lê cem milhões de números por dia. O que se lê, na prática, são alarmes — e alarmes são decisões automatizadas. A qualidade do monitoramento é, portanto, a qualidade dos algoritmos que decidem quando tocar um alarme.

1.1.2 O que dá errado

Os eventos indesejáveis que acometem poços de petróleo formam uma taxonomia razoavelmente estável, detalhada no Capítulo 2. Por ora, quatro exemplos bastam para dar concretude ao problema:

- **Formação de hidratos.** Em águas profundas, a combinação de alta pressão e baixa temperatura leva moléculas de água e gás leve a formar um sólido cristalino semelhante a gelo. Um tampão de hidrato pode obstruir completamente uma linha de produção. A remoção exige despressurização controlada, injeção de inibidor ou intervenção submarina, com custo que se mede em milhões de dólares e prazo que se mede em semanas.
- **Fechamento espúrio da válvula de segurança de subsuperfície (DHSV).** A DHSV é o dispositivo que fecha o poço em situação de emergência. Quando ela fecha sem que haja emergência — por perda de pressão hidráulica na linha de controle, por exemplo — a produção é interrompida. Não é um evento perigoso; é um evento caro, e sua reabertura exige diagnóstico correto.
- **Golfadas severas.** O escoamento multifásico em um *riser* vertical pode entrar em regime oscilatório de grande amplitude, em que golfadas de líquido e bolhas de gás se alternam. O resultado são oscilações de pressão que castigam equipamentos de superfície e degradam a eficiência de separação.
- **Incrustação na válvula reguladora de produção (PCK).** Depósitos minerais reduzem gradualmente a área de passagem. O sintoma é lento, cumulativo e facilmente confundido com declínio natural do reservatório.

Observe a heterogeneidade. O hidrato é um evento de horas; a incrustação, de meses. O fechamento de DHSV é uma transição quase instantânea; a golfada é um regime estacionário oscilatório. Um método que detecte bem um deles não detectará necessariamente bem os outros — e essa observação, que parece trivial aqui, será a justificativa técnica para praticamente todas as escolhas de arquitetura discutidas neste livro.

1.2 O custo de não saber

Definição 1.1 — Tempo não produtivo

Chama-se tempo não produtivo (*non-productive time*) (NPT) o intervalo em que um poço, sonda ou instalação está indisponível para sua função por causa não planejada. O NPT é contabilizado em horas ou dias e convertido em custo pela soma do custo de oportunidade da produção perdida com o custo direto da intervenção corretiva.

O NPT é a métrica econômica que conecta a estatística de detecção à decisão de investimento. Um sistema de monitoramento que antecipa a identificação de um evento em algumas

horas pode transformar uma intervenção submarina em um ajuste de *choke* feito da sala de controle.

Exemplo 1.1 — Estimativa de NPT em um cenário hipotético

Considere um poço que produziria $q = 10.000$ barris por dia, preço de referência $p = 70$ dólares por barril, doze dias de NPT e quatro dias de intervenção com custo diário $c = 500.000$ dólares. Desprezando impostos, descontos e custos variáveis, o custo de oportunidade é

$$C_{\text{produção}} = qpd = 10.000 \times 70 \times 12 = \text{US\$ } 8.400.000.$$

O custo direto é $C_{\text{intervenção}} = c \times 4 = \text{US\$ } 2.000.000$, e a estimativa total é **US\$ 10,4 milhões**. Se uma ação antecipada reduzisse ambos os períodos em 30 %, sob a hipótese simplificadora de custos proporcionais ao tempo, a economia estimada seria $0,30 \times 10,4 = \text{US\$ } 3,12$ milhões. O cálculo é uma análise de cenário, não uma previsão: seu resultado muda linearmente com q , p , d e c .

Exemplo 1.2 — Da janela de detecção ao valor

Considere o caso do hidrato, discutido em profundidade no Capítulo 10. O intervalo disponível para agir depende do processo e da implantação; a fonte do 3W consultada nesta revisão não fornece uma faixa temporal que permita fixá-lo. Ainda assim, o comprimento da janela determina quanto histórico o sistema precisa acumular antes de produzir uma decisão e deve ser comparado ao intervalo operacional disponível.

Esse é o motivo pelo qual, no Capítulo 10, dedicamos uma tabela inteira ao efeito do comprimento da janela sobre a acurácia. A escolha não é apenas ajuste de hiperparâmetro: ela combina desempenho observado e restrição operacional, que precisa ser definida para cada implantação.

Há ainda um custo que não aparece em planilha: o custo de credibilidade (*alarm fatigue*). Um sistema que gera falsos alarmes em excesso é desligado — não formalmente, mas na prática, quando o operador aprende a ignorá-lo. Esse é o motivo pelo qual, ao longo do livro, a taxa de falsos positivos recebe tanta atenção quanto a acurácia, e por que a acurácia balanceada (Capítulo 4) é preferida à acurácia simples.

1.3 Três problemas, não um

É comum ouvir que “monitoramento de poços é um problema de classificação”. Não é. São três problemas, com requisitos diferentes e, como veremos, soluções diferentes.

Detecção.

Alguma coisa mudou? É uma decisão binária sobre uma janela ou sobre cada amostra de um sinal. Não requer conhecimento de classes; requer apenas um modelo de normalidade. É o problema atacado por autoencoders com limiar de erro de reconstrução (Capítulo 7) e, mais tarde, por segmentação supervisionada (Capítulo 11).

Classificação.

O que mudou? Requer um catálogo de classes e, se feita de forma ingênua, requer que o catálogo seja completo. É o problema atacado pelo ensemble de classificadores binários (Capítulo 8) e pela classificação por distância no espaço latente (Capítulo 12).

Explicação.

Por que o sistema acha isso? Requer que a decisão seja apresentada em termos que um engenheiro de produção reconheça: qual sensor mudou, em que direção, com que magnitude, e por que essa combinação é compatível com a hipótese proposta. É o problema atacado pela camada de agente de linguagem (Capítulos 14 e 15).

A tese central deste livro é que **esses três problemas exigem componentes distintos e que a tentativa de resolvê-los com um único modelo monolítico é a origem da maior parte das falhas observadas na prática**. Um classificador multiclasse bem treinado é excelente no segundo problema, péssimo no primeiro quando a anomalia é inédita, e simplesmente incapaz do terceiro.

1.4 A hipótese de mundo fechado

Definição 1.2 — Hipótese de mundo fechado

Diz-se que um sistema de classificação opera sob a hipótese de mundo fechado (*closed-world assumption*) quando pressupõe que toda instância a ser classificada pertence a uma das classes vistas durante o treinamento. Formalmente, se $\mathcal{K}$ é o conjunto de classes conhecidas, o sistema modela $\mathbb{P}(y \mid \mathbf{X})$ com suporte restrito a $\mathcal{K}$ e satisfazendo $\sum_{k \in \mathcal{K}} \mathbb{P}(y = k \mid \mathbf{X}) = 1$ para toda entrada $\mathbf{X}$.

A definição parece inocente. A consequência não é. A restrição $\sum_k \mathbb{P}(y = k \mid \mathbf{X}) = 1$ é imposta pela função *softmax* na camada de saída de praticamente toda rede neural de classificação, e ela significa que *não existe massa de probabilidade disponível para a hipótese “nenhuma das anteriores”*. Quando uma instância de uma classe inédita é apresentada, o modelo é obrigado, por construção, a distribuir a probabilidade entre as classes que conhece. Pior: não há nada que force essa distribuição a ser uniforme. É rotineiro observar uma rede atribuir noventa e cinco por cento de confiança a uma classe errada diante de uma entrada que ela nunca viu.

A confiança não é a probabilidade

A saída de uma *softmax* é frequentemente lida como “a probabilidade de a classe ser k ”. Ela não é. Ela é “a probabilidade de a classe ser k , *dado que a classe está entre as que eu conheço*”. O condicionamento é omitido na leitura informal, e é exatamente onde mora o erro.

O contraponto formal da hipótese de mundo fechado é o reconhecimento em conjunto aberto (*open-set recognition*), formulado por Scheirer et al. (2013), e sua extensão dinâmica, o aprendizado de mundo aberto (*open-world learning*), que não apenas rejeita o desconhecido como o incorpora ao catálogo. Esses conceitos são desenvolvidos no Capítulo 6 e constituem o eixo da Parte II.

Exemplo 1.3 — O experimento que dá nome ao livro

No Capítulo 10 reproduzimos um experimento simples e decisivo. Treina-se um sistema de classificação com seis das nove classes de anomalia do conjunto 3W, escondendo deliberadamente a classe 8 (hidrato na linha de produção). Em seguida, apresentam-se instâncias dessa classe oculta.

Um classificador multiclasse convencional distribui essas instâncias entre as seis classes

que conhece, com confiança alta e sem qualquer sinal de alerta. O ensemble de classificadores binários, ao contrário, sinaliza 89% das instâncias como “nenhuma das classes treinadas”.

A diferença não está na capacidade de representação — as arquiteturas são essencialmente as mesmas. Está na estrutura da decisão.

1.5 O percurso deste livro

A narrativa se desenvolve em cinco movimentos.

Parte I — Fundamentos (Capítulo 1 a Capítulo 6). Construimos o vocabulário. O Capítulo 2 apresenta a arquitetura física de um poço submarino, seus sensores e a taxonomia de eventos. O Capítulo 3 dissectiona o conjunto de dados 3W e suas armadilhas. O Capítulo 4 estabelece o arcabouço de avaliação, com ênfase em métricas robustas a desbalanceamento. O Capítulo 5 percorre as arquiteturas de aprendizado profundo empregadas no livro. O Capítulo 6 formaliza o problema de mundo aberto e as ferramentas para atacá-lo.

Parte II — A base (Capítulo 7 a Capítulo 9). Apresentamos o sistema completo desenvolvido na tese de doutorado que originou esta linha de pesquisa (Lopes, 2025). O Capítulo 7 descreve o sistema dual — diagrama de decisão mais autoencoder recorrente — efetivamente implantado em campo. O Capítulo 8 introduz o ensemble de classificadores binários um-contra-todos e o valida analiticamente no caso do hidrato. O Capítulo 9 fecha o ciclo com o pipeline de seis estágios de aprendizado de mundo aberto.

Parte III — A evolução (Capítulo 10 a Capítulo 12). Três limitações da base são atacadas. O Capítulo 10 aprofunda e valida o ensemble binário (Lopes et al., 2026c), incluindo a comparação com um modelo termodinâmico analítico de formação de hidrato. O Capítulo 11 substitui a detecção por erro de reconstrução pela segmentação temporal supervisionada com uma U-Net unidimensional. O Capítulo 12 substitui a detecção de novidade por ensemble pela distância de Mahalanobis calculada no espaço latente de um classificador multiclasse (Lopes et al., 2026a).

Parte IV — A explicação (Capítulo 13 a Capítulo 15). Acrescentamos a camada que nenhum dos sistemas anteriores possuía. O Capítulo 13 introduz modelos de linguagem de grande porte com o rigor necessário. O Capítulo 14 descreve a engenharia da camada de agente: extração de descritores numéricos, construção de perfis de classe e formulação do *prompt*. O Capítulo 15 apresenta os três estudos que delimitam, com números, o que o agente sabe e o que ele não sabe fazer.

Parte V — Síntese (Capítulo 16 a Capítulo 18). O Capítulo 16 consolida todos os resultados em uma tabela única e propõe uma arquitetura de referência integrada, com divisão de trabalho por classe. O Capítulo 17 trata de implantação, interface com o operador, deriva de dados e governança. O Capítulo 18 expõe as limitações remanescentes e as questões em aberto.

Um livro que mostra as falhas

Uma advertência de método. Este livro reporta resultados ruins com o mesmo destaque que reporta resultados bons. A classe 4 (instabilidade de fluxo) atravessa todos os capítulos com desempenho medíocre; a classe 9 (hidrato na linha de serviço) idem; a detecção precoce medida por SoftED fica em 0,22 no Capítulo 11; o agente de linguagem acerta apenas 35,1% na primeira tentativa no Capítulo 15. Esses números estão aqui porque são informativos: eles delimitam a fronteira do que a metodologia atual alcança, e é nessa fronteira que o trabalho futuro tem valor.

Resumo do capítulo

O monitoramento de poços submarinos é um problema de inferência a partir de telemetria esparsa, com consequências econômicas mensuráveis em tempo não produtivo. Os eventos indesejáveis são heterogêneos em escala temporal e em assinatura, o que torna improvável que um único modelo os cubra bem. Três problemas distintos convivem sob o rótulo de “monitoramento”: detectar que algo mudou, classificar o que mudou e explicar por que o sistema chegou a essa conclusão. A hipótese de mundo fechado — pressupor que toda instância pertence a uma classe conhecida — é uma consequência estrutural da formulação usual da classificação e produz falhas silenciosas diante de eventos inéditos. Superá-la é o fio condutor deste livro, que percorre cinco movimentos: fundamentos, a base metodológica original, sua evolução, a camada de explicação e a síntese.

Exercícios

1. Explique, com suas palavras, por que a restrição $\sum_{k \in \mathcal{K}} \mathbb{P}(y = k \mid \mathbf{X}) = 1$ imposta pela *softmax* impede que um classificador expresse a hipótese “nenhuma das anteriores”. Proponha duas modificações da camada de saída que removeriam essa restrição e discuta o que cada uma custaria em termos de treinamento.
2. Um poço produz 20.000 barris de óleo por dia. Considere um preço de 70 dólares por barril e um custo diário de intervenção com sonda de 500.000 dólares. Estime o custo total de um evento de hidrato que causa 12 dias de NPT, dos quais 4 exigem sonda. Em seguida, estime a economia obtida por um sistema que reduza esse NPT em 30 %. Discuta quais hipóteses do seu cálculo são as mais frágeis.
3. Classifique cada um dos quatro eventos citados na Seção 1.1.2 quanto à escala temporal característica (segundos, minutos, horas, meses) e quanto ao tipo de assinatura (degrau, rampa, oscilação, perda de sinal). Argumente qual tipo de modelo — recorrente, convolucional ou baseado em regras — você esperaria que funcionasse melhor em cada caso, e registre sua previsão. Ao terminar a Parte III, confronte-a com os resultados reportados.
4. Discuta a seguinte afirmação: “um sistema de monitoramento com 99 % de acurácia é bom o suficiente”. Considere um poço monitorado a cada segundo e uma taxa de eventos reais de um por mês. Quantos falsos alarmes por dia esse sistema produziria se os 1 % de erro se distribuíssem uniformemente? O que isso implica sobre a escolha da métrica de avaliação?
5. Considere os três problemas da Seção 1.3. Para cada um, identifique qual seria a consequência operacional de uma falha: o que acontece se a detecção falha? E se a classificação falha, mas a detecção funciona? E se ambas funcionam, mas não há explicação?

Leituras recomendadas

- Vargas et al. (2019) apresentam o conjunto de dados 3W e, mais importante para este capítulo, o contexto operacional que motivou sua construção. É a leitura obrigatória para quem quiser entender a taxonomia de eventos a partir da prática de campo.
- Scheirer et al. (2013) formalizam o reconhecimento em conjunto aberto. O artigo é anterior à popularização do aprendizado profundo e, por isso mesmo, expõe o problema com clareza incomum.
- Pimentel et al. (2014) oferecem uma revisão ampla de detecção de novidade, útil para situar as abordagens deste livro em um panorama maior.
- Lopes (2025) é a tese que originou a Parte II; os capítulos introdutórios contêm um levantamento detalhado do contexto industrial brasileiro.

Capítulo 2

Anatomia de um poço submarino

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- descrever os componentes de um poço submarino de produção, do reservatório à unidade flutuante, e nomear as válvulas que compõem a árvore de natal molhada;
- explicar a função dos sensores PDG e TPT e justificar por que o subconjunto recorrente de quatro variáveis aparece na maior parte dos métodos deste livro;
- caracterizar cada uma das nove classes de anomalia do conjunto 3W em termos de mecanismo físico e assinatura esperada nos sensores;
- distinguir eventos de causa-raiz de eventos sintomáticos, e explicar por que essa distinção afeta o projeto do classificador;
- descrever a completação inteligente e os eventos associados a válvulas de controle de intervalo (ICV).

2.1 Do reservatório à plataforma

Um sistema de produção *offshore* pode ser lido como uma sequência de quatro domínios, cada um com sua física e seus modos de falha.

1. **Reservatório.** A rocha porosa que contém os hidrocarbonetos. Fornece a energia primária do escoamento (pressão estática) e determina a composição do fluido produzido — razão gás-óleo, fração de água, presença de CO_2 e H_2S .
2. **Poço.** A conexão vertical (ou desviada) entre reservatório e leito marinho, revestida por colunas de aço cimentadas e equipada internamente com a coluna de produção (*production tubing*) e seus acessórios.
3. **Sistema submarino.** A árvore de natal molhada instalada na cabeça do poço, o *jumper* que a conecta ao *manifold* ou diretamente ao *riser*, e as linhas de fluxo que atravessam o leito marinho.
4. **Unidade de superfície.** O *riser* que sobe até a unidade flutuante, o separador trifásico, o sistema de compressão e o de tratamento de água.

Neste livro, o objeto de interesse é predominantemente o segundo e o terceiro domínio. Os eventos indesejáveis do conjunto 3W ocorrem entre o fundo do poço e a válvula reguladora de produção, e é ali que estão os sensores que os revelam.

2.1.1 A completação

Chama-se completação (*well completion*) o conjunto de operações e equipamentos que preparam o poço para produzir de forma controlada. Os elementos relevantes para este livro são:

Coluna de produção.

Tubo interno por onde o fluido escoia até a superfície. Isola o fluxo do revestimento e permite a instalação de acessórios.

Packer.

Elemento de vedação que ancora a coluna ao revestimento e isola o espaço anular, impedindo comunicação de pressão entre a zona produtora e o restante do poço.

Válvula de segurança de subsuperfície (DHSV).

Instalada tipicamente a algumas centenas de metros abaixo do leito marinho, é uma válvula do tipo *flapper* mantida aberta por pressão hidráulica aplicada por uma linha de controle. *A falha segura é o fechamento*: se a pressão hidráulica se perde por qualquer motivo, a válvula fecha. Essa escolha de projeto — correta do ponto de vista de segurança — é a origem do fechamento espúrio, um dos eventos mais frequentes no conjunto 3W.

Válvulas de gás de elevação (GLV).

Em poços com elevação artificial por gás, permitem a injeção de gás do anular para a coluna, reduzindo a densidade da mistura e, portanto, a pressão hidrostática que o reservatório precisa vencer.

Válvulas de controle de intervalo (ICV).

Em poços de completação inteligente (*intelligent completion*), permitem regular ou fechar remotamente cada zona produtora individualmente. São o assunto de uma classe de anomalia inteira (Seção 2.4) e aparecem com destaque no Capítulo 9.

2.1.2 A árvore de natal molhada

A árvore de natal molhada (*wet christmas tree*) (ANM) é o conjunto de válvulas instalado sobre a cabeça do poço no leito marinho. Sua função é dar controle de fluxo, permitir intervenções e garantir barreiras de segurança redundantes. A nomenclatura das válvulas varia entre operadoras; a que adotamos aqui é a usual na literatura brasileira e no conjunto 3W:

Sigla	Nome	Função
M1	Master 1	Válvula mestre inferior da linha de produção; primeira barreira.
M2	Master 2	Válvula mestre superior; segunda barreira em série com M1.
W1	Wing 1	Válvula de asa da linha de produção.
W2	Wing 2	Válvula de asa da linha de serviço ou anular.
XO	<i>Cross-Over</i>	Interliga produção e anular; usada em operações especiais.
PXO	<i>Production Cross-Over</i>	Cruzamento dedicado à produção.
CKP	<i>Production Choke</i>	Válvula reguladora de produção; controla a vazão por estrangulamento. Também chamada PCK.
CKGL	<i>Gas-Lift Choke</i>	Válvula reguladora da injeção de gás de elevação.

PCK ou CKP?

As duas siglas designam a mesma válvula reguladora de produção. O conjunto 3W nomeia duas de suas classes com “PCK” (*Quick Restriction in PCK e Scaling in PCK*), enquanto a documentação de engenharia usa com frequência “CKP”. Neste livro mantemos “PCK” ao nos referirmos às classes do 3W, para preservar a rastreabilidade, e “CKP” ao discutirmos o equipamento.

2.2 O que os sensores enxergam

Aqui está o fato que molda todo o restante do livro: **o número de variáveis observadas é pequeno, e elas são fortemente correlacionadas.**




Figura 2.1: Disposição típica de válvulas e sensores em um poço submarino. Os medidores PDG, TPT e PT ocupam posições fixas ao longo do caminho do fluido, e cada válvula — DHSV, M1, M2, W1, W2, XO, PXO e a reguladora — define um estado operacional distinto. Adaptado de Aranha et al. (2024a).

A Figura 2.1 situa os sensores no caminho do fluido. Essa geometria explica boa parte do que vem a seguir: o PDG está a montante de tudo e responde primeiro a variações no reservatório; o TPT está no leito marinho, onde o resfriamento é máximo; o PT está a jusante da reguladora, e portanto enxerga a pressão já estrangulada. Duas anomalias de mesma

origem física produzem assinaturas diferentes em cada um desses pontos, e é essa diferença que os modelos exploram.

2.2.1 Os quatro sinais fundamentais

P-PDG — pressão no medidor permanente de fundo.

O medidor permanente de fundo (*permanent downhole gauge*) (PDG) é instalado na coluna de produção, próximo à zona produtora. Mede a pressão no ponto mais próximo do reservatório que a instrumentação alcança. É o sinal mais informativo sobre o comportamento do reservatório e sobre eventos de fundo, e é também o mais sujeito a falha — sua substituição exige intervenção com sonda.

T-PDG — temperatura no medidor permanente de fundo.

Mede a temperatura do fluido no fundo. Varia lentamente em condições normais e reage a mudanças de vazão com constante de tempo apreciável, o que a torna útil para discriminar transitórios rápidos de mudanças de regime.

P-TPT — pressão no transdutor de temperatura e pressão.

O transdutor de temperatura e pressão (*temperature and pressure transducer*) (TPT) está instalado na árvore de natal, a jusante do poço e a montante da válvula reguladora. Mede a pressão na cabeça do poço.

T-TPT — temperatura no transdutor de temperatura e pressão.

Temperatura na cabeça do poço. É a variável mais diretamente ligada à formação de hidratos, já que a região da ANM é onde a combinação de baixa temperatura ambiente e alta pressão é mais severa.

O conjunto 3W disponibiliza outras variáveis — pressão a jusante da *choke* (P-JUS-CKP), temperatura a jusante, vazões de gás de elevação, posição da *choke*. Contudo, a maior parte dos trabalhos discutidos neste livro utiliza o subconjunto {P-PDG, T-PDG, P-TPT, T-TPT}, por três razões: são as variáveis presentes em praticamente todas as instâncias, são as menos afetadas por convenções de instalação específicas de cada poço, e carregam a informação física essencial dos eventos de interesse. Esse núcleo não é uma regra universal: o sistema dual acrescenta um quinto sinal, e os experimentos dos Capítulos 8 e 10 usam oito quando a disponibilidade permite. A Tabela 3.1 registra essas diferenças.

Exemplo 2.1 — O gradiente entre fundo e cabeça

A diferença $P_{PDG} - P_{TPT}$ é, aproximadamente, a perda de carga ao longo da coluna de produção — soma da componente hidrostática com a componente friccional e, quando relevante, da aceleração. Em uma geometria e um regime de escoamento fixados, maior densidade tende a aumentar a componente hidrostática, enquanto menor vazão tende a reduzir a friccional. Em escoamento multifásico, inclinação, holdup, sentido do fluxo e posição efetiva dos sensores podem alterar essa leitura.

Um único par de sensores fornece, portanto, indícios combinados sobre propriedades distintas do escoamento, sem identificá-las isoladamente. É por essa razão que o agente de linguagem do Capítulo 14 calcula explicitamente um descritor de *relação entre P-PDG e P-TPT* — “mesma direção”, “divergentes” ou “um estável” — e o entrega ao modelo como evidência. A informação está na relação, não em cada sinal isolado.

2.2.2 Por que os sensores mentem

Três patologias de instrumentação atravessam todo o livro e precisam ser enunciadas desde já.

- **Congelamento.** O sensor para de atualizar e repete indefinidamente a última leitura válida. Uma série congelada tem desvio-padrão nulo e é trivialmente detectável — desde que alguém procure por isso.
- **Perda de telemetria.** O valor se torna ausente ou é substituído por zero. Essa patologia terá importância inesperada no Capítulo 15: em várias classes do 3W, o início da anomalia coincide com a perda dos medidores de fundo, o que cria uma correlação espúria entre “anomalia” e “ausência de dado”.
- **Deriva.** O sensor mantém a dinâmica, mas seu nível absoluto se desloca lentamente. É a mais perigosa das três, porque não produz nenhuma assinatura óbvia e corrompe silenciosamente qualquer modelo calibrado em valores absolutos.

Consequência de projeto

As três patologias acima são o argumento técnico para trabalhar com *variações relativas a uma linha de base* em vez de valores absolutos. Essa decisão aparece de formas diferentes ao longo do livro: normalização por janela no Capítulo 7, padronização por poço no Capítulo 11 e, de forma mais explícita, no cálculo do descritor $\delta = \bar{e} - \bar{b}$ do Capítulo 14.

2.3 A taxonomia dos eventos indesejáveis

O conjunto 3W organiza os eventos em uma classe normal e nove classes de anomalia (Vargas et al., 2019; Vaz Vargas et al., 2026). Descrevemos cada uma pelo mecanismo físico e pela assinatura esperada.

2.3.1 Classe 0 — Estado normal

Operação estável. Os sinais apresentam variação de baixa amplitude em torno de níveis determinados pelo ponto de operação. É a classe de referência contra a qual todas as demais são contrastadas e, em quantidade de amostras, a mais numerosa por larga margem.

2.3.2 Classe 1 — Aumento abrupto de BSW

Mecanismo. O teor de água e sedimentos (*basic sediment and water*) (BSW) é a fração volumétrica de água no fluido produzido. Um aumento abrupto indica avanço da frente de água do aquífero ou de um poço injetor, ou ainda comunicação com uma zona aquífera por falha de isolamento.

Assinatura. Água é mais densa que óleo. O aumento da fração de água eleva a massa específica média da coluna, aumentando a pressão hidrostática. Espera-se aumento de P-PDG e mudança no gradiente entre fundo e cabeça. A temperatura pode cair, já que a água tem capacidade calorífica maior.

Dificuldade. O evento é gradual em muitos casos reais, o que o confunde com declínio natural. A classe 1 apresenta desempenho apenas mediano em quase todos os experimentos deste livro.

2.3.3 Classe 2 — Fechamento espúrio da DHSV

Mecanismo. Perda de pressão na linha de controle hidráulico leva a DHSV a fechar sem comando. O poço é isolado abaixo da válvula.

Assinatura. A mais nítida de todas. A pressão a montante da válvula (P-PDG) sobe rapidamente, pois o reservatório continua a alimentar um volume fechado; a pressão a jusante (P-TPT) despenca. As duas pressões divergem de forma inequívoca. As temperaturas caem, pois cessa o transporte convectivo de calor do fundo.

Consequência para os métodos. A classe 2 é aquela em que praticamente todo método deste livro atinge desempenho excelente — 95 % no ensemble binário do Capítulo 10, 100 % na detecção de novidade do Capítulo 15. É o caso fácil, e serve de controle positivo: um método que falhe na classe 2 tem um defeito estrutural.

2.3.4 Classe 3 — Golfadas severas

Mecanismo. Em escoamento multifásico ascendente com *riser* em catenária, o líquido pode acumular-se no ponto baixo até bloquear a passagem de gás. A pressão a montante cresce até vencer a coluna de líquido, que é então expelida em golfada. O ciclo se repete com período de minutos a dezenas de minutos.

Assinatura. Oscilação periódica de grande amplitude em P-TPT e, com menor amplitude, em P-PDG. É a única classe cuja assinatura característica é *de frequência*, não de nível.

Consequência para os métodos. Métodos que resumem uma janela por média e desvio-padrão perdem a informação de periodicidade. Esse é um dos motivos pelos quais o agente de linguagem do Capítulo 14 calcula uma *razão de oscilação* explícita, e um dos motivos pelos quais o desempenho da classe 3 melhora substancialmente quando se usa segmentação temporal (Capítulo 11) em vez de classificação de janela agregada.

2.3.5 Classe 4 — Instabilidade de fluxo

Mecanismo. Regime de escoamento não estacionário sem a periodicidade regular da golfada severa. Pode originar-se de instabilidade de gás de elevação, de acoplamento entre reservatório e coluna, ou de operação próxima ao limite de estabilidade.

Assinatura. Variabilidade aumentada em todos os sinais, sem padrão dominante.

Advertência. A classe 4 é *sintomática*, não causal. Instabilidade de fluxo é aquilo que se observa; o que a causou pode ser qualquer coisa. Essa característica explica por que ela apresenta o pior desempenho médio do livro — 69 % no ensemble binário (Capítulo 10), 18,5 % na primeira escolha do agente (Capítulo 15) — e por que foi deliberadamente excluída de dois dos três estudos com modelos de linguagem.

2.3.6 Classe 5 — Perda rápida de produtividade

Mecanismo. Queda súbita do índice de produtividade do poço, por dano à formação, colapso de canhoneado, produção de finos ou bloqueio na região próxima ao poço.

Assinatura. Queda de vazão com aumento da pressão de fundo (o reservatório deixa de conseguir entregar fluido à mesma taxa).

Advertência. Como a classe 4, é sintomática. O Capítulo 12 reporta para ela o pior resultado de detecção de novidade de toda a Tabela correspondente: 67,5 % no espaço latente, contra mais de 96 % para as demais classes.

2.3.7 Classe 6 — Restrição rápida no PCK

Mecanismo. Obstrução súbita da válvula reguladora de produção, por detrito, falha mecânica ou deposição abrupta.

Assinatura. Aumento da pressão a montante da *choke* (P-TPT) com queda da pressão a jusante. Contraste com a classe 2: ali a divergência ocorre *através da DHSV*, no fundo; aqui, *através da choke*, na superfície.

2.3.8 Classe 7 — Incrustação no PCK

Mecanismo. Deposição gradual de sais inorgânicos — carbonato de cálcio, sulfato de bário — na passagem da válvula reguladora, reduzindo progressivamente a área efetiva.

Assinatura. Mesma direção da classe 6, mas em escala de tempo de semanas a meses. A distinção entre 6 e 7 é, essencialmente, *uma distinção de derivada*.

2.3.9 Classe 8 — Hidrato na linha de produção

Mecanismo. Hidratos de gás natural são estruturas cristalinas em que moléculas de água formam gaiolas que aprisionam moléculas de metano, etano e propano. Formam-se em condições de alta pressão e baixa temperatura — exatamente as condições de uma linha de produção submarina em águas profundas. O tampão resultante obstrui o escoamento.

Assinatura. Aumento da pressão a montante do tampão, queda a jusante, e queda de temperatura. A dinâmica é de horas.

Destaque. A classe 8 é o objeto do experimento central do Capítulo 10, em que é comparada com um modelo termodinâmico analítico, e é a classe escondida no experimento de conjunto aberto. No Capítulo 12, ela apresenta a razão de separação mais extrema já observada nos experimentos deste livro — 186,5 vezes no espaço latente.

2.3.10 Classe 9 — Hidrato na linha de serviço

Mecanismo. O mesmo da classe 8, mas na linha de serviço (anular ou linha de injeção de gás), que opera em condições distintas e é menos instrumentada.

Assinatura. Semelhante à classe 8, porém observada indiretamente, por reflexo sobre a linha de produção.

Advertência. A classe 9 é a mais escassa em número de instâncias e a de pior desempenho consistente. No Capítulo 15, o agente acerta 7,1 % na primeira tentativa e não converge para um nome consensual quando solicitado a batizar o evento como novidade.

2.4 Além do 3W: eventos de completção inteligente

Dois eventos discutidos neste livro não pertencem ao conjunto 3W. Vêm de dados proprietários e cumprem um papel metodológico específico: *servem de novidade genuína*, isto é, de classe que o sistema comprovadamente nunca viu.

Falha de ICV.

A válvula de controle de intervalo não responde ao comando, ou responde parcialmente, ou apresenta vazamento entre zonas. A assinatura é um degrau de pressão e vazão que não corresponde a nenhum comando registrado. No Capítulo 9, instâncias de falha de ICV são apresentadas a um sistema treinado apenas nas nove classes do 3W: 48 % são classificadas como pertencentes a alguma classe conhecida e 52 % são corretamente marcadas como desconhecidas e encaminhadas ao estágio de agrupamento.

Operação de válvula.

Manobras programadas de abertura e fechamento. São *eventos normais* cuja assinatura se assemelha à de anomalias — o caso clássico do falso positivo legítimo. Um sistema que não distinga uma operação programada de um fechamento espúrio é inútil em campo.

Por que isso importa metodologicamente

Avaliar detecção de novidade escondendo uma classe do próprio conjunto de treinamento é válido, mas otimista: a classe escondida foi gerada pelo mesmo processo de coleta, rotulada pela mesma equipe, com a mesma instrumentação. Uma classe genuinamente externa — vinda de outro conjunto de poços, com outra completação — é um teste mais duro. Os dois eventos acima cumprem esse papel.

2.5 Uma taxonomia por assinatura

Encerramos com uma reorganização das nove classes que será útil em todos os capítulos seguintes. Em vez de agrupá-las por mecanismo, agrupamo-las por *aquilo que o algoritmo vê*.

Assinatura	Classes	Implicação para o método
Divergência entre dois sinais de pressão	2, 6	Facilmente capturada por descritores de relação entre sensores; alto desempenho universal.
Oscilação periódica	3	Exige preservação da estrutura temporal; penaliza agregação por média.
Rampa lenta	1, 7	Exige janela longa; confunde-se com deriva de sensor e com declínio natural.
Degrau com queda de temperatura	8, 9	Bem separável quando há dados de temperatura confiáveis; a classe 9 sofre por escassez.
Aumento de variabilidade sem padrão	4, 5	Sintomática; baixa separabilidade intrínseca. Candidata a tratamento diferenciado.

Essa tabela antecipa a proposta de *divisão de trabalho por classe* do Capítulo 16: em vez de exigir que um único modelo trate igualmente as cinco famílias de assinatura, atribui-se a cada família o componente que a trata melhor.

Resumo do capítulo

Um poço submarino é observado por um punhado de sensores — essencialmente pressão e temperatura no fundo (PDG) e na cabeça (TPT) — cujas leituras estão sujeitas a congelamento, perda de telemetria e deriva. As nove classes de anomalia do conjunto 3W diferem radicalmente em mecanismo físico, escala temporal e assinatura: há degraus nítidos (fechamento espúrio de DHSV), oscilações periódicas (golfadas), rampas lentas (incrustação) e classes meramente sintomáticas (instabilidade de fluxo, perda de produtividade). Essa heterogeneidade é a razão estrutural pela qual nenhum modelo único apresenta bom desempenho em todas as classes, e é o ponto de partida da arquitetura modular defendida neste livro. Eventos de completação inteligente — falha de ICV e operação de válvula — fornecem, por serem externos ao 3W, testes rigorosos de detecção de novidade.

Exercícios

1. Desenhe, à mão, as curvas esperadas de P-PDG e P-TPT ao longo de trinta minutos para: (a) fechamento espúrio da DHSV; (b) restrição rápida no PCK. Indique claramente em que ponto as duas assinaturas se distinguem e qual descritor numérico capturaria essa distinção.

2. A diferença $P_{PDG} - P_{TPT}$ combina componente hidrostática e componente friccional. Para cada uma das classes 1, 2, 5 e 8, diga se você espera que essa diferença aumente, diminua ou permaneça estável, e justifique fisicamente.
3. As classes 6 e 7 compartilham a mesma assinatura qualitativa e diferem apenas na escala de tempo. Proponha dois descritores numéricos que as separariam de forma robusta e discuta como o comprimento da janela de observação afeta cada um deles.
4. Argumente a favor e contra a seguinte proposta: “as classes 4 e 5 deveriam ser removidas do catálogo de classificação e tratadas apenas como sinalizadores de atenção”. Considere as consequências para a métrica global, para o operador e para o registro histórico de eventos.
5. Um sensor de fundo apresenta deriva de +2 bar por mês. Descreva o efeito dessa deriva sobre: (a) um detector de anomalia baseado em limiar absoluto; (b) um detector baseado em erro de reconstrução de autoencoder treinado há seis meses; (c) um descritor de variação relativa à linha de base imediatamente anterior ao evento. Ordene as três abordagens por robustez.
6. Consulte a documentação do conjunto 3W (Vaz Vargas et al., 2026) e liste todas as variáveis disponíveis. Para cada variável não utilizada neste livro, argumente se ela poderia ou não contribuir para separar as classes 4 e 5.

Leituras recomendadas

- Vargas et al. (2019) descrevem a origem operacional de cada classe do 3W. É a fonte primária para o conteúdo da Seção 2.3.
- Vaz Vargas et al. (2026) apresentam a versão 2.0 do conjunto, com classes adicionais e revisão da rotulação.
- Safamirzaei (2015) tratam da termodinâmica de formação de hidratos, base do modelo analítico usado no Capítulo 10.
- Aranha et al. (2024a) e Aranha et al. (2024b) descrevem sistemas de monitoramento em operação, com ênfase nos requisitos práticos que raramente aparecem em artigos metodológicos.

Capítulo 3

Os dados: séries temporais de poços e o conjunto 3W

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- formalizar uma série temporal multivariada de poço e definir janela, passo e rótulo;
- descrever a estrutura do conjunto 3W nas versões 1.0 e 2.0, incluindo a distinção entre instâncias reais, simuladas e desenhadas à mão;
- explicar a rotulação em três estados — normal, transiente e anômalo — e distinguir rótulo por amostra de rótulo por instância;
- identificar as principais armadilhas do conjunto: desbalanceamento, valores ausentes, sensores congelados, vazamento temporal e correlação espúria entre anomalia e perda de telemetria;
- projetar um protocolo de particionamento que evite vazamento entre treino e teste.

3.1 Formalização

Definição 3.1 — Série temporal multivariada de poço

Uma série temporal multivariada de poço é uma função $\mathbf{x} : \mathcal{T} \rightarrow \mathbb{R}^S$, onde $\mathcal{T} \subset \mathbb{Z}$ é um conjunto de instantes amostrados a intervalo regular Δt e S é o número de sensores. Escrevemos $\mathbf{x}_t = (x_t^{(1)}, \dots, x_t^{(S)})^\top$ para a leitura conjunta no instante t , e $x_t^{(s)}$ para a leitura do sensor s .

No conjunto 3W, $\Delta t = 1$ s e uma instância típica cobre de algumas horas a alguns dias. O subconjunto de sensores usado ao longo deste livro é, salvo menção em contrário, $S = 4$, com os canais P-PDG, T-PDG, P-TPT e T-TPT descritos na Seção 2.2.

Definição 3.2 — Janela deslizante

Dada uma série $\mathbf{x}$, um comprimento de janela T e um passo h , a janela deslizante (*sliding window*) de índice i é a matriz

$$\mathbf{X}_i = [\mathbf{x}_{t_0+ih}, \mathbf{x}_{t_0+ih+1}, \dots, \mathbf{x}_{t_0+ih+T-1}]^\top \in \mathbb{R}^{T \times S}.$$

Quando $h < T$ as janelas se sobrepõem; quando $h = T$ elas são disjuntas.

A janela é a unidade de entrada de praticamente todos os modelos deste livro, e sua parametrização varia de forma significativa entre eles. A Tabela 3.1 consolida as escolhas, o que é útil como referência ao longo da leitura.

Tabela 3.1: Parametrização de janela adotada em cada capítulo deste livro.

Capítulo	T (amostras)	S	Passo h
Capítulo 7	500	5	contínuo (tempo real)
Capítulos 8 e 10	150 a 7500 (varrido)	8	sobreposto
Capítulo 9	200	4	sobreposto
Capítulos 11 e 12	200	4	100 (5 s de avanço)
Capítulo 14	segmento variável	4	— (segmentos rotulados)

A escolha de T não é livre

O comprimento da janela impõe um compromisso duplo. Janelas curtas permitem resposta rápida, mas não contêm informação suficiente para eventos lentos — uma janela de 150 s não pode, em princípio, distinguir incrustação (classe 7) de restrição rápida (classe 6). Janelas longas capturam eventos lentos, mas atrasam a detecção e diluem transientes curtos na média. O Capítulo 10 quantifica esse compromisso com uma varredura de catorze valores de T .

3.2 O conjunto 3W

3.2.1 Origem e propósito

O 3W — o nome registra que o conjunto reúne instâncias de *três* procedências distintas (reais, simuladas e desenhadas à mão) de eventos indesejáveis que ocorrem em poços (*wells*) de petróleo (Petróleo Brasileiro S.A. (Petrobras), 2026) — foi publicado pela Petrobras com o objetivo explícito de dar à comunidade acadêmica um banco de dados realista para detecção e classificação de eventos (Vargas et al., 2019). Antes dele, a literatura da área trabalhava quase exclusivamente com dados simulados ou proprietários, o que tornava impossível comparar métodos.

3.2.2 Versão 1.0

A versão original contém 1.984 instâncias distribuídas entre a classe normal e oito classes de anomalia. Cada instância é um arquivo CSV com uma coluna de tempo, colunas de sensores e uma coluna de rótulo por amostra.

3.2.3 Versão 2.0

A versão 2.0 (Vaz Vargas et al., 2026) amplia o conjunto para 2.228 instâncias e 10 classes (normal mais nove anomalias), revisa a rotulação de instâncias da versão anterior e acrescenta metadados de poço. Os trabalhos discutidos nos Capítulos 7 a 9 foram desenvolvidos sobre a versão 1.0; os dos Capítulos 11, 12 e 14 incorporam a versão 2.0.

Comparabilidade entre versões

Números de acurácia obtidos em versões diferentes do 3W *não são diretamente comparáveis*. A revisão de rótulos da versão 2.0 alterou a fronteira entre normal e transiente em várias instâncias, e a inclusão de novas instâncias mudou a distribuição de classes. Sempre que este livro compara resultados de capítulos distintos, a versão utilizada é declarada.

3.2.4 Três procedências

Cada instância do 3W pertence a uma de três procedências, identificada pelo prefixo do nome do arquivo:

Real (WELL-...).

Registro efetivo de um poço em operação, com todos os defeitos que isso implica: ruído, lacunas, deriva, comportamento idiossincrático. É a única procedência que sustenta conclusões sobre desempenho em campo.

Simulado (SIMULATED-...).

Gerado por simulador de escoamento multifásico. Tem a vantagem de cobrir condições raras e a desvantagem de refletir as hipóteses do simulador. Útil para aumentar a amostra de classes escassas.

Desenhado à mão (DRAWN-...).

Construído manualmente por especialistas para ilustrar a assinatura canônica de um evento. *Não deve ser usado para avaliação*: são exemplos idealizados, e um modelo avaliado sobre eles reporta um desempenho que não se sustenta em campo.

Uma decisão de projeto recorrente

O trabalho descrito no Capítulo 14 adota a seguinte política, que recomendamos: usar exclusivamente instâncias reais; recorrer a simuladas apenas quando a classe tem menos de trinta instâncias reais; e excluir integralmente as desenhadas à mão. Essa política reduz o tamanho do conjunto e piora os números publicados — e é exatamente por isso que ela é correta.

3.3 A rotulação**3.3.1 Três estados por amostra**

O 3W rotula *cada amostra* de cada instância com um de três estados:

Código	Estado	Significado
0	Normal	Operação estável, anterior ao evento.
$100 + k$	Transiente	Transição em curso para a anomalia de classe k .
k	Anômalo	Regime anômalo estabelecido da classe k .

O estado transiente é a contribuição mais original — e mais problemática — do esquema de rotulação. Ele reconhece que a passagem de normal para anômalo não é instantânea, e que existe um intervalo em que o evento já começou mas ainda não se manifestou plenamente. Do ponto de vista operacional, *o transiente é exatamente onde a detecção tem valor*: detectar depois que o regime anômalo se estabeleceu é tarde demais.

O que fazer com o transiente

Três políticas convivem na literatura e neste livro:

1. **Descartar** as amostras transientes do treinamento. Produz classes mais puras e números melhores, ao custo de tornar o modelo cego justamente à fase que interessa.
2. **Tratar como anômalo**. Favorece detecção precoce e aumenta o falso positivo.
3. **Tratar como classe própria**. Triplica o número de classes e agrava o desbalanceamento.

Os trabalhos deste livro adotam predominantemente a segunda política. A métrica SoftED do Capítulo 11 foi introduzida precisamente para avaliar a detecção com tolerância temporal, tornando a questão menos binária.

3.3.2 Rótulo por instância

Além do rótulo por amostra, cada instância possui um rótulo global — a classe do evento que ela contém. Essa distinção gera duas famílias de métricas que *não podem ser confundidas*:

- **Métrica por amostra**: fração de amostras corretamente rotuladas. Dominada pelas instâncias mais longas e pela classe normal.
- **Métrica por instância**: fração de instâncias em que o evento foi corretamente identificado. É a que corresponde à pergunta operacional.

Exemplo 3.1 — A diferença em números

No Capítulo 9, o classificador binário da classe 6 apresenta acurácia média por amostra de $0,75 \pm 0,13$ e acurácia média por instância de $0,34 \pm 0,42$. O desvio-padrão enorme na segunda métrica revela o que a primeira esconde: o modelo acerta quase todas as amostras de algumas instâncias e erra quase todas as de outras. Uma média de 0,75 por amostra é compatível com “funciona bem em metade dos poços e não funciona na outra metade”.

3.4 As armadilhas**3.4.1 O estado das válvulas muda a estrutura de correlação**

Antes das armadilhas de rotulação, uma armadilha de estacionariedade. As variáveis observadas não guardam entre si uma relação fixa: a estrutura de correlação depende da configuração das válvulas no momento da medição.

A Figura 3.1 mostra o efeito. Pares de sensores que se correlacionam positivamente com a M2 aberta podem correlacionar-se de forma fraca ou invertida com a M2 fechada, porque o caminho do fluido mudou. Um modelo treinado sobre a mistura dos dois regimes aprende uma correlação média que não descreve nenhum dos dois.

A consequência prática

É por isso que o sistema do Capítulo 7 suspende a análise durante manobras de válvula e retoma apenas após a estabilização, e é por isso que ele mantém modelos distintos por configuração. Não é excesso de zelo: sem essa segmentação, toda manobra programada




Figura 3.1: Matrizes de correlação entre os sinais de pressão e temperatura (PT, TPT e PDG), calculadas separadamente para dados do 3W e para dados de operação com a válvula M2 aberta e fechada. Vermelho indica correlação positiva; azul, negativa. Adaptado de Aranha et al. (2024a).

vira um alarme.

O mesmo cuidado não é possível no 3W, que não distribui o estado das válvulas. Essa ausência é uma limitação do conjunto, e não do método.

3.4.2 Desbalanceamento

A classe normal domina o conjunto por ordens de magnitude ao nível de amostra, e as classes de anomalia são desbalanceadas entre si — a classe 9 tem uma pequena fração das instâncias da classe 7. As consequências são conhecidas e as contramedidas também: métricas balanceadas (Capítulo 4), amostragem estratificada, ponderação de classe na função de perda e, no caso do ensemble binário do Capítulo 8, subamostragem da classe negativa.

3.4.3 Valores ausentes e sensores congelados

Instâncias reais contêm lacunas. As estratégias usadas neste livro são:

- preenchimento com o último valor válido (*forward fill*), adequado quando a lacuna é curta;
- preenchimento com o próximo valor válido (*backward fill*), para lacunas no início da série;
- preenchimento pela média da janela, usado no Capítulo 11;
- descarte da instância, quando a fração ausente excede um limiar.

Um sensor congelado não gera valor ausente — gera um valor constante, que passa por todos os filtros de qualidade baseados em nulos. Detectá-lo exige verificar explicitamente $\text{std}(x_{t:t+T}^{(s)}) < \epsilon$.

3.4.4 A correlação espúria mais perigosa do 3W

Este é o achado mais desconfortável reportado neste livro, e ele aparece no Capítulo 15. Em várias classes do 3W — notadamente 2, 6, 7 e 8 — o instante de início da anomalia coincide, com frequência muito acima do acaso, com a perda dos medidores de fundo: P-PDG e T-PDG tornam-se ausentes ou zerados.

A explicação provável é banal e não tem nada a ver com física de poços. Muitos eventos indesejáveis são acompanhados de intervenção, e intervenção frequentemente implica reconfiguração da aquisição. O rótulo de anomalia e a interrupção da telemetria têm uma causa comum.

Por que isso importa

Um modelo treinado nesses dados pode aprender “se os sensores de fundo sumiram, é anomalia”. Essa regra tem alto desempenho no conjunto de teste e valor operacional próximo de zero. Pior: ela é invisível às métricas usuais.

Foi um modelo de linguagem, ao ser solicitado a *descrever em texto* o que observava, que tornou o padrão explícito: em quatro das sete classes analisadas, a descrição gerada continha a expressão “perda de telemetria de fundo”. O episódio é o argumento mais forte deste livro a favor da explicabilidade — não porque o modelo de linguagem classifique melhor, mas porque ele *fala*, e ao falar expõe o que o classificador silencioso teria escondido.

3.4.5 Vazamento temporal e vazamento entre poços

Duas formas de vazamento comprometem avaliações neste domínio.

Vazamento temporal.

Ocorre quando janelas sobrepostas de uma mesma instância são distribuídas entre treino e teste. Como janelas adjacentes compartilham a maior parte de suas amostras, o modelo essencialmente memoriza. A contramedida é a *divisão temporal*: os primeiros 80 % de cada instância para treino, os últimos 20 % para teste, sem sobreposição na fronteira. É o protocolo adotado no Capítulo 10.

Vazamento entre poços.

Ocorre quando janelas de um mesmo poço aparecem em treino e teste. O modelo aprende as idiossincrasias daquele poço — nível de pressão característico, ruído do sensor — em vez da assinatura do evento. A contramedida é a *divisão por poço*, mais rigorosa e mais realista. O Capítulo 11 reporta resultados por poço individual justamente para expor a variabilidade que uma média global esconde.

Exemplo 3.2 — Quanto custa fazer certo

No Capítulo 11, o desempenho da U-Net varia de 0,720 de acurácia no poço F1 a 0,975 no poço C2. A média global, $0,863 \pm 0,082$, só é informativa porque vem acompanhada do desvio-padrão e da tabela completa. Uma avaliação com divisão aleatória de janelas reportaria um número maior e menos honesto.

3.5 Pré-processamento

As etapas de pré-processamento empregadas no livro formam um repertório pequeno.

1. **Tratamento de ausentes**, conforme descrito acima.
2. **Normalização Min-Max** para o intervalo $[0, 1]$:

$$\tilde{x} = \frac{x - \min(x)}{\max(x) - \min(x)}.$$

Usada no Capítulo 7, onde o autoencoder tem saída sigmoide. Sensível a *outliers* e ao intervalo de calibração.

3. **Padronização** (escore z):

$$\tilde{x} = \frac{x - \mu}{\sigma}.$$

Usada nos Capítulos 11 e 12. Preferível quando o modelo assume distribuição aproximadamente gaussiana — caso, notadamente, da distância de Mahalanobis.

4. **Filtragem por transformada *wavelet***. Decomposição com *wavelet* de Daubechies db4 em três níveis, aplicação de limiar suave aos coeficientes de detalhe e reconstrução. Remove ruído de alta frequência preservando descontinuidades — o que um filtro passa-baixas convencional não faz. É particularmente relevante aqui, já que as assinaturas de interesse são descontinuidades.
5. **Injeção de ruído** de 0 a 0,5 % durante o treinamento, empregada no Capítulo 7 como regularização e para tornar o autoencoder robusto à variabilidade de instrumentação entre poços.

O conjunto de ajuste importa

Aplicar padronização e, em seguida, normalização Min-Max não produz dois efeitos distintos quando ambas são ajustadas sobre as mesmas amostras. Nesse caso, a transformação afim da primeira etapa é cancelada pela segunda e o resultado coincide com a normalização Min-Max direta. A composição só acrescenta informação quando os parâmetros são estimados sobre referências diferentes — por exemplo, média e desvio do regime de base de cada poço, seguidos de limites globais estimados exclusivamente no conjunto de treinamento. Por isso, uma implementação reprodutível deve registrar não apenas a ordem, mas também os dados usados para ajustar cada transformação.

Prática

Todo o percurso deste capítulo — carga dos arquivos do 3W, comparação entre os quatro métodos de escalonamento, janelamento e partição por validação cruzada — está implementado e executável no recurso descrito no Capítulo E, no caderno `1_data_treatment` (Lopes, 2026).

Resumo do capítulo

O conjunto 3W é a referência pública da área, com 1.984 instâncias e oito classes de anomalia na versão 1.0 e 2.228 instâncias e nove classes na versão 2.0. Suas instâncias têm três procedências — real, simulada e desenhada à mão — e apenas as reais sustentam conclusões operacionais. A rotulação por amostra em três estados (normal, transiente, anômalo) reconhece que eventos têm início gradual, e o tratamento dado ao estado transiente é uma decisão de projeto com efeito direto sobre a detecção precoce. As principais armadilhas são o desbalanceamento

severo, os sensores congelados que passam por filtros de nulos, o vazamento temporal e entre poços em protocolos de avaliação descuidados e, sobretudo, a correlação espúria entre início de anomalia e perda de telemetria de fundo — um artefato de coleta capaz de produzir modelos com alto desempenho e nenhum valor.

Exercícios

1. Uma instância do 3W tem 86.400 amostras (um dia a 1 Hz). Calcule quantas janelas de $T = 200$ com passo $h = 100$ ela produz. Em seguida, calcule a fração de amostras compartilhadas entre duas janelas consecutivas e discuta o impacto disso sobre uma divisão aleatória treino/teste.
2. Implemente um detector de sensor congelado: dado um sinal e uma janela, retorne as regiões em que o desvio-padrão fica abaixo de ϵ . Aplique-o a instâncias reais do 3W e reporte a fração de amostras afetadas por classe. Discuta se essa fração é uniforme entre classes e o que uma não uniformidade implicaria.
3. Compare experimentalmente três políticas de tratamento do estado transiente (descartar, tratar como anômalo, classe própria) em um classificador binário simples para a classe 2. Reporte acurácia balanceada e a distância temporal média entre o início real do evento e a primeira detecção.
4. Considere o achado da Seção 3.4.4. Proponha um experimento controlado que quantifique a contribuição da perda de telemetria para o desempenho de um classificador. Dica: pense em uma ablação em que a informação de “dado ausente” é deliberadamente removida.
5. Justifique matematicamente por que a normalização Min-Max é sensível a *outliers* e a padronização é sensível à hipótese de simetria. Para cada uma, construa um exemplo numérico de dez pontos em que ela falha.
6. Projete um protocolo de validação cruzada para o 3W que simultaneamente: (a) evite vazamento entre poços; (b) mantenha a estratificação por classe; (c) garanta que cada classe apareça em pelo menos três dobras. Discuta se as três condições são sempre simultaneamente satisfazíveis dado o desbalanceamento do conjunto.

Leituras recomendadas

- Vargas et al. (2019) — artigo original do 3W, com a descrição do processo de rotulação.
- Vaz Vargas et al. (2026) — versão 2.0, com discussão explícita das limitações da versão anterior.
- Marins et al. (2021b) e Marins et al. (2021a) — primeiros trabalhos de referência sobre o 3W, úteis como linha de base e como ilustração das convenções de avaliação que se consolidaram na área.
- Carvalho et al. (2021) e Brønstad et al. (2021) — perspectivas complementares sobre qualidade de dados em séries temporais industriais.

Capítulo 4

Aprendizado de máquina e avaliação

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- formular detecção e classificação de anomalias como problemas de aprendizado supervisionado e não supervisionado;
- calcular e interpretar acurácia, acurácia balanceada, precisão, revocação, especificidade, medida F_1 e SMAPE;
- justificar por que a acurácia simples é enganosa em cenários desbalanceados e escolher a métrica adequada ao objetivo operacional;
- construir intervalos de confiança de Wilson para proporções e usá-los para decidir se uma diferença entre métodos é significativa;
- distinguir avaliação por amostra, por instância e por evento, e reconhecer quando cada uma responde à pergunta certa.

4.1 As duas formulações

4.1.1 Supervisionada

Dispõe-se de pares $(\mathbf{X}_i, y_i)$ com $y_i \in \mathcal{K}$, e busca-se $f_\theta : \mathbb{R}^{T \times S} \rightarrow \mathcal{K}$ que minimize o risco empírico

$$\hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^n \mathcal{L}(f_\theta(\mathbf{X}_i), y_i).$$

Para classificação binária, $\mathcal{L}$ é a entropia cruzada binária

$$\mathcal{L}(\hat{y}, y) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})],$$

e para classificação multiclasse, a entropia cruzada categórica. Essa é a formulação do ensemble binário (Capítulos 8 e 10) e da U-Net de segmentação (Capítulo 11).

4.1.2 Não supervisionada

Dispõe-se apenas de $\mathbf{X}_i$. Duas subformulações interessam aqui:

- **Modelagem de normalidade.** Ajusta-se um modelo à classe normal e declara-se anômalo aquilo que se afasta dele. É o princípio do autoencoder com limiar de erro de reconstrução (Capítulo 7) e da distância de Mahalanobis (Capítulo 12).

- **Agrupamento.** Particiona-se um conjunto sem rótulos em grupos coerentes. É o mecanismo pelo qual instâncias rejeitadas como desconhecidas se tornam classes candidatas (Capítulo 9).

Uma terceira formulação, implícita

Os Capítulos 13 a 15 usam um modelo de linguagem *sem qualquer treinamento sobre os dados de poço*. Não é aprendizado supervisionado nem não supervisionado: é inferência com conhecimento prévio, guiada por descritores numéricos. A avaliação, contudo, usa as mesmas métricas — e é precisamente por isso que este capítulo antecede aquela discussão.

4.2 A matriz de confusão e o que se extrai dela

Para um problema binário, com a convenção de que “positivo” significa “anomalia presente”:

		Predito	
		Positivo	Negativo
Real	Positivo	VP	FN
	Negativo	FP	VN

Definição 4.1 — Métricas fundamentais

$$ACC = \frac{VP + VN}{VP + VN + FP + FN} \quad (4.1)$$

$$REC = \frac{VP}{VP + FN} \quad (\text{revocação, } recall, \text{ sensibilidade}) \quad (4.2)$$

$$SP = \frac{VN}{VN + FP} \quad (\text{especificidade}) \quad (4.3)$$

$$PR = \frac{VP}{VP + FP} \quad (\text{precisão}) \quad (4.4)$$

$$F_1 = \frac{2 \cdot PR \cdot REC}{PR + REC} \quad (4.5)$$

Definição 4.2 — Acurácia balanceada

$$ACC_b = \frac{REC + SP}{2}. \quad (4.6)$$

Equivale à média das acurácias por classe e, portanto, atribui o mesmo peso à classe positiva e à negativa independentemente de sua frequência. Um classificador que sempre prediz a classe majoritária tem $ACC_b = 0,5$, qualquer que seja o desbalanceamento.

Exemplo 4.1 — Por que a acurácia simples engana

Considere um poço monitorado a 1 Hz durante trinta dias, com um único evento de anomalia que dura duas horas. O número de amostras anômalas é $2 \times 3600 = 7.200$; o de amostras normais, $30 \times 86400 - 7200 = 2.584.800$. A prevalência da anomalia é de

aproximadamente 0,28 %.

Um classificador que responda “normal” para toda amostra obtém

$$\text{ACC} = \frac{2.584.800}{2.592.000} \approx 0,9972,$$

ou seja, 99,72 % de acurácia. Sua acurácia balanceada, contudo, é $\text{ACC}_b = (0 + 1)/2 = 0,5$, sua revocação é zero e sua medida F_1 é indefinida (ou zero, por convenção). O sistema é inútil e a acurácia simples não diz.

Qual métrica escolher

A escolha deve seguir a consequência operacional do erro.

- Se o custo de *perder* um evento domina (hidrato, integridade), priorize **revocação**.
- Se o custo de *alarme falso* domina (fadiga de alarme, parada desnecessária), priorize **precisão**.
- Se ambos importam e não há razão para privilegiar um, use F_1 .
- Se as classes são fortemente desbalanceadas e você quer uma leitura única, use ACC_b .

Este livro reporta, em geral, o conjunto completo, porque a escolha depende do leitor.

4.3 Métricas de regressão e reconstrução

Modelos que reconstroem um sinal, como os autoencoders dos Capítulos 7, 9 e 12, precisam de uma medida de erro de reconstrução. A escolha feita no Capítulo 7 é o SMAPE.

Definição 4.3 — Erro percentual absoluto médio simétrico

$$\text{SMAPE} = \frac{100\%}{n} \sum_{t=1}^n \frac{|\hat{x}_t - x_t|}{(|x_t| + |\hat{x}_t|)/2}. \quad (4.7)$$

O SMAPE tem três propriedades que o tornam adequado ao problema. É *relativo*, logo comparável entre sensores de escalas diferentes — pressão em bar e temperatura em graus Celsius. É *simétrico*, penalizando igualmente superestimação e subestimação, ao contrário do erro percentual absoluto usual. E é *limitado* a 200 %, o que impede que um único ponto próximo de zero domine a média, patologia que compromete o erro percentual convencional.

A armadilha do SMAPE

O denominador anula-se quando $x_t = \hat{x}_t = 0$. Em séries normalizadas para $[0, 1]$, isso não é hipotético. A implementação deve adicionar um termo de regularização ϵ ou tratar explicitamente o caso.

4.4 Avaliação de detecção de eventos

Há uma incompatibilidade estrutural entre as métricas apresentadas até aqui e a pergunta operacional. As métricas por amostra tratam cada instante como um item independente; a

operação pergunta “o evento foi detectado, e com que antecedência?”.

Exemplo 4.2 — O problema do deslocamento

Suponha que um evento comece no instante $t = 1.000$ e que um detector o sinalize em $t = 1.005$. Do ponto de vista operacional, cinco segundos de atraso é uma detecção essencialmente perfeita. Do ponto de vista de uma métrica por amostra, foram cinco falsos negativos seguidos de acertos — e se o detector tivesse sinalizado em $t = 995$, seriam cinco falsos positivos.

Uma métrica que penaliza igualmente “cinco segundos adiantado” e “nunca detectou” não está medindo o que interessa.

A família SoftED (Salles et al., 2024) resolve isso introduzindo uma tolerância temporal k : uma detecção é creditada como verdadeiro positivo se ocorrer dentro de k amostras do evento real, com peso decrescente conforme a distância. O Capítulo 11 avalia a U-Net com $k = 1.000$ — aproximadamente dezesseis minutos — e reporta separadamente a taxa de *detecção precoce*, isto é, a fração de eventos sinalizados antes do instante rotulado.

Três níveis de avaliação

Ao ler qualquer tabela deste livro, verifique primeiro o nível:

1. **Por amostra** — cada instante conta. Domina o Capítulo 7 e o Capítulo 11 (acurácia e IOU).
2. **Por janela ou segmento** — cada janela conta. Domina o Capítulo 10 e o Capítulo 15.
3. **Por evento** — cada evento conta, com tolerância temporal. É o SoftED, no Capítulo 11.

Números de níveis diferentes não são comparáveis, ainda que ambos se chamem “acurácia”.

4.4.1 A métrica de sobreposição para segmentação

Definição 4.4 — Razão entre interseção e união

Para uma região predita $\hat{A}$ e uma região real A , ambas subconjuntos do eixo temporal,

$$\text{IOU}(\hat{A}, A) = \frac{|\hat{A} \cap A|}{|\hat{A} \cup A|}. \quad (4.8)$$

Ao excluir verdadeiros negativos, o IoU mede diretamente a sobreposição da classe positiva e não é inflado pela classe majoritária. Isso não o torna universalmente “mais exigente”; ele responde a uma pergunta diferente da acurácia por amostra. É por isso que, na tabela de segmentação do Capítulo 11, a acurácia global é 94,00 % enquanto o IOU global é 85 %.

4.5 Métricas para *ranking*: acurácia top- k

Quando um sistema devolve uma lista ordenada de hipóteses em vez de uma única resposta, a métrica natural é a acurácia top- k .

Definição 4.5 — Acurácia top- k

Seja $R_i = (r_i^{(1)}, \dots, r_i^{(m)})$ a lista ordenada de classes candidatas produzida para a instância i , e y_i o rótulo verdadeiro. A acurácia top- k é

$$\text{ACC@}k = \frac{1}{n} \sum_{i=1}^n \mathbb{I}[y_i \in \{r_i^{(1)}, \dots, r_i^{(k)}\}]. \quad (4.9)$$

Essa métrica é central no Capítulo 15, onde o agente de linguagem devolve as três hipóteses mais prováveis com justificativa individual. A leitura correta desses números exige contexto: para nove classes, um sistema aleatório obterá $\text{ACC@}1 = 11,1\%$, $\text{ACC@}2 = 22,2\%$ e $\text{ACC@}3 = 33,3\%$. Os valores observados — $35,1\%$, $53,4\%$ e $63,9\%$ — são portanto cerca de três, duas e meia e duas vezes o acaso, respectivamente.

Top- k não é uma métrica “mais fácil”

É comum descartar a acurácia top-3 como “inflada”. Isso ignora o uso pretendido. Quando o sistema é um *assistente* que apresenta hipóteses a um especialista, a pergunta certa é “a resposta correta está entre as opções que ele considerou?”. A acurácia top-1 é a métrica de um sistema autônomo; a top- k é a métrica de um sistema de apoio à decisão. O Capítulo 14 argumenta que a segunda é a arquitetura apropriada para este domínio.

4.6 Incerteza: intervalos de confiança para proporções

Toda métrica reportada neste livro é uma estimativa a partir de amostra finita, e várias delas vêm de amostras pequenas — catorze instâncias na classe 9 do Capítulo 15, por exemplo. Reportar “7,1 %” sem intervalo é irresponsável.

Definição 4.6 — Intervalo de Wilson

Para x sucessos em n ensaios, com $\hat{p} = x/n$ e nível de confiança correspondente a z (com $z = 1,96$ para 95 %), o intervalo de Wilson (Wilson, 1927) é

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}. \quad (4.10)$$

O intervalo de Wilson é preferível ao intervalo normal (de Wald) $\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/n}$ por duas razões decisivas neste contexto: ele nunca ultrapassa $[0, 1]$, e continua bem definido quando $\hat{p} = 0$ ou $\hat{p} = 1$ — casos que ocorrem repetidamente nas tabelas por classe deste livro.

Exemplo 4.3 — Intervalos individuais não testam uma diferença

No Capítulo 15, o agente atinge $\text{ACC@}1 = 35,1\%$ sobre $n = 191$ segmentos, com intervalo de Wilson $[28,7\%; 42,1\%]$. Suponha que um método alternativo obtenha $40,0\%$ sobre a mesma amostra. O intervalo do segundo método seria aproximadamente $[33,3\%; 47,1\%]$. Esses dois intervalos descrevem cada proporção separadamente; sua sobreposição, ou ausência dela, não é um teste da diferença entre os métodos.

Como os dois métodos foram avaliados nos mesmos segmentos, a comparação é pareada. Para acerto e erro binários, o teste de McNemar usa apenas os casos discordantes: b , em que somente o primeiro acerta, e c , em que somente o segundo acerta. Para métricas como F_1 ou acurácia balanceada, um intervalo da diferença pode ser obtido por *bootstrap* pareado, reamostrando segmentos ou poços como unidades indivisíveis. Se a hipótese for “não houve perda relevante”, é necessário definir antes uma margem de não inferioridade; ausência de significância não demonstra equivalência.

O mesmo raciocínio aplicado às classes individuais é ainda mais severo: com $n = 15$, o intervalo de Wilson para $\hat{p} = 0,267$ vai de aproximadamente 0,107 a 0,522. Praticamente nenhuma comparação entre classes com essa amostra é estatisticamente conclusiva — o que não impede que os padrões qualitativos sejam informativos.

Regra prática deste livro

Toda proporção reportada com $n < 200$ deve vir acompanhada de n e de intervalo de 95 % quando as contagens estiverem disponíveis. Toda média sobre poços ou dobras deve vir acompanhada de uma medida de dispersão. Comparações sobre os mesmos casos devem preservar o pareamento; intervalos individuais não substituem um teste ou intervalo da diferença. Quando a dispersão é grande em relação à média — como o $0,34 \pm 0,42$ do Capítulo 9 — o texto deve discutir explicitamente o que isso significa.

4.7 Validação

4.7.1 Validação cruzada estratificada

Os Capítulos 11 e 12 usam validação cruzada estratificada em cinco dobras: o conjunto é particionado em cinco partes preservando a proporção de classes, e cada parte serve uma vez como conjunto de teste. A estratificação é indispensável sob desbalanceamento severo.

4.7.2 Divisão temporal

O Capítulo 10 usa divisão temporal 80/20 dentro de cada instância, pelo motivo exposto na Capítulo 3: janelas sobrepostas distribuídas aleatoriamente produzem vazamento.

4.7.3 Avaliação por poço

O protocolo mais rigoroso, adotado no Capítulo 11, avalia poço a poço e reporta a tabela completa. Ele revela a variabilidade entre poços — o desvio-padrão de 0,187 na acurácia do detector baseado em autoencoder — que uma média esconderia.

Prática

O caderno `4_introduction_to_supervised_learning`, descrito no Capítulo E, treina árvores, florestas, SVM e redes densas sobre o 3W e reporta as métricas discutidas aqui (Lopes, 2026). É o caminho mais curto para ver, em dados reais, por que a acurácia simples engana sob desbalanceamento.

Resumo do capítulo

A avaliação é a parte do método em que os erros são mais fáceis e mais caros. Sob o desbalanceamento característico de dados de poço, a acurácia simples é sistematicamente enganosa: um detector inútil atinge 99,7 %. A acurácia balanceada, definida como a média de revocação e especificidade, corrige o problema. A escolha entre precisão e revocação deve seguir a consequência operacional do erro, não a conveniência do número. Erros de reconstrução são medidos por SMAPE, relativo, simétrico e limitado. A avaliação de detecção de eventos exige tolerância temporal, formalizada pela família SoftED, e a avaliação de segmentação exige IOU além de acurácia. Sistemas que devolvem *rankings* são avaliados por acurácia top- k , que deve sempre ser lida contra a linha de base do acaso. Toda proporção estimada de amostra pequena deve vir acompanhada de intervalo de confiança de Wilson.

Exercícios

1. Demonstre que, para um classificador que sempre prediz a classe majoritária, $ACC_b = 0,5$ independentemente da prevalência. Em seguida, mostre que ACC_b é a média das acurácias condicionais a cada classe.
2. Um detector apresenta $VP = 45$, $FN = 15$, $FP = 90$ e $VN = 9.850$. Calcule ACC , ACC_b , PR , REC , SP e F_1 . Comente a discrepância entre ACC e F_1 e diga qual você reportaria a um gerente de operação e por quê.
3. Mostre que o SMAPE é limitado superiormente por 200 %. Construa em seguida uma série de dez pontos em que o erro percentual absoluto médio convencional diverge mas o SMAPE permanece finito.
4. Calcule o intervalo de Wilson de 95 % para $x = 1$ sucesso em $n = 14$ ensaios (o caso da classe 9 no Capítulo 15). Compare com o intervalo de Wald e explique por que o segundo é inadequado.
5. Implemente a métrica SoftED com tolerância k e aplique-a a um detector simples sobre uma instância do 3W. Trace a curva de F_1 em função de k para $k \in \{10, 100, 500, 1000, 5000\}$ e discuta como escolher k a partir de requisitos operacionais.
6. Um sistema devolve três hipóteses ordenadas para um problema de nove classes. Calcule a acurácia top-1, top-2 e top-3 esperadas sob escolha aleatória *sem* repetição. Em seguida, calcule quantas vezes acima do acaso estão os valores 35,1 %, 53,4 % e 63,9 % reportados no Capítulo 15.
7. Discuta a seguinte proposta: “para evitar a discussão sobre qual métrica usar, basta reportar todas”. Considere o problema de comparação múltipla e o risco de seleção da métrica mais favorável após ver os resultados.

Leituras recomendadas

- Salles et al. (2024) introduzem a família SoftED e discutem em profundidade a inadequação das métricas por amostra para detecção de eventos.
- Wilson (1927) é o artigo original do intervalo que leva seu nome; curto e surpreendentemente legível.

- Pimentel et al. (2014) discutem, em sua revisão de detecção de novidade, os problemas específicos de avaliação quando a classe positiva é rara por construção.
- Chollet (2015) e Jones et al. (2001) documentam as implementações de referência das métricas discutidas aqui.

Capítulo 5

Aprendizado profundo para séries temporais

Objetivos de aprendizagem

Este capítulo é um panorama de referência, não um curso de aprendizado profundo: ele apresenta apenas o que é necessário para acompanhar as arquiteturas usadas no restante do livro. Ao final, você será capaz de:

- descrever a estrutura de um perceptron de múltiplas camadas e explicar por que ele é inadequado a séries temporais longas;
- explicar, no nível das equações de estado, o que as células LSTM e GRU fazem e que problema de gradiente elas atenuam;
- aplicar convoluções unidimensionais a sinais e calcular o campo receptivo de uma pilha convolucional;
- descrever a estrutura de um autoencoder, interpretar seu espaço latente e usar o erro de reconstrução como escore de anomalia;
- distinguir autoencoder, autoencoder variacional e rede de agrupamento profundo quanto ao que cada um otimiza;
- descrever a arquitetura U-Net e justificar por que suas conexões de atalho importam para segmentação;
- enunciar a equação da atenção e situar o Transformer no contexto deste livro — nenhum modelo aqui treinado é um Transformer, e a arquitetura não é desenvolvida em detalhe.

5.1 Da regressão à rede profunda

5.1.1 O perceptron de múltiplas camadas

Uma camada densa aplica uma transformação afim seguida de não linearidade:

$$\mathbf{h}^{(\ell)} = \sigma(\mathbf{W}^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad (5.1)$$

com $\mathbf{h}^{(0)} = \mathbf{x}$. Empilhando L camadas obtém-se o perceptron de múltiplas camadas (*multilayer perceptron*) (MLP). As não linearidades usadas neste livro são a ReLU, $\sigma(z) = \max(0, z)$, nas camadas ocultas, e a sigmoide, $\sigma(z) = 1/(1 + e^{-z})$, nas saídas binárias.

Aplicar um MLP a uma série temporal exige achatá-la em um vetor de dimensão $T \cdot S$. Para $T = 200$ e $S = 4$, isso resulta em 800 entradas — exatamente a representação “bruta” usada como linha de base no Capítulo 12. O procedimento preserva a ordem apenas de forma posicional: cada instante ocupa coordenadas fixas, de modo que permutá-los em geral altera a saída. O que falta é o viés arquitetural adequado à estrutura temporal: não há compartilhamento local de pesos nem equivariância a translações, e o mesmo padrão em posições diferentes ativa parâmetros diferentes. Além disso, o número de pesos da primeira camada cresce com $T \cdot S$.

Por que a linha de base bruta ainda aparece

O Capítulo 12 reporta que classificadores binários sobre a representação bruta de 800 dimensões atingem $0,691 \pm 0,162$ de acurácia, contra $0,755 \pm 0,171$ sobre a representação latente de um classificador multiclasse. A diferença observada é modesta e, sem uma análise pareada, não estabelece superioridade estatística. O fato de a representação bruta chegar tão perto ainda é informativo: as assinaturas dessas anomalias são, em boa medida, capturáveis por estatísticas de primeira ordem.

5.1.2 Regularização

Três mecanismos são usados de forma recorrente:

- **Dropout** (Srivastava et al., 2014): durante o treinamento, cada unidade é zerada com probabilidade p . Nas arquiteturas deste livro, p varia de 0,1 a 0,5, tipicamente decrescendo em direção à saída.
- **Normalização em lote** (*batch normalization*): normaliza as ativações de cada camada pela média e variância do lote, acelerando a convergência e atuando como regularizador leve. Presente em todos os blocos da U-Net do Capítulo 11.
- **Parada antecipada** (*early stopping*): interrompe o treinamento quando a perda de validação deixa de melhorar por um número fixo de épocas. O Capítulo 10 usa paciência de cinco épocas.

5.2 Redes recorrentes

5.2.1 O problema

Uma rede recorrente processa a sequência mantendo um estado oculto:

$$\mathbf{h}_t = \sigma(\mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{W}_{xh}\mathbf{x}_t + \mathbf{b}). \quad (5.2)$$

A retropropagação através do tempo desdobra essa recorrência em T passos, e o gradiente em relação a $\mathbf{h}_1$ envolve o produto de T jacobianas. Se os autovalores dominantes dessas matrizes forem menores que um, o gradiente decai exponencialmente e a rede não aprende dependências longas; se forem maiores, ele explode. É o problema do gradiente evanescente (*vanishing gradient problem*) (Schmidhuber, 2015).

Para $T = 500$, como no Capítulo 7, uma RNN simples é inviável.

5.2.2 A célula LSTM

A memória de curto prazo longa (*long short-term memory*) (LSTM) (Hochreiter and Schmidhuber, 1997) introduz um estado de célula $\mathbf{c}_t$ que se propaga por soma, não por produto matricial, e três portas que regulam o fluxo de informação:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (\text{esquecimento}) \quad (5.3)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (\text{entrada}) \quad (5.4)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (\text{candidato}) \quad (5.5)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (\text{estado de célula}) \quad (5.6)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (\text{saída}) \quad (5.7)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (\text{estado oculto}) \quad (5.8)$$

onde $\odot$ denota produto elemento a elemento. A Equação (5.6) é o coração do mecanismo: quando $\mathbf{f}_t \approx \mathbf{1}$ e $\mathbf{i}_t \approx \mathbf{0}$, o estado de célula é copiado inalterado, e o gradiente flui sem atenuação.

LSTM em todos os capítulos da Parte II e III

O Capítulo 7 usa uma pilha LSTM(16)–LSTM(4) como codificador e o espelho como decodificador. O Capítulo 9 usa LSTM(32)–LSTM(8) com camada densa latente de dimensão 16. O Capítulo 12 usa LSTM(256)–LSTM(128) com latente de dimensão 128. A tendência de crescimento não é acidental: reflete o aumento da quantidade de dados e a mudança de objetivo, de reconstrução para representação discriminativa.

5.2.3 GRU

A unidade recorrente com portas (*gated recurrent unit*) funde as portas de esquecimento e entrada em uma única porta de atualização, eliminando o estado de célula separado. Tem cerca de um quarto a menos de parâmetros e desempenho comparável na maioria das tarefas. Não é usada nos experimentos deste livro, mas é a primeira alternativa a considerar quando o custo computacional importa.

5.3 Convoluções unidimensionais

Uma convolução unidimensional com núcleo de tamanho κ aplica

$$h_t^{(j)} = \sigma \left(\sum_{s=1}^S \sum_{u=0}^{\kappa-1} w_{s,u}^{(j)} x_{t+u}^{(s)} + b^{(j)} \right), \quad (5.9)$$

compartilhando os pesos $w^{(j)}$ ao longo de todo o eixo temporal. Duas consequências seguem imediatamente: o número de parâmetros independe de T , e a resposta é equivariante a translações — o mesmo padrão detectado em posições diferentes produz a mesma ativação, deslocada.

Definição 5.1 — Campo receptivo

O campo receptivo de uma unidade é o número de amostras da entrada que influenciam seu valor. Para uma pilha de L camadas convolucionais de núcleo κ , sem subamostragem, o campo receptivo é $L(\kappa - 1) + 1$. Com subamostragem por fator 2 após cada camada, ele cresce aproximadamente como 2^L .

Exemplo 5.1 — O campo receptivo da U-Net do Capítulo 11

A arquitetura tem dois blocos de codificação com duas convoluções de núcleo 5 cada, seguidos de subamostragem por 2, e um gargalo com mais duas convoluções de núcleo 5. Partindo de campo $r = 1$ e salto $j = 1$, cada convolução atualiza $r \leftarrow r + 4j$; cada *pooling* de núcleo e passo 2 atualiza $r \leftarrow r + j$ e $j \leftarrow 2j$. Os valores após os dois blocos são $(r, j) = (28, 4)$; as duas convoluções do gargalo levam a $r = 60$ amostras. O valor depende da convenção de borda, mas não ultrapassa oitenta nessa arquitetura. O cálculo importa: se o campo receptivo fosse menor que a duração característica do evento, a rede não poderia, em princípio, reconhecê-lo.

5.3.1 Convolução *versus* recorrência

	Recorrente (LSTM)	Convolutacional 1D
Paralelização	Sequencial; lenta em T grande.	Totalmente paralelizável.
Dependência longa	Ilimitada em princípio.	Limitada pelo campo receptivo.
Parâmetros	Independem de T .	Independem de T .
Adequação	Dinâmica com memória de estado.	Padrões locais e invariantes a translação.
Uso neste livro	Capítulo 7, Capítulo 9, Capítulo 12.	Capítulo 11.

5.4 Autoencoders**Definição 5.2 — Autoencoder**

Um autoencoder (*autoencoder*) é um par de funções $g_\phi : \mathbb{R}^{T \times S} \rightarrow \mathbb{R}^d$ (codificador) e $h_\psi : \mathbb{R}^d \rightarrow \mathbb{R}^{T \times S}$ (decodificador), treinado para minimizar o erro de reconstrução

$$\mathcal{L}(\phi, \psi) = \frac{1}{n} \sum_{i=1}^n \mathcal{D}(\mathbf{X}_i, h_\psi(g_\phi(\mathbf{X}_i))), \quad (5.10)$$

com $d \ll T \cdot S$. O vetor $\mathbf{z} = g_\phi(\mathbf{X})$ é a representação latente (*latent representation*).

A restrição dimensional é o que dá poder ao mecanismo. Como $\mathbf{z}$ não tem capacidade para armazenar a entrada integralmente, o treinamento força a retenção dos fatores de variação mais frequentes. Se o treinamento usa apenas dados normais, esses fatores são os da normalidade, e a reconstrução de uma entrada anômala é ruim por construção.

Definição 5.3 — Escore de anomalia por reconstrução

Dado um autoencoder treinado sobre dados normais,

$$a(\mathbf{X}) = \mathcal{D}(\mathbf{X}, h_\psi(g_\phi(\mathbf{X}))), \quad (5.11)$$

e declara-se anomalia quando $a(\mathbf{X}) > \tau$. O limiar é tipicamente estimado a partir da distribuição de a sobre dados normais, na forma $\tau = \mu_a + k\sigma_a$.

O Capítulo 7 usa $\mathcal{D} = \text{SMAPE}$ e $k = 3$. O Capítulo 12 abandona esse escore em favor da distância no espaço latente, e o motivo será desenvolvido lá: um autoencoder treinado para reconstruir pode reconstruir bem demais, inclusive anomalias, quando sua capacidade é suficiente.




Figura 5.1: Estrutura de um autoencoder: o codificador comprime a entrada até uma representação latente de baixa dimensão e o decodificador tenta reconstruí-la. A restrição $d \ll T \cdot S$ força a rede a reter apenas os fatores de variação mais relevantes.

5.4.1 Autoencoder variacional

O autoencoder variacional (*variational autoencoder*) (VAE) (Xu et al., 2018; Kingma and Ba, 2014) substitui o vetor latente determinístico por uma distribuição. O codificador produz $\mu(\mathbf{X})$ e $\sigma(\mathbf{X})$, amostra-se $\mathbf{z} \sim \mathcal{N}(\mu, \text{diag}(\sigma^2))$ pelo truque de reparametrização, e acrescenta-se à perda um termo de divergência de Kullback-Leibler que puxa a posterior aproximada para uma normal padrão:

$$\mathcal{L}_{\text{VAE}} = \underbrace{\mathbb{E}_q[-\log p(\mathbf{X} | \mathbf{z})]}_{\text{reconstrução}} + \beta \underbrace{D_{\text{KL}}(q(\mathbf{z} | \mathbf{X}) \| \mathcal{N}(\mathbf{0}, \mathbf{I}))}_{\text{regularização}}. \quad (5.12)$$

O efeito é um espaço latente contínuo e suave. A expectativa natural seria que isso melhorasse o agrupamento subsequente; o Capítulo 9 mostra que não melhorou: 0,727 contra 0,730 do autoencoder determinístico, diferença sem significância.

5.4.2 Rede de agrupamento profundo

A rede de agrupamento profundo (*deep clustering network*) (DCN) (Ren et al., 2022) otimiza simultaneamente reconstrução e uma perda de agrupamento no espaço latente:

$$\mathcal{L}_{\text{DCN}} = \mathcal{L}_{\text{recon}} + \lambda \sum_i \|\mathbf{z}_i - \mathbf{c}_{\pi(i)}\|^2, \quad (5.13)$$

onde $\mathbf{c}_{\pi(i)}$ é o centroide atribuído a $\mathbf{z}_i$. A intenção é produzir um espaço latente com agrupamentos bem separados. No Capítulo 9, obteve 0,725 — também sem ganho.




Figura 5.2: Projeção t-SNE do espaço latente produzido por uma DCN. Cada cor é uma classe conhecida; o polígono destaca a região ocupada pelas janelas da falha de ICV, uma classe que a rede nunca viu. Os pontos novos são absorvidos pelos agrupamentos existentes em vez de formar um agrupamento próprio.

A Figura 5.2 mostra por que o ganho não aparece — e o motivo é mais interessante que a ausência de ganho. A perda de agrupamento da Equação (5.13) pune explicitamente pontos distantes de qualquer centroide. Diante de uma classe nunca vista, a rede faz exatamente o que foi instruída a fazer: puxa os pontos novos para dentro dos agrupamentos que já conhece.

Regularizar o latente pode ser contraproducente

Autoencoder, VAE e DCN diferem justamente em quanto impõem estrutura ao espaço latente — nenhuma, gaussiana e por agrupamentos, respectivamente. Para reconstruir, mais estrutura ajuda. Para *detectar o desconhecido*, ela atrapalha.

O autoencoder simples reconstrói mal o que nunca viu, e essa incompetência é útil: joga os pontos novos para as bordas do latente, onde são fáceis de isolar. O VAE os regulariza para junto dos conhecidos; a DCN os absorve nos agrupamentos. Ambos apagam o sinal que se queria capturar.

É um caso raro em que a propriedade desejável de um modelo é a sua fragilidade.

Um resultado negativo instrutivo

Três variantes de autoencoder, três resultados indistinguíveis: 0,730, 0,727 e 0,725. A conclusão do Capítulo 9 é que a escolha da variante não era o gargalo. O gargalo estava no *objetivo*: todas as três otimizam reconstrução, e reconstrução não é discriminação. O Capítulo 12 testa a hipótese oposta — extrair a representação da camada penúltima de um classificador multiclasse, treinado com objetivo discriminativo — e obtém uma melhora de outra ordem de grandeza: índice de silhueta de 0,2299 contra $-0,0149$, e razão de separação de até 186,5 vezes contra menos de 2,5.

5.5 A U-Net unidimensional

A U-Net (Ronneberger et al., 2015) foi proposta para segmentação de imagens biomédicas e adaptada aqui para segmentação de séries temporais. Sua estrutura tem três partes.

Caminho de contração.

Blocos de convolução seguidos de subamostragem. A cada bloco, a resolução temporal cai pela metade e o número de canais dobra. Captura contexto progressivamente mais amplo.

Caminho de expansão.

Blocos de superamostragem seguidos de convolução, que restauram a resolução original.

Conexões de atalho.

Cada nível do caminho de expansão recebe, por concatenação, o mapa de ativação do nível correspondente do caminho de contração.

Por que as conexões de atalho são o ponto principal

Sem elas, a informação de localização precisa seria destruída pelas subamostragens sucessivas: a rede saberia *que* há uma anomalia na janela, mas não *onde* ela começa. As conexões de atalho reinjetam, em alta resolução, exatamente essa informação. Para segmentação temporal de eventos de poço, isso é a diferença entre “esta janela de duzentos segundos contém um evento” e “o evento começa no segundo 137”. A segunda resposta é a que o operador precisa.

A instanciação concreta, com dois níveis, núcleos de tamanho 5 e 32, 64 e 128 canais, é detalhada no Capítulo 11.

5.6 Atenção e Transformers

O mecanismo de atenção (*attention*) (Vaswani et al., 2017) calcula, para cada posição, uma combinação ponderada de todas as posições da sequência:

$$\text{Atenção}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}, \quad (5.14)$$

onde $\mathbf{Q}$, $\mathbf{K}$ e $\mathbf{V}$ — consultas, chaves e valores — são projeções lineares da entrada. Ao contrário da recorrência, o caminho entre duas posições quaisquer tem comprimento constante, o que elimina o problema do gradiente evanescente por outra via. O custo é quadrático em T .

Nenhum dos modelos treinados neste livro é um Transformer. Ele aparece, contudo, de forma decisiva: o modelo de linguagem da Parte IV é um Transformer com centenas de bilhões de parâmetros, e compreender a Equação (5.14) é pré-requisito para entender o que ele faz e o que ele não faz. Essa discussão é o objeto do Capítulo 13.

Prática

O caderno `3_introduction_to_unsupervised_learning`, descrito no Capítulo E, treina um autoencoder LSTM sobre janelas do 3W e usa o erro de reconstrução como escore de anomalia (Lopes, 2026). Suas escolhas de estabilidade numérica — ativação `tanh`, inicialização ortogonal e recorte de gradiente — tornam concreto por que treinar recorrentes sobre sequências longas exige cuidados que redes densas dispensam.

Resumo do capítulo

As arquiteturas empregadas neste livro formam um repertório pequeno e bem delimitado. Camadas densas fornecem os classificadores binários. Células LSTM, com seu estado de célula propagado por soma, tornam viável o processamento de janelas de centenas de amostras e sustentam os autoencoders recorrentes dos Capítulos 7, 9 e 12. Convoluções unidimensionais, com pesos compartilhados no tempo e campo receptivo controlado pela profundidade e pela subamostragem, sustentam a U-Net de segmentação do Capítulo 11, cujas conexões de atalho preservam a informação de localização temporal. Autoencoders comprimem a entrada em uma representação latente e permitem detectar anomalias por erro de reconstrução; suas variantes variacional e de agrupamento profundo não produziram ganho mensurável, o que indica que o gargalo estava no objetivo de reconstrução e não na arquitetura. O mecanismo de atenção, embora não treinado aqui, é a base dos modelos de linguagem da Parte IV.

Exercícios

1. Calcule o número de parâmetros de uma camada LSTM com n_h unidades recebendo entrada de dimensão n_x . Aplique ao codificador do Capítulo 12 (LSTM(256) seguido de LSTM(128), entrada de 4 canais) e compare com o número de parâmetros de um MLP de mesma capacidade de saída sobre a entrada achatada de 800 dimensões.
2. Mostre, a partir da Equação (5.6), que quando $\mathbf{f}_t = \mathbf{1}$ e $\mathbf{i}_t = \mathbf{0}$ para todo t em um intervalo, o gradiente de $\mathbf{c}_{t_2}$ em relação a $\mathbf{c}_{t_1}$ é a identidade. Explique por que esse é o mecanismo que resolve o gradiente evanescente.
3. Calcule o campo receptivo de uma pilha de quatro convoluções unidimensionais com núcleo 3 e dilatação 1, 2, 4, 8. Compare com quatro convoluções de núcleo 3 sem dilatação. Discuta quando convoluções dilatadas seriam preferíveis à subamostragem da U-Net.

4. Um autoencoder com $d = T \cdot S$ pode aprender a função identidade e ter erro de reconstrução nulo para qualquer entrada, inclusive anômala. Discuta três formas de impedir isso além da redução de d , e relacione cada uma a um mecanismo de regularização apresentado neste capítulo.
5. Derive a Equação (5.12) a partir do limite inferior da evidência (ELBO). Explique qual o papel do coeficiente β e o que acontece nos limites $\beta \rightarrow 0$ e $\beta \rightarrow \infty$.
6. Implemente uma U-Net unidimensional com dois níveis e treine-a para segmentar regiões anômalas em uma instância sintética. Em seguida, remova as conexões de atalho, retreine e compare o IOU. Quantifique a degradação.
7. A complexidade da atenção é $O(T^2d)$. Para $T = 86.400$ (um dia a 1 Hz) e $d = 128$, estime o número de operações de uma única camada de atenção. Discuta por que isso inviabiliza a aplicação direta de Transformers a séries temporais brutas de poço e cite duas estratégias da literatura para contornar o problema.

Leituras recomendadas

- Hochreiter and Schmidhuber (1997) — artigo original da LSTM. Denso, mas a Equação (5.6) fica muito mais clara depois de lê-lo.
- Schmidhuber (2015) — panorama histórico do aprendizado profundo, útil para situar cada arquitetura em sua motivação original.
- Ronneberger et al. (2015) — a U-Net. A figura em forma de U do artigo é uma das mais reproduzidas da área, e por bons motivos.
- Vaswani et al. (2017) — o Transformer.
- Kingma and Ba (2014) e Xu et al. (2018) — autoencoders variacionais.
- Srivastava et al. (2014) — *dropout*, com a análise que justifica sua interpretação como *ensemble* implícito.

Capítulo 6

Detecção de novidade e mundo aberto

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- distinguir formalmente classificação de mundo fechado, reconhecimento em conjunto aberto e aprendizado de mundo aberto;
- calcular o risco de espaço aberto e explicar por que classificadores discriminativos convencionais o ignoram;
- comparar quatro famílias de escore de novidade — erro de reconstrução, máquina de vetores de suporte de uma classe, distância de Mahalanobis e rejeição por ensemble binário — e discutir critérios para escolher entre elas;
- enunciar as hipóteses que K-means, MeanShift e DBSCAN fazem sobre os dados e comparar sua adequação a partir dessas hipóteses;
- avaliar a qualidade de um agrupamento sem rótulos usando os índices de silhueta, Davies-Bouldin e Calinski-Harabasz;
- interpretar projeções de PCA, t-SNE e UMAP, reconhecendo os limites de cada uma.

6.1 Três níveis de abertura

Definição 6.1 — Classificação de mundo fechado

Dado um conjunto de classes conhecidas $\mathcal{K} = \{1, \dots, K\}$, busca-se $f : \mathcal{X} \rightarrow \mathcal{K}$. Pressupõe-se que toda entrada pertence a $\mathcal{K}$.

Definição 6.2 — Reconhecimento em conjunto aberto

Busca-se $f : \mathcal{X} \rightarrow \mathcal{K} \cup \{\text{desconhecido}\}$. O sistema pode recusar-se a classificar, mas não faz nada com o que recusou (Scheirer et al., 2013).

Definição 6.3 — Aprendizado de mundo aberto

Além de recusar, o sistema *agrupa* as instâncias rejeitadas, propõe novas classes, submete-as a validação e incorpora as validadas a $\mathcal{K}$, de modo que $\mathcal{K}_{t+1} \supseteq \mathcal{K}_t$. O ciclo se repete indefinidamente.

Os três níveis correspondem, quase exatamente, aos capítulos da Parte II: o Capítulo 7 opera em mundo fechado com um mecanismo de detecção acoplado; o Capítulo 8 realiza reconhecimento em conjunto aberto; o Capítulo 9 fecha o ciclo completo de aprendizado de mundo aberto.

6.1.1 Risco de espaço aberto

Scheirer et al. (2013) formalizam por que classificadores discriminativos falham em conjunto aberto. Seja f uma função de decisão para a classe k e seja $\mathcal{S}_o$ uma região limitada do espaço de características contendo todos os exemplos de treinamento. Define-se o risco de espaço aberto (*open space risk*) como

$$R_O(f) = \frac{\int_{\mathcal{O}} f(\mathbf{x}) d\mathbf{x}}{\int_{\mathcal{S}_o} f(\mathbf{x}) d\mathbf{x}}, \quad (6.1)$$

onde $\mathcal{O} = \mathcal{S}_o \setminus \mathcal{S}_{\text{treino}}$ é o espaço aberto — a região do espaço de características arbitrariamente longe de qualquer exemplo visto.

A leitura é simples e devastadora. Um hiperplano separador, como o de uma regressão logística ou de uma SVM linear, produz $f(\mathbf{x}) = 1$ em um semiespaço *de volume infinito*. Seu risco de espaço aberto é ilimitado: existem regiões arbitrariamente distantes de qualquer dado de treinamento em que o modelo declara, com confiança máxima, pertinência à classe.

Essa conclusão se aplica a funções de decisão cuja região positiva é não limitada, como o hiperplano linear deste exemplo; não é uma propriedade automática de todo modelo discriminativo, pois arquitetura e regra de decisão podem produzir regiões limitadas.

A geometria da rejeição

A conclusão prática é que *funções de decisão que declaram pertinência devem ser limitadas*. As quatro abordagens da Seção 6.2 são, cada uma à sua maneira, formas de impor essa limitação: uma esfera no espaço latente (Mahalanobis), um envelope em torno dos dados (OCSVM), um limiar sobre o erro de reconstrução, ou a conjunção de K decisões binárias independentes.

6.2 Quatro escores de novidade**6.2.1 Erro de reconstrução**

Já apresentado no Capítulo 5: treina-se um autoencoder sobre dados normais e usa-se $a(\mathbf{X}) = \mathcal{D}(\mathbf{X}, h_\psi(g_\phi(\mathbf{X})))$ como escore.

Vantagem. Não requer rótulos de anomalia — é a única das quatro que funciona quando não há um único exemplo de anomalia disponível.

Desvantagem. Depende criticamente da capacidade do modelo. Um autoencoder muito expressivo generaliza demais e reconstrói bem entradas anômalas; um autoencoder pouco expressivo reconstrói mal tudo. Não há critério simples para acertar o ponto.




Figura 6.1: Densidade interpolada do erro de reconstrução para dados normais e para janelas de falha de ICV, com o limiar probabilístico assinalado. A área sob cada curva soma um.

A Figura 6.1 mostra o formato típico do problema. As duas distribuições se sobrepõem, e o limiar é uma linha vertical que escolhe onde pagar o custo: mais à esquerda, capturam-se quase todas as anomalias ao preço de falsos alarmes; mais à direita, o oposto.

Essa figura também explica por que a escolha do limiar costuma importar mais que a escolha da arquitetura. Deslocar a linha percorre toda a curva ROC; trocar o autoencoder move as duas distribuições apenas alguns por cento uma em relação à outra.

6.2.2 Máquina de vetores de suporte de uma classe

A OCSVM (Smola and Scholkopf, 2004) busca a hipersfera de raio mínimo (ou o hiperplano de margem máxima em relação à origem, no espaço de características induzido pelo núcleo) que contenha uma fração $1 - \nu$ dos dados de treinamento:

$$\min_{\mathbf{w}, \rho, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 + \frac{1}{\nu n} \sum_i \xi_i - \rho \quad \text{s.a.} \quad \langle \mathbf{w}, \varphi(\mathbf{x}_i) \rangle \geq \rho - \xi_i, \quad \xi_i \geq 0. \quad (6.2)$$

Vantagem. Fronteira de decisão limitada por construção; risco de espaço aberto controlado.

Desvantagem. Escala mal com o número de amostras e é sensível à escolha do núcleo e de ν . No Capítulo 10, uma OCSVM aplicada diretamente aos dados brutos atinge apenas 0,65 de acurácia global, contra 0,87 do ensemble binário. A comparação descreve o protocolo daquele capítulo, com representações e objetivos distintos; não estabelece uma ordenação universal entre OCSVM e ensembles. A OCSVM reaparece, contudo, no Capítulo 9 como *componente* de um voto ponderado — e ali contribui, porque erra de forma diferente do ensemble.

A Figura 6.2 torna visível o que a Equação (6.2) formaliza: a fronteira envolve o suporte dos dados conhecidos em vez de separar duas classes. É a diferença entre *onde os dados estão* e *o que os separa* — e é exatamente essa diferença que limita o risco de espaço aberto da Equação (6.1).




Figura 6.2: Fronteira de decisão de uma OCSVM treinada sobre o espaço latente, projetada por t-SNE. O gradiente representa o valor da função de decisão: regiões escuras são classificadas com confiança como conhecidas; regiões claras, como não-classe. Os pontos sobrepostos distinguem dados de validação, dados de ICV e amostras de não-classe.

6.2.3 Distância de Mahalanobis

Definição 6.4 — Distância de Mahalanobis

Para uma distribuição com média μ e covariância Σ ,

$$d_M(x) = \sqrt{(x - \mu)^\top \Sigma^{-1} (x - \mu)}. \quad (6.3)$$

A distância de Mahalanobis é a distância euclidiana medida no sistema de coordenadas em que a distribuição é esférica: ela normaliza pela variância em cada direção e descorrelaciona os eixos. Um ponto a duas unidades de distância ao longo de uma direção de alta variância é menos surpreendente que um ponto a duas unidades ao longo de uma direção de baixa variância, e a Equação (6.3) captura exatamente isso.

Em alta dimensão, Σ é frequentemente mal condicionada ou singular. A contramedida padrão, adotada no Capítulo 12, é a regularização

$$\Sigma_{\text{reg}} = \Sigma + \lambda I. \quad (6.4)$$

Vantagem. Fechada, barata, com uma única hipótese explícita (aproximação gaussiana por classe) e um limiar natural via quantil da distribuição χ^2 — ou, empiricamente, o percentil 95 dos dados de treinamento.

Desvantagem. A hipótese gaussiana. Aplicada ao espaço bruto, ela é grosseiramente violada, e o desempenho reflete isso. Aplicada a um espaço latente discriminativo, torna-se aceitável — e o desempenho salta. Esse é, em uma frase, o achado central do Capítulo 12.

Exemplo 6.1 — A diferença que o espaço faz

O Capítulo 12 reporta, para a classe 8 (hidrato na linha de produção), uma razão de separação — distância média das instâncias desconhecidas dividida pela distância média das conhecidas — de menos de 1,0 no espaço bruto e de 186,5 no espaço latente do classificador multiclasse.

Não é um ganho incremental. No espaço bruto, as instâncias desconhecidas estão *mais próximas* do centro da distribuição que as conhecidas: o escore é anti-informativo. No espaço latente, a separação é tão grande que qualquer limiar razoável funciona.

6.2.4 Rejeição por ensemble binário

A quarta abordagem é a que dá nome ao Capítulo 8. Em vez de um classificador multiclasse, treinam-se K classificadores binários independentes, um por classe, cada um respondendo “esta janela é da classe k ?”. A decisão final é

$$\hat{y} = \begin{cases} \arg \max_k s_k(\mathbf{X}), & \text{se } \max_k s_k(\mathbf{X}) > \tau, \\ \text{desconhecido}, & \text{caso contrário.} \end{cases} \quad (6.5)$$

A diferença em relação a aplicar um limiar sobre a *softmax* de um classificador multiclasse é estrutural, não cosmética. Os escores s_k são produzidos por modelos independentes, cada um com sua própria sigmoide, e *não somam um*. Nada impede que todos sejam simultaneamente baixos — e “todos baixos” é precisamente a assinatura de uma classe desconhecida.

O preço da independência

Nove modelos custam nove vezes mais em memória e tempo. O Capítulo 10 quantifica: um classificador ocupa cerca de 2,3 MB e leva 45 ms por inferência; o ensemble de nove ocupa 21 MB e leva 405 ms. Para um evento cuja escala característica é de horas, esse custo é irrelevante — e é essa observação, e não uma otimização de arquitetura, que justifica a escolha.

6.2.5 Comparação

Escore	Rótulos de anomalia	de	Hipótese principal	princi-	Onde aparece
Reconstrução	Não requer		Anomalia	recons-	Capítulo 7, Capítulo 9
OCSVM	Não requer		trói mal		
			Normalidade é com-		Capítulo 9, Capítulo 10
			pacta		
Mahalanobis	Requer (por classe)	(por	Gaussiana	por	Capítulo 12
			classe		
Ensemble binário	Requer		Classes são sepa-	ráveis individual-	Capítulo 8, Capítulo 10
			mente		

6.3 Agrupamento

Rejeitar é metade do problema. A outra metade — organizar o que foi rejeitado em grupos coerentes que possam se tornar classes — é agrupamento.

6.3.1 K-means

Minimiza a inércia

$$J = \sum_{i=1}^n \|z_i - c_{\pi(i)}\|^2, \quad (6.6)$$

alternando atribuição de pontos a centroides e recálculo de centroides (Lloyd, 1982). Rápido e simples, com duas limitações severas: exige K conhecido a priori e pressupõe agrupamentos aproximadamente esféricos e de tamanhos comparáveis.

Como o Capítulo 9 resolve o problema do K

Em mundo aberto, K é exatamente a quantidade que não se conhece — é o número de classes novas. A solução adotada é original: treina-se uma floresta aleatória para *prever* K a partir de oito características do próprio conjunto a ser agrupado (número de pontos, índice de silhueta, Davies-Bouldin, Calinski-Harabasz, inércia, e três descritores geométricos). Lopes et al. (2025) reportam 98,3 % de acurácia e erro médio absoluto de 1,12 para essa etapa. O Capítulo 9 reproduz os demais indicadores publicados e discute por que esses dois valores não devem ser interpretados conjuntamente sem confirmar seus denominadores e definições.

6.3.2 MeanShift

Desloca iterativamente cada ponto na direção do gradiente estimado da densidade, convergindo para modos locais (Comaniciu and Meer, 2002). Não exige K — ele emerge do número de modos — mas exige a largura de banda do núcleo, que controla implicitamente a mesma coisa. É computacionalmente mais caro que o K-means.

6.3.3 DBSCAN

Define agrupamentos como regiões de densidade suficiente, conectando pontos que têm ao menos `minPts` vizinhos em raio ε (Deng, 2020). Duas propriedades o distinguem: encontra agrupamentos de forma arbitrária, e classifica explicitamente pontos de baixa densidade como *ruído*.

A segunda propriedade é atraente em mundo aberto — rejeitar é desejável — mas tem um custo: em espaços de alta dimensão, a noção de densidade se degrada e o DBSCAN tende a classificar quase tudo como ruído. É o motivo pelo qual o Capítulo 9 o usa apenas como comparação, e não como componente do pipeline.

6.3.4 Combinação e refinamento

O Capítulo 9 não escolhe um algoritmo: executa K-means e MeanShift e *intersecta* os resultados, mantendo apenas os pontos em que ambos concordam. Aplica em seguida um refinamento por limiar adaptativo, no qual pontos distantes do centroide são removidos com um multiplicador k que depende da razão $R = \mu/\sigma$ das distâncias intra-agrupamento:

$$k = \begin{cases} 2, & R \geq 4, \\ 1 + \frac{R-2}{2}, & 2 \leq R < 4, \\ 0, & R < 2. \end{cases} \quad (6.7)$$

A intuição: quando as distâncias são concentradas (R alto), o agrupamento é coeso e pode-se ser tolerante; quando são dispersas (R baixo), o agrupamento é duvidoso e convém

ser agressivo na remoção. Uma salvaguarda impede que mais de um terço dos pontos seja descartado.

6.4 Avaliar agrupamentos sem rótulos

Três índices internos são usados neste livro.

Definição 6.5 — Índice de silhueta

Para cada ponto i , sejam $a(i)$ a distância média aos pontos do próprio agrupamento e $b(i)$ a menor distância média aos pontos de outro agrupamento. Então

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1], \quad (6.8)$$

e o índice global é a média sobre todos os pontos (Rousseeuw, 1987). Valores próximos de 1 indicam agrupamentos bem separados; próximos de 0, sobreposição; negativos, atribuição incorreta.

Definição 6.6 — Índice de Davies-Bouldin

$$DB = \frac{1}{K} \sum_{i=1}^K \max_{j \neq i} \frac{\sigma_i + \sigma_j}{d(\mathbf{c}_i, \mathbf{c}_j)}, \quad (6.9)$$

onde σ_i é a dispersão média do agrupamento i . *Menor é melhor.*

Definição 6.7 — Índice de Calinski-Harabasz

Razão entre dispersão entre agrupamentos e dispersão intra-agrupamento, normalizada pelos graus de liberdade (Caliński and Harabasz, 1974). *Maior é melhor.*

Exemplo 6.2 — Os três índices concordando

O Capítulo 12 compara o espaço latente de um autoencoder com o de um classificador multiclasse:

Índice	Latente do AE	Latente multiclasse
Silhueta (maior é melhor)	-0,0149	0,2299
Calinski-Harabasz (maior é melhor)	687,8008	2818,2310
Davies-Bouldin (menor é melhor)	4,5592	1,7460

Os três índices, que medem coisas diferentes e podem discordar, apontam na mesma direção. Quando isso acontece, a conclusão é robusta.

Índices internos não substituem rótulos

Todo índice interno mede coerência geométrica, não correção semântica. Um agrupamento com silhueta 0,9 pode separar perfeitamente dois poços em vez de duas anomalias. É por isso que o pipeline do Capítulo 9 termina com validação por especialista, e por isso que o Capítulo 14 propõe usar um modelo de linguagem para *nomear* os agrupamentos

— transformando geometria em hipótese interpretável.

6.5 Visualização

Três técnicas de redução de dimensionalidade são usadas para inspeção.

PCA.

Projeção linear nas direções de maior variância. Preserva distâncias globais e é determinística e interpretável. Falha quando a estrutura é não linear.

t-SNE.

Preserva vizinhanças locais minimizando a divergência entre distribuições de similaridade no espaço original e no reduzido (van der Maaten and Hinton, 2008). Excelente para revelar agrupamentos; *as distâncias entre agrupamentos no gráfico não têm significado*, e o resultado depende da perplexidade e da semente aleatória.

UMAP.

Baseia-se em geometria riemanniana e topologia algébrica; preserva melhor a estrutura global que o t-SNE e é mais rápido. Compartilha, contudo, a mesma limitação: é uma ferramenta de inspeção, não de medida.

Regra de uso

Nenhuma conclusão quantitativa deste livro se apoia em uma projeção bidimensional. As projeções aparecem para *ilustrar* uma conclusão já estabelecida por índices numéricos. A inversão dessa ordem — olhar a projeção, ver agrupamentos, concluir que existem — é um dos erros mais comuns na aplicação de aprendizado não supervisionado.

6.6 O ciclo completo

Reunindo as peças, o aprendizado de mundo aberto pode ser enunciado como um ciclo de seis estágios, que é exatamente a estrutura do Capítulo 9:

1. **Representar.** Mapear a janela bruta em um espaço latente ($\mathbf{z} = g_\phi(\mathbf{X})$).
2. **Classificar.** Aplicar os classificadores da base de conhecimento atual.
3. **Rejeitar.** Marcar como desconhecido aquilo que nenhum classificador reivindica com confiança suficiente.
4. **Agrupar.** Organizar o material rejeitado em grupos coerentes, estimando o número de grupos.
5. **Validar.** Submeter os grupos a um especialista — humano ou, como propõe a Parte IV, um agente de linguagem que produza uma hipótese nomeada e justificada.
6. **Incorporar.** Treinar um novo classificador binário para cada grupo validado e adicioná-lo ao ensemble, sem retrainar os existentes.

O sexto estágio merece destaque. Como os classificadores são binários e independentes, acrescentar uma classe custa *um* treinamento, e não o retreinamento de todo o sistema. Essa




Figura 6.3: O ciclo de aprendizado de mundo aberto aplicado à operação de poços. O fluxo é fechado: o conhecimento validado ao fim de uma volta passa a integrar a base de classificadores usada na volta seguinte.

propriedade — consequência direta da escolha arquitetural do Capítulo 8 — é o que torna o ciclo operacionalmente viável.

A Figura 6.3 representa o mesmo processo em forma de diagrama, e a representação circular não é ornamental: ela afirma que não existe um estado final. Cada volta amplia o conjunto de classes conhecidas, e o mundo aberto de hoje é o mundo fechado de amanhã — até que a próxima anomalia inédita apareça.

Prática

Os cadernos `2_visualization_techniques` e `5_clustering_methods`, descritos no Capítulo E, cobrem os dois estágios centrais deste ciclo (Lopes, 2026). O primeiro mostra, com quatro configurações de t-SNE e quatro de UMAP sobre os mesmos dados, por que a projeção é uma escolha e não uma medida. O segundo aplica K -médias, DBSCAN e MeanShift com silhueta e índice de Rand ajustado, e reproduz em escala reduzida a dificuldade que estrutura o Capítulo 9.

Resumo do capítulo

A hipótese de mundo fechado é uma escolha, não uma necessidade. O reconhecimento em conjunto aberto permite recusar-se a classificar; o aprendizado de mundo aberto vai além e transforma o recusado em novo conhecimento. O risco de espaço aberto explica formalmente por que fronteiras de decisão ilimitadas — hiperplanos, *softmax* — falham nesse cenário: elas declaram pertinência com confiança máxima em regiões arbitrariamente distantes de qualquer dado visto. Quatro famílias de escore de novidade impõem limitação de formas distintas: erro de reconstrução, OCSVM, distância de Mahalanobis e rejeição por ensemble de classificadores binários. O material rejeitado é organizado por agrupamento — K-means, MeanShift, DBSCAN — cuja qualidade se avalia por índices internos de silhueta, Davies-Bouldin e Calinski-Harabasz. Índices internos e projeções bidimensionais medem coerência

geométrica, jamais correção semântica; a validação exige um especialista, e é essa lacuna que a Parte IV se propõe a preencher.

Exercícios

1. Considere um classificador linear binário em $\mathbb{R}^2$ com fronteira $w_1x_1 + w_2x_2 + b = 0$. Mostre que a região classificada como positiva tem área infinita e conclua que seu risco de espaço aberto, conforme a Equação (6.1), é ilimitado. Em seguida, mostre que uma esfera de raio finito tem risco limitado.
2. Demonstre que, quando $\Sigma = \sigma^2 I$, a distância de Mahalanobis reduz-se à distância euclidiana dividida por σ . Interprete geometricamente o papel de Σ^{-1} no caso geral.
3. Explique por que os escores de K classificadores binários independentes não somam um, e por que isso é exatamente a propriedade necessária para expressar “nenhuma das anteriores”. Em seguida, discuta o que acontece quando dois classificadores reivindicam a mesma janela com escores altos.
4. Implemente o limiar adaptativo da Equação (6.7) e aplique-o a agrupamentos sintéticos com diferentes razões $R = \mu/\sigma$. Verifique empiricamente se a salvaguarda de um terço é acionada e em que condições.
5. Gere dois conjuntos bidimensionais: um com dois agrupamentos gaussianos bem separados, outro com dois anéis concêntricos. Aplique K-means, MeanShift e DBSCAN a ambos e calcule os três índices internos. Discuta em quais casos os índices concordam com a estrutura verdadeira e em quais não.
6. O estimador de K do Capítulo 9 usa oito características, entre elas os próprios índices de silhueta, Davies-Bouldin e Calinski-Harabasz. Explique por que isso não é circular. Proponha duas características adicionais que poderiam melhorar o estimador.
7. Discuta a seguinte objeção ao ciclo de seis estágios: “se o especialista precisa validar cada grupo, o sistema não é autônomo e o ganho é ilusório”. Formule uma resposta quantitativa em termos do número de decisões que o especialista precisaria tomar com e sem o sistema.

Leituras recomendadas

- Scheirer et al. (2013) — a formalização do conjunto aberto e do risco de espaço aberto.
- Pimentel et al. (2014) — revisão abrangente de detecção de novidade, organizada por família de método.
- Smola and Scholkopf (2004) — fundamentação da OCSVM.
- Rousseeuw (1987), Caliński and Harabasz (1974) — índices de validação de agrupamento.
- Deng (2020) e Comaniciu and Meer (2002) — os algoritmos originais.
- van der Maaten and Hinton (2008) — t-SNE, com discussão honesta de suas limitações.

Parte II

A base: da regra ao mundo aberto

Capítulo 7

O sistema dual: regra e reconstrução

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- descrever a arquitetura de um sistema dual que combina um diagrama de decisão determinístico com um autoencoder recorrente;
- justificar por que a combinação supera cada componente isolado, em termos de cobertura e de taxa de falsos positivos;
- descrever as decisões de projeto de um autoencoder LSTM para detecção de anomalias e a definição de seu limiar pela regra $\mu + 3\sigma$;
- explicar como o sistema se autotrena em campo, sem rotulação humana, e quais salvaguardas isso exige;
- interpretar os resultados de três estudos de caso reais e compará-los com a literatura sobre fechamento espúrio de DHSV.

7.1 O problema que este capítulo resolve

Começemos pelo requisito, não pelo método.

Uma operadora deseja monitorar duzentos e cinquenta poços submarinos em tempo real. Cada poço tem um comportamento distinto: níveis de pressão diferentes, curvas de declínio diferentes, esquemas de elevação artificial diferentes. Não há rotulação humana disponível de forma contínua. Não há garantia de que os eventos que ocorrerão estejam catalogados. E o sistema precisa funcionar a partir do momento em que é ligado.

Essas quatro restrições eliminam, de saída, a solução acadêmica padrão — treinar um classificador supervisionado sobre um conjunto rotulado e implantá-lo. O que se propõe neste capítulo, e que efetivamente opera em campo, é uma arquitetura de dois componentes com naturezas complementares.

Um diagrama de decisão determinístico.

Codifica conhecimento de engenharia em regras explícitas. Não requer treinamento, funciona no primeiro segundo, é auditável e seu comportamento é previsível. Em contrapartida, só reconhece o que foi explicitamente programado.

Um autoencoder recorrente.

Aprende o comportamento normal *daquele poço específico* a partir dos próprios dados, sem

rótulos, e sinaliza qualquer desvio. Detecta o inesperado, mas não sabe nomeá-lo e precisa de tempo para aprender.

A tese deste capítulo

Os dois componentes não competem: eles se alimentam. O diagrama de decisão determina *quais dados são normais* e, com isso, fornece ao autoencoder o conjunto de treinamento que ele não teria de outra forma. O autoencoder, por sua vez, cobre o espaço de eventos que o diagrama não enumera. É uma relação de mão dupla, e é essa relação que produz o ganho de desempenho reportado na Seção 7.6.

7.2 Arquitetura geral




Figura 7.1: Fluxo geral do sistema dual. Os dados do poço alimentam simultaneamente o diagrama de decisão e o módulo de detecção de anomalias por inteligência artificial. O diagrama de decisão encaminha ao módulo de aprendizado apenas os trechos que classifica como normais. Qualquer um dos dois componentes pode disparar o alerta ao operador. Adaptado de Aranha et al. (2024a).

A Figura 7.1 mostra a estrutura. Note a seta rotulada como entrada de dados normais: é ela que materializa a relação descrita acima. O autoencoder nunca vê dados que o diagrama de decisão considera anômalos, e portanto o modelo de normalidade que ele constrói não é contaminado por eventos.

7.3 O diagrama de decisão

O diagrama de decisão é uma árvore de regras organizada em quatro camadas sucessivas. Cada camada responde a uma pergunta e restringe o espaço de hipóteses da seguinte.

A Figura 7.2 mostra o fluxo. Vale insistir num ponto que a semelhança visual esconde: apesar do nome e do formato, isto *não* é uma árvore de decisão aprendida. Nenhum de seus nós foi ajustado por otimização; cada bifurcação foi escrita por engenheiros de produção e pode ser lida, auditada e alterada linha a linha. É conhecimento declarado, não induzido — e é essa diferença que sustenta a arquitetura dual descrita neste capítulo.




Figura 7.2: Estrutura do diagrama de decisão. O fluxo bifurca conforme o dado seja o primeiro do poço, siga uma mudança de estado de válvula ou dê continuidade a um regime já estabelecido, encaminhando cada caso para estabilização, análise de anomalia ou atualização da média móvel. Adaptado de Aranha et al. (2024a).

1. **Identificação do poço.** Qual poço é este, qual seu esquema de completação, quais sensores estão disponíveis e quais são os limites operacionais declarados? Essa camada não classifica nada — ela carrega o contexto sem o qual as camadas seguintes não podem operar. É também onde entram informações que nenhum modelo aprende dos dados: profundidade, número de zonas produtoras, presença de gás de elevação.
2. **Tipo de dado.** O sinal recebido é válido? Esta camada implementa as verificações discutidas no Capítulo 2: valor ausente, sensor congelado, leitura fora da faixa física do instrumento, salto incompatível com a dinâmica do processo. Um dado reprovado aqui não prossegue, e não contamina nem o alerta nem o treinamento.
3. **Transiente ou estabilizado?** O poço está em regime permanente ou em transição? A distinção é essencial: durante uma partida, uma parada programada ou uma manobra de válvula, os sinais apresentam variações de grande amplitude que são perfeitamente normais. Sinalizá-las como anomalia é a receita para a fadiga de alarme descrita no Capítulo 1.
4. **Análise de anomalia.** Somente aqui, com poço identificado, dado válido e regime estabilizado, aplicam-se as regras de diagnóstico propriamente ditas — divergência entre pressões, queda de temperatura, oscilação sustentada.

Por que quatro camadas e não uma lista de regras

A organização em camadas não é estética. Cada camada elimina uma fonte de falso positivo antes que a próxima seja avaliada, e o resultado é que a última camada — a única que gera alarme — opera sobre um subconjunto de dados já saneado. Uma lista plana de regras avaliadas em paralelo produziria alarmes durante partidas, durante falhas de sensor e durante manobras programadas.

7.3.1 O tratamento de manobras de válvula

Uma consequência prática merece destaque, porque é onde a maior parte dos sistemas falha. Quando o operador altera deliberadamente o estado de uma válvula, o poço muda de ponto de operação. Todos os sinais se deslocam. Um detector de anomalia baseado em desvio da normalidade aprendida sinalizará — corretamente, do ponto de vista estatístico, e inutilmente, do ponto de vista operacional.

A solução adotada é radical e correta: *ao detectar mudança de válvula, o sistema descarta o modelo aprendido e reinicia o ciclo de treinamento*. O poço, depois da manobra, é tratado como um poço novo. O custo é o período de reaprendizado; o benefício é a ausência de alarmes espúrios sistemáticos.

7.4 O detector por autoencoder

7.4.1 Lógica de operação

A Figura 7.3 detalha a máquina de estados. Três aspectos merecem comentário.

- **O sistema informa que não sabe.** Antes de acumular dados suficientes, ele responde explicitamente “rede não treinada”. Não há resposta silenciosamente errada. É uma forma primitiva — mas efetiva — da rejeição que o Capítulo 8 formalizará.
- **Dados anômalos são excluídos do treinamento futuro.** Sem essa salvaguarda, o modelo aprenderia gradualmente a considerar a anomalia normal, e o alarme se extinguiria sozinho. É a versão local do problema de deriva discutido no Capítulo 17.




Figura 7.3: Lógica operacional do módulo de detecção por inteligência artificial. Note os três estados possíveis: antes do treinamento, o sistema apenas acumula dados normais selecionados pelo diagrama de decisão; após o treinamento, ele prediz, compara com a tolerância e informa o estado do poço; uma mudança de válvula reinicia o ciclo. Dados julgados anômalos nunca retornam ao conjunto de treinamento. Adaptado de Aranha et al. (2024a).

- **O treinamento é contínuo.** Dados normais posteriores ao treinamento inicial continuam sendo acumulados e usados em retreinamentos, o que permite ao modelo acompanhar a evolução lenta e legítima do poço.

7.4.2 Arquitetura da rede

O autoencoder é do tipo *sequence-to-sequence* com camadas LSTM. A entrada é um tensor de forma (lote, 500, 5): quinhentos passos de tempo de cinco sensores.

Camada	Forma de saída	Função
Entrada	(500, 5)	janela de 500 s
LSTM(16), ReLU	(500, 16)	codificação
LSTM(4), ReLU	(4)	representação latente
<i>RepeatVector</i> (500)	(500, 4)	replicação temporal
LSTM(16), ReLU	(500, 16)	decodificação
<i>TimeDistributed</i> Densa(5)	(500, 5)	reconstrução

A compressão é de $500 \times 5 = 2.500$ valores para 4: um fator de 625. Essa severidade é deliberada, e responde diretamente à advertência do Capítulo 5 sobre autoencoders excessivamente expressivos. Com quatro dimensões latentes, a rede não tem como memorizar; ela é obrigada a capturar apenas a estrutura dominante da normalidade.

7.4.3 Treinamento

Hiperparâmetro	Valor
Função de perda	SMAPE (Equação (4.7))
Otimizador	Adam
Épocas	500
Tamanho do lote	100
Ativação	ReLU
Normalização	Min-Max para $[0, 1]$
Ruído injetado	0 a 0,5 %
Dados mínimos	≈ 500 amostras normais (≈ 5.000 s)

Duas escolhas merecem justificativa.

A **perda SMAPE** em vez do erro quadrático médio decorre da heterogeneidade de escalas discutida no Capítulo 4: pressões da ordem de centenas de bar e temperaturas da ordem de dezenas de graus. Um erro quadrático médio sobre variáveis normalizadas ainda pondera implicitamente pela variância de cada canal; o SMAPE, sendo relativo, trata todos os canais de forma comparável.

O **ruído injetado** de até 0,5 % cumpre dois papéis. Regulariza, impedindo que a rede se apoie em detalhes de alta frequência específicos daquele poço; e simula a variabilidade de instrumentação, tornando o modelo mais robusto quando transferido entre poços com sensores de calibração ligeiramente diferente.

7.4.4 Limiar e classificação de risco

O escore de anomalia é o SMAPE de reconstrução. Sobre o conjunto de dados normais acumulados, calculam-se μ e σ desse escore, e define-se

$$\tau = \mu + 3\sigma. \quad (7.1)$$

Sob normalidade aproximada, a probabilidade unilateral de o escore ultrapassar τ é de aproximadamente 0,135 %. O valor de cerca de 0,27 %, frequentemente associado à regra dos

três desvios, soma as duas caudas e não se aplica a este limiar unilateral. Como a distribuição do erro de reconstrução não é gaussiana, porém, esses valores são apenas referências teóricas: a taxa de falso positivo relevante deve ser medida empiricamente no conjunto de validação. O valor do escore é então convertido em três níveis de risco:




Figura 7.4: Exemplo de detecção em dados reais. Nos dois painéis superiores, as pressões e as temperaturas medidas por PDG e TPT; no inferior, o escore de anomalia com a linha de tolerância da Equação (7.1). A ultrapassagem do limiar precede em várias horas o desvio que seria visível a olho nu nos sinais brutos. Adaptado de Aranha et al. (2024a).

Faixa	Nível	Ação recomendada
< 30 %	Baixo	Registro; sem notificação.
30 % a 70 %	Médio	Notificação ao operador; acompanhamento.
> 70 %	Alto	Alerta; investigação imediata.

Os cortes de 30 % e 70 % são regras operacionais de triagem adotadas no sistema, não probabilidades calibradas de ocorrência. Sua transferência para outro poço requer calibração com a matriz de custo e a taxa de alarmes observada localmente.

Por que graduar o alarme

Um alarme binário força uma escolha entre perder eventos e cansar o operador. A graduação em três níveis desloca essa escolha para o operador, que dispõe de contexto que o sistema não tem. É uma decisão de projeto de interface, não de aprendizado de máquina, e é frequentemente o que separa um sistema usado de um sistema desligado.

7.5 Implantação

O sistema foi implementado com Node-RED (Node-RED, 2019) para orquestração de fluxo e aquisição, e Python 3.7 com Keras (Chollet, 2015) para o modelo. A escolha do Node-RED merece nota: trata-se de uma ferramenta de programação visual por fluxo, amplamente usada em automação industrial, que permite a engenheiros de operação inspecionar e modificar o encadeamento sem tocar no código do modelo. À época da avaliação, Aranha et al. (2024a) reportam que o sistema estava implantado em **mais de vinte unidades flutuantes de produção e mais de duzentos e cinquenta poços submarinos** nas bacias de Santos e de Campos. Esta edição não auditou independentemente a escala dessa implantação.




Figura 7.5: Interface do sistema em operação. À esquerda, os valores instantâneos dos cinco sensores monitorados; ao centro, os registros de pressão e temperatura; à direita, os erros relativos de reconstrução por sensor e o erro agregado. O painel inferior direito mostra o escore de anomalia cruzando o limiar, indicado pela linha horizontal. Adaptado de Aranha et al. (2024a).

O que “implantado” significa

Vale a pena explicitar, porque a palavra é usada com generosidade na literatura. Aqui significa: executando continuamente em ambiente de produção da operadora, sobre dados de tempo real, com saída visível a operadores em turno, e sujeito às consequências operacionais de seus alertas. Não é um protótipo avaliado *offline*.

7.6 Resultados

7.6.1 Contribuição de cada componente

A Tabela 7.1 isola o efeito de acrescentar o autoencoder ao diagrama de decisão.

Tabela 7.1: Desempenho do diagrama de decisão isolado e do sistema dual completo.

Configuração	ACC	ACC _b	F ₁
Diagrama de decisão	0,9727	0,9615	0,9758
Diagrama de decisão + autoencoder	0,9894	0,9771	0,9917

Resultado-chave

O acréscimo do autoencoder reduz o erro de 2,73 % para 1,06 % — uma redução relativa de aproximadamente 61 %. A acurácia balanceada sobe de 0,9615 para 0,9771, e a medida F_1 de 0,9758 para 0,9917.

A leitura correta desse ganho exige cuidado. Em valor absoluto, 1,67 ponto percentual parece pouco. A redução relativa de 61 % descreve as taxas agregadas; sem contagens pareadas

e protocolo operacional, não permite afirmar que três de cada cinco erros individuais deixaram de ocorrer.

7.6.2 Comparação com a literatura

O fechamento espúrio de DHSV (classe 2) é o evento mais estudado na literatura do 3W, o que permite comparação direta.

Tabela 7.2: Detecção de fechamento espúrio da DHSV: comparação com trabalhos anteriores.

Trabalho	Método	ACC	F_1
Marins et al. (2021a)	Floresta aleatória	0,8708	—
Turan and Jaschke (2021)	Árvore de decisão	0,6000	0,4900
Machado et al. (2022)	LSTM	0,9922	0,9360
Este capítulo	Diagrama + autoencoder	0,9894	0,9917

Como ler esta tabela

O sistema dual tem acurácia ligeiramente inferior à de Machado et al. (2022) (0,9894 contra 0,9922) e medida F_1 substancialmente superior (0,9917 contra 0,9360).

A combinação é diagnóstica. Uma medida F_1 de 0,9360 com acurácia de 0,9922 indica desequilíbrio entre precisão e revocação — tipicamente, muitos falsos positivos ou muitos falsos negativos concentrados na classe minoritária, mascarados pela acurácia global (Capítulo 4). O sistema dual apresenta as duas métricas alinhadas, o que indica desempenho equilibrado.

Uma ressalva de honestidade: os conjuntos de avaliação não são idênticos entre os trabalhos, e a comparação é indicativa, não conclusiva.

7.6.3 Estudos de caso em poços reais

Os três casos a seguir são eventos reais, com data e hora, detectados pelo sistema em operação. Eles importam porque são a única evidência disponível sobre generalização a condições que nenhum conjunto de dados público contém.

Tabela 7.3: Estudos de caso: características dos poços. WD é a lâmina d'água e TD a profundidade total.

Poço	Tipo	WD (m)	TD (m)	Zonas
1	Produtor, pré-sal de Santos	2.041	5.870	3 (5.432 a 5.774 m)
2	Produtor	2.125	5.552	2 (5.137 a 5.440 m)
3	Injetor WAG	1.946	6.197	3 (5.437 a 5.730 m)

A Figuras 7.6 e 7.7 apresentam os dois eventos do poço 1, e a comparação entre elas contém a lição mais útil do capítulo sobre a divisão de trabalho entre as duas camadas.

No primeiro evento, às 01:16, **apenas o diagrama analítico detectou**. A rede não teve chance: o fechamento espúrio da DHSV alterou o estado das válvulas, e o sistema entrou em modo de análise — justamente o comportamento projetado para evitar alarmes durante manobras. O operador corrigiu com ciclagem de válvulas entre 01:39 e 01:52.

No segundo evento, às 08:48, **ambos detectaram**, e o diagrama classificou corretamente a causa como fechamento espúrio da DHSV ou da M1.

Tabela 7.4: Estudos de caso: eventos detectados e desempenho. O SMAPE indicado é o valor de pico do erro de reconstrução durante o evento.

Poço	Evento	Data e hora	SMAPE	ACC_b	F_1
1	Fechamento espúrio (1º)	01/08/2022 01:16	39,148 %	0,9897	0,9987
1	Fechamento espúrio (2º)	01/08/2022 08:48	48,312 %	0,9988	0,9989
2	Comunicação de pressão na CKGL	06/06/2018 14:37	33,136 %	0,9998	0,9998
3	Fechamento espúrio DHSV/M1	18/10/2022 02:10	23,390 %	0,9988	0,9991




Figura 7.6: Poço 1, primeiro evento. De cima para baixo: os sensores PDG, PT e TPT, o estado das válvulas e a comparação entre a classificação dos dois modelos (*LSTM status* e *analytical status*) e a classificação humana posterior (*class*). Adaptado de Aranha et al. (2024a).




Figura 7.7: Poço 1, segundo evento, no mesmo dia. Adaptado de Aranha et al. (2024a).

Por que isto justifica a arquitetura dual

O primeiro evento é o argumento inteiro deste capítulo em uma linha: houve uma anomalia real que a rede neural, por construção, não podia enxergar. A regra explícita enxergou.

Um sistema apenas aprendido teria perdido esse evento. Um sistema apenas analítico teria perdido a classificação mais fina que a rede oferece em outros casos. A redundância não é conservadorismo — é a única configuração em que a janela cega de um componente é coberta pelo outro.




Figura 7.8: Poço 2, retroanálise do evento de 6 de junho de 2018. Adaptado de Aranha et al. (2024a).

Exemplo 7.1 — O poço 3, minuto a minuto

O caso do poço 3, mostrado na Figura 7.9, é o mais instrutivo, porque tem começo, meio e fim documentados.

Trata-se de um injetor de água e gás alternados (WAG) em lâmina d'água de 1.946 m. Às **02:10** de 18 de outubro de 2022, DHSV e M1 fecharam sem comando. O sistema sinalizou o desvio com SMAPE de pico de 23,390 %. As válvulas foram reabertas às **07:14**, e o poço retornou à condição normal às **08:29**.

Dois pontos merecem atenção. Primeiro, o SMAPE de pico deste caso é o menor dos quatro — cerca de metade do observado no segundo evento do poço 1 — e ainda assim suficiente para ultrapassar o limiar com folga. Isso indica que $\tau = \mu + 3\sigma$ está calibrado de forma conservadora o bastante para eventos de assinatura mais discreta.

Segundo, o sistema acompanhou corretamente o *retorno* à normalidade, com uma hora e quinze minutos de defasagem em relação à reabertura das válvulas — o tempo físico de reestabilização do poço, não um atraso do algoritmo.

Exemplo 7.2 — O poço 2 e o valor de detectar o não catalogado

O evento do poço 2 foi uma comunicação indevida de pressão através da válvula reguladora de gás de elevação. *Esse evento não pertence a nenhuma das nove classes do 3W*, não estava programado no diagrama de decisão e não teria sido detectado por nenhum classificador supervisionado treinado no catálogo padrão.

Foi detectado pelo autoencoder, com $ACC_b = 0,9998$, simplesmente porque não se parecia com a normalidade daquele poço. A Figura 7.8 mostra a retroanálise: o desvio




Figura 7.9: Poço 3, evento de 18 de outubro de 2022, com o ciclo completo: detecção, fechamento pelo operador, ciclagem, reabertura e retorno à normalidade. Adaptado de Aranha et al. (2024a).

é visível nos três sensores muito antes de a intervenção ter sido decidida em campo. É a demonstração mais direta do argumento deste livro: o componente que não sabe o nome de nada é o único capaz de reagir ao que ainda não tem nome. O que lhe falta — dizer *o que* está acontecendo — é o que os Capítulos 8 e 9 e, em outro registro, a Parte IV vão perseguir.

7.7 Limitações

1. **Não classifica.** O autoencoder responde “anômalo” ou “normal”. O diagrama de decisão classifica, mas apenas o que foi programado. Nenhum dos dois nomeia um evento inédito.
2. **Período cego.** São necessárias aproximadamente quinhentas amostras normais — cerca de uma hora e vinte e três minutos — antes que o modelo esteja disponível. E o relógio reinicia a cada mudança de válvula.
3. **Limiar único e global.** Um único τ para todos os sensores e todos os regimes. Um evento que afete fortemente um sensor e pouco os demais pode ser diluído no erro agregado.
4. **Hipótese de normalidade sobre o erro.** A regra $\mu + 3\sigma$ pressupõe uma distribuição que os dados não seguem exatamente. Na prática funciona, mas a taxa de falso positivo nominal de 0,3 % não deve ser levada ao pé da letra.
5. **Avaliação limitada.** Três poços e quatro eventos. É evidência forte de funcionamento e evidência fraca de generalização.

Para onde isso leva

A limitação (1) é a mais estrutural, e é ela que abre o Capítulo 8: como transformar “algo está errado” em “isto é um hidrato” *sem* recair na hipótese de mundo fechado que o Capítulo 1 descartou.

Resumo do capítulo

O sistema dual combina um diagrama de decisão determinístico em quatro camadas — identificação do poço, validação do dado, discriminação de transiente e análise de anomalia — com um autoencoder LSTM que comprime janelas de quinhentos segundos e cinco sensores em quatro dimensões latentes. A relação entre os componentes é de mão dupla: o diagrama seleciona os dados normais que treinam o autoencoder, e o autoencoder cobre os eventos que o diagrama não enumera. O limiar de detecção é $\mu + 3\sigma$ sobre o SMAPE de reconstrução, convertido em três níveis de risco. O sistema opera em mais de vinte unidades flutuantes e mais de duzentos e cinquenta poços. O acréscimo do autoencoder ao diagrama eleva a acurácia de 0,9727 para 0,9894 e a medida F_1 de 0,9758 para 0,9917, resultado competitivo com o estado da arte na detecção de fechamento espúrio de DHSV. Quatro eventos reais em três poços confirmam o funcionamento em campo, inclusive para um evento fora do catálogo. A limitação decisiva é que o sistema detecta sem classificar — e é essa lacuna que o restante da Parte II ataca.

Exercícios

1. O autoencoder comprime $500 \times 5 = 2.500$ valores em quatro dimensões. Calcule a taxa de compressão e discuta, em termos de teoria da informação, que tipos de estrutura podem

sobreviver a essa compressão e quais necessariamente se perdem.

2. **Projeto de extensão.** Com acesso ao 3W e a um ambiente de aprendizado profundo, implemente o autoencoder descrito neste capítulo e treine-o sobre instâncias normais. Compare o histograma do SMAPE de reconstrução em dados normais e anômalos e verifique empiricamente se $\mu + 3\sigma$ é uma escolha adequada de limiar. Teste também $\mu + 2\sigma$ e $\mu + 4\sigma$, reportando a curva ROC.
3. O sistema reinicia o treinamento a cada mudança de válvula. Modele o custo dessa política: dado um poço com λ manobras por mês e um período cego de 5.000s, qual a fração de tempo em que o sistema está indisponível? Para que valor de λ a indisponibilidade ultrapassa 10 %?
4. Proponha e justifique uma alternativa ao reinício completo após manobra de válvula. Considere: um modelo por estado de válvula; um modelo condicionado ao estado como entrada adicional; adaptação incremental. Discuta prós e contras.
5. O sistema usa um limiar único sobre o erro agregado. Proponha um esquema de limiares por sensor e discuta como combinar as decisões individuais. Que ganho você esperaria para um evento que afeta apenas a temperatura de fundo?
6. A Tabela 7.2 mostra $ACC = 0,9922$ com $F_1 = 0,9360$ para um dos trabalhos. Construa uma matriz de confusão compatível com esse par de valores e explique qual desequilíbrio ele revela.
7. Discuta criticamente a evidência dos estudos de caso. Quatro eventos em três poços sustentam qual afirmação? Formule três afirmações de força decrescente e indique qual delas os dados suportam.

Leituras recomendadas

- Lopes (2025) — a tese que originou este capítulo, com detalhamento adicional do diagrama de decisão.
- Machado et al. (2022), Marins et al. (2021a) e Turan and Jaschke (2021) — os trabalhos comparados na Tabela 7.2.
- Aranha et al. (2024a) e Aranha et al. (2024b) — descrição de sistemas de monitoramento em operação, com os requisitos de campo que motivaram a arquitetura dual.
- Malhotra et al. (2015) — referência clássica sobre autoencoders LSTM para detecção de anomalias em séries temporais.

Capítulo 8

Ensemble de classificadores binários

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- explicar a diferença estrutural entre um classificador multiclasse e um ensemble de classificadores binários um-contra-todos, e por que apenas o segundo pode expressar rejeição;
- descrever o projeto e o treinamento de um classificador binário por classe de anomalia, incluindo o tratamento do desbalanceamento da classe negativa;
- interpretar os resultados de uma busca sistemática de hiperparâmetros;
- comparar o desempenho por classe do ensemble binário com o de um classificador multiclasse, de uma OCSVM e da literatura;
- reconhecer as classes em que a abordagem falha e formular hipóteses sobre o motivo.

8.1 Uma mudança de pergunta

O Capítulo 7 terminou com um sistema que detecta sem classificar. A tentação natural é acoplar-lhe um classificador multiclasse: nove classes, uma camada *softmax*, entropia cruzada categórica. É a solução que qualquer curso introdutório sugeriria, e é a solução que o Capítulo 1 descartou.

Este capítulo desenvolve a alternativa. Em vez de perguntar

“qual das nove classes é esta janela?”

pergunta-se, nove vezes de forma independente,

“esta janela é da classe k ? Sim ou não.”

Por que isso não é uma reformulação vazia

Em mundo fechado, as duas formulações são equivalentes: dado que a janela pertence a alguma das nove classes, saber a resposta das nove perguntas binárias é saber a resposta da pergunta multiclasse.

Em mundo aberto, elas deixam de ser equivalentes, e a razão é puramente estrutural. O classificador multiclasse produz escores acoplados pela restrição $\sum_k \hat{p}_k = 1$: se um escore cai, outro necessariamente sobe. Os nove classificadores binários produzem

escores *independentes*, cada um saído de sua própria sigmoide. Nada os impede de serem todos simultaneamente baixos — e “todos baixos” é a assinatura do desconhecido.

Formalmente, a regra de decisão é a Equação (6.5) do Capítulo 6:

$$\hat{y} = \begin{cases} \arg \max_k s_k(\mathbf{X}), & \text{se } \max_k s_k(\mathbf{X}) > \tau, \\ \text{desconhecido}, & \text{caso contrário.} \end{cases}$$

8.1.1 Três consequências adicionais

A independência dos classificadores traz três benefícios que não são o objetivo declarado, mas que se revelaram decisivos.

Extensibilidade incremental.

Acrescentar uma décima classe custa *um* treinamento. Nenhum dos nove classificadores existentes precisa ser tocado, porque nenhum deles depende dos demais. Em um classificador multiclasse, acrescentar uma classe altera a camada de saída e exige retreinamento completo. Essa propriedade é o que torna viável o ciclo de incorporação de novas classes do Capítulo 9.

Otimização independente.

Cada classe pode ter sua própria arquitetura, seu próprio comprimento de janela, seu próprio limiar. Um evento lento como a incrustação (classe 7) e um evento abrupto como o fechamento de DHSV (classe 2) não precisam compartilhar hiperparâmetros — e, como argumentou o Capítulo 2, eles não deveriam.

Diagnóstico interpretável.

Quando o sistema erra, sabe-se *qual* dos nove classificadores errou. Em um classificador multiclasse, o erro é uma propriedade do modelo inteiro.

8.1.2 E os custos

Três, e vale enunciá-los com a mesma clareza.

Primeiro, **custo computacional multiplicado por nove** — quantificado no Capítulo 10 e, como se verá, irrelevante na prática. Segundo, **possibilidade de conflito**: dois classificadores podem reivindicar a mesma janela com escores altos, situação que a regra $\arg \max$ resolve arbitrariamente e que o Capítulo 9 tratará com voto ponderado. Terceiro, **desbalanceamento severo em cada tarefa binária**: ao treinar o classificador da classe k , todas as demais classes formam a classe negativa, tipicamente numa razão de oito ou nove para um.

8.2 Metodologia

8.2.1 Análise exploratória

A etapa que costuma ser omitida em artigos é aqui a que determina as decisões seguintes. Três achados orientaram o projeto.

1. **Forte correlação entre sensores.** As pressões de fundo e de cabeça são altamente correlacionadas em regime normal, e é justamente a *quebra* dessa correlação que caracteriza vários eventos. Isso confirma a observação do Capítulo 2 de que a informação está na relação, não no sinal isolado.




Figura 8.1: Fluxo metodológico do desenvolvimento dos classificadores binários: análise exploratória, preparação dos dados, construção dos classificadores, otimização de hiperparâmetros e, por fim, verificação e validação — esta última incluindo a comparação com um modelo termodinâmico independente, discutida no Capítulo 10.

2. **Heterogeneidade das escalas temporais.** A duração característica dos eventos varia de minutos a meses, o que torna implausível um comprimento de janela único. Essa constatação motivou a varredura sistemática de T reportada no Capítulo 10.
3. **Desbalanceamento em dois níveis.** Entre normal e anômalo, e entre as próprias classes anômalas.

8.2.2 Preparação dos dados

- Seleção de instâncias reais, com instâncias simuladas usadas apenas para complementar classes escassas.
- Tratamento de valores ausentes e detecção de sensores congelados, conforme o Capítulo 3.
- Extração de janelas com sobreposição.
- **Divisão temporal 80/20 dentro de cada instância**, e não divisão aleatória de janelas. Essa decisão, discutida na Seção 3.4.4 e vizinhança, custa alguns pontos percentuais de acurácia reportada e é a diferença entre um número honesto e um número inflado por vazamento.
- Subamostragem da classe negativa para atenuar o desbalanceamento induzido pela formulação um-contra-todos.

8.2.3 Arquitetura dos classificadores

Cada classificador binário é uma rede recorrente seguida de camadas densas:

Camada	Configuração
Entrada	(T, S)
LSTM	32 a 128 unidades (buscado)
Dropout	0,1 a 0,5 (buscado)
Densa, ReLU	32 a 64 unidades (buscado)
Densa, sigmoide	1 unidade

A saída é um único escalar em $[0, 1]$ — e é a ausência de acoplamento entre esses escalares, ao longo dos nove modelos, que carrega toda a diferença conceitual deste capítulo.

8.2.4 Otimização de hiperparâmetros

A busca foi conduzida com Keras-Tuner em modo de busca aleatória (*random search*), com **cem combinações por anomalia**. O espaço de busca e as condições de treinamento estão na Tabela 8.1.

Tabela 8.1: Espaço de busca de hiperparâmetros e condições de treinamento dos classificadores binários.

Item	Valor ou faixa
Estratégia de busca	Busca aleatória, 100 combinações por classe
Unidades LSTM	32 a 128
Taxa de <i>dropout</i>	0,1 a 0,5
Unidades densas	32 a 64
Taxa de aprendizado	10^{-4} a 10^{-2}
Épocas	25
Parada antecipada	paciência de 5 épocas
Tamanho do lote	64
Otimizador	Adam
Função de perda	Entropia cruzada binária
Divisão treino/teste	Temporal, 80/20

Por que busca aleatória e não busca em grade

Com cinco hiperparâmetros e uma grade grosseira de cinco valores cada, seriam $5^5 = 3.125$ combinações por classe, ou 28.125 treinamentos. A busca aleatória com cem amostras cobre o espaço de forma mais eficiente quando poucos hiperparâmetros dominam o desempenho — o que é o caso aqui, e é o resultado clássico sobre o assunto. O ponto prático: nove classes tornam qualquer procedimento de busca nove vezes mais caro, e isso obriga a escolher métodos econômicos.

8.3 Resultados por classe

A Tabela 8.2 é a tabela central deste capítulo. Ela compara, classe a classe, quatro abordagens: o ensemble um-contra-todos proposto, um classificador multiclasse treinado sobre os mesmos dados, uma OCSVM aplicada ao espaço bruto, e os resultados publicados por Marins et al. (2021a) nas duas modalidades.

Tabela 8.2: Acurácia por classe. OVA é o ensemble um-contra-todos proposto; Multi. é o classificador multiclasse; OCSVM é a máquina de vetores de suporte de uma classe aplicada ao espaço bruto. As duas últimas colunas reproduzem Marins et al. (2021a) nas modalidades binária e multiclasse. Traços indicam classes não avaliadas naquele trabalho.

Cl.	Evento	OVA	Multi.	OCSVM	Lit. bin.	Lit. multi.
0	Normal	0,73	0,710	—	—	—
1	Aumento de BSW	0,91	0,916	0,63	0,99	0,508
2	Fechamento de DHSV	0,92	0,919	0,57	0,99	0,888
3	Golfadas severas	0,94	0,866	0,67	1,00	0,791
4	Instabilidade de fluxo	0,69	0,758	0,64	0,99	0,954
5	Perda de produtividade	0,79	0,953	0,69	0,98	0,833
6	Restrição rápida no PCK	0,91	0,609	0,63	0,97	0,710
7	Incrustação no PCK	0,82	0,865	0,65	—	—
8	Hidrato na produção	0,88	0,989	0,74	0,99	0,000
9	Hidrato no serviço	0,93	0,981	0,63	—	—
Global		0,87	0,86	0,65	0,98	0,930

8.3.1 Leitura global

Resultado-chave

O ensemble um-contratodos atinge acurácia global de **0,87**, contra 0,86 do classificador multiclasse e 0,65 da OCSVM. A diferença para o multiclasse é de um ponto percentual; sem as predições pareadas ou um teste de não inferioridade, não é possível afirmar superioridade nem equivalência.

Esse resultado precisa ser lido com precisão, porque é fácil lê-lo errado nos dois sentidos.

A leitura pessimista seria: “o ensemble não é melhor, logo não vale o custo”. Ela ignora que o ensemble *faz outra coisa*. O classificador multiclasse não pode rejeitar; o ensemble pode. O empate em desempenho de mundo fechado significa que **a capacidade de rejeição foi acrescentada sem perda observada na acurácia agregada** neste experimento — um resultado compatível com o objetivo, mas que não demonstra não inferioridade.

A leitura otimista seria: “o ensemble é superior”. Um ponto percentual sobre esse conjunto não sustenta essa afirmação.

O que a tabela realmente sustenta

Que a acurácia agregada de mundo fechado permaneceu próxima à do classificador multiclasse enquanto a arquitetura passou a expressar rejeição. A evidência de que essa rejeição funciona para uma classe omitida está no Capítulo 10, no experimento em que a classe 8 é escondida e 89 % de suas instâncias são sinalizadas como desconhecidas.

8.3.2 Onde as duas abordagens divergem

Comparar classe a classe é mais informativo que comparar médias.

	Classe	OVA	Multi.	Diferença
OVA melhor	6 — Restrição no PCK	0,91	0,609	+0,301
	3 — Golfadas	0,94	0,866	+0,074
	0 — Normal	0,73	0,710	+0,020
Multi. melhor	5 — Perda de produtiv.	0,79	0,953	−0,163
	8 — Hidrato produção	0,88	0,989	−0,109
	4 — Instabilidade	0,69	0,758	−0,068

O padrão é coerente com a taxonomia por assinatura do Capítulo 2. O ensemble binário vence nas classes com assinatura própria e bem delimitada (6 e 3); o multiclasse vence nas classes sintomáticas ou de assinatura compartilhada (5, 4) e na classe 8. Essa associação é pós-hoc e deve ser testada com medidas de separabilidade ou ablação. Uma explicação plausível é que, quando a assinatura é distintiva, um modelo dedicado a ela é melhor; quando a assinatura é ambígua, a informação de *contraste* entre classes — que só o multiclasse possui — ajuda a desambiguar.

Uma pista para a arquitetura final

Esse padrão é a primeira evidência, neste livro, de que a resposta correta não é “escolher entre ensemble e multiclasse”, mas usar cada um onde ele é bom. O Capítulo 12 vai reforçá-la em outro registro — o espaço latente do classificador multiclasse revela-se superior ao do autoencoder para detecção de novidade — e o Capítulo 16 a transformará em proposta de projeto.

8.3.3 A falha da OCSVM

A OCSVM aplicada diretamente ao espaço bruto atinge 0,65 de acurácia global, com desempenho notavelmente uniforme entre classes (0,57 a 0,74). Uniformidade, neste caso, não é virtude: indica que o método está capturando pouco da estrutura específica de cada classe.

A explicação está no Capítulo 6. A OCSVM impõe uma fronteira limitada em torno dos dados, o que é conceitualmente correto para mundo aberto, mas o faz *no espaço em que os dados lhe são apresentados*. No espaço bruto de alta dimensão, com sensores correlacionados e escalas heterogêneas, a noção de proximidade que a OCSVM usa é pobre.

A moral — que atravessa o restante do livro — é que **o método de detecção de novidade importa menos que o espaço em que ele opera**. A mesma OCSVM, aplicada a um espaço latente adequado, contribui de forma útil no voto ponderado do Capítulo 9.

8.3.4 As duas classes problemáticas

A classe 4 (instabilidade de fluxo) obtém 0,69 e a classe 5 (perda rápida de produtividade) obtém 0,79 com o ensemble — os dois piores resultados da tabela, excetuando a classe normal.

Não é coincidência, e o Capítulo 2 já antecipou o motivo: ambas são *sintomáticas*. Elas descrevem o que se observa, não o que causou. Duas instâncias rotuladas como classe 4 podem ter causas físicas completamente distintas e assinaturas correspondentemente distintas. Um classificador binário treinado sobre esse rótulo está sendo solicitado a aprender uma categoria que não é internamente coerente.

Um problema de rótulo, não de modelo

Se a taxonomia for internamente inconsistente, mudar apenas a arquitetura não resolve o problema. As classes 4 e 5 tendem a apresentar desempenho ruim em todos os capítulos deste livro: 0,69 e 0,79 aqui; 67,5 % de detecção de novidade para a classe 5 no Capítulo 12 contra mais de 96 % das demais; 18,5 % de acerto na primeira escolha do agente para a classe 4 no Capítulo 15.

A recomendação que emerge — e que o Capítulo 16 formaliza — é tratá-las como *sinalizadores*, não como classes: “há instabilidade; investigue a causa” é uma saída honesta, “esta é a classe 4” não é.

8.3.5 Sobre a comparação com a literatura

As duas últimas colunas da Tabela 8.2 servem apenas como contexto e não como comparação controlada. Os valores binários de Marins et al. (2021a) — 0,97 a 1,00 — são superiores aos deste capítulo em todas as classes. Três diferenças de protocolo podem contribuir para a discrepância:

1. **Divisão dos dados.** A divisão temporal adotada aqui é mais rigorosa que a divisão aleatória de janelas, e produz números sistematicamente menores.
2. **Composição da classe negativa.** Um classificador binário “classe k contra normal” é uma tarefa substancialmente mais fácil que “classe k contra todas as outras oito anomalias mais normal”.
3. **Uso de instâncias simuladas e desenhadas à mão.**

O valor de 0,000 na coluna multiclasse da literatura para a classe 8 é, por si só, instrutivo: um classificador multiclasse que erra *todas* as instâncias de hidrato enquanto atinge 0,930 de

acurácia global. É a patologia do desbalanceamento em sua forma mais pura, e o argumento mais eloquente a favor das métricas balanceadas do Capítulo 4.

Comparações entre trabalhos

Números de trabalhos diferentes sobre o 3W raramente são comparáveis sem verificação do protocolo. Ao ler a literatura da área, verifique sempre: divisão temporal ou aleatória? Instâncias simuladas incluídas? Estado transiente descartado? Classe negativa composta de quê? As respostas movem a acurácia em mais pontos percentuais do que qualquer escolha de arquitetura.

8.4 O que falta

Este capítulo estabeleceu que a rejeição é estruturalmente possível e que ela não custa acurácia. Restam três lacunas, que organizam o restante do livro.

1. **A rejeição funciona?** O experimento decisivo — esconder uma classe e verificar se ela é rejeitada — está no Capítulo 10, junto com a validação contra um modelo termodinâmico independente e a análise do compromisso entre janela e tempo de resposta.
2. **E depois de rejeitar?** O material rejeitado precisa ser organizado, nomeado e reincorporado. É o Capítulo 9.
3. **Por que o sistema decidiu assim?** Nem o escore binário nem o rótulo dizem ao operador o que motivou a decisão. É a Parte IV.

Resumo do capítulo

Substituir um classificador multiclasse por um ensemble de classificadores binários um-contratodos não é uma reformulação equivalente: os escores dos classificadores binários são independentes e não somam um, o que permite que sejam todos simultaneamente baixos — a assinatura do desconhecido. A independência traz ainda extensibilidade incremental, otimização por classe e diagnóstico interpretável, ao custo de nove vezes o esforço computacional e de desbalanceamento severo em cada tarefa binária. Com busca aleatória de cem combinações por classe e divisão temporal 80/20, o ensemble atinge acurácia global de 0,87, contra 0,86 do multiclasse e 0,65 de uma OCSVM aplicada ao espaço bruto: não houve perda observada na acurácia agregada, embora o experimento não estabeleça não inferioridade. A comparação classe a classe revela um padrão coerente — o ensemble vence onde a assinatura é distintiva, o multiclasse vence onde ela é ambígua — que antecipa a arquitetura híbrida proposta ao final do livro. As classes sintomáticas 4 e 5 falham em ambas as abordagens, resultado compatível com uma limitação da taxonomia, mas que não exclui limitações dos modelos.

Exercícios

1. Demonstre formalmente que, se K classificadores binários independentes produzem escores $s_k \in [0, 1]$, então o vetor $(s_1, \dots, s_K)$ pode assumir qualquer ponto do hipercubo $[0, 1]^K$, enquanto a saída de uma *softmax* de K classes está restrita ao simplexo. Calcule a dimensão de cada conjunto e interprete a diferença.
2. Ao treinar o classificador binário da classe k , a classe negativa reúne todas as demais. Para o 3W com dez classes aproximadamente equilibradas em número de instâncias, qual a razão

de desbalanceamento? Compare três contramedidas — subamostragem, superamostragem e ponderação na perda — quanto ao efeito sobre revocação e precisão.

3. **Projeto de reprodução.** Com acesso ao 3W, implemente o ensemble e busque reproduzir a Tabela 8.2. Registre versão dos dados, divisão, sementes e divergências em relação aos valores publicados. Em seguida, repita o experimento com divisão aleatória de janelas em vez de divisão temporal e quantifique o ganho artificial de acurácia. Discuta o que isso implica para a leitura da literatura da área.
4. A classe 6 obtém 0,91 com o ensemble e 0,609 com o multiclasse. Formule duas hipóteses para essa diferença de trinta pontos percentuais e proponha, para cada uma, um experimento que a testaria.
5. Discuta a proposta de tratar as classes 4 e 5 como sinalizadores em vez de classes. Que métricas você usaria para avaliar um “sinalizador”? Como isso afetaria a acurácia global reportada e a utilidade operacional do sistema?
6. Proponha e implemente uma estratégia de resolução de conflito para o caso em que dois classificadores binários reivindicam a mesma janela com escores acima do limiar. Considere: $\arg \max$ simples, voto ponderado por desempenho histórico da classe, e apresentação de ambas as hipóteses ao operador. Avalie cada uma no conjunto 3W.
7. O limiar τ da Equação (6.5) é único para todas as classes. Proponha um procedimento para calibrar τ_k por classe usando um conjunto de validação, e discuta o compromisso entre taxa de rejeição e acurácia sobre as janelas não rejeitadas.

Leituras recomendadas

- Lopes (2025) — a tese que originou este capítulo.
- Lopes et al. (2026c) — a extensão que constitui o Capítulo 10, com a validação da capacidade de rejeição.
- Marins et al. (2021a) e Marins et al. (2021b) — os trabalhos de referência comparados na Tabela 8.2.
- Scheirer et al. (2013) — o arcabouço teórico que justifica a rejeição.
- Smola and Scholkopf (2004) — a OCSVM, cujo desempenho aqui ilustra a importância do espaço de representação.

Capítulo 9

O ciclo de aprendizado de mundo aberto

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- descrever as seis etapas do ciclo de aprendizado de mundo aberto e o papel de cada uma;
- descrever a construção de um espaço latente por autoencoder recorrente e justificar essa escolha frente a alternativas variacionais e de *clustering* profundo;
- combinar classificadores binários e OCSVM em um voto ponderado por classe;
- explicar o procedimento publicado para estimar automaticamente o número de agrupamentos com uma floresta aleatória treinada sobre índices internos de qualidade;
- avaliar criticamente o desempenho do ciclo completo sobre uma anomalia genuinamente inédita.

9.1 A questão em aberto

O Capítulo 8 entregou um sistema capaz de dizer “nenhuma das classes que conheço”. É um avanço real e, ao mesmo tempo, uma resposta insatisfatória. Se todo evento inédito recebe o mesmo rótulo — **desconhecido** — então, após alguns meses de operação, o sistema terá acumulado milhares de janelas rejeitadas em um único balde indistinto, sem qualquer estrutura.

O problema tem nome: *rejeitar não é aprender*. Este capítulo fecha o ciclo.

Definição 9.1 — Aprendizado de mundo aberto

Processo iterativo em que um sistema (i) reconhece o que sabe, (ii) rejeita o que não sabe, (iii) organiza o material rejeitado em categorias candidatas, (iv) as caracteriza e valida, e (v) as incorpora ao seu repertório, retornando a (i) com um conjunto de classes maior.

A diferença em relação ao aprendizado incremental clássico é que aqui *as classes novas não são fornecidas por um professor*: elas emergem dos dados.

9.2 As seis etapas

1. **Representação.** Um autoencoder recorrente comprime a janela bruta em um espaço latente de baixa dimensão.
2. **Reconhecimento.** Classificadores binários operando *sobre o espaço latente* identificam as classes conhecidas.
3. **Rejeição.** Um voto ponderado entre o escore binário e uma OCSVM decide o que é desconhecido.
4. **Agrupamento.** O material rejeitado é particionado em grupos candidatos.
5. **Refinamento e validação.** Os grupos são depurados por um limiar adaptativo e avaliados por índices internos.
6. **Incorporação.** Grupos validados tornam-se *classes virtuais*, sobre as quais novos classificadores binários são treinados.

Onde está o humano

Em nenhuma das seis etapas o ciclo exige rotulação humana para operar. Ele exige um humano para *nomear* as classes virtuais — e é precisamente essa lacuna que a Parte IV atacará, propondo que um modelo de linguagem produza a descrição inicial que o especialista então valida ou corrige.

9.3 Etapa 1: a representação latente

9.3.1 Arquitetura

O autoencoder recebe quatro sensores amostrados em duzentos passos de tempo:

Camada	Saída	Papel
Entrada	(200, 4)	janela bruta
LSTM(32)	(200, 32)	codificação
LSTM(8)	(8)	compressão temporal
Densa(16)	(16)	espaço latente
LSTM(8) → LSTM(32)	(200, 32)	decodificação
Densa(4 × 200)	(200, 4)	reconstrução

A compressão é de 800 para 16 valores, um fator de 50 — bem menos agressiva que a do Capítulo 7, porque aqui o latente não serve apenas para detectar desvio: ele precisa *discriminar* entre classes.

9.3.2 Por que não um VAE ou um DCN

A pergunta é legítima. Um autoencoder variacional impõe estrutura probabilística ao latente; um *deep clustering network* otimiza simultaneamente reconstrução e separabilidade de agrupamentos. Ambos parecem, no papel, mais adequados à tarefa.

Resultado-chave

A diferença entre as três arquiteturas é de meio ponto percentual. O autoencoder mais simples é o melhor dos três, e a sofisticação adicional do VAE e do DCN não se

Tabela 9.1: Acurácia do ciclo completo em função da arquitetura de representação.

Arquitetura da representação	Acurácia
Autoencoder LSTM	0,730
Autoencoder variacional (VAE)	0,727
Deep clustering network (DCN)	0,725

converteu em desempenho.

Esse é um resultado negativo, e ele foi mantido no livro deliberadamente. Duas interpretações são possíveis. A primeira: o gargalo do sistema não está na representação, mas em outro ponto da cadeia — e as etapas seguintes mostrarão que ele está no agrupamento. A segunda: métodos que impõem estrutura ao latente (gaussianidade, no VAE; agrupamento, no DCN) só ajudam quando essa estrutura corresponde à realidade dos dados, e séries multivariadas de poços não são obviamente gaussianas nem obviamente agrupáveis em esferas.




Figura 9.1: Projeção t-SNE do espaço latente do codificador. À esquerda, os pontos coloridos pelos oito rótulos originais do 3W; à direita, pelos agrupamentos obtidos com K -médias sobre a mesma representação. A correspondência entre as duas partições é parcial: alguns rótulos ocupam regiões bem definidas, outros se dispersam por vários agrupamentos. Adaptado de Lopes et al. (2025).

A Figura 9.1 antecipa esse diagnóstico. Se a representação fosse o gargalo, o painel da direita seria uma versão embaralhada do da esquerda. Não é: a estrutura existe, e o agrupamento a recupera em boa parte. O que falha é a *fronteira* entre classes vizinhas — e nenhuma variante de autoencoder resolve isso, porque todas otimizam reconstrução, e reconstrução não distingue vizinhos.

A releitura pelo Capítulo 12

Há uma terceira interpretação, que só ficará disponível quando a evolução narrada na Parte III for apresentada: talvez o problema não seja *qual* autoencoder, mas o fato de usar um autoencoder. O Capítulo 12 mostrará que o espaço latente extraído da penúltima camada de um classificador multiclasse é substancialmente melhor — silhueta de 0,2299 contra $-0,0149$ do autoencoder. A razão é intuitiva em retrospecto: um autoencoder é treinado para *reconstruir*, não para *separar*.

9.4 Etapas 2 e 3: reconhecer e rejeitar

9.4.1 Classificadores binários no espaço latente

Sobre o vetor latente, um classificador binário por classe:

Camada	Configuração
Entrada	vetor latente
Densa(64)	ReLU
Dropout	0,3
Densa(32)	ReLU
Dropout	0,2
Densa(1)	sigmoide

Note a diferença em relação ao Capítulo 8: lá os classificadores recebiam a série bruta e precisavam de camadas recorrentes; aqui recebem um vetor de dezesseis dimensões e bastam camadas densas. O trabalho de extrair estrutura temporal foi transferido para o autoencoder — o que é, ao mesmo tempo, uma economia e um risco: o que o autoencoder descartou está perdido para sempre.

9.4.2 O voto ponderado

Cada classe dispõe de dois escores: o do classificador binário, $s_i^{(b)}$, e o da OCSVM ajustada aos dados daquela classe no latente, $s_i^{(o)}$. A decisão combina os dois:

$$S_i = w_i^{(b)} s_i^{(b)} + w_i^{(o)} s_i^{(o)}, \quad w_i^{(b)} + w_i^{(o)} = 1, \quad (9.1)$$

com rejeição quando $\max_i S_i < \tau$, $\tau = 0,65$.

Os pesos foram ajustados por classe, no conjunto de validação (Tabela 9.2).

Tabela 9.2: Pesos do voto ponderado por classe. $w^{(b)}$ é o peso do classificador binário e $w^{(o)}$ o da OCSVM.

Classe	$w^{(b)}$	$w^{(o)}$
1 — Aumento de BSW	0,65	0,35
2 — Fechamento de DHSV	0,54	0,46
3 — Golfadas severas	0,75	0,25
4 — Instabilidade de fluxo	0,52	0,48
5 — Perda de produtividade	0,58	0,42
6 — Restrição rápida no PCK	0,77	0,23
7 — Incrustação no PCK	0,62	0,38
8 — Hidrato na produção	0,53	0,47
9 — Hidrato no serviço	0,54	0,46
Nenhuma (rejeição)	0,26	0,74

A linha mais informativa da tabela

É a última. Para decidir que uma janela *não pertence a nenhuma classe conhecida*, o peso ótimo da OCSVM é 0,74 — quase três vezes o do classificador binário. Para todas as outras decisões, a proporção se inverte.

A interpretação é direta e generaliza para além deste sistema: **classificadores discriminativos são bons para dizer o que algo é; modelos de suporte, treinados**

apenas sobre dados de uma classe, são bons para dizer o que algo não é. Cada família de método tem o seu papel, e tentar que uma delas cumpra os dois é o erro que o Capítulo 1 descreveu.

9.4.3 Desempenho dos classificadores binários latentes

A Tabela 9.3 reporta o desempenho por classe em dois níveis de granularidade discutidos no Capítulo 4.

Tabela 9.3: Desempenho dos classificadores binários no espaço latente. As duas primeiras colunas referem-se ao experimento consolidado; as duas últimas, à média e ao desvio padrão entre execuções, por amostra e por instância.

Classe	ACC	F_1	ACC (méd. $\pm$ dp)	Instância (méd. $\pm$ dp)
1	0,92	0,93	$0,82 \pm 0,04$	1,00
2	0,90	0,90	$0,85 \pm 0,03$	$0,98 \pm 0,05$
3	0,85	0,87	$0,89 \pm 0,02$	1,00
4	0,69	0,68	$0,64 \pm 0,03$	1,00
5	0,82	0,83	$0,75 \pm 0,03$	$0,76 \pm 0,05$
6	0,94	0,95	$0,75 \pm 0,13$	$0,34 \pm 0,42$
7	0,79	0,83	$0,80 \pm 0,01$	1,00
8	0,90	0,91	$0,80 \pm 0,06$	$0,94 \pm 0,12$
9	0,92	0,92	$0,81 \pm 0,05$	1,00

Três observações.

A classe 4 permanece a pior, com 0,69 — *exatamente* o mesmo valor obtido no Capítulo 8 sobre o espaço bruto. Mudar a representação não mudou nada, o que reforça o diagnóstico de que o problema está no rótulo.

A classe 6 exibe a patologia mais interessante da tabela: acurácia por amostra de $0,75 \pm 0,13$, mas acurácia por instância de $0,34 \pm 0,42$. Um desvio padrão de 0,42 sobre uma média de 0,34 significa que o classificador acerta a instância inteira ou erra a instância inteira, sem meio-termo, dependendo da execução. É um classificador instável, e a métrica por amostra o esconde.

Por que reportar os dois níveis

Sete das nove classes atingem acurácia por instância de 0,94 ou mais, contra acurácias por amostra entre 0,64 e 0,89. Reportar apenas o nível de instância sugeriria um sistema quase perfeito; reportar apenas o nível de amostra sugeriria um sistema medíocre. Ambos são verdadeiros e respondem a perguntas operacionais diferentes: “o sistema identifica o evento?” e “o sistema delimita o evento?”.

9.5 O teste real: a anomalia de ICV

Toda a discussão anterior seria acadêmica sem uma anomalia genuinamente inédita. Ela existe: a falha em válvula de controle de intervalo (ICV), descrita no Capítulo 2, que *não pertence a nenhuma das nove classes do 3W* e cujos dados são de poços reais.




Figura 9.2: Distribuição dos escores dos nove classificadores binários quando apresentados a janelas da anomalia de ICV — uma classe que nenhum deles conhece. Seis dos nove (1, 3, 4, 6, 8 e 9) produzem escore identicamente nulo. O classificador da classe 2 concentra-se em torno do limiar 0,5, sem decidir. Os classificadores das classes 5 e 7 distribuem massa acima do limiar. A linha tracejada indica o limiar de decisão. Adaptado de Lopes et al. (2025).

9.5.1 Como o ensemble reage

A Figura 9.2 é uma das figuras mais informativas deste livro, porque mostra simultaneamente o sucesso e o limite da rejeição.

O sucesso: seis dos nove classificadores respondem *zero absoluto*. Não é incerteza — é recusa. O comportamento é exatamente o que a formulação um-contra-todos do Capítulo 8 prometia e que uma *softmax* jamais poderia produzir, já que os escores somariam um por construção.

O limite: os classificadores das classes 5 e 7 — perda de produtividade e incrustação — atribuem probabilidade alta a parte das janelas. E a explicação, novamente, é física, não algorítmica: uma ICV com falha *de fato* restringe fluxo e *de fato* reduz produtividade. A assinatura sintomática é compartilhada. O classificador não está errado no que observa; o rótulo é que não distingue causa de efeito.

Resultado-chave

Do total de janelas de ICV, **48 %** foram atribuídas a alguma classe conhecida — majoritariamente 5 e 7 — e **52 %** foram corretamente rejeitadas e encaminhadas ao agrupamento.

Metade de uma anomalia genuinamente nova é reconhecida como nova. É simultaneamente um resultado forte — comparado a zero, que é o que um classificador de mundo fechado entregaria — e um resultado que deixa clara a distância até um sistema confiável.

9.6 Etapas 4 e 5: agrupar, refinar, validar

9.6.1 Estimar o número de grupos

Antes de agrupar é preciso decidir em quantos grupos. A solução adotada evita tanto o arbítrio quanto a inspeção visual do cotovelo: uma **floresta aleatória** treinada para prever K a partir de oito características do próprio conjunto de dados.

Característica	Descrição
n	número de amostras
Silhueta	Equação (6.8)
Davies-Bouldin	Equação (6.9)
Calinski-Harabasz	razão de dispersão entre e intra grupos
Inércia	soma dos quadrados intra grupo
avg_k	estimativa por média de índices
entropy_k	estimativa por entropia da distribuição
Volume do envoltório	hipervolume da caixa delimitadora dos dados

A estimativa final é a média de duas delas:

$$\hat{K} = \frac{\text{avg_k} + \text{entropy_k}}{2}.$$
 (9.2)

Tabela 9.4: Indicadores do estimador do número de agrupamentos reportados por Lopes et al. (2025).

Métrica	Valor publicado
Acurácia	98,3 %
Precisão	0,98
Revocação	0,86
Medida F_1	0,87
Erro médio absoluto em K	1,12

Resultado publicado e verificação independente

A Tabela 9.4 preserva os valores publicados e os atribui à fonte primária; ela não é uma reprodução independente. Se “acurácia” significar acerto exato de K e o MAE usar as mesmas predições, os dois indicadores não passam por uma verificação aritmética: os 1,7 % de casos incorretos teriam erro absoluto médio condicionado de $1,12/0,017 \approx 65,9$ grupos. Esse valor é incompatível com a escala descrita para a tarefa.

As explicações possíveis incluem denominadores distintos, outra definição de acurácia, MAE calculado para um componente intermediário ou erro de transcrição. Sem as predições por conjunto ou material suplementar, não é possível escolher entre elas. Portanto, os valores podem ser citados individualmente como resultados do artigo, mas não sustentam a conclusão de que o estimador acerta exatamente K em 98,3 % dos casos e erra, em média, apenas um grupo quando falha.

9.6.2 Interseção entre dois algoritmos

O agrupamento não é confiado a um único método. Executam-se **K-means** — com o K estimado — e **MeanShift**, cuja largura de banda é determinada pelos próprios dados, e retêm-se as amostras em que os dois concordam.




Figura 9.3: Projeção t-SNE do espaço latente. Cada cor corresponde a um agrupamento identificado pelo K-means sobre as classes conhecidas; os círculos vermelhos são as janelas de ICV rejeitadas, e a região sombreada é o envoltório convexo que elas ocupam. Note que as janelas de ICV não formam um grupo compacto: elas se distribuem em subgrupos separados, no limite entre agrupamentos existentes. Adaptado de Lopes et al. (2025).




Figura 9.4: Agrupamento das janelas de ICV rejeitadas por MeanShift, projetado por t-SNE. O algoritmo identifica dois grupos e marca como ruído as amostras que não pertencem a nenhum deles — comportamento desejável, já que a rejeição inevitavelmente arrasta janelas de transição. Adaptado de Lopes et al. (2025).




Figura 9.5: Agrupamento das mesmas janelas por DBSCAN. O algoritmo não exige que se declare o número de grupos, mas transfere a dificuldade para os parâmetros ε e $minPts$: com a densidade heterogênea do espaço latente, ele ou funde os subgrupos ou classifica a maior parte das amostras como ruído. Adaptado de Lopes et al. (2025).

A comparação entre as Figuras 9.3 e 9.4 explica por que a interseção é necessária. Os dois algoritmos partem de premissas diferentes — o K-means supõe grupos esféricos de tamanho comparável; o MeanShift, modos de densidade — e a concordância entre eles é um indício de estrutura genuína, não de artefato do método. A Figura 9.5 mostra o terceiro candidato descartado: o DBSCAN é o método teoricamente mais adequado a grupos de forma arbitrária, mas neste espaço latente sua sensibilidade a ε o torna instável demais para uso automático.

Uma advertência sobre o t-SNE

As Figuras 9.3 e 9.4 são projeções t-SNE, e o Capítulo 6 advertiu: distâncias no t-SNE não são distâncias no latente, e o algoritmo produz agrupamentos visualmente convincentes mesmo em ruído puro. Estas figuras servem para *ilustrar*, nunca para *provar*. A evidência quantitativa está nos índices internos e nas taxas de acerto.

9.6.3 Refinamento por limiar adaptativo

Nem toda amostra atribuída a um grupo pertence a ele. Aplica-se, dentro de cada grupo, um limiar sobre a distância ao centroide:

$$T = \mu + k\sigma,$$

com k determinado pela razão $R = \mu/\sigma$ da distribuição de distâncias:

$$k = \begin{cases} 2, & \text{se } R \geq 4, \\ 1 + \frac{R - 2}{2}, & \text{se } 2 \leq R < 4, \\ 0, & \text{se } R < 2. \end{cases} \quad (9.3)$$

A lógica é a seguinte. R alto indica grupo compacto e homogêneo, e nesse caso pode-se ser tolerante ($k = 2$). R baixo indica grupo disperso, provavelmente contaminado, e exige rigor ($k = 0$, ou seja, retém-se apenas o que está abaixo da distância média). Entre os dois extremos, interpola-se linearmente.

Uma salvaguarda final: se o critério eliminar mais de dois terços do grupo, ele é descartado e mantêm-se os dois terços mais próximos do centroide. Sem essa proteção, um grupo mal formado poderia ser reduzido a um punhado de amostras e ainda assim promovido a classe.

9.6.4 Validação

Grupos sobreviventes são avaliados pelos índices internos do Capítulo 6: silhueta, Davies-Bouldin e Calinski-Harabasz. Um grupo só é promovido a classe virtual se apresentar coesão e separação adequadas segundo os três.

9.6.5 O que o agrupamento acerta, quando acerta

A acurácia agregada esconde uma variabilidade grande entre combinações de classes desconhecidas. Vale examinar um caso favorável para saber o que o método produz quando as condições lhe são próprias.




Figura 9.6: Ocultando as classes 3, 6 e 8 e tratando-as como desconhecidas. À esquerda, a distribuição original dos dados, colorida pelos rótulos verdadeiros; à direita, os três agrupamentos recuperados por K -médias sem acesso a esses rótulos. Adaptado de Lopes et al. (2025).

A Figura 9.6 mostra esse caso: escondem-se três das nove classes conhecidas, treina-se o sistema com as seis restantes e verifica-se o que o agrupamento faz com o material rejeitado. A correspondência entre os dois painéis é boa — medida F_1 de 0,71, 0,97 e 0,76 para as classes 3, 6 e 8 — e o número de grupos foi estimado corretamente.

Um caso favorável, contudo, não é evidência. Por isso o experimento foi repetido para *todas* as 168 combinações de três classes escolhidas entre nove, e a Figura 9.7 agrega o resultado. A leitura importante não é a diagonal, e sim o padrão fora dela: os erros concentram-se nos mesmos pares que já haviam aparecido na Figura 9.3 e na rejeição da anomalia de ICV. Não é ruído do algoritmo — é sobreposição real de assinatura entre classes vizinhas, e nenhum método de agrupamento a desfaz sozinho.




Figura 9.7: Matriz de confusão normalizada do agrupamento por K -médias, agregada sobre as $\binom{9}{3} = 168$ combinações possíveis de três classes ocultas. A diagonal domina, mas os erros não estão distribuídos de modo uniforme. Adaptado de Lopes et al. (2025).

9.7 Etapa 6: classes virtuais

Definição 9.2 — Classe virtual

Agrupamento validado que passa a ser tratado como classe pelo sistema, recebendo seu próprio classificador binário, mas que ainda não foi nomeado nem confirmado por um especialista.

A promoção a classe virtual é a etapa que fecha o ciclo, e ela é barata precisamente por causa da propriedade de extensibilidade incremental estabelecida no Capítulo 8: treina-se um novo classificador binário, e nenhum dos existentes é tocado.

A Figura 9.8 é o fecho experimental do ciclo, e deve ser lida em par com a Figura 9.2. São os mesmos dados de ICV apresentados ao mesmo conjunto de classificadores, com uma única diferença: um décimo classificador foi acrescentado, treinado apenas com o material que o próprio sistema havia separado como desconhecido. O que era detecção dispersa entre duas classes erradas torna-se uma reivindicação concentrada e correta — a validação de que 0,98 de acurácia na décima classe não custou desempenho nas nove anteriores.

O que esta figura não prova

O décimo classificador aprendeu a reconhecer a falha de ICV, mas ninguém lhe disse que aquilo *era* uma falha de ICV. Para o sistema, a classe continua anônima: um agrupamento coerente, reproduzível e agora reconhecível, sem nome nem causa. Nomear é outro problema, e é exatamente onde começa a Parte IV.




Figura 9.8: O mesmo cenário da Figura 9.2, agora com dez classificadores. O décimo foi treinado exclusivamente sobre as janelas antes rejeitadas e reivindica a maior parte delas; as reivindicações espúrias das classes 2 e 5 retrocedem. Adaptado de Lopes et al. (2025).

Resultado-chave

Sobre o conjunto de janelas rejeitadas, o ciclo de agrupamento e refinamento atinge acurácia de **80,8 %** no nível de amostra na atribuição a grupos coerentes.

9.8 Balanço

O ciclo funciona, e funciona parcialmente. Vale enunciar as duas metades com igual clareza.

O que funciona. A rejeição não é uma promessa teórica: 52 % de uma anomalia genuinamente inédita foram identificados como tal, com seis de nove classificadores respondendo zero absoluto. O agrupamento subsequente organiza esse material com 80,8 % de acurácia. A estimativa automática de K dispensa arbítrio. E o mecanismo de classes virtuais permite crescimento do repertório sem retreinamento global.

O que não funciona. Quase metade das janelas de ICV foi absorvida pelas classes sintomáticas 5 e 7. A escolha da representação — autoencoder, VAE ou DCN — é irrelevante, o que sugere que o gargalo não foi identificado. As classes 4 e 5 falham sistematicamente. E, sobretudo, **as classes virtuais não têm nome**: o sistema produz “grupo 11”, não “falha de ICV”.

As três portas que este capítulo abre

Cada uma dessas limitações define uma das partes seguintes do livro.

A representação inadequada leva ao Capítulo 12: o latente do classificador multi-classe supera o do autoencoder por uma margem que torna o resultado da Tabela 9.1 compreensível em retrospecto.

A detecção grosseira, no nível de janela inteira, leva ao Capítulo 11: uma U-Net que segmenta ponto a ponto, elevando a acurácia de 0,500 para 0,863.

E a ausência de nomes leva à Parte IV, onde um modelo de linguagem recebe as estatísticas do segmento anômalo e produz uma descrição em linguagem natural — que,

para a maioria das classes, converge para um nome consistente.

Resumo do capítulo

O ciclo de aprendizado de mundo aberto tem seis etapas: representação, reconhecimento, rejeição, agrupamento, refinamento e incorporação. A representação é um autoencoder LSTM que comprime 200×4 valores em dezesseis dimensões; alternativas variacionais e de *clustering* profundo produzem desempenho estatisticamente indistinguível (0,730, 0,727 e 0,725), o que indica que o gargalo está em outro lugar. A rejeição combina classificadores binários e OCSVM em um voto ponderado por classe, e o peso ótimo da OCSVM na decisão de rejeitar é 0,74 contra 0,26 do classificador — evidência de que reconhecer e rejeitar são tarefas para famílias distintas de método. Sobre uma anomalia genuinamente inédita, a falha de ICV, seis dos nove classificadores produzem escore nulo e 52 % das janelas são corretamente rejeitadas; os 48 % restantes são absorvidos pelas classes sintomáticas 5 e 7. O agrupamento usa a interseção entre K-means e MeanShift, com K estimado por uma floresta aleatória sobre oito índices. O artigo reporta 98,3 % de acurácia e MAE de 1,12, valores preservados aqui com a ressalva de que suas definições conjuntas aguardam reconciliação a partir das predições por conjunto. O refinamento usa um limiar adaptativo $\mu + k\sigma$ com k dependente da razão $R = \mu/\sigma$. A acurácia do ciclo de agrupamento é de 80,8 % no nível de amostra. Os grupos validados tornam-se classes virtuais — que ainda não têm nome.

Exercícios

1. O peso ótimo da OCSVM na decisão de rejeição é 0,74, contra valores entre 0,23 e 0,48 nas decisões de reconhecimento. Explique essa assimetria em termos da natureza discriminativa dos classificadores binários e da natureza generativa dos modelos de suporte.
2. Implemente o limiar adaptativo da Equação (9.3). Gere conjuntos sintéticos com diferentes graus de dispersão e verifique se o comportamento de k corresponde à intenção declarada. Proponha e avalie uma alternativa contínua e diferenciável.
3. Mostre que, se a acurácia de acerto exato de K é a e o erro médio absoluto é m , então o erro absoluto médio condicionado aos casos incorretos é $m/(1 - a)$. Use essa identidade para propor verificações de consistência para um relatório que apresente as duas métricas.
4. **Projeto de extensão.** Com acesso aos dados e a um protocolo explicitamente versionado, substitua o autoencoder por um *transformer* de séries temporais e compare-o com a Tabela 9.1. As diferenças entre representações permanecem pequenas? Documente por que seus valores podem divergir dos publicados e o que o resultado implica sobre onde concentrar esforço de engenharia.
5. A interseção entre K-means e MeanShift descarta amostras em que os dois algoritmos discordam. Quantifique, sobre o 3W, a fração descartada. Discuta o compromisso entre pureza dos grupos e cobertura, e proponha um critério para decidir quando a interseção é preferível à união.
6. Argumenta-se que 48 % das janelas de ICV foram absorvidas pelas classes 5 e 7 por compartilharem assinatura sintomática. Projete um experimento que teste essa hipótese contra a alternativa de que se trata de simples limitação do classificador.

7. Uma classe virtual é promovida sem nome nem confirmação humana. Discuta os riscos operacionais de acumular classes virtuais indefinidamente e proponha uma política de governança: quando promover, quando fundir, quando descartar, e com que frequência solicitar revisão humana.

Leituras recomendadas

- Lopes (2025) — a tese que originou este capítulo, com detalhamento completo do ciclo.
- Lopes et al. (2025) — o artigo em que o ciclo foi publicado, origem das figuras deste capítulo.
- Parmar et al. (2022), Jafarzadeh et al. (2022) e Zhu et al. (2024) — os fundamentos do aprendizado de mundo aberto.
- Pimentel et al. (2014) — revisão abrangente de detecção de novidade.
- Breiman (2001) — florestas aleatórias, aqui usadas de forma incomum, como estimador de metaparâmetro.
- van der Maaten and Hinton (2008) — o t-SNE, com a discussão original sobre o que suas projeções podem e não podem sustentar.

Parte III

A evolução

Capítulo 10

Superando o mundo fechado

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- descrever e interpretar um experimento de mundo aberto por classe escondida;
- analisar o compromisso entre comprimento de janela, acurácia e tempo de resposta operacional;
- interpretar a validação de um classificador contra um modelo físico independente e analisar as discrepâncias;
- estimar o custo computacional de um ensemble e discutir sua viabilidade no ambiente avaliado;
- posicionar corretamente as limitações de um resultado positivo.

10.1 Do princípio à evidência

O Capítulo 8 estabeleceu que um ensemble de classificadores binários *pode* rejeitar, sem perda observada na acurácia agregada daquele experimento. Faltava confrontá-lo com uma classe que o sistema realmente nunca viu e medir se a rejeição continuava útil nesse protocolo.

Este capítulo apresenta essa evidência para uma classe escondida, junto com três investigações que a acompanham: a varredura sistemática do comprimento de janela, a validação contra um modelo termodinâmico independente e a análise do custo computacional. É o aprofundamento do Capítulo 8 — mesmos classificadores, perguntas mais duras.

10.2 O experimento da classe escondida

10.2.1 Protocolo

O experimento é conceitualmente simples e metodologicamente decisivo.

1. Treinam-se classificadores binários para **seis** classes apenas.
2. A classe 8 — hidrato na linha de produção — é **completamente removida** do treinamento. Nenhuma janela dela é vista, em nenhum momento, por nenhum classificador.
3. Apresentam-se ao ensemble as instâncias da classe 8.

4. Mede-se a fração dessas instâncias para as quais *todos* os seis escores ficam abaixo do limiar.

A pergunta que o experimento responde não é “o sistema classifica bem?”, mas “**o sistema sabe que não sabe?**”.

10.2.2 Resultado

Resultado-chave

89 % das instâncias da classe escondida foram sinalizadas como “nenhuma das classes treinadas”.

A Figura 10.1 mostra o que acontece quando o mesmo experimento é feito com um classificador multiclasse, e é a ilustração mais direta do problema que este livro ataca.




Figura 10.1: Escores de um classificador multiclasse treinado em seis classes, quando apresentado às instâncias da classe 8 — que ele nunca viu. Note a concentração de massa próxima de 1,0 para as classes 3, 2 e 5: o modelo não hesita, ele afirma com convicção máxima que o hidrato é outra coisa. A restrição $\sum_k \hat{p}_k = 1$ não lhe permite outra resposta. Adaptado de Lopes et al. (2026c).

O que a figura mostra e o que ela não mostra

Ela não mostra um modelo mal treinado. Os picos próximos de 1,0 indicam alta confiança, e a alta confiança é apropriada *dentro* do mundo fechado em que o modelo foi treinado e avaliado.

O que a figura mostra é que a confiança de um classificador multiclasse não carrega informação alguma sobre se a entrada pertence ao domínio para o qual ele foi treinado. É um alerta que vale muito além do monitoramento de poços.

Por que este é o resultado central da tese

Um classificador multiclasse, no mesmo experimento, teria acertado 0% — não por ser mal treinado, mas por construção. A restrição $\sum_k \hat{p}_k = 1$ o obriga a distribuir toda a massa de probabilidade entre as seis classes que conhece. A resposta “nenhuma delas” não pertence ao seu espaço de saída.

Os 89% não medem, portanto, uma melhoria incremental sobre uma linha de base: eles medem a existência de uma capacidade que antes era literalmente inexpressável.

10.2.3 Os onze por cento restantes

Um resultado honesto exige olhar para o complemento. Onze por cento das instâncias de hidrato foram atribuídas com confiança a alguma das seis classes conhecidas — ou seja, o sistema afirmou algo falso com convicção.

Em termos operacionais, esse é o modo de falha mais perigoso do sistema. Um alarme ausente leva o operador a investigar por conta própria; um diagnóstico errado o leva a investigar *na direção errada*. O Capítulo 17 retornará a essa distinção ao discutir o projeto da interface.

Uma comparação de escala

Vale registrar a ordem de grandeza. Os 89% deste experimento contrastam com os 52% obtidos sobre a anomalia de ICV no Capítulo 9 — e a diferença é instrutiva.

O hidrato tem assinatura física própria e distintiva. A falha de ICV é sintomaticamente próxima de classes existentes. A capacidade de rejeição, portanto, não é uma propriedade fixa do método: ela depende de quão distinta é a novidade em relação ao que já se conhece. Sistemas de mundo aberto detectam melhor o que é mais estranho — o que é tranquilizador e, ao mesmo tempo, é a razão pela qual o número reportado em qualquer trabalho da área deve vir acompanhado da identificação da classe escondida.

10.3 O comprimento da janela**10.3.1 Um compromisso que não é técnico**

Quanto tempo de sinal é necessário para reconhecer um hidrato? Em uma janela causal, T define o histórico mínimo necessário após o início da aquisição; o atraso adicional depende do passo entre janelas, do alinhamento do evento e da frequência de inferência.

A Tabela 10.1 apresenta a varredura completa, de 150 s a 7.500 s, para o classificador binário de hidrato.

10.3.2 Três leituras da tabela

A tendência. A acurácia cresce de 0,866 para 0,966 ao longo de duas ordens de grandeza de T . O ganho é real, mas modesto: dez pontos percentuais para um aumento de cinquenta vezes no comprimento da janela. E ele não é monótono — há uma queda pronunciada em 6.000 s (0,869), com revocação despencando para 0,832.

Sobre a não monotonicidade

A queda em 6.000 s não deve ser explicada apressadamente. Duas causas concorrem. Primeira, janelas mais longas produzem *menos* exemplos de treinamento a partir do mesmo conjunto de dados — a variância da estimativa cresce. Segunda, com $T = 6.000$ s

Tabela 10.1: Desempenho do classificador binário de hidrato em função do comprimento da janela T . FP e FN são as taxas de falso positivo e falso negativo.

T (s)	ACC	PR	REC	F_1	FP	FN
150	0,866	0,863	0,898	0,881	0,175	0,102
300	0,891	0,883	0,928	0,905	0,154	0,072
600	0,891	0,891	0,918	0,904	0,144	0,082
900	0,902	0,885	0,952	0,917	0,166	0,048
1200	0,898	0,893	0,937	0,915	0,157	0,063
1500	0,907	0,911	0,935	0,923	0,132	0,065
2250	0,899	0,923	0,910	0,917	0,117	0,090
3000	0,930	0,949	0,941	0,945	0,090	0,059
3750	0,961	0,958	0,985	0,971	0,085	0,015
4500	0,920	0,895	0,997	0,943	0,236	0,003
5250	0,962	0,977	0,966	0,971	0,047	0,034
6000	0,869	0,968	0,832	0,895	0,056	0,168
6750	0,942	0,922	1,000	0,959	0,180	0,000
7500	0,966	0,958	0,994	0,975	0,092	0,006

a janela passa a conter, frequentemente, tanto o regime normal quanto o evento inteiro, e o rótulo agregado torna-se ambíguo.

A lição metodológica: uma varredura de hiperparâmetro que produz curva ruidosa está comunicando algo sobre a quantidade de dados, não apenas sobre o hiperparâmetro.

O compromisso entre FP e FN. As duas últimas colunas revelam um padrão que a acurácia esconde. Em 4.500s, a taxa de falso negativo cai para 0,003 — praticamente nenhum hidrato escapa — mas a de falso positivo sobe para 0,236. Em 5.250s, quase o oposto: FP de 0,047 e FN de 0,034.

Qual configuração é melhor? **A pergunta não tem resposta técnica.** Um hidrato não detectado pode custar dias de produção e uma intervenção submarina; um alarme falso custa atenção do operador. A razão entre esses custos é uma decisão da operadora, e o papel do engenheiro é apresentar a curva, não escolher o ponto.

A leitura operacional. É a mais importante, e a Tabela 10.2 a torna explícita.

Tabela 10.2: Compromisso entre histórico mínimo e acurácia para três comprimentos de janela representativos; o atraso efetivo depende do passo e do alinhamento.

T (s)	Histórico mínimo	Acurácia
150	2,5 minutos	86,6 %
300	5 minutos	89,1 %
900	15 minutos	90,2 %

Resultado-chave

Reduzir a janela de 900s para 150s — de quinze para dois minutos e meio de histórico — custa 3,6 pontos percentuais de acurácia neste teste.

Esse número precisa ser confrontado, em cada implantação, com o intervalo disponível para agir. A faixa de trinta minutos a cinco horas antes atribuída a Vargas et al. (2019) não

foi confirmada na fonte consultada nesta revisão e, por isso, não é usada aqui como evidência.

A conclusão que inverte a intuição

O gargalo do sistema não é o tempo de detecção. É a confiabilidade do diagnóstico. Otimizar por latência, neste problema, é otimizar a variável errada. É por isso que o restante deste livro investe em segmentação precisa (Capítulo 11), em detecção de novidade confiável (Capítulo 12) e em explicabilidade (Parte IV) — e não em inferência mais rápida.

10.4 Validação contra um modelo físico

10.4.1 A ideia

Comparar um classificador com outro classificador diz pouco: ambos podem estar compartilhando os mesmos vieses do conjunto de dados. Comparar um classificador com um **modelo termodinâmico independente** é outra coisa — o modelo físico não foi treinado em dado nenhum e não conhece o 3W.

10.4.2 O modelo de Motiee




Figura 10.2: Arquitetura de validação cruzada entre modelo físico e modelo aprendido. Os mesmos valores de sensor alimentam dois caminhos independentes — a análise pressão-temperatura contra a envoltória de formação de hidrato e o classificador binário — cujos resultados são então confrontados antes de gerar o alerta. Adaptado de Lopes et al. (2026c).

A correlação empírica de Motiee (1991, p. 98–99) estima a temperatura de formação de hidrato T_{hid} a partir da pressão absoluta P e da densidade relativa do gás q . Na forma publicada, define-se $x = \log_{10}(P/\text{psia})$, e a saída é dada em graus Fahrenheit:

$$T_{\text{hid}, ^\circ\text{F}} = -238,24469 + 78,99667x - 5,352544x^2 + 349,473877q - 150,854675q^2 - 27,604065xq. \quad (10.1)$$

Trata-se de uma correlação de triagem para gás natural doce baseada em gravidade específica, não de um modelo composicional. Por isso, seu uso fora da faixa de pressão e composição coberta pela fonte exige validação contra dados de equilíbrio ou simulador termodinâmico.

A partir dela define-se um índice de proximidade da condição de hidrato,

$$C_{\text{hid}} = 100 \frac{T - T_{\text{hid}}}{T}, \quad (10.2)$$

onde T é a temperatura medida. Valores negativos ou próximos de zero indicam operação dentro ou junto da envoltória de formação. A curva pressão-temperatura de referência é a de Safamirzaei (2015).




Figura 10.3: Envoltória de formação de hidrato no plano temperatura–pressão. A curva separa a zona de operação normal da zona de formação: para uma dada pressão, temperaturas à esquerda da curva colocam o sistema em risco. Adaptado de Lopes et al. (2026c).

A Figura 10.3 apresenta essa envoltória. Note que a curva é monotônica e suave — e é justamente essa simplicidade que a torna um instrumento de validação útil. Ela não tem parâmetros ajustados aos dados, não conhece o 3W e não pode ter aprendido nenhum atalho do conjunto. Se o classificador concorda com ela, a concordância significa alguma coisa.

Exemplo 10.1 — Usando a Equação (10.1) na prática

Considere um trecho de linha operando a $P = 7$ MPa, ou aproximadamente 1015 psia, com gás de densidade relativa $q = 0,65$ e temperatura medida $T = 18^\circ\text{C}$.

Com $x = \log_{10}(1015) \approx 3,007$, a Equação (10.1) fornece $T_{\text{hid}} \approx 60,4^\circ\text{F} \approx 15,8^\circ\text{C}$. Pela Equação (10.2), $C_{\text{hid}} \approx 100 \times (18 - 15,8)/18 \approx 12\%$.

Uma queda de aproximadamente 2,2 graus na temperatura da linha levaria C_{hid} a zero. É esse tipo de raciocínio de margem que o modelo analítico oferece e que um classificador, por si só, não comunica.

10.4.3 Resultado da comparação

Tabela 10.3: Classificador binário de hidrato *versus* critério analítico baseado na correlação de Motiee.

Métrica	Classificador binário	Critério analítico
Acurácia	90,02 %	76,60 %
Falsos positivos	16,80 %	18,61 %
Falsos negativos	4,80 %	20,10 %

Resultado-chave

O classificador supera o critério analítico em treze pontos percentuais de acurácia. A diferença concentra-se nos falsos negativos: 4,8 % contra 20,1 % — uma redução de quatro vezes.

10.4.4 Interpretando a diferença

Por que o modelo físico perde? Não por estar errado. A correlação de Motiee descreve corretamente a *condição termodinâmica de formação* de hidrato. O que ela não descreve é a *cinética*: a formação leva tempo, depende da presença de água livre, de nucleação, de histórico de escoamento e de eventual injeção de inibidor.

Um trecho pode estar dentro da envoltória por horas sem formar hidrato; outro pode formar com margem aparentemente confortável, se houver acúmulo de água. O modelo analítico responde “é termodinamicamente possível?”; o classificador aprende a responder “está acontecendo?”.

Complementaridade, não substituição

As taxas de falso positivo são quase idênticas — 16,8 % e 18,6 % — o que sugere que ambos os métodos são igualmente conservadores ao alertar. A diferença está inteiramente na detecção.

A arquitetura sensata não escolhe entre os dois. O modelo analítico fornece contexto físico interpretável — a margem de C_{hid} — que o classificador não produz; o classificador fornece a sensibilidade que o modelo não tem. O Capítulo 14 retomará essa ideia em outro registro, ao alimentar o agente de linguagem com conhecimento de domínio explícito.

Vale ainda notar que esta validação é possível apenas para o hidrato, porque apenas ele dispõe de um modelo físico fechado e bem estabelecido. Para golfadas, incrustação ou falha de ICV não há equivalente — e essa é uma limitação da estratégia de validação, não do classificador.

10.4.5 A complementaridade na tela do operador

A Figura 10.4 materializa a recomendação da seção anterior. A decisão de projeto — exibir os dois riscos separadamente, em vez de combiná-los em um índice único — é deliberada. Um risco analítico de 19,71 % com risco aprendido nulo comunica ao operador algo específico e acionável: *as condições termodinâmicas se aproximam da envoltória, mas ainda não há assinatura de formação*. Um índice combinado de, digamos, 10 % destruiria essa informação.

Fundir indicadores é perder informação

A tentação de reduzir múltiplos indicadores a um número único é forte, e quase sempre equivocada em contextos de decisão especializada. Dois indicadores que discordam são informativos precisamente por discordarem. O Capítulo 17 desenvolverá esse princípio ao discutir o projeto do painel do operador.

10.5 Custo computacional

O argumento recorrente contra ensembles é o custo. Convém quantificá-lo.




Figura 10.4: Painel operacional com os dois indicadores lado a lado. À direita, a curva de formação de hidrato com o ponto de operação atual; abaixo, os dois medidores de risco: o analítico (PVT), em 19,71 %, e o aprendido (IA), em 0,00 %. Os dois números respondem a perguntas diferentes e são apresentados sem tentativa de fundi-los em um só. Adaptado de Lopes et al. (2026c).

Tabela 10.4: Custo computacional por inferência, para janela de 900 s.

	Memória	Latência
Um classificador binário	≈ 2,3 MB	≈ 45 ms
Ensemble de nove	≈ 21 MB	≈ 405 ms

Resultado-chave

O ensemble completo ocupa cerca de 21 MB e responde em cerca de 405 ms para uma janela de 900 s.

A inferência é mais de três ordens de grandeza menor que a janela avaliada. Cabe em um computador industrial embarcado, e o custo de multiplicar por nove — que parecia uma objeção séria no Capítulo 8 — não é limitante no hardware e na frequência avaliados.

Uma observação sobre argumentos de eficiência

Este é um caso em que a quantificação delimita o debate. Objeções de custo computacional devem ser sempre confrontadas com a escala de tempo do processo monitorado. Em monitoramento de hidrato no cenário avaliado, a inferência é rápida em relação à janela; rede, aquisição, concorrência entre poços e requisitos de disponibilidade ainda precisam ser medidos na implantação.

10.6 Limitações

1. **Uma única classe escondida.** O experimento foi feito removendo a classe 8. Não se sabe se 89 % se sustentaria com outra classe — e a comparação com os 52 % da ICV no Capítulo 9 sugere fortemente que não.
2. **Detecção sem localização.** O sistema classifica a janela inteira. Não diz onde, dentro dela, o evento começa. É a lacuna que o Capítulo 11 preenche.
3. **Rejeição sem organização.** Rejeitar é o primeiro passo; o Capítulo 9 mostrou o que vem depois, e mostrou também que essa etapa é a mais frágil da cadeia.
4. **Rejeição sem explicação.** O sistema diz “desconhecido” sem dizer por quê. É a Parte IV.
5. **Validação física restrita ao hidrato.** As demais classes não dispõem de modelo independente contra o qual comparar.

Resumo do capítulo

O experimento decisivo do princípio de mundo aberto consiste em treinar o ensemble sobre seis classes, esconder completamente a classe 8 — hidrato na produção — e verificar se suas instâncias são reconhecidas como desconhecidas: 89 % delas são, contra 0 % que um classificador multiclasse obteria por construção. A varredura do comprimento de janela, de 150 s a 7.500 s, mostra ganho modesto e não monótono (0,866 a 0,966) e revela que reduzir a janela de quinze para dois minutos e meio de histórico custa 3,6 pontos percentuais; o atraso operacional ainda depende do passo e do alinhamento. No ambiente avaliado, a inferência não é o gargalo. A validação contra a correlação termodinâmica de Motiee dá ao classificador 90,02 % de acurácia contra 76,60 % do critério analítico, com falsos negativos de 4,8 % contra 20,1 %: o modelo físico descreve a condição de formação, o classificador aprende a ocorrência. O custo do ensemble — 21 MB e 405 ms — é três ordens de grandeza menor que a escala de tempo assumida para o processo e não foi limitante no ambiente avaliado.

Exercícios

1. Repita o experimento da classe escondida para cada uma das nove classes, reportando a taxa de rejeição em cada caso. Correlacione os resultados com alguma medida de distinção da assinatura — por exemplo, a distância entre centroides no espaço latente. A hipótese de que “a rejeição depende de quão estranha é a novidade” se sustenta?
2. A Tabela 10.1 mostra queda de acurácia em 6.000 s. Projete dois experimentos que discriminem entre as duas explicações oferecidas (menos exemplos de treinamento *versus* rótulo agregado ambíguo).
3. Para $T = 4.500$ s, $FP = 0,236$ e $FN = 0,003$; para $T = 5.250$ s, $FP = 0,047$ e $FN = 0,034$. Formule o problema de escolha como minimização de custo esperado, atribua custos plausíveis a um hidrato não detectado e a um alarme falso, e determine para que razão de custos cada configuração é preferível.
4. **Projeto de reprodução.** Com acesso às instâncias e às variáveis físicas necessárias, implemente a Equação (10.1) e a Equação (10.2) para as classes 8 e 9 do 3W e busque reproduzir a Tabela 10.3. Registre protocolo e divergências. Em seguida, examine os casos em que o critério analítico erra e o classificador acerta: há padrão?
5. O modelo analítico e o classificador têm taxas de falso positivo semelhantes mas taxas de falso negativo muito distintas. Proponha três formas de combiná-los — conjunção, disjunção e voto ponderado — e avalie cada uma quanto a FP, FN e interpretabilidade.
6. Estime o custo computacional do ensemble para os duzentos e cinquenta poços mencionados no Capítulo 7, supondo inferência a cada 60 s. Discuta arquiteturas de implantação: inferência na plataforma, em terra, ou híbrida.
7. Argumente a favor e contra a seguinte afirmação: “o resultado de 89 % é superestimado porque a classe 8 tem assinatura particularmente distintiva”. Que evidência adicional resolveria a disputa?

Leituras recomendadas

- Lopes et al. (2026c) — o artigo que originou este capítulo.
- Lopes (2025) — a tese, para o contexto completo.
- Motiee (1991) e Safamirzaei (2015) — as correlações termodinâmicas usadas na validação independente.
- Vargas et al. (2019) — a descrição do conjunto 3W.
- Scheirer et al. (2013) — a formalização do risco de espaço aberto, que dá suporte teórico ao experimento da classe escondida.

Capítulo 11

Da detecção à segmentação

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- distinguir detecção de segmentação e justificar por que a segunda fornece informação temporal mais útil ao operador;
- descrever o projeto de uma U-Net unidimensional para segmentação de séries temporais;
- explicar o papel das conexões de atalho na preservação da resolução temporal;
- avaliar segmentação com IoU e com SoftED, e interpretar a diferença entre as duas famílias de métrica;
- diagnosticar desalinhamento de anotação a partir de padrões anômalos nas métricas.

11.1 A pergunta errada

Todos os capítulos anteriores fizeram a mesma pergunta: *esta janela contém uma anomalia?* A resposta é um rótulo por janela.

Considere o que isso significa em operação. Com janelas de 900s, o sistema informa “houve um evento em algum ponto destes quinze minutos”. O operador precisa então examinar novecentas amostras para descobrir onde. Se a janela for de 7.500s, são mais de duas horas de sinal.

A pergunta correta é outra: *quais amostras, exatamente, pertencem ao evento?*

Definição 11.1 — Segmentação de séries temporais

Tarefa de atribuir um rótulo a *cada amostra* de uma série temporal, produzindo uma saída de mesmo comprimento que a entrada. Formalmente, dado $\mathbf{X} \in \mathbb{R}^{T \times S}$, produzir $\mathbf{y} \in \{0, 1\}^T$, em contraste com a detecção, que produz um único $y \in \{0, 1\}$.

Três ganhos, não um

A mudança de detecção para segmentação parece um refinamento de granularidade. Ela é mais que isso.

Primeiro, **localização**: o operador sabe onde olhar.

Segundo, **início do evento**: com o instante inicial identificado, torna-se possível medir antecedência de detecção — métrica que o rótulo por janela não permite sequer definir. Terceiro, e menos óbvio, **qualidade da entrada para as etapas seguintes**. Um segmento delimitado com precisão contém apenas o evento; uma janela contém o evento mais o regime normal que o precede. Todas as estatísticas calculadas sobre o segmento — e o Capítulo 14 calculará treze delas por sensor — são tão boas quanto a delimitação. **A segmentação é pré-requisito da explicabilidade.**

11.2 A U-Net unidimensional

11.2.1 Por que esta arquitetura

A U-Net foi proposta por Ronneberger et al. (2015) para segmentação de imagens médicas, sob restrições que ecoam as deste problema: poucos exemplos anotados, necessidade de saída na mesma resolução da entrada, e classes desbalanceadas.

Sua ideia central é o contorno de um dilema. Para reconhecer um evento é preciso contexto amplo — e contexto amplo se obtém reduzindo a resolução. Mas para delimitá-lo com precisão é preciso resolução fina. As conexões de atalho (*skip connections*) resolvem o conflito transportando as ativações de alta resolução do codificador diretamente para o decodificador, contornando o gargalo.

11.2.2 Arquitetura

Bloco	Composição	Resolução
Entrada	$(L, 1)$	L
Cod. 1	Conv1D(32,5)+BN, $\times 2$; MaxPool(2); <i>Dropout</i> 0,2	$L/2$
Cod. 2	Conv1D(64,5)+BN, $\times 2$; MaxPool(2); <i>Dropout</i> 0,2	$L/4$
Gargalo	Conv1D(128,5)+BN, $\times 2$	$L/4$
Dec. 1	<i>UpSampling</i> (2); concatena atalho (64); Conv1D(64,5)+BN, $\times 2$	$L/2$
Dec. 2	<i>UpSampling</i> (2); concatena atalho (32); Conv1D(32,5)+BN, $\times 2$	L
Saída	Conv1D(1,1), sigmoide	L

A saída é uma probabilidade por amostra, limiarizada em 0,5. O modelo é aplicado **por sensor**, e as regiões resultantes são combinadas em seguida — decisão que preserva a informação de *qual* sensor evidencia o evento, e que será usada pelo agente do Capítulo 14.

Por que núcleo 5 e não 3

Com núcleos de tamanho 5, duas convoluções por bloco e dois níveis de subamostragem, o campo receptivo do gargalo cobre algumas dezenas de amostras — suficiente para capturar a dinâmica de transição de um evento de poço, e ainda estreito o bastante para que a fronteira do segmento não seja borrada. Com núcleos 3, o campo receptivo exigiria mais níveis; com núcleos 7 ou maiores, as fronteiras perdem definição. É um compromisso que vale a pena verificar empiricamente em qualquer aplicação nova.

11.3 Protocolo experimental

- **Dados:** 3W complementado por instâncias proprietárias de poços reais; quatro variáveis (P-PDG, P-TPT, T-TPT e P-MON-CKP).
- **Amostra:** 200 passos $\times$ 4 variáveis, ou 800 dimensões quando achatada.

- **Janela deslizante:** comprimento de 100 passos, passo de 5 s.
- **Pré-processamento:** imputação de faltantes (último válido, próximo válido, média), padronização e remoção de ruído por transformada *wavelet*.
- **Validação:** cruzada estratificada em cinco dobras.
- **Treinamento:** Adam, 30 a 50 épocas.
- **Limiares:** 0,5 na saída da U-Net; percentil 95 para a distância de Mahalanobis (Capítulo 12); 0,3 para os classificadores binários.

A avaliação é feita **poço a poço**, e não sobre um conjunto agregado. Dez poços — identificados como G1, A1, A2, A3, B1, C1, C2, D1, E1 e F1 — são reportados individualmente. Essa escolha é deliberada: o desvio padrão entre poços é a única medida honesta de generalização disponível, e agregá-los produziria um número único que esconderia exatamente a informação mais relevante.

11.4 Resultados

11.4.1 Autoencoder *versus* U-Net

A Tabela 11.1 confronta a abordagem anterior — detecção por erro de reconstrução de autoencoder, como no Capítulo 7 — com a segmentação por U-Net, poço a poço.

Tabela 11.1: Detecção por autoencoder *versus* segmentação por U-Net, avaliadas no nível de amostra, por poço.

Poço	Autoencoder		U-Net	
	ACC	F_1	ACC	F_1
G1	0,818	0,706	0,882	0,731
A1	0,541	0,703	0,775	0,739
A2	0,582	0,736	0,929	0,936
A3	0,293	0,454	0,951	0,915
B1	0,285	0,443	0,752	0,632
C1	0,772	0,766	0,885	0,817
C2	0,329	0,277	0,975	0,912
D1	0,296	0,457	0,892	0,777
E1	0,496	0,663	0,870	0,874
F1	0,567	0,724	0,720	0,674
Global	0,500 ± 0,187	0,593 ± 0,160	0,863 ± 0,082	0,801 ± 0,102

Resultado-chave

A acurácia média sobe de 0,500 para 0,863 — e o desvio padrão entre poços cai de 0,187 para 0,082, uma redução de 56 %.

11.4.2 O número que importa não é a média

Uma acurácia de 0,500 em um problema binário é o desempenho de uma moeda. É tentador concluir que o autoencoder “não funciona”, mas essa leitura é errada e vale desmontá-la: o autoencoder do Capítulo 7 obteve 0,9894 em operação real.

A diferença está na *tarefa*. Lá ele decidia se uma janela era anômala; aqui, cada amostra. O erro de reconstrução é um escalar por janela e não carrega informação temporal fina; usá-lo para segmentar é usá-lo para o que ele não faz.

A redução da variância é o resultado principal

A média subiu 73 %, mas é o desvio padrão que conta a história decisiva.

Com o autoencoder, a acurácia varia de 0,285 (B1) a 0,818 (G1) — uma faixa de cinquenta e três pontos percentuais. O sistema funciona bem em alguns poços e falha em outros, e não há como saber de antemão em quais. **Um sistema imprevisível é inutilizável, mesmo que sua média seja aceitável**, porque o operador não pode calibrar quanta confiança depositar no alerta.

Com a U-Net, a faixa é de 0,720 (F1) a 0,975 (C2). O pior caso passa a ser melhor que o caso médio anterior. Essa propriedade — e não apenas a média — reduz um obstáculo à implantação; não demonstra, por si só, prontidão operacional.

Vale ainda notar o poço A3: acurácia de 0,293 com o autoencoder e 0,951 com a U-Net, um ganho de sessenta e seis pontos percentuais. Esse poço reaparecerá adiante, com um comportamento que revela algo sobre os dados, não sobre os modelos.

11.4.3 Qualidade da delimitação

Acurácia por amostra é uma métrica generosa em problemas desbalanceados. A Tabela 11.2 acrescenta a interseção sobre união (Equação (4.8)), que mede diretamente a sobreposição entre o segmento predito e o real.

Tabela 11.2: Acurácia e interseção sobre união da segmentação por U-Net, por poço.

Poço	ACC (%)	IoU (%)
A1	89,00	74
A2	95,50	93
A3	96,00	85
B1	84,00	56
C1	99,50	98
C2	97,75	84
D1	97,05	93
E1	94,22	83
F1	86,94	72
G1	98,73	94
Global	94,00	85

Resultado-chave

IoU global de 85 %: o segmento predito e o segmento real coincidem em cerca de cinco sextos de sua união.

O poço B1 merece atenção: 84 % de acurácia mas apenas 56 % de IoU. A combinação é diagnóstica — o modelo acerta a maior parte das amostras, mas as fronteiras do segmento estão substancialmente deslocadas. Em termos operacionais, o evento é detectado e mal delimitado. Como toda a cadeia de explicabilidade depende da delimitação, esse é um caso em que a saída deve ser marcada como de baixa confiança.

11.5 Avaliação por SoftED

11.5.1 O problema das métricas ponto a ponto

Considere um evento que começa na amostra 1000. Um detector o sinaliza na amostra 995; outro, na 1400. Pela acurácia por amostra, ambos erram — o primeiro erra cinco amostras, o segundo quatrocentas. A diferença entre um sistema que antecipa em cinco segundos e um que atrasa em quase sete minutos praticamente desaparece na métrica.

Em detecção de eventos, isso é inaceitável, e o SoftED de Salles et al. (2024) existe para corrigi-lo, atribuindo crédito parcial a detecções próximas do instante verdadeiro dentro de uma tolerância k .

11.5.2 Resultados

Tabela 11.3: Avaliação SoftED com tolerância $k = 1000$ amostras, por poço.

Poço	Precisão	Revocação	F_1
G1	1,00	1,00	1,00
A1	1,00	1,00	1,00
C2	1,00	1,00	1,00
D1	1,00	1,00	1,00
F1	1,00	1,00	1,00
B1	1,00	0,40	0,58
E1	1,00	0,41	0,58
A2	1,00	0,30	0,46
A3	0,00	1,00	0,00
Global	0,89	0,68	0,74

Métricas complementares globais: antecedência de detecção de 0,22 e taxa de falso positivo de 0,11.

11.5.3 Três leituras

Precisão alta, revocação baixa. Precisão de 0,89 contra revocação de 0,68: quando o sistema aponta um evento, ele quase sempre está certo; mas ele deixa passar cerca de um terço dos eventos. A preferência entre esse perfil e outro com mais falsos alarmes depende do custo e da criticidade de cada classe; não pode ser definida apenas pelas métricas agregadas. A revocação de 0,68 é uma limitação relevante.

Cinco poços perfeitos. G1, A1, C2, D1 e F1 obtêm 1,00 nas três métricas. Metade dos poços é resolvida completamente. Isso indica que o método não tem uma limitação intrínseca — ele falha por razões específicas, em poços específicos, e essas razões podem ser investigadas.

Antecedência de 0,22. O sistema raramente antecipa o evento; ele o detecta no momento em que ocorre ou pouco depois. Para eventos de desenvolvimento lento — incrustação, aumento de BSW — a antecipação seria valiosa e não está sendo obtida.

11.5.4 O poço A3, ou como uma métrica revela um problema de dados

O poço A3 apresenta a combinação mais estranha do livro:

Acurácia de segmentação (Tabela 11.1)	0,951
IoU (Tabela 11.2)	85 %
SoftED — revocação	1,00
SoftED — precisão	0,00

Um modelo que segmenta com 95 % de acurácia e 85 % de IoU, e cuja precisão de detecção de evento é exatamente zero. Isso não é um resultado ruim — é um resultado *impossível*, sob a hipótese de que as anotações estão corretas.

O que precisão 0,00 com revocação 1,00 significa

Revocação 1,00 indica que todo evento anotado tem uma detecção próxima. Precisão 0,00 indica que nenhuma detecção está próxima de um evento anotado. As duas afirmações só são simultaneamente verdadeiras se houver **muitas** detecções, das quais apenas algumas caem perto de eventos anotados — ou se houver um deslocamento sistemático maior que a tolerância entre o que o modelo detecta e o que está anotado. A segunda hipótese é plausível e aponta para possível *desalinhamento da anotação* do poço A3. A alta acurácia de segmentação é compatível com essa leitura, mas uma revisão cega por especialista é necessária para distingui-la de erro de implementação da métrica ou comportamento espúrio do modelo.

Este é o tipo de achado que justifica reportar múltiplas métricas em vez de uma. Nenhuma delas, isoladamente, revelaria o problema; a *contradição* entre elas revela.

11.6 Os classificadores binários sobre segmentos

Com o segmento delimitado, os classificadores binários do Capítulo 8 podem ser aplicados a ele, e não à janela inteira. A arquitetura, mais leve por operar sobre um segmento já isolado, é:




Figura 11.1: Classificador binário aplicado ao segmento identificado, com as dimensões efetivas de cada tensor de parâmetros: uma camada recorrente seguida de camadas densas decrescentes até uma única saída escalar. A figura mostra a variante com LSTM de 256 unidades; o número de unidades recorrentes é ajustado por classe. Adaptado de Lopes et al. (2026a).

Camada	Configuração
Entrada	segmento
LSTM(128 a 256)	opcional, conforme a classe
Densa(64)	+ BN + <i>Dropout</i> 0,3
Densa(32)	+ BN + <i>Dropout</i> 0,2
Densa(16)	+ <i>Dropout</i> 0,1
Densa(1)	sigmoide

O desempenho desses classificadores, e sobretudo o efeito do *espaço* em que o segmento é representado, é o assunto do Capítulo 12.

11.7 Limitações

1. **Revocação de 0,68.** Um terço dos eventos não é detectado dentro da tolerância.
2. **Antecedência de 0,22.** Praticamente não há detecção antecipada.
3. **Variabilidade entre poços persistente**, ainda que reduzida: IoU de 56 % em B1 contra 98 % em C1.
4. **Dependência da qualidade da anotação**, como o caso A3 demonstra de forma contundente.
5. **Segmentação binária.** A U-Net separa normal de anômalo; ela não classifica o tipo de anomalia.

Resumo do capítulo

Trocar detecção por segmentação — rótulo por amostra em vez de rótulo por janela — produz três ganhos: localização do evento, identificação do instante inicial e, o mais importante para o restante do livro, qualidade das estatísticas que alimentarão a camada de explicabilidade. A U-Net unidimensional, com codificador de dois níveis, gargalo de 128 filtros e conexões de atalho que preservam a resolução temporal, eleva a acurácia média de 0,500 para 0,863 e reduz o desvio padrão entre poços de 0,187 para 0,082 — a menor dispersão favorece a generalização entre os poços avaliados, mas implantação requer validação prospectiva, latência e análise de falhas. A interseção sobre união global é de 85 %. A avaliação por SoftED, que atribui crédito parcial a detecções próximas do instante verdadeiro, dá precisão de 0,89, revocação de 0,68 e medida F_1 de 0,74, com cinco dos dez poços resolvidos perfeitamente. O poço A3, com revocação 1,00 e precisão 0,00 apesar de 95 % de acurácia de segmentação, revela desalinhamento de anotação — um achado que só a contradição entre métricas distintas torna visível.

Exercícios

1. Calcule o campo receptivo do gargalo da U-Net descrita, considerando núcleos de tamanho 5, duas convoluções por bloco e dois níveis de subamostragem por fator 2. Compare com a duração típica da transição de um fechamento de DHSV.
2. **Projeto de reprodução e ablação.** Com acesso aos dados, implemente a U-Net e busque reproduzir a Tabela 11.1, registrando divisão, sementes e divergências. Em seguida, remova as conexões de atalho e repita. Quantifique a degradação em acurácia e, separadamente, em IoU. Qual das duas métricas é mais sensível à remoção? Por quê?
3. Um modelo obtém acurácia de 0,84 e IoU de 0,56 (poço B1). Construa um exemplo de segmentação predita e real, sobre uma série de mil amostras, compatível com esse par de valores. O que isso revela sobre o erro do modelo?
4. Implemente o SoftED e avalie a sensibilidade dos resultados à tolerância k . Trace precisão, revocação e F_1 globais em função de k , de 100 a 5000. Existe um valor de k além do qual os resultados deixam de mudar? O que ele significa fisicamente?
5. O poço A3 apresenta precisão 0,00 e revocação 1,00. Projete um procedimento automático que detecte esse padrão de contradição entre métricas e sinalize possíveis erros de anotação em um conjunto de dados novo.

6. A antecedência de detecção é de 0,22. Proponha três modificações da arquitetura ou do treinamento que poderiam aumentá-la — por exemplo, ponderação assimétrica da perda nas amostras iniciais do evento — e discuta o efeito esperado de cada uma sobre a taxa de falso positivo.
7. A U-Net é aplicada por sensor e as regiões são combinadas depois. Compare essa estratégia com uma U-Net multivariada que recebe os quatro sensores simultaneamente. Que informação cada abordagem preserva e qual descarta? Implemente ambas e compare.

Leituras recomendadas

- Lopes et al. (2026a) — o artigo que originou este capítulo.
- Ronneberger et al. (2015) — a U-Net original, cuja motivação em imagens médicas espelha as restrições do problema de poços.
- Salles et al. (2024) — a métrica SoftED e a discussão sobre por que métricas ponto a ponto são inadequadas para detecção de eventos.
- Vaz Vargas et al. (2026) — a versão 2.0 do 3W, com discussão sobre a qualidade das anotações.

Capítulo 12

Novidade no espaço latente

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- aplicar a distância de Mahalanobis como escore de novidade e calibrar seu limiar por percentil;
- comparar espaços de representação — bruto, latente de autoencoder e penúltima camada de classificador — por índices internos de qualidade;
- explicar por que, nos experimentos apresentados, uma representação treinada para discriminar supera uma treinada para reconstruir na detecção do desconhecido;
- interpretar razões de separação entre classes conhecidas e desconhecidas;
- reconhecer as hipóteses estatísticas embutidas no método e as situações em que elas falham.

12.1 Retomando um resultado incômodo

O Capítulo 9 apresentou um achado que ficou sem explicação: autoencoder, VAE e DCN produziram acurácias de 0,730, 0,727 e 0,725. Três arquiteturas de sofisticação crescente, desempenho indistinguível.

A interpretação oferecida na ocasião foi que o gargalo estava em outro lugar. Os experimentos deste capítulo sustentam uma explicação mais específica para este conjunto: o problema não é *qual* autoencoder, mas usar uma representação otimizada para reconstrução na tarefa de separar classes.

A hipótese deste capítulo

Um autoencoder é treinado para minimizar erro de reconstrução. Nada em seu objetivo o incentiva a *separar* classes; ao contrário, ele gasta capacidade representando fielmente aquilo que é comum a todas elas.

Um classificador multiclasse é treinado justamente para separar. A representação implícita em sua penúltima camada — o vetor que alimenta a camada de saída — é, por construção, um espaço em que as classes são linearmente separáveis.

A hipótese testada é que **esse espaço, construído para discriminar entre classes conhecidas, também é melhor para reconhecer o desconhecido neste protocolo** — mesmo que nada em seu treinamento tenha visado a isso.

12.2 A distância de Mahalanobis como escore

12.2.1 Definição

Dado um conjunto de referência com média μ e covariância Σ , a distância de Mahalanobis (Equação (6.3)) de um ponto z é

$$d_M(z) = \sqrt{(z - \mu)^\top \Sigma^{-1} (z - \mu)}.$$

Sua virtude sobre a distância euclidiana é ponderar cada direção pela variabilidade observada. Em um espaço latente onde algumas dimensões variam muito naturalmente e outras quase nada, essa correção é o que separa um escore útil de um escore dominado pelas direções de maior escala.

12.2.2 Calibração do limiar

O limiar é fixado no **percentil 95** da distribuição de d_M sobre os dados conhecidos. A escolha é operacional, não estatística: aceita-se, por construção, uma taxa de falso alarme de aproximadamente 5% em troca de sensibilidade.

Por que percentil e não χ^2

Sob normalidade multivariada, d_M^2 segue distribuição χ^2 com graus de liberdade iguais à dimensão, e o limiar poderia ser lido diretamente de uma tabela.

Os dados não são normais. Calibrar por percentil empírico dispensa a hipótese e produz a taxa de falso alarme desejada *por construção*, qualquer que seja a distribuição real. É um exemplo geral: quando a hipótese paramétrica é duvidosa e há dados suficientes, o quantil empírico é preferível ao valor teórico.

12.3 Três espaços em competição

1. **Espaço bruto**, com $200 \times 4 = 800$ dimensões. Nenhuma transformação.
2. **Latente de autoencoder LSTM**, com 128 dimensões. Codificador: entrada $\rightarrow$ LSTM(256) $\rightarrow$ LSTM(128) $\rightarrow$ Densa(128). Decodificador simétrico. Treinado para reconstruir.
3. **Penúltima camada de classificador multiclasse**, com 64 dimensões. Treinada para discriminar entre as classes conhecidas.




Figura 12.1: Cabeça classificadora aplicada sobre a representação latente: duas camadas densas com ativação ReLU seguidas da camada de saída. É a mesma cabeça para os três espaços comparados, o que isola o efeito da representação.

O controle experimental importa: a arquitetura da cabeça classificadora é idêntica nos três casos. Qualquer diferença de desempenho é atribuível à representação, não ao classificador.

12.4 Resultados

12.4.1 Detecção de novidade

A Tabela 12.1 apresenta o resultado central. Cada linha corresponde a uma classe tratada como *desconhecida* — removida do treinamento — e reporta a fração de suas amostras corretamente identificadas como novidade por três métodos.

Tabela 12.1: Acurácia de detecção de novidade (%) por classe tratada como desconhecida, sob três abordagens.

Classe tratada como desconhecida	Class. bin.	Mahal. bruto	Mahal. latente
1 — Aumento de BSW	22,8	41,5	99,0
2 — Fechamento de DHSV	76,9	77,1	96,5
3 — Golfadas severas	48,1	61,0	99,0
4 — Instabilidade de fluxo	44,7	57,8	96,0
5 — Perda rápida de produtiv.	0,1	62,3	67,5
6 — Restrição rápida no PCK	47,6	47,6	99,0
7 — Incrustação no PCK	36,5	36,7	52,3
8 — Hidrato na produção	50,5	91,1	99,0
9 — Hidrato no serviço	51,9	88,7	99,0
Falha de ICV	37,0	67,5	98,2

Resultado-chave

Aplicar a distância de Mahalanobis no espaço latente do classificador multiclasse eleva a detecção de novidade a 99 % em cinco das dez classes, e a mais de 96 % em sete delas. Sobre a anomalia de ICV — a única genuinamente inédita — o salto é de 52 % (Capítulo 9) para **98,2 %**.

12.4.2 Três observações

A progressão é sistemática. Em nove das dez linhas, o Mahalanobis no espaço bruto supera os classificadores binários, e o Mahalanobis latente supera o bruto. Não é um ganho concentrado em poucos casos favoráveis: é um padrão consistente neste protocolo. Essa consistência, sozinha, não exclui seleção de hiperparâmetros, vazamento ou ajuste ao conjunto; uma ablação controlada deve separar objetivo de treino, arquitetura e dimensão da representação.

A classe 5 e o valor de 0,1 %. Um detector que identifica um décimo de um por cento das novidades de uma classe está, para todos os efeitos, cego a ela. Ainda assim, o Mahalanobis latente eleva o número a 67,5 % — o pior resultado da coluna, e um ganho de seiscentas vezes. A classe 5 continua sendo o ponto fraco do sistema em todos os capítulos deste livro.

A classe 7 e o limite físico. A incrustação no PCK atinge apenas 52,3 % mesmo no melhor espaço. A explicação é a escala temporal: incrustação se desenvolve ao longo de semanas, e uma janela de duzentos passos não contém a evidência necessária. Essa é uma hipótese física plausível, a ser testada variando o horizonte; o resultado atual não exclui limitações da representação ou da amostra.

12.4.3 Quanto o desconhecido se afasta

A acurácia diz se o limiar foi ultrapassado. A Tabela 12.2 diz por quanto.

Tabela 12.2: Razão de separação: distância de Mahalanobis média das amostras desconhecidas dividida pela das conhecidas, nos espaços bruto e latente.

Classe desconhecida	Espaço bruto	Espaço latente
1	2,1×	15,8×
2	1,8×	12,4×
3	2,3×	18,2×
4	2,0×	16,1×
5	1,9×	14,7×
6	2,4×	13,9×
8	< 1,0×	186,5×
9	2,2×	17,3×

A linha da classe 8

No espaço bruto, a razão de separação da classe 8 é *menor que um*: as amostras de hidrato estão, em média, **mais próximas** do centro dos dados conhecidos do que as próprias amostras conhecidas. Qualquer detector de novidade baseado em distância falharia — não por má calibração, mas porque no espaço bruto a informação simplesmente não está disponível de forma acessível a uma métrica de distância.

No espaço latente, a mesma classe atinge 186,5×. É o maior valor da tabela por uma ordem de grandeza.

A inversão é a demonstração mais forte da tese deste capítulo. Nenhum ajuste de limiar, nenhuma escolha de escore, nenhuma sofisticação algorítmica recuperaria o desempenho no espaço bruto. **A representação não é um detalhe de pré-processamento; ela determina o que é detectável.**

Vale ainda notar a uniformidade das demais linhas: entre 12,4× e 18,2× no latente, contra 1,8× a 2,4× no bruto. O ganho é de aproximadamente uma ordem de grandeza, de forma consistente.

12.4.4 Por que o latente é melhor: a evidência direta

Até aqui o argumento foi indireto — o desempenho é melhor, logo o espaço é melhor. A Tabela 12.3 mede a qualidade dos espaços diretamente, pelos índices internos do Capítulo 6.

Tabela 12.3: Qualidade do espaço de representação segundo três índices internos. Para silhueta e Calinski-Harabasz, maior é melhor; para Davies-Bouldin, menor é melhor.

Índice	Latente do autoencoder	Latente do multiclasse
Silhueta	−0,0149	0,2299
Calinski-Harabasz	687,8008	2818,231
Davies-Bouldin	4,5592	1,746

Resultado-chave

A silhueta do latente do autoencoder é **negativa** ($-0,0149$): em média, as amostras estão mais próximas de um agrupamento vizinho do que do seu próprio. O latente do multiclasse atinge 0,2299. O índice Calinski-Harabasz é quatro vezes maior e o Davies-Bouldin, dois pontos e meio menor.

A explicação retroativa do Capítulo 9

Silhueta negativa significa que **não há estrutura de classe** no latente do autoencoder. Isso explica, de uma vez, três observações anteriores:
 por que autoencoder, VAE e DCN produziram desempenho equivalente — todos otimizavam reconstrução, e nenhum criava separação;
 por que o agrupamento sobre o material rejeitado alcançou apenas 80,8 % — não há agrupamentos bem definidos para encontrar;
 e por que o refinamento por limiar adaptativo precisou de tanta engenharia — ele estava compensando a ausência de estrutura no espaço subjacente.
 O esforço do Capítulo 9 foi, em boa medida, gasto tentando extrair estrutura de um espaço que não a tinha.

12.4.5 Efeito sobre a classificação

O ganho não se restringe à detecção de novidade. A Tabela 12.4 mostra o desempenho dos classificadores binários — arquitetura idêntica — sobre os três espaços.

Tabela 12.4: Desempenho dos classificadores binários em função do espaço de representação. Média e desvio padrão sobre as classes.

Espaço	ACC	PR	REC	F_1
Latente do multiclasse	0,755 $\pm$ 0,171	0,732 $\pm$ 0,280	0,685 $\pm$ 0,384	0,668 $\pm$ 0,322
Latente do autoencoder	0,697 $\pm$ 0,154	0,697 $\pm$ 0,277	0,530 $\pm$ 0,367	0,559 $\pm$ 0,318
Espaço bruto	0,691 $\pm$ 0,162	0,642 $\pm$ 0,329	0,535 $\pm$ 0,392	0,543 $\pm$ 0,349

A ordem se mantém, mas as diferenças são bem menores — seis pontos percentuais de acurácia entre o melhor e o pior espaço, contra dezenas de pontos na detecção de novidade.

Uma assimetria reveladora

A qualidade do espaço importa muito mais para *detectar o desconhecido* do que para *classificar o conhecido*.

A razão é que um classificador suficientemente expressivo pode compensar uma representação ruim: ele aprende a fronteira onde quer que ela esteja. Um escore de distância não pode — ele depende inteiramente da geometria que lhe é dada.

Corolário prático: se o objetivo é classificar bem o que se conhece, invista no classificador. Se o objetivo é reconhecer o que não se conhece, invista na representação.

Note também os desvios padrão elevados — revocação de $0,685 \pm 0,384$. Um desvio maior que metade da média indica que o desempenho varia enormemente entre classes, o que as tabelas por classe dos capítulos anteriores já mostraram: excelente para as classes 2, 3 e 9, ruim para as classes 4 e 5.

12.5 Balanço da evolução

Resultado-chave

No conjunto das classes avaliadas, a distância de Mahalanobis no espaço latente do classificador multiclasse detecta **95,4 %** das falhas não vistas com **4,5 %** de falsos alarmes — uma melhoria média de 17 % sobre a melhor alternativa anterior.

A Tabela 12.5 resume o percurso da Parte III.

Tabela 12.5: Evolução da detecção de novidade sobre a anomalia de ICV ao longo do livro.

Capítulo	Método	Detecção
Capítulo 7	Erro de reconstrução, limiar $\mu + 3\sigma$	apenas binária
Capítulo 9	Ensemble binário no latente do autoencoder	52,0 %
Capítulo 12	Mahalanobis no espaço bruto	67,5 %
Capítulo 12	Mahalanobis no latente do multiclasse	98,2 %

Uma lição sobre engenharia de sistemas de aprendizado

A progressão de 52 % a 98,2 % não veio de um modelo maior, de mais dados ou de uma arquitetura nova. Veio de duas mudanças conceituais: segmentar em vez de detectar (Capítulo 11) e representar com um classificador em vez de um autoencoder (este capítulo).

Ambas custam pouco em implementação. Ambas exigiram identificar corretamente onde estava o gargalo — e, no caso da representação, foi um resultado *negativo* do Capítulo 9 que apontou o caminho. Resultados negativos, quando reportados, são informação.

12.6 Limitações

1. **Hipótese elíptica.** A distância de Mahalanobis supõe distribuição aproximadamente elíptica, caracterizada por média e covariância. Se a classe conhecida é multimodal — e várias são —, a hipótese é violada e uma mistura de gaussianas ou uma estimativa por vizinhança seria mais adequada.
2. **Ausência de tratamento de deriva.** μ e Σ são estimados uma vez. Poços mudam ao longo de anos, e o método não prevê atualização.
3. **Dependência da segmentação.** Todo o desempenho pressupõe segmentos bem delimitados. Nos poços em que a U-Net vai mal — B1, com IoU de 56 % —, o escore de novidade é calculado sobre um segmento contaminado.
4. **Variabilidade entre poços.** Persistente, como os desvios padrão da Tabela 12.4 mostram.
5. **Possível confundimento de telemetria.** As representações e os limiares foram aprendidos sobre dados em que valores ausentes, zerados ou congelados podem coincidir com os rótulos. Sem a ablação proposta no Capítulo 18, os resultados medem o protocolo observado, mas não isolam quanto da separação decorre da assinatura física e quanto decorre do processo de aquisição.

6. **Revocação e antecedência.** SoftED de 0,678 e antecedência de 0,222 permanecem inalteradas por este capítulo, que atua sobre a natureza da decisão e não sobre o instante em que ela é tomada.
7. **Classes 5 e 7.** 67,5 % e 52,3 % mesmo no melhor espaço, por razões que são de rótulo e de escala temporal, respectivamente.
8. **Ainda não há explicação.** O sistema agora detecta o desconhecido com 98,2 % de acerto e continua incapaz de dizer uma palavra sobre o que ele é.

O que a Parte III deixa para a seguinte

Ao final desta parte, o sistema sabe *onde* está o evento, sabe *que* ele é desconhecido, e sabe com alta confiança. A única pergunta do Capítulo 1 que permanece inteiramente sem resposta é a terceira: *por quê?*

Resumo do capítulo

A distância de Mahalanobis aplicada ao espaço latente extraído da penúltima camada de um classificador multiclasse detecta 95,4 % das falhas não vistas com 4,5 % de falsos alarmes, contra 67,5 % no espaço bruto e 52 % com o ensemble sobre o latente do autoencoder. Sobre a anomalia de ICV, a detecção salta de 52 % para 98,2 %. A razão é geométrica e mensurável: a silhueta do latente do autoencoder é negativa ($-0,0149$), indicando ausência de estrutura de classe, enquanto a do multiclasse é 0,2299, com Calinski-Harabasz quatro vezes maior e Davies-Bouldin dois pontos e meio menor. A razão de separação entre desconhecidos e conhecidos passa de cerca de $2\times$ no bruto para 12 a $18\times$ no latente, e atinge $186,5\times$ para a classe 8 — que no espaço bruto tinha razão *menor que um*. A qualidade da representação importa muito mais para detectar o desconhecido do que para classificar o conhecido: seis pontos percentuais de acurácia de classificação contra dezenas de pontos de detecção de novidade. Isso explica retroativamente por que autoencoder, VAE e DCN produziram desempenho indistinguível no Capítulo 9. Permanecem em aberto as classes 5 e 7, a antecedência de detecção e — sobretudo — a explicação.

Exercícios

1. Demonstre que a distância de Mahalanobis é invariante a transformações lineares invertíveis do espaço, e que a distância euclidiana não é. Relacione esse fato à superioridade observada da primeira em espaços latentes com escalas heterogêneas.
2. A razão de separação da classe 8 é menor que 1,0 no espaço bruto. Construa um exemplo bidimensional em que amostras de uma classe ausente do treinamento fiquem, em média, mais próximas do centroide dos dados de treinamento do que os próprios dados de treinamento. Que geometria produz esse efeito?
3. **Projeto de reprodução e extensão.** Com acesso aos dados, implemente os três espaços e busque reproduzir a Tabela 12.3, registrando protocolo e divergências. Em seguida, calcule a silhueta do latente de um classificador multiclasse treinado com diferentes números de classes (3, 5, 7, 9). A qualidade do espaço melhora monotonicamente com o número de classes?
4. A hipótese elíptica é violada quando a classe conhecida é multimodal. Implemente uma alternativa baseada em mistura de gaussianas e compare com o Mahalanobis simples sobre

as classes do 3W. Em quais classes o ganho é maior? Isso corresponde à sua expectativa sobre quais classes são multimodais?

5. O limiar é o percentil 95 dos dados conhecidos. Trace a curva de detecção de novidade *versus* taxa de falso alarme variando o percentil de 80 a 99,9, para o espaço bruto e para o latente. Compare as áreas sob as curvas.
6. Argumenta-se que a classe 7 falha por razão de escala temporal e não de representação. Projete um experimento que teste essa hipótese — por exemplo, repetindo a avaliação com janelas progressivamente maiores — e preveja o resultado esperado sob a hipótese e sob sua negação.
7. Proponha um mecanismo de atualização de μ e Σ que acompanhe a deriva lenta do poço sem absorver eventos anômalos. Discuta o compromisso entre taxa de adaptação e risco de o modelo aprender a considerar normal uma degradação progressiva.

Leituras recomendadas

- Lopes et al. (2026a) — o artigo que originou este capítulo.
- Mahalanobis (1936) — o trabalho original que define a distância.
- Rousseeuw (1987), Caliński and Harabasz (1974) — os índices internos usados na comparação de espaços.
- Pimentel et al. (2014) — revisão de detecção de novidade, útil para situar o Mahalanobis entre as alternativas.
- van der Maaten and Hinton (2008) — para a visualização dos espaços latentes, com as ressalvas já discutidas.

Parte IV

A explicabilidade

Capítulo 13

Modelos de linguagem como camada de raciocínio

Objetivos de aprendizagem

Este capítulo não ensina a construir um modelo de linguagem nem desenvolve a arquitetura *transformer* em detalhe; ele apresenta o mínimo necessário para julgar o que essa tecnologia pode e não pode fazer no problema do livro. Ao final, você será capaz de:

- enunciar a equação da atenção e explicar as duas propriedades que ela trouxe — paralelização e caminho curto entre posições;
- explicar o que é uma mistura de especialistas e por que ela reduz o custo de inferência;
- reconhecer os elementos de um *prompt* com saída estruturada e os critérios para validá-la;
- reconhecer os modos de falha característicos de modelos de linguagem — alucinação, sensibilidade ao prompt, ausência de calibração — e as salvaguardas correspondentes;
- posicionar corretamente o papel de um modelo de linguagem em um sistema de monitoramento industrial.

13.1 A pergunta que sobrou

Ao final da Parte III, o sistema delimita o evento e, no experimento com a anomalia de ICV, sinaliza corretamente 98,2% de suas janelas como desconhecidas. O que ele entrega ao operador é, literalmente, isto:

```
{ segmento: [14230, 15870], classe: desconhecida, escore: 0.94 }
```

O operador precisa então abrir as séries temporais, examinar cada sensor, comparar com o regime anterior, lembrar de eventos semelhantes e formar uma hipótese. O sistema fez o trabalho de percepção; todo o trabalho de *interpretação* continua com o humano.

Esta parte do livro investiga se um modelo de linguagem pode assumir parte dessa carga.

O que se está e o que não se está propondo

Não se propõe substituir os modelos numéricos por um modelo de linguagem. Um *transformer* de propósito geral é ruim em séries temporais multivariadas amostradas a

cada segundo, e não há razão para esperar o contrário.

Propõe-se acrescentar uma camada *acima* deles. Os modelos numéricos detectam, segmentam e quantificam; o modelo de linguagem recebe as quantidades resultantes — não os dados brutos — e produz a interpretação. É uma divisão de trabalho por competência, e o restante desta parte a testa empiricamente.

13.2 O *transformer*

13.2.1 Atenção

O mecanismo central, introduzido por Vaswani et al. (2017), é a atenção por produto escalar escalado (Equação (5.14)):

$$\text{Atenção}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}.$$

A leitura intuitiva: cada posição da sequência emite uma consulta (*query*), compara-a com as chaves (*keys*) de todas as demais posições, e agrega os valores (*values*) ponderados pela similaridade. O resultado é que qualquer posição pode acessar qualquer outra em uma única operação — em contraste com uma LSTM, onde a informação precisa atravessar todos os passos intermediários.

O fator $\sqrt{d_k}$ evita que o produto escalar cresça com a dimensão e sature a *softmax*.

Por que isso mudou tudo

Duas propriedades, e nenhuma delas é “o modelo entende linguagem”.

Paralelização. Uma LSTM processa a sequência passo a passo, e o passo t depende do $t - 1$. A atenção computa todas as posições simultaneamente. Isso é o que tornou possível treinar sobre corpora de trilhões de tokens.

Caminho curto. Em uma LSTM, a distância informacional entre duas posições separadas por n passos é $O(n)$. Na atenção, é $O(1)$. Dependências de longo alcance deixam de ser um problema arquitetural.

13.2.2 Da arquitetura ao modelo de linguagem

Empilhando blocos de atenção com camadas densas, normalização e conexões residuais, e treinando o resultado para prever o próximo token (*token*) em um corpus muito grande, obtém-se um modelo de linguagem.

O que emerge desse treinamento — e permanece objeto de debate legítimo — é a capacidade de executar tarefas não vistas explicitamente, quando descritas em linguagem natural. É essa capacidade que este livro explora, com o ceticismo apropriado.

13.3 Mistura de especialistas

Definição 13.1 — Mistura de especialistas

Arquitetura em que a camada densa de cada bloco é substituída por um conjunto de sub-redes especialistas e uma rede de roteamento que seleciona, para cada *token*, apenas um subconjunto pequeno delas. O modelo tem muitos parâmetros no total, mas ativa poucos por inferência.

O modelo usado nesta parte do livro tem aproximadamente **397 bilhões de parâmetros totais** e ativa cerca de **17 bilhões** por *token* — uma fração de aproximadamente 4% (Qwen Team, 2026).

Por que isso importa para uma aplicação industrial

Um modelo denso de 397 bilhões de parâmetros exigiria muito mais memória e computação; sua viabilidade dependeria de hardware, quantização, paralelismo e meta de latência. A mistura de especialistas reduz o custo por *token* ao ativar apenas parte dos parâmetros.

Para o problema deste livro, a consequência prática é que a camada de linguagem pode ser consultada em segundos, contra os 405 ms do ensemble numérico e os segundos ou minutos de histórico das janelas numéricas. Na configuração observada, a camada de raciocínio não dominou a latência; essa conclusão deve ser reavaliada sob carga e com a latência de rede da implantação.

13.4 Como se instrui um modelo de linguagem

13.4.1 Prompt

Definição 13.2 — Prompt

Texto de entrada fornecido ao modelo, contendo instruções, contexto, dados e formato de saída desejado. Diferentemente de um programa, não é executado: é interpretado estatisticamente.

A construção do prompt é a principal alavanca de engenharia disponível, e as decisões relevantes para esta aplicação são quatro.

Papel e escopo.

Declarar explicitamente o papel do modelo — “você é um especialista em análise de dados de poços submarinos” — e, tão importante quanto, seus limites — “julgue apenas com base nas estatísticas fornecidas”.

Conhecimento de domínio explícito.

Não confiar no que o modelo possa ter absorvido durante o pré-treinamento. Os perfis de classe do Capítulo 14 são fornecidos no prompt, de forma explícita e verificável.

Formato de saída estruturado.

Exigir JSON com campos definidos. Isso permite validação automática e integração com o restante do sistema, e é o que separa um experimento de uma peça de software.

Temperatura baixa.

Reduzir a aleatoriedade da amostragem para privilegiar consistência sobre criatividade.

13.4.2 Saída estruturada

O agente do Capítulo 14 produz, para cada segmento:

- três classes candidatas, ordenadas;
- uma justificativa por candidata, referenciando as estatísticas;
- um nível de confiança (*High*, *Medium*, *Low*);

- um nome e uma descrição, caso julgue tratar-se de fenômeno não catalogado.

Por que três candidatas e não uma

Porque uma única resposta força o modelo a comprometer-se, e um modelo que se compromete sob incerteza produz afirmações confiantes e falsas — exatamente a patologia que a Figura 10.1 exibiu para o classificador multiclasse. Três candidatas ordenadas comunicam a estrutura da incerteza. E, como o Capítulo 15 mostrará, a diferença entre acerto na primeira escolha (35,1 %) e nas três primeiras (63,9 %) é grande o bastante para que essa decisão de projeto seja o que separa um sistema inútil de um sistema útil.

13.4.3 Modo de raciocínio

Modelos recentes podem ser instruídos a gerar uma cadeia de raciocínio intermediária antes da resposta final. O ganho, em tarefas que exigem comparação de múltiplas evidências, é consistente; o custo é latência e *tokens*.

Neste trabalho o modo está ativado, com temperatura 0,2, *top-p* 0,7 e limite de 4.096 *tokens*.

Cadeia de raciocínio não é explicação

Distinção importante e frequentemente ignorada. O texto que o modelo gera antes da resposta é uma sequência que aumenta a probabilidade de acerto; não há garantia de que ele descreva o processo computacional efetivamente realizado. Neste sistema, a explicabilidade genuína vem de outro lugar: as estatísticas do Capítulo 14 são calculadas deterministicamente e podem ser verificadas independentemente. A justificativa do modelo é auditável *contra elas*. É essa ancoragem — e não a cadeia de raciocínio — que torna a saída confiável.

13.5 Modos de falha

Um capítulo sobre modelos de linguagem em contexto industrial que não enumere seus modos de falha seria irresponsável.

Alucinação.

O modelo produz afirmações plausíveis e falsas com a mesma fluência com que produz afirmações corretas. Em um contexto onde a saída pode motivar uma intervenção de milhões de dólares, isso é inaceitável sem salvaguarda.

Mitigação adotada: fornecer todas as estatísticas no prompt, restringir a julgamento sobre elas, exigir justificativa que as referencie, e manter o humano como decisor.

Sensibilidade ao prompt.

Reformulações semanticamente equivalentes podem alterar o resultado. Isso compromete a reprodutibilidade.

Mitigação adotada: prompt fixo, versionado e reportado integralmente.

Ausência de calibração.

A confiança declarada pelo modelo não corresponde necessariamente a uma probabilidade. “High” não significa 90 %.

Mitigação adotada: tratar o nível de confiança como ordinal e reportar a acurácia empírica separadamente.

Contaminação de dados.

O 3W é público desde 2019, e um modelo treinado em corpus amplo pode tê-lo visto. Um acerto pode refletir memorização, não raciocínio.

Mitigação adotada: nenhuma completamente satisfatória. É uma limitação declarada, e o Capítulo 15 argumenta a partir dos *padrões* de erro, que memorização não explicaria bem.

Custo e dependência externa.

Inferência em serviço de terceiros implica custo por chamada, latência de rede e dependência operacional.

Mitigação adotada: acionar o modelo apenas sobre segmentos já detectados como anômalos — um punhado por dia, não a cada segundo.

A regra que organiza esta parte do livro

Um modelo de linguagem **nunca decide sozinho** em um sistema de monitoramento industrial. Ele propõe, justifica e ordena hipóteses. A decisão é do operador, e o sistema deve ser projetado para que essa fronteira seja explícita na interface.

13.6 Infraestrutura

O modelo é acessado por um serviço gerenciado de inferência, com os parâmetros resumidos na Tabela 13.1.

Tabela 13.1: Configuração de inferência do agente.

Parâmetro	Valor
Modelo	Qwen3.5-397B-A17B (mistura de especialistas)
Parâmetros totais	≈ 397 bilhões
Parâmetros ativos	≈ 17 bilhões por <i>token</i>
Serviço	NVIDIA NIM
Modo de raciocínio	ativado
Temperatura	0,2
<i>Top-p</i>	0,7
Limite de <i>tokens</i>	4.096
Formato de saída	JSON estruturado

Sobre reprodutibilidade

Modelos servidos por API são atualizados sem aviso, e o mesmo prompt pode produzir saídas diferentes meses depois. Trabalhos que dependem deles devem reportar data de execução, identificador exato do modelo e todos os parâmetros de amostragem — e ainda assim a reprodutibilidade é inferior à de um modelo local. É um custo real da abordagem, e o Capítulo 18 discutirá alternativas.

Resumo do capítulo

Modelos de linguagem baseados em *transformer* devem sua eficácia a duas propriedades do mecanismo de atenção — paralelização completa e caminho informacional de comprimento

constante entre quaisquer posições — e não a qualquer compreensão no sentido humano. A arquitetura de mistura de especialistas permite modelos de centenas de bilhões de parâmetros com custo de inferência de modelos muito menores: o modelo aqui utilizado tem 397 bilhões de parâmetros e ativa 17 bilhões por *token*. A instrução se dá por prompt, cujas decisões de projeto relevantes são declarar papel e escopo, fornecer conhecimento de domínio explicitamente, exigir saída estruturada em JSON e usar temperatura baixa. O agente produz três candidatas ordenadas, com justificativa e confiança por candidata — decisão que se mostrará determinante nos resultados. Os modos de falha característicos são alucinação, sensibilidade ao prompt, ausência de calibração, contaminação de dados de treinamento e dependência de serviço externo; cada um exige salvaguarda explícita. A regra que organiza esta parte: o modelo de linguagem propõe e justifica, nunca decide.

Exercícios

1. Calcule a complexidade computacional da atenção em função do comprimento da sequência n e da dimensão d . Compare com a de uma LSTM. Para que valores de n a atenção deixa de ser vantajosa?
2. Um modelo com 397 bilhões de parâmetros ativa 17 bilhões por *token*. Estime a memória necessária para armazenar os pesos em precisão de 16 bits e a necessária para uma inferência. Discuta as implicações para implantação local em uma unidade de produção.
3. **Atividade com serviço externo.** Escreva um prompt que instrua um modelo a classificar um segmento anômalo de poço a partir de estatísticas fornecidas, com saída em JSON válido. Registre modelo, revisão, data e parâmetros; aplique-o a três segmentos e avalie a estabilidade das respostas ao reformular o prompt sem alterar seu conteúdo semântico.
4. Discuta a afirmação: “a cadeia de raciocínio gerada pelo modelo é uma explicação de sua decisão”. Apresente um argumento contra e proponha um experimento que distinga entre cadeia de raciocínio fiel e cadeia de raciocínio confabulada.
5. Projete um procedimento automático de validação da saída do agente contra as estatísticas fornecidas no prompt — por exemplo, verificar se cada afirmação numérica na justificativa corresponde a um valor efetivamente presente na entrada. Que fração das alucinações esse procedimento capturaria?
6. O 3W é público desde 2019 e pode ter sido visto durante o pré-treinamento. Proponha três estratégias para estimar o grau de contaminação e discuta os limites de cada uma.
7. Compare o custo total de propriedade de três arquiteturas: modelo servido por API, modelo aberto executado localmente, e modelo aberto ajustado ao domínio. Considere custo por inferência, latência, reprodutibilidade, privacidade dos dados e esforço de manutenção.

Leituras recomendadas

- Vaswani et al. (2017) — o artigo que introduz o *transformer*.
- Qwen Team (2025) — os fundamentos da família Qwen3; Qwen Team (2026) — a ficha oficial da versão Qwen3.5-397B-A17B utilizada nos experimentos.
- Lopes et al. (2026b) — o trabalho que originou esta parte do livro.
- Liu et al. (2024) e Chebbi and Kolade (2025) — aplicações de modelos de linguagem no setor de petróleo e gás.

- Sharma and Mehta (2025) — explicabilidade em sistemas baseados em agentes.
- Zhang et al. (2025) — modelos de linguagem aplicados a detecção de falhas em séries temporais.

Capítulo 14

A camada de agente

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- descrever uma cadeia de pré-processamento que produza sinais comparáveis entre poços;
- calcular as treze métricas por sensor que traduzem um segmento anômalo em descrição quantitativa;
- descrever a construção de perfis estatísticos de classe robustos a valores extremos;
- reconhecer a estrutura do *prompt* de um agente de diagnóstico e os critérios de validação de sua saída;
- explicar por que a tradução para linguagem intermediária é o que torna a camada de linguagem viável.

14.1 O problema de tradução

Um modelo de linguagem não recebe séries temporais. Ele recebe texto.

A questão central deste capítulo é, portanto, uma questão de tradução: como converter um segmento anômalo — centenas de amostras, quatro sensores — em uma descrição textual que preserve a informação diagnóstica e seja compreensível pelo modelo.

Duas abordagens ingênuas falham de imediato. Despejar os números brutos no prompt gasta milhares de *tokens* em informação de baixíssima densidade, e o modelo não é bom em extrair padrões de listas longas de floats. Descrever qualitativamente — “a pressão subiu” — perde a magnitude, a velocidade e a relação entre sensores.

A solução: uma linguagem intermediária

Calcular deterministicamente um conjunto pequeno de métricas interpretáveis, e apresentar ao modelo essas métricas em vez dos dados.

A escolha tem três consequências que valem ser explicitadas.

Auditabilidade. As métricas são calculadas por código verificável. Qualquer afirmação do modelo pode ser confrontada com elas.

Economia. Treze números por sensor, contra centenas de amostras.

Transferência de responsabilidade. O trabalho de percepção fica com os métodos

numéricos — que são bons nisso — e o de interpretação com o modelo de linguagem. O preço é que *o que as métricas não capturam está perdido*. A escolha das métricas é, portanto, a decisão de projeto mais consequente desta parte do livro.

14.2 Pré-processamento

A cadeia tem quatro etapas, nesta ordem.

1. **Padronização por *escore-z***. Cada sensor é centrado e escalado pela média e pelo desvio padrão de sua referência. O conjunto usado para ajustar esses parâmetros deve ser registrado para impedir vazamento e definir o que significa “regime normal”.
2. **Normalização Min-Max para $[0, 1]$** . Acomoda a entrada ao intervalo usado pelo restante da cadeia. Se seus limites forem ajustados sobre as mesmas amostras da etapa anterior, a composição é equivalente à normalização Min-Max direta; para ter efeito adicional, as duas etapas precisam usar referências de ajuste distintas e exclusivas do treinamento.
3. **Remoção de ruído por *wavelet***. Transformada de Daubechies db4, nível 3, com limiarização suave.
4. **Tratamento de valores ausentes**. Conforme o Capítulo 3.

Por que db4, nível 3, limiar suave

A escolha não é arbitrária, e cada componente responde a uma exigência do problema. **Daubechies 4** tem suporte compacto e quatro momentos nulos — suficiente para representar bem transições abruptas, como o fechamento de uma válvula, sem introduzir os artefatos oscilatórios que uma base mais suave produziria.

Nível 3 remove três oitavas de alta frequência. Em sinais amostrados a cada segundo, isso elimina ruído de instrumentação preservando dinâmicas de dezenas de segundos.

Limiarização suave encolhe os coeficientes em vez de zerá-los, evitando as descontinuidades que a limiarização dura introduz — descontinuidades que seriam interpretadas pelas métricas de *slope* e *rate* como eventos reais.

14.2.1 Seleção de instâncias

Uma decisão metodológica com consequência direta sobre a interpretação dos resultados:

- usam-se **apenas instâncias de poços reais** (WELL);
- instâncias simuladas são acrescentadas somente quando uma classe tem menos de trinta instâncias reais;
- instâncias desenhadas à mão (DRAWN) são **sempre excluídas**.

A justificativa: o objetivo é avaliar a capacidade de interpretar fenômenos físicos reais. Uma instância desenhada à mão contém a assinatura que um especialista *acredita* que o evento tem — e um acerto sobre ela mediria concordância com a intuição do anotador, não com a física.

14.3 As treze métricas

Para cada sensor, comparam-se dois trechos: o regime de base (*baseline*), anterior ao evento, e o regime do evento (*event window*), delimitado pela segmentação do Capítulo 11. Sejam $\bar{b}$ e σ_b a média e o desvio padrão do primeiro, e $\bar{e}$ e σ_e os do segundo.

14.3.1 Métricas de deslocamento

$$\delta = \bar{e} - \bar{b}, \quad (14.1)$$

$$\text{variação percentual} = 100 \frac{\delta}{|\bar{b}|}, \quad (14.2)$$

$$z = \frac{|\delta|}{\max(\sigma_b, 10^{-6})}. \quad (14.3)$$

As três métricas dizem coisas diferentes

Uma pressão que sobe 5 bar sobre uma base de 200 bar com desvio padrão de 0,5 bar tem $\delta = 5$, variação percentual de 2,5 % e $z = 10$.

O deslocamento absoluto é pequeno. A variação percentual é desprezível. E o escore- z de 10 indica um evento estatisticamente extraordinário.

É por isso que as três são fornecidas ao modelo. Cada uma responde a uma pergunta: “quanto mudou?”, “mudou muito em relação ao nível?” e “mudou muito em relação ao que costuma variar?”. A última é quase sempre a diagnóstica, e é a que um humano examinando o gráfico tende a subestimar.

O termo $\max(\sigma_b, 10^{-6})$ protege contra divisão por zero quando o sensor está congelado — situação frequente, como o Capítulo 3 discutiu.

14.3.2 Métricas categóricas

Três métricas convertem grandezas contínuas em categorias verbais, que o modelo de linguagem manipula melhor que números.

Métrica	Categoria	Critério
direction	<i>increase</i>	$\delta > 0,5 \sigma_b$
	<i>decrease</i>	$\delta < -0,5 \sigma_b$
	<i>stable</i>	caso contrário
magnitude	<i>small</i>	$z < 1$
	<i>moderate</i>	$1 \leq z < 3$
	<i>large</i>	$z \geq 3$
rate	<i>sudden</i>	$ \text{inclinação} > 0,01$
	<i>fast</i>	$ \text{inclinação} > 0,002$
	<i>gradual</i>	caso contrário

Categorizar é uma decisão, não uma conveniência

Fornecer “a pressão aumentou de forma súbita e de grande magnitude” em vez de “ $\delta = 4,7$, $z = 8,2$, inclinação = 0,031” facilita o trabalho do modelo, que foi treinado sobre texto e não sobre tabelas numéricas.

O custo é a perda de informação nas fronteiras: $z = 2,99$ e $z = 3,01$ recebem categorias diferentes apesar de serem praticamente idênticos. Por isso as métricas contínuas são

fornecidas *junto* com as categóricas, e não em vez delas. O modelo recebe ambas e pode reconhecer casos de fronteira.

14.3.3 Métricas de forma e variabilidade

- **slope** — inclinação da regressão linear sobre o segmento.
- **behavior** — descrição qualitativa da forma da curva.
- **oscillation_ratio** — razão entre a energia oscilatória do evento e a da base. Discrimina golfadas de deslocamentos monotônicos.
- **noise_ratio** = σ_e/σ_b — razão entre desvios padrão.
- **event_range** — amplitude do segmento.
- **baseline_mean** e **event_mean** — os níveis absolutos.

Por que fornecer os níveis absolutos

As demais doze métricas são relativas, e há um bom motivo: elas precisam ser comparáveis entre poços. Mas há informação diagnóstica no valor absoluto que o relativo apaga.

Uma temperatura de fundo de 4 °C está próxima da condição de formação de hidrato; uma de 60 °C não está, e nenhuma variação relativa comunica isso. Fornecer **baseline_mean** e **event_mean** permite ao modelo aplicar conhecimento físico sobre faixas absolutas — exatamente o tipo de raciocínio que os métodos numéricos dos capítulos anteriores não fazem.

14.3.4 Métricas entre sensores

As treze métricas descrevem cada sensor isoladamente. Mas o Capítulo 2 insistiu que a informação diagnóstica está frequentemente na *relação* entre sensores. Duas métricas adicionais capturam isso:

- **relação P-PDG × P-TPT**, com três valores possíveis: *same_direction*, *diverging*, ou *one_stable_or_both_stable*;
- **sensor dominante**, aquele com maior $|z|$.

Exemplo 14.1 — Por que a divergência é diagnóstica

Considere duas situações.

Primeira: P-PDG e P-TPT caem juntas. O poço inteiro está despressurizando — é consistente com uma redução de produção, uma restrição a jusante, ou uma parada.

Segunda: P-PDG sobe enquanto P-TPT cai. As duas pressões estão divergindo, o que só é fisicamente possível se algo entre elas mudou — tipicamente uma restrição ou o fechamento de uma válvula na coluna.

O valor absoluto de cada pressão pode ser idêntico nos dois casos. É a relação que distingue, e nenhuma métrica por sensor a captura.

14.4 Perfis de classe

O modelo precisa saber contra o que comparar. Para cada classe conhecida constrói-se um perfil estatístico a partir das instâncias de treinamento.

14.4.1 Remoção de valores extremos em duas passagens

Um perfil contaminado por uma instância atípica descreve mal a classe. A depuração usa o critério do intervalo interquartil em duas passagens, com rigor crescente:

1. primeira passagem com $k = 3,0$ — remove apenas extremos grosseiros;
2. segunda passagem com $k = 1,5$ — refina sobre a distribuição já limpa.

Por que duas passagens e não uma com $k = 1,5$

Porque quartis são estimados a partir dos próprios dados. Um único valor muito extremo desloca o terceiro quartil e, com ele, o limite superior — fenômeno conhecido como mascaramento. Aplicar $k = 1,5$ diretamente pode não remover o extremo que corrompeu a estimativa.

Removendo primeiro os extremos grosseiros com $k = 3,0$, os quartis da segunda passagem são estimados sobre dados mais limpos, e o critério mais rigoroso opera sobre uma referência confiável. É um procedimento simples e frequentemente esquecido.

14.4.2 Composição do perfil

Cada perfil contém quatro elementos:

Comportamento macro.

Padrão agregado ao longo de todo o evento.

Comportamento local.

Padrão nos instantes iniciais — útil para detecção precoce.

Conhecimento de domínio.

Descrição física do mecanismo, redigida a partir da literatura e da experiência operacional. É a única parte não derivada dos dados, e é deliberadamente explícita: não se confia no que o modelo possa ter absorvido durante o pré-treinamento.

Características distintivas.

O que separa esta classe das mais parecidas com ela.

O último elemento é o mais importante

As três primeiras seções descrevem a classe. A quarta descreve suas *fronteiras*.

Uma classe descrita isoladamente permite ao modelo reconhecer compatibilidade; descrita em contraste com suas vizinhas, permite discriminar. Como o Capítulo 15 mostrará, a maior parte dos erros do agente é entre classes fisicamente vizinhas — e é exatamente essa seção do perfil que ataca esse modo de falha.

14.5 O prompt

A estrutura final entregue ao modelo:

Seção	Conteúdo
Papel	especialista em análise de dados de poços submarinos
Escopo	julgar apenas com base nas estatísticas fornecidas
Perfis	as nove classes, com os quatro elementos acima
Evidência	as treze métricas por sensor, mais as métricas entre sensores
Tarefa	ordenar três candidatas; justificar; avaliar confiança
Novidade	se nenhuma classe servir, nomear e descrever o fenômeno
Formato	JSON com campos especificados

A saída é validada automaticamente: JSON bem formado, exatamente três candidatas, classes pertencentes ao conjunto declarado, confiança em $\{High, Medium, Low\}$.

O que este projeto *não* inclui — e por quê

Não há ajuste fino do modelo, não há aprendizado com exemplos no prompt, não há múltiplas passagens com agregação de votos, não há uso de ferramentas externas pelo agente.

Cada uma dessas técnicas provavelmente melhoraria os resultados. A omissão é deliberada: o objetivo é estabelecer uma **linha de base honesta** para o que um modelo de propósito geral, sem qualquer adaptação, consegue fazer nesta tarefa. Os números do Capítulo 15 devem ser lidos como piso, não como teto.

14.6 A arquitetura completa

Vale, ao final desta descrição, situar a camada de agente no sistema inteiro.

1. A U-Net segmenta o sinal e delimita a região anômala (Capítulo 11).
2. O classificador multiclasse produz a representação latente (Capítulo 12).
3. A distância de Mahalanobis decide se o segmento é conhecido ou novidade.
4. As métricas deste capítulo são calculadas sobre o segmento.
5. O agente recebe métricas e perfis, e produz hipóteses justificadas.
6. O operador decide.

Cada camada depende da anterior

A cadeia é sequencial, e isso significa que erros se propagam. Se a segmentação erra as fronteiras — como no poço B1, com IoU de 56 % —, as métricas dos passos 4 são calculadas sobre um segmento contaminado, e a interpretação do agente parte de premissas erradas.

É a razão pela qual o Capítulo 11 foi apresentado como pré-requisito da explicabilidade, e não como um refinamento independente.

Resumo do capítulo

A camada de agente resolve um problema de tradução: converter um segmento anômalo em descrição textual que preserve informação diagnóstica. A solução é uma linguagem intermediária de treze métricas por sensor — deslocamento absoluto, variação percentual, escore- z , inclinação, direção, magnitude, velocidade, comportamento, razão de oscilação, razão de ruído, amplitude e os dois níveis médios — acrescidas de duas métricas entre sensores, entre as quais a relação entre P-PDG e P-TPT. Métricas contínuas e categóricas são fornecidas simultaneamente, para que o modelo reconheça casos de fronteira. O pré-processamento aplica padronização e normalização Min-Max com referências de ajuste que precisam ser registradas, além de remoção de ruído por *wavelet* db4 nível 3 com limiarização suave, e usa apenas instâncias de poços reais. Os perfis de classe, depurados por remoção de extremos em duas passagens com $k = 3,0$ e depois $k = 1,5$, contêm comportamento macro, comportamento local, conhecimento de domínio explícito e — o elemento decisivo — as características que distinguem a classe de suas vizinhas. O agente recebe perfis e evidência, e produz três candidatas ordenadas com justificativa e confiança, em JSON validado. Não há ajuste fino nem agregação de múltiplas passagens: os resultados do próximo capítulo são um piso.

Exercícios

1. **Projeto de extensão.** Implemente as treze métricas e aplique-as a instâncias de cada classe do 3W. Construa uma matriz de correlação entre elas: quais são redundantes? Proponha um subconjunto mínimo que preserve a capacidade discriminativa.
2. O escore- z usa $\max(\sigma_b, 10^{-6})$. Analise o comportamento da métrica quando o sensor de base está congelado ($\sigma_b = 0$) mas o evento apresenta variação. O valor resultante é informativo ou é um artefato? Proponha um tratamento alternativo.
3. As categorias de **magnitude** usam fronteiras em $z = 1$ e $z = 3$. Justifique essas escolhas sob a hipótese de normalidade e discuta o que acontece quando ela é violada. Proponha fronteiras baseadas em quantis empíricos e compare.
4. Implemente a remoção de extremos em duas passagens e compare com uma única passagem com $k = 1,5$. Construa um conjunto sintético em que o mascaramento ocorra e quantifique a diferença nos perfis resultantes.
5. Projete uma métrica adicional entre sensores que capture a defasagem temporal entre a resposta de P-PDG e a de P-TPT. Que classes ela ajudaria a discriminar? Implemente-a e verifique empiricamente.
6. **Atividade com serviço externo.** Escreva o prompt completo descrito neste capítulo, registre modelo, revisão, data e parâmetros, e submeta o mesmo segmento vinte vezes com temperatura 0,2. Meça a variabilidade da saída. Repita com temperatura 0,0 e 0,7 e discuta o compromisso entre consistência e diversidade de hipóteses.
7. Argumenta-se que instâncias desenhadas à mão devem ser excluídas porque medem concordância com a intuição do anotador. Construa o argumento contrário: em que circunstâncias avaliar sobre instâncias sintéticas seria legítimo e informativo?

Leituras recomendadas

- Lopes et al. (2026b) — o trabalho que originou este capítulo, com o prompt completo.

- Vargas et al. (2019) e Vaz Vargas et al. (2026) — a descrição do 3W e das proveniências das instâncias.
- Ma et al. (2024) e Wei et al. (2024) — aplicações de modelos de linguagem a registros e a diagnóstico no setor.
- Belay et al. (2026) — detecção de anomalias com arquiteturas de agente.
- Zhang and Jain (2026) — extração de regras de domínio com modelos de linguagem.

Capítulo 15

O que o agente acerta e o que não acerta

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- interpretar acurácia em três níveis de ordenação e explicar por que a diferença entre elas é informativa;
- avaliar um sistema no papel de validador, distinguindo precisão de revocação nesse contexto;
- analisar convergência de nomes gerados em linguagem natural;
- identificar artefatos de conjunto de dados a partir de padrões nas descrições produzidas;
- derivar uma divisão de trabalho entre modelos numéricos e camada de linguagem a partir de evidência empírica.

15.1 Três estudos, três perguntas

O Capítulo 14 descreveu como o agente é construído. Este capítulo mede o que ele faz, por meio de três estudos independentes que respondem a três perguntas distintas.

1. **Estudo 0 — classificação.** O agente consegue nomear a classe correta a partir apenas das estatísticas?
2. **Estudo 1 — validação.** O agente consegue julgar se a decisão de um classificador numérico está correta?
3. **Estudo 2 — novidade.** O agente consegue reconhecer que um segmento não corresponde a nenhuma classe conhecida?

Adianta-se a conclusão, porque ela organiza a leitura: **o agente é ruim na primeira tarefa, razoável na segunda e bom na terceira.** E essa ordenação, longe de ser um resultado decepcionante, é o que define seu papel correto no sistema.

15.2 Estudo 0: classificação

15.2.1 Protocolo

O agente recebe as métricas de um segmento e os perfis das nove classes, e produz três candidatas ordenadas. Avaliam-se 191 segmentos de poços reais.

Reportam-se três níveis de acurácia: *top-1* (a primeira candidata está correta), *top-2* (a correta está entre as duas primeiras) e *top-3*. Intervalos de confiança de 95 % são de Wilson (Equação (4.10)).

15.2.2 Resultados globais

Tabela 15.1: Acurácia global do agente na tarefa de classificação, com intervalos de confiança de Wilson a 95 %. As linhas de acaso correspondem a escolha aleatória entre nove classes.

Nível	Acurácia	IC 95 %	Acaso
Top-1	35,1 %	[28,7; 42,1]	11,1 %
Top-2	53,4 %	[46,3; 60,3]	22,2 %
Top-3	63,9 %	[56,9; 70,4]	33,3 %

Resultado-chave

O agente acerta a classe na primeira tentativa em 35,1 % dos casos — três vezes o acaso — e a inclui entre as três primeiras em 63,9 %, quase o dobro do acaso. Nenhum desses números é competitivo com os classificadores numéricos, que atingem 0,87 de acurácia (Capítulo 8).

15.2.3 Como não ler estes números

Duas leituras erradas são tentadoras, e ambas devem ser afastadas.

“O agente é inútil.” Ele opera em condições incomparavelmente mais duras: recebe treze métricas por sensor em vez de duzentas amostras por sensor, nunca foi treinado nesta tarefa, e não viu um único exemplo rotulado. Três vezes o acaso, sob essas condições, indica que a linguagem intermediária do Capítulo 14 de fato carrega informação diagnóstica.

“O agente vai substituir os classificadores.” 35,1 % contra 87 % encerra o assunto.

A informação está na diferença entre os níveis

De top-1 para top-3, a acurácia quase dobra: 35,1 % para 63,9 %.

Isso significa que, em cerca de 29 % dos casos, o agente *tem* a resposta certa em mãos e a coloca em segundo ou terceiro lugar. Ele identifica o conjunto plausível de hipóteses e falha em ordená-lo.

É exatamente o perfil de um sistema que deve ser usado como **gerador de hipóteses**, e não como decisor. E é a justificativa empírica da decisão de projeto — tomada antes de conhecer estes resultados — de exigir três candidatas em vez de uma.

15.2.4 Por classe

A dispersão é enorme — de 7,1 % a 86,4 % na primeira escolha — e os extremos são instrutivos.

Tabela 15.2: Acurácia do agente por classe na tarefa de classificação (%).

Cl.	Evento	<i>n</i>	Top-1	Top-2	Top-3
1	Aumento de BSW	15	26,7	40,0	53,3
2	Fechamento de DHSV	22	86,4	90,9	100,0
3	Golfadas severas	32	18,8	53,1	53,1
4	Instabilidade de fluxo	27	18,5	25,9	37,0
5	Perda de produtividade	15	26,7	53,3	66,7
6	Restrição rápida no PCK	15	66,7	66,7	66,7
7	Incrustação no PCK	36	38,9	66,7	83,3
8	Hidrato na produção	15	26,7	53,3	60,0
9	Hidrato no serviço	14	7,1	14,3	42,9

Classe 2, o melhor caso. 86,4 % na primeira escolha e 100 % nas três primeiras. O fechamento de DHSV tem assinatura inequívoca: queda abrupta e simultânea de pressão a montante e a jusante, com direção e magnitude que nenhuma outra classe reproduz. Quando a assinatura é distintiva, treze métricas bastam.

Classe 6, o caso rígido. 66,7 % nos três níveis — valor idêntico. O agente ou acerta de primeira, ou não considera a classe correta em lugar algum. Não há hesitação nem gradação. É o comportamento de um critério determinístico embutido no perfil da classe, que ou é satisfeito ou não é.

Classe 9, o pior caso. 7,1 % na primeira escolha, 42,9 % nas três primeiras. Hidrato na linha de serviço é sistematicamente confundido com hidrato na linha de produção (classe 8) — e não poderia ser diferente: o mecanismo físico é o mesmo, apenas a localização difere, e nenhuma das treze métricas codifica localização.

Um erro que não é do modelo

A confusão entre as classes 8 e 9 não é uma falha de raciocínio. É uma consequência direta da escolha de métricas do Capítulo 14, que foi apresentada lá como “a decisão de projeto mais consequente desta parte do livro”.

O que as métricas não capturam, o modelo não pode inferir. Distinguir 8 de 9 exigiria informação de qual conjunto de sensores está afetado — informação disponível, mas não codificada.

Este é um problema corrigível. Vários dos números baixos desta tabela podem estar medindo a linguagem intermediária, não o agente.

Classes 4 e 5. 18,5 % e 26,7 %. Pela quarta vez neste livro, as classes sintomáticas aparecem no fundo da tabela. A consistência do padrão — em métodos completamente distintos, de ensembles binários a modelos de linguagem — é a evidência mais forte, neste conjunto de dados, de que a taxonomia contribui para a dificuldade; ela não isola essa causa de limitações de representação ou amostragem.

Por essa razão, **as classes 4 e 5 foram excluídas dos Estudos 1 e 2.** Avaliar capacidade de validação sobre rótulos internamente incoerentes mediria a incoerência, não a capacidade.

15.3 Estudo 1: validação

15.3.1 Uma tarefa diferente

Aqui o agente não classifica. Ele recebe a decisão de um classificador numérico e julga se ela é válida, dadas as estatísticas.

A tarefa é intrinsecamente mais fácil — verificar é mais fácil que gerar — e operacionalmente mais valiosa: um sistema que sinaliza quando o classificador provavelmente errou permite ao operador calibrar sua confiança caso a caso.

O conjunto tem 187 casos, sendo 149 decisões corretas e 38 incorretas, distribuídos pelas sete classes não sintomáticas (1, 2, 3, 6, 7, 8 e 9).

15.3.2 Resultados

Tabela 15.3: Desempenho do agente na tarefa de validação.

Métrica	Valor	IC 95 %
Acurácia top-2 global	71,7 % (134/187)	[64,8; 77,6]
confirmação de decisões corretas	71,8 % (107/149)	—
rejeição de decisões incorretas	71,1 % (27/38)	—
Corretas julgadas VÁLIDAS	67,1 % (100/149)	—
Incorretas julgadas INVÁLIDAS	73,7 % (28/38)	—
Precisão	0,909 (100/110)	[0,841; 0,950]
Revocação	0,671	—
Medida F_1	0,772	—

Resultado-chave

Quando o agente declara uma classificação VÁLIDA, ele está certo em **90,9 %** dos casos. E ele rejeita 73,7 % das classificações efetivamente erradas.

15.3.3 Por que a precisão é o número que importa

A assimetria entre precisão (0,909) e revocação (0,671) define o uso operacional correto.

Um selo de VÁLIDO é confiável.

Nove em cada dez são corretos. O operador pode tratá-lo como forte evidência a favor da classificação.

A ausência do selo não é evidência contra.

Cerca de um terço das classificações corretas não recebe confirmação. Um caso não confirmado exige exame; não deve ser descartado.

O uso correto

Este perfil sustenta uma política concreta de triagem. Segmentos com selo de VÁLIDO podem ser processados com menor escrutínio; segmentos sem selo entram na fila de revisão humana.

Como o agente confirma cerca de 59 % do total (110 de 187), essa política reduz em mais da metade o volume que exige atenção detalhada nesta amostra, na qual aproximadamente 9 % das confirmações foram incorretas. Antes do uso operacional,

essa taxa precisa ser estimada prospectivamente e comparada ao custo dos erros. É uma proposta de triagem mensurável, diferente de “a IA classifica os eventos”.

15.3.4 Por classe

Tabela 15.4: Desempenho do agente na validação, por classe (%). “Val. OK” é a fração de decisões corretas julgadas válidas; “Val. Rej.” é a fração de decisões incorretas julgadas inválidas.

Cl.	Conf. top-1	Conf. top-2	Erradas rejeitadas	Val. OK	Val. Rej.
1	40	53	60	53	60
2	95	95	80	95	80
3	62	62	40	59	60
6	73	73	80	73	80
7	86	89	100	81	100
8	47	60	40	53	60
9	29	43	88	29	75

Duas linhas merecem comentário.

Classe 7. Rejeita 100 % das classificações erradas e confirma 81 % das corretas. É o melhor validador da tabela — notavelmente, para uma classe cuja detecção de novidade atingia apenas 52,3 % no Capítulo 12. As competências não são as mesmas.

Classe 9. Confirma apenas 29 % das corretas, mas rejeita 88 % das erradas. O agente é um péssimo confirmador e um excelente cético para essa classe.

Especialização por classe, medida e não postulada

As Tabelas 15.2 e 15.4 juntas permitem atribuir a cada classe o papel em que o agente é efetivamente bom:

classes 2 e 7 — confirmar, justificar e validar;

classes 1, 3, 6 e 8 — segunda opinião e nomeação de novidades;

classe 9 — cético, acionado apenas para rejeitar;

classes 4 e 5 — sinalizador sintomático, com reordenação das três candidatas para o operador.

Essa atribuição não foi decidida a priori. Ela foi extraída dos dados, e o Capítulo 16 a incorporará à arquitetura de referência.

15.4 Estudo 2: detecção de novidade

15.4.1 Protocolo

Para cada classe, o agente recebe os perfis das *demaís* classes — nunca o da classe do segmento — e deve reconhecer que nenhuma delas se aplica, além de propor um nome e uma descrição. São 611 segmentos.

15.4.2 Resultados

Intervalo de confiança de Wilson a 95 %: [87,0; 91,9].

Tabela 15.5: Taxa de reconhecimento de novidade pelo agente nas sete classes não sintomáticas avaliadas.

Classe ocultada	Acertos	Taxa
1	51/72	70,8 %
2	99/99	100,0 %
3	103/123	83,7 %
6	67/70	95,7 %
7	166/175	94,9 %
8	56/61	91,8 %
9	6/11	54,5 %
Global (7 classes)	548/611	89,7 %

Resultado-chave

Nas sete classes não sintomáticas, o agente reconhece corretamente que um segmento não pertence a nenhuma das classes apresentadas em **89,7 %** dos casos — contra 35,1 % de acerto quando precisa nomear a classe correta.

A assimetria central deste livro

35,1 % para dizer o que algo é. 89,7 % para dizer que não é nada conhecido. A mesma assimetria apareceu no Capítulo 9, quando o peso ótimo da OCSVM na decisão de rejeição (0,74) inverteu-se em relação às decisões de reconhecimento. Ela reaparece aqui, em um sistema de natureza completamente diferente. Isso levanta a hipótese de que reconhecer incompatibilidade seja mais fácil que estabelecer identidade: uma evidência contraditória pode descartar uma classe, enquanto afirmar identidade exige convergência. Como tarefas, amostras e denominadores diferem, a comparação não demonstra que a assimetria seja propriedade universal do problema.

15.5 Os nomes gerados

Ao rejeitar, o agente propõe um nome. A Tabela 15.6 apresenta os nomes consolidados por classe.

Tabela 15.6: Nomes consolidados propostos pelo agente para cada classe apresentada como desconhecida.

Cl.	Nome consolidado
1	<i>Wellhead Thermal-Pressure Surge</i> (sem convergência)
2	<i>Downhole Isolation Event with Wellhead Depressurization</i>
3	<i>Production Rate Surge with Cyclic Pressure Decline</i>
6	<i>Downhole Telemetry Loss with Dual Pressure Surge</i>
7	<i>Downhole Telemetry Loss with Wellhead Pressure Buildup</i>
8	<i>Flow Restriction with Thermal Cooling and Telemetry Loss</i>
9	Sem convergência (seis nomes distintos)

15.5.1 O acerto notável

Para a classe 2, o agente — que nunca viu o rótulo “fechamento espúrio de DHSV” — produziu *Downhole Isolation Event with Wellhead Depressurization*.

Traduzindo: “evento de isolamento de fundo com depressurização na cabeça”. É uma descrição fisicamente correta do fechamento espúrio da DHSV. O agente não recuperou o nome; ele o *reconstruiu* a partir do comportamento dos sensores.

Por que isso importa mais que a taxa de acerto

Um sistema que rejeita produz um balde de segmentos sem nome — foi a limitação com que o Capítulo 9 terminou. Um sistema que rejeita *e propõe uma descrição fisicamente plausível* produz uma hipótese que o especialista pode confirmar ou corrigir em minutos, em vez de horas de análise.

É a diferença entre “grupo 11, $n = 340$ ” e “possível evento de isolamento de fundo com depressurização na cabeça”. A segunda saída é acionável.

15.5.2 A não convergência

A classe 1 produziu **51 nomes únicos** em suas 51 rejeições. A análise dos termos mostra dispersão: *thermal* aparece 16 vezes, *pressure* 13, *wellhead* 10, *surge* 10. O nome consolidado da Tabela 15.6 é uma síntese posterior, não um consenso do agente.

A classe 9 produziu seis nomes distintos em seis rejeições.

A não convergência é um sinal útil

Quando o agente converge para um nome, há estrutura reconhecível. Quando cada segmento gera um nome diferente, o agente está confabulando — e isso pode ser **medido** automaticamente, sem rótulos.

Propõe-se, portanto, a taxa de convergência de nomes como *métrica de confiança não supervisionada*: agrupar as descrições geradas e medir sua concentração. Alta concentração indica descoberta genuína; alta dispersão indica que a saída não deve ser apresentada ao operador como hipótese.

15.5.3 O achado incômodo

Quatro das sete classes — 2, 6, 7 e 8 — receberam nomes contendo *telemetry loss*, perda de telemetria.

Isso não é uma característica física dos eventos. É um artefato do 3W: em muitas instâncias, o início da anomalia coincide com sensores de fundo reportando NaN ou zero. O agente descreveu corretamente o que *está nos dados*, e o que está nos dados inclui uma correlação espúria entre anomalia e falha de telemetria.

Quando o modelo revela o conjunto de dados

O Capítulo 3 já havia alertado, na Seção 3.4.4, para essa correlação. O que este resultado acrescenta é que ela é **forte o bastante para dominar a descrição gerada** de quatro classes distintas.

A implicação é séria: qualquer modelo treinado no 3W pode estar aprendendo, em parte, a detectar falha de telemetria em vez de detectar a anomalia. Os resultados de todos os capítulos anteriores deste livro devem ser lidos com essa ressalva.

E há uma lição metodológica geral: um sistema que descreve o que vê em linguagem

natural funciona como instrumento de auditoria do conjunto de dados. Nenhuma das matrizes de confusão dos capítulos anteriores tornou esse artefato visível.

15.6 Limitações

1. **Ausência de estudos de ablação.** Não se avaliou a contribuição individual de cada métrica, nem se comparou com métodos de atribuição como SHAP ou gradientes integrados.
2. **Ausência de ajuste fino.** Modelo de propósito geral, sem adaptação ao domínio.
3. **Passagem única de inferência.** Sem agregação de múltiplas amostragens, que tipicamente melhora consistência.
4. **Apenas dados públicos.** Somente o 3W, com todos os seus artefatos.
5. **Confundimento de telemetria.** Discutido acima; afeta quatro das sete classes avaliadas.
6. **Amostras pequenas por classe.** A classe 9 tem $n = 11$ no Estudo 2. Os intervalos de confiança correspondentes são largos.
7. **Possível contaminação.** O 3W é público desde 2019.

Por que os resultados ainda sustentam a conclusão

A objeção mais séria é a contaminação: o modelo poderia estar recuperando conhecimento memorizado sobre o 3W, e não raciocinando.

Três observações tornam a memorização pura uma explicação incompleta. Primeiro, se ela dominasse o resultado, seria razoável esperar acurácia de classificação alta, não 35,1 %. Segundo, os erros seguem padrões fisicamente coerentes — a confusão entre as classes 8 e 9 corresponde a mecanismos idênticos, o que memorização de rótulos não produziria. Terceiro, os nomes gerados não reproduzem a nomenclatura do 3W; eles a reconstroem em vocabulário próprio.

Essas observações não medem contaminação nem excluem sua contribuição. Sustentam apenas que ela, isoladamente, não explica todos os padrões observados.

Resumo do capítulo

Três estudos medem o agente. Na classificação, ele acerta 35,1 % na primeira escolha e 63,9 % nas três primeiras — três vezes o acaso, e muito abaixo dos 87 % dos classificadores numéricos; a diferença entre os níveis mostra que ele identifica o conjunto plausível de hipóteses e falha em ordená-lo, o que o caracteriza como gerador de hipóteses. Na validação, obtém precisão de 0,909 com revocação de 0,671: um selo de VÁLIDO é confiável, sua ausência não é evidência contra, e isso sustenta uma política de triagem que reduz à metade o volume de revisão humana. Na detecção de novidade, atinge 89,7 % — a assimetria entre 35,1 % para afirmar identidade e 89,7 % para reconhecer incompatibilidade reaparece aqui em um sistema completamente distinto daquele do Capítulo 9, sugerindo tratar-se de um padrão a testar em avaliações controladas. Os nomes gerados convergem para descrições consideradas fisicamente plausíveis na análise qualitativa em cinco das sete classes, com destaque para a classe 2 — *Downhole Isolation Event with Wellhead Depressurization* —, e a taxa de convergência é proposta como métrica de confiança não supervisionada. Quatro classes receberam nomes contendo “perda de telemetria”, levantando a hipótese de um artefato do 3W forte o bastante para dominar a descrição e exigir ressalva sobre os resultados que usam esse conjunto.

Exercícios

1. Calcule os intervalos de confiança de Wilson para todas as taxas da Tabela 15.5. Para quais classes o intervalo é largo o bastante para tornar a comparação entre elas inconclusiva?
2. O agente acerta 35,1 % em top-1 e 63,9 % em top-3. Modele o processo como ordenação de nove candidatas e estime a distribuição da posição da resposta correta. Que fração da massa está além da terceira posição?
3. A precisão de 0,909 com revocação de 0,671 sustenta uma política de triagem. Formalize essa política, estime a redução de carga de revisão em função do volume diário de segmentos e calcule o risco residual.
4. Implemente a métrica de convergência de nomes proposta no capítulo: agrupe descrições geradas por similaridade semântica e meça a concentração. Valide-a verificando se ela distingue as classes 2 e 9.
5. A confusão entre as classes 8 e 9 é atribuída à ausência de informação de localização nas métricas. Proponha duas métricas adicionais que a codifiquem e preveja o efeito sobre a acurácia top-1 da classe 9.
6. Projete um experimento que quantifique o efeito do confundimento de telemetria: por exemplo, remover instâncias em que a anomalia coincide com valores ausentes e repetir a avaliação. Quanta acurácia você espera perder, e por quê?
7. Argumente a favor e contra a afirmação: “a contaminação do conjunto de dados de treinamento invalida estes resultados”. Proponha um conjunto de avaliação que resolveria definitivamente a questão e discuta a viabilidade de construí-lo.

Leituras recomendadas

- Lopes et al. (2026b) — o trabalho que originou este capítulo, com os três estudos completos.
- Wilson (1927) — o intervalo de confiança usado em todas as taxas.
- Vaz Vargas et al. (2026) — a versão 2.0 do 3W, com discussão sobre qualidade dos dados relevante ao artefato de telemetria.
- Sharma and Mehta (2025) e Belay et al. (2026) — trabalhos contemporâneos sobre agentes e explicabilidade em detecção de anomalias.

Parte V

Síntese e prática

Capítulo 16

Síntese: uma arquitetura de referência

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- reconstruir a trajetória metodológica completa e identificar o que produziu cada salto de desempenho;
- consolidar resultados heterogêneos em uma visão comparável;
- derivar, a partir da evidência, qual componente deve ser usado para qual tarefa;
- avaliar criticamente uma arquitetura de referência que integre modelos numéricos e camada de linguagem;
- enunciar os princípios de projeto que o percurso deste livro sustenta.

16.1 Onde chegamos

Este livro contou uma história em quatro atos.

No primeiro, a avaliação publicada do sistema dual — regras e autoencoder — reportou operação em mais de duzentos e cinquenta poços e estudos de caso com eventos fora do catálogo. O sistema detectava desvios, mas não sabia dizer o que via.

No segundo, o ensemble de classificadores binários trocou a pergunta “qual das nove classes?” pela pergunta “é esta? sim ou não”, e com isso tornou expressável a resposta “nenhuma delas”. O experimento da classe escondida deu 89 %.

No terceiro, duas mudanças conceituais — segmentar em vez de detectar, e representar com um classificador em vez de um autoencoder — levaram a detecção de novidade de 52 % a 98,2 %.

No quarto, uma camada de linguagem recebeu as estatísticas do segmento e produziu hipóteses justificadas, reconstruindo descrições fisicamente corretas de eventos cujo nome nunca lhe foi apresentado.

Este capítulo consolida o percurso e propõe a arquitetura que ele sustenta.

Tabela 16.1: Marcos de desempenho e a mudança conceitual responsável por cada um.

Capítulo	Mudança conceitual	Resultado	Custo
Capítulo 7	Combinar regras determinísticas com aprendizado não supervisionado	ACC 0,9727 → 0,9894	Duas bases de código
Capítulo 8	Escores independentes em vez de <i>softmax</i> acoplada	Rejeição torna-se expressável	9× o treinamento
Capítulo 10	Validar a rejeição com classe escondida	89 % de rejeição	Nenhum
Capítulo 9	Organizar o rejeitado em classes virtuais	80,8 % de agrupamento	Muita engenharia
Capítulo 11	Segmentar em vez de detectar	ACC 0,500 → 0,863; desvio 0,187 → 0,082	Anotação por amostra
Capítulo 12	Representar com classificador, não com autoencoder	Novidade 52 → 98,2 %	Reusar o latente treinado
Capítulo 15	Descrever em linguagem natural	89,7 % de novidade; nomes fisicamente corretos	Serviço externo

16.2 O que produziu cada ganho

Ganhos grandes vieram de mudanças conceituais simples

Trocar o autoencoder pelo latente do classificador multiclasse elevou a detecção de novidade em quarenta e seis pontos percentuais neste protocolo. A alteração de inferência é pequena, mas depende do custo anterior de treinar e validar o classificador. Segmentar em vez de detectar elevou a acurácia em trinta e seis pontos e reduziu a variância entre poços em mais da metade. Exigiu uma arquitetura nova, mas nenhuma novidade arquitetural — a U-Net é de 2015 — e aumentou o custo de anotação por amostra.

Em contraste, o ciclo de mundo aberto do Capítulo 9 — estimativa automática de K , interseção entre dois algoritmos de agrupamento, limiar adaptativo com três regimes, salvaguarda de dois terços — exigiu esforço de engenharia desproporcional ao seu resultado, porque operava sobre um espaço sem estrutura de classe.

A lição é geral e vale ser lembrada: **antes de sofisticar o método, verifique o espaço em que ele opera.**

Tabela 16.2: Detecção de novidade ao longo do livro. Valores em porcentagem. Traços indicam que a combinação não foi avaliada.

Classe	Ens. bin. latente AE	Mahal. bruto	Mahal. latente MC	Agente LLM
1	22,8	41,5	99,0	70,8
2	76,9	77,1	96,5	100,0
3	48,1	61,0	99,0	83,7
4	44,7	57,8	96,0	—
5	0,1	62,3	67,5	—
6	47,6	47,6	99,0	95,7
7	36,5	36,7	52,3	94,9
8	50,5	91,1	99,0	91,8
9	51,9	88,7	99,0	54,5
ICV	52,0	67,5	98,2	—
Global	—	—	95,4	89,7

16.3 Resultados consolidados

16.3.1 Detecção de novidade

A linha mais interessante da tabela é a da classe 7

A incrustação no PCK é o pior caso do Mahalanobis latente (52,3 %) — e um dos melhores do agente (94,9 %).

A explicação está na natureza da evidência. O método geométrico enxerga uma janela de duzentos passos e não encontra desvio suficiente, porque a incrustação se desenvolve ao longo de semanas. O agente recebe a *tendência* — a inclinação, a razão de oscilação, a comparação com o regime de base — que já é uma síntese temporal, e reconhece o padrão.

Não é que um método seja melhor. É que eles falham em situações diferentes, e isso é precisamente o que torna a combinação valiosa.

Vale registrar a simetria: para a classe 9, a relação se inverte — 99,0 % do Mahalanobis contra 54,5 % do agente. A complementaridade é bidirecional.

16.3.2 Classificação

Tabela 16.3: Acurácia de classificação por abordagem.

Capítulo	Abordagem	Acurácia global
Capítulo 8	Ensemble binário (espaço bruto)	0,87
Capítulo 8	Multiclasse (espaço bruto)	0,86
Capítulo 12	Binários no latente do multiclasse	$0,755 \pm 0,171$
Capítulo 9	Binários no latente do autoencoder	0,730
Capítulo 8	OCSVM (espaço bruto)	0,65
Capítulo 15	Agente, top-3	0,639
Capítulo 15	Agente, top-1	0,351

A ordenação é inequívoca: para classificar o conhecido, os métodos supervisionados clássicos dominam. O agente fica em último lugar, e a distância não é pequena.

16.3.3 As duas assimetrias

Duas comparações resumem o livro inteiro.

	Afirmar identidade	Reconhecer incompatibilidade
Métodos numéricos	87 %	95,4 %
Agente de linguagem	35,1 %	89,7 %

Duas leituras de uma mesma tabela

Por coluna: nas avaliações apresentadas, reconhecer incompatibilidade obteve taxas maiores que afirmar identidade para *ambas* as famílias de método. Uma explicação plausível é que uma evidência contraditória basta para descartar uma hipótese, enquanto afirmar identidade exige convergência; protocolos e amostras diferentes, contudo, impedem tratar a diferença bruta como comparação causal.

Por linha: os métodos numéricos são melhores nas duas tarefas, mas a diferença é de cinquenta e dois pontos percentuais na primeira e de apenas seis na segunda. É onde a distância é pequena que a contribuição do agente pode ser aproveitada — somada ao fato de que ele, e apenas ele, produz uma descrição.

16.4 Divisão de trabalho por classe

A Tabela 16.4 atribui a cada classe o papel em que cada componente é efetivamente bom, com base na evidência acumulada.

Tabela 16.4: Divisão de trabalho derivada dos resultados. “Numérico” refere-se ao pipeline U-Net + latente do multiclasse + Mahalanobis.

Cl.	Evento	Papel do numérico	Papel do agente
1	BSW	Decisor (99,0 %)	Segunda opinião; nomear novidade
2	DHSV	Decisor (96,5 %)	Confirmar, justificar e validar (95 %)
3	Golfadas	Decisor (99,0 %)	Segunda opinião; nomear novidade
4	Instabilidade	Sinalizador , não classificador	Reordenar as três candidatas para o operador
5	Perda de produtiv.	Sinalizador , não classificador	Reordenar as três candidatas para o operador
6	Restrição PCK	Decisor (99,0 %)	Segunda opinião; nomear novidade
7	Incrustação	Fraco (52,3 %)	Segunda opinião priorizada ; rejeitou 100 % dos erros na amostra
8	Hidrato prod.	Decisor (99,0 %)	Segunda opinião; nomear novidade
9	Hidrato serv.	Decisor (99,0 %)	Cético : acionar apenas para rejeitar (88 %)

Esta tabela não foi decidida; foi medida

Nenhuma das atribuições acima foi postulada a priori. Cada uma decorre de um número reportado nos capítulos anteriores.

Isso é diferente da prática comum de propor uma arquitetura e depois avaliá-la. Aqui a avaliação por classe — que exigiu resistir à tentação de reportar apenas médias globais — produziu a arquitetura.

É o argumento mais forte deste livro a favor de reportar desempenho desagregado.

16.4.1 As classes sintomáticas

As classes 4 e 5 recebem, na Tabela 16.4, um tratamento distinto de todas as demais: elas deixam de ser classes.

A recomendação é que o sistema, ao identificar um segmento compatível com elas, emita “há instabilidade de fluxo; investigue a causa” em vez de “esta é a classe 4”. A primeira saída é verdadeira e útil; a segunda é uma afirmação sobre uma categoria que não é internamente coerente.

O suporte empírico é a consistência com que essas classes falham: 0,69 e 0,79 nos ensembles binários; 67,5% de detecção de novidade para a classe 5 contra mais de 96% das demais; 18,5% e 26,7% de acerto do agente. Quatro métodos independentes, o mesmo resultado.

Uma recomendação para o próprio conjunto de dados

A conclusão que este livro sustenta é que as classes 4 e 5 deveriam ser *redefinidas* no 3W — por mecanismo, e não por sintoma — ou explicitamente marcadas como categorias sintomáticas, para as quais métricas de classificação não são apropriadas.

16.5 A arquitetura de referência**16.5.1 Estrutura em camadas**

1. **Aquisição e validação.** Diagrama de decisão do Capítulo 7: identificação do poço, validação do dado, discriminação de transiente. Determinístico, auditável, funciona no primeiro segundo.
2. **Segmentação.** U-Net unidimensional por sensor (Capítulo 11). Produz a delimitação de que todas as camadas seguintes dependem.
3. **Representação.** Penúltima camada do classificador multiclasse (Capítulo 12). Sessenta e quatro dimensões com estrutura de classe.
4. **Decisão conhecido/novidade.** Distância de Mahalanobis com limiar no percentil 95.
5. **Classificação.** Ensemble binário sobre o latente, para os segmentos julgados conhecidos.
6. **Interpretação.** Métricas do Capítulo 14 e agente de linguagem, para todos os segmentos anômalos.
7. **Decisão.** Operador humano, com as saídas das camadas 4 a 6 apresentadas separadamente.
8. **Incorporação.** Ciclo de classes virtuais (Capítulo 9), agora sobre um espaço latente com estrutura, e com nomes propostos pelo agente.

16.5.2 Fluxo

Situação	Comportamento do sistema
Dado inválido	Descartado na camada 1; não gera alerta
Transiente conhecido	Descartado na camada 1
Normal	Camada 4 não sinaliza; registro apenas
Anomalia conhecida	Camadas 5 e 6; agente valida ou contesta
Anomalia desconhecida	Camada 4 sinaliza; agente nomeia; camada 8 acumula
Classes 4 ou 5	Sinalizador; três candidatas do agente ao operador

A camada 8 fecha o ciclo, agora com nome

O Capítulo 9 terminou com classes virtuais anônimas — “grupo 11” — e apontou isso como sua principal limitação.

Nesta arquitetura, a camada 8 recebe segmentos rejeitados por um método que acerta 95,4 %, agrupados em um espaço com silhueta positiva, e acompanhados de descrições geradas pelo agente com taxa de convergência mensurável. O especialista recebe: um grupo coeso, um nome proposto, uma justificativa ancorada em estatísticas verificáveis, e um indicador de quão consistente foi a descrição.

Confirmar ou corrigir isso é trabalho de minutos. Era trabalho de horas.

16.6 Sete princípios

O percurso deste livro sugere sete princípios para teste além do problema de poços submarinos. Alguns decorrem da formulação matemática; outros são generalizações empíricas que ainda exigem validação em novos domínios.

1. **A representação determina o que é detectável.** Um mesmo escore de distância detecta 67,5 % ou 98,2 % da mesma anomalia, conforme o espaço. Antes de trocar o método, verifique o espaço.
2. **Reconhecer incompatibilidade pode ser mais fácil que afirmar identidade.** Essa assimetria foi observada nos métodos geométricos e no modelo de linguagem avaliados. Projete sistemas que a meçam e, quando confirmada, a explorem.
3. **Escore acoplados não podem expressar rejeição.** A restrição $\sum_k \hat{p}_k = 1$ é uma decisão de projeto com consequência epistemológica, e quase sempre é tomada sem que se note.
4. **Reportar desempenho desagregado é o que permite projetar arquiteturas.** A divisão de trabalho da Tabela 16.4 é invisível em qualquer média global.
5. **Reduzir a variância pode ser tão importante quanto aumentar a média.** Entre sistemas com acurácia média de 0,86, aquele com desvio 0,08 é mais previsível entre poços do que outro com desvio 0,19. Isso favorece a avaliação operacional, mas não basta para declarar nenhum deles implantável.
6. **Resultados negativos são informação.** O empate entre autoencoder, VAE e DCN no Capítulo 9 foi o que apontou o gargalo que o Capítulo 12 resolveu.
7. **Um sistema que descreve o que vê pode ajudar a auditar os dados.** Nesta análise, a hipótese de artefato de telemetria ganhou visibilidade quando quatro classes receberam

nomes contendo “perda de telemetria”; as matrizes de confusão examinadas não a haviam evidenciado.

Resumo do capítulo

A trajetória do livro produziu ganhos cuja magnitude foi inversamente proporcional ao seu custo de implementação: trocar o autoencoder pelo latente do classificador multiclasse elevou a detecção de novidade em quarenta e seis pontos percentuais e custa extrair a saída de outra camada, enquanto o elaborado ciclo de agrupamento do Capítulo 9 exigiu esforço desproporcional por operar sobre um espaço sem estrutura de classe. Consolidados, os resultados revelam duas assimetrias: reconhecer incompatibilidade é mais fácil que afirmar identidade, para ambas as famílias de método; e a vantagem dos métodos numéricos sobre o agente é de cinquenta e dois pontos na classificação e de apenas seis na detecção de novidade. A avaliação desagregada por classe permitiu derivar — e não postular — uma divisão de trabalho: métodos numéricos decidem nas classes 1, 2, 3, 6, 8 e 9; o agente fornece segunda opinião priorizada na classe 7, onde o método geométrico atinge apenas 52,3%; é cético na classe 9; e as classes sintomáticas 4 e 5 devem ser tratadas como sinalizadores, não como classes. A arquitetura de referência resultante tem oito camadas, da validação determinística do dado ao ciclo de incorporação de classes virtuais — que agora recebe grupos coesos, nomes propostos e justificativas verificáveis. Sete princípios generalizáveis encerram o capítulo.

Exercícios

1. A Tabela 16.2 mostra que a classe 7 é o pior caso do método geométrico e um dos melhores do agente, enquanto a classe 9 apresenta a relação inversa. Formule uma regra de seleção de método por classe e estime o desempenho global de um sistema que a aplique.
2. **Projeto integrador.** Especifique e implemente uma versão da arquitetura de referência de oito camadas e meça o desempenho fim a fim sobre o 3W. Como os artefatos completos dos estudos originais não acompanham esta edição, registre as decisões que precisou reconstruir. Compare com cada componente isolado. O ganho da integração é aditivo, subaditivo ou superaditivo?
3. O princípio 5 afirma que reduzir variância vale mais que aumentar média. Formalize essa intuição: sob que função de utilidade do operador ela é verdadeira? Construa um contraexemplo em que ela seja falsa.
4. Proponha uma redefinição das classes 4 e 5 do 3W baseada em mecanismo em vez de sintoma. Que informação adicional seria necessária para rotular as instâncias existentes sob a nova definição?
5. A arquitetura é sequencial e erros se propagam. Estime a acurácia fim-a-fim em função das acurácias das camadas 2, 4 e 6, sob independência. Compare com o valor medido no exercício 2 e discuta a diferença.
6. Projete um mecanismo de realimentação em que as correções do operador sobre as classes virtuais melhorem as camadas 3 e 5. Que riscos de deriva esse laço introduz?
7. Escolha um dos sete princípios e teste-o em um domínio completamente diferente — diagnóstico médico, detecção de fraude, manutenção de equipamentos rotativos. Ele se sustenta? Que adaptação exige?

Leituras recomendadas

- Lopes (2025), Lopes et al. (2026c), Lopes et al. (2026a) e Lopes et al. (2026b) — os quatro trabalhos consolidados neste capítulo.
- Scheirer et al. (2013) — o arcabouço teórico de mundo aberto que atravessa todo o percurso.
- Vaz Vargas et al. (2026) — a evolução do 3W, relevante para a recomendação sobre as classes sintomáticas.

Capítulo 17

Da bancada à plataforma

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- enumerar os requisitos não funcionais que distinguem um protótipo de um sistema implantado;
- enunciar os princípios de uma interface que comunique incerteza sem induzir fadiga de alarme;
- estruturar o laço de realimentação humana e a governança de classes virtuais;
- reconhecer e monitorar deriva de conceito e de dados;
- estimar o custo total de operação de um sistema de monitoramento com camada de linguagem.

17.1 O que muda quando o sistema é ligado

A maior parte dos números deste livro foi obtida em avaliação controlada. O Capítulo 7 também apresenta estudos de caso de campo e uma escala de implantação reportada pela fonte primária, superior a vinte unidades flutuantes; esta edição não auditou independentemente essa implantação. É justamente por isso que ele é o capítulo com o menor número de tabelas e o maior número de decisões de engenharia aparentemente banais.

Este capítulo trata dessas decisões. Elas não aparecem em artigos, e determinam se o sistema é usado ou desligado.

A assimetria entre pesquisa e operação

Em pesquisa, o critério é a métrica. Em operação, o critério é: *o operador confia?* Um sistema com acurácia de 0,95 que emite três alarmes falsos por turno será ignorado em uma semana. Um sistema com acurácia de 0,85 que quase nunca alarma indevidamente será consultado. A métrica não captura essa diferença; o desvio padrão entre poços — discutido no Capítulo 11 — captura parte dela.

Tabela 17.1: Requisitos não funcionais e a resposta arquitetural correspondente.

Requisito	Resposta no sistema descrito
Disponibilidade desde o primeiro segundo	Diagrama de decisão determinístico, que não requer treinamento (Capítulo 7)
Ausência de rotulação contínua	Autoencoder e ciclo de mundo aberto operam sem rótulos
Heterogeneidade entre poços	Modelo por poço; normalização por escore-z; avaliação com desvio padrão entre poços reportado
Robustez a falha de sensor	Camada de validação de dado; imputação; detecção de sensor congelado
Robustez a manobra de liberada	Reinício do ciclo de treinamento na mudança de válvula
Latência compatível	405 ms do ensemble contra 30 min a 5 h de tempo de resposta do processo
Auditabilidade	Métricas determinísticas verificáveis; justificativas ancoradas nelas
Extensibilidade	Classificadores binários independentes; classes virtuais

17.2 Requisitos não funcionais

Nenhum desses requisitos é sobre acurácia

Vale notar o que a Tabela 17.1 não contém. Nenhuma linha exige acurácia mínima. Isso não significa que a acurácia seja irrelevante — significa que ela é condição necessária e largamente insuficiente. Um sistema perfeitamente acurado que exige rotulação contínua, ou que leva uma semana para ficar disponível, ou cujo comportamento varia imprevisivelmente entre poços, não é implantável.

17.3 A interface

17.3.1 O que apresentar

O sistema produz, para cada segmento anômalo, quatro objetos distintos:

1. a delimitação temporal do evento;
2. a decisão conhecido/novidade, com o escore de Mahalanobis;
3. a classe, quando conhecida, com o escore do classificador binário;
4. três hipóteses ordenadas com justificativa, do agente.

A tentação é fundir tudo em um número. O Capítulo 10 já argumentou contra, ao discutir o painel que exibe risco analítico e risco aprendido lado a lado (Figura 10.4).

Indicadores que discordam são informativos

Quando o método geométrico diz “conhecido, classe 7” e o agente diz “incompatível com todas as classes”, essa discordância é o achado mais valioso que o sistema pode produzir naquele instante. Fundir os dois em um índice a destruiria.

A regra de projeto: **fundir indicadores é aceitável quando eles concordam e inaceitável quando discordam** — e como não se sabe de antemão qual será o caso, não se funde.

17.3.2 Graduação em vez de binário

O Capítulo 7 usa três níveis de risco — baixo, médio, alto — em vez de um alarme binário. A justificativa merece ser repetida: um alarme binário força uma escolha entre perder eventos e cansar o operador, e essa escolha é feita por quem projeta o sistema, que tem menos contexto que quem o opera.

A graduação transfere a decisão para onde há mais informação.

17.3.3 Validação de agrupamentos




Figura 17.1: Interface de validação de agrupamentos. O especialista inspeciona a projeção do espaço latente, seleciona um ponto e recebe as variações percentuais por sensor daquele segmento. Pode então reatribuir o ponto a outro agrupamento ou removê-lo da análise.

A Figura 17.1 materializa o laço humano do ciclo de mundo aberto. Três decisões de projeto merecem comentário.

A projeção é interativa, não estática. O especialista precisa explorar, não apenas contemplar. As ressalvas do Capítulo 6 sobre projeções não lineares valem aqui: a interface deve ser entendida como ferramenta de navegação, não como representação fiel de distâncias.

Cada ponto expõe suas estatísticas. Selecionar um ponto revela as variações percentuais por sensor — as mesmas métricas do Capítulo 14. O especialista julga sobre números verificáveis, não sobre a posição visual.

As ações são reversíveis e explícitas. Reatribuir e remover, ambas registradas. A remoção é particularmente importante: nem tudo que foi rejeitado merece virar classe.

Note o valor de 15722 % na figura

A variação percentual de T-TPT exibida é de mais de quinze mil por cento. Isso não é um evento físico — é o comportamento da Equação (14.2) quando $\bar{b}$ é próximo de zero, tipicamente porque o sensor estava congelado ou zerado no regime de base.

A interface expõe esse valor sem tratamento, e isso é uma virtude: o especialista reconhece imediatamente um artefato de instrumentação. Uma interface que “limpasse” o número o esconderia.

É também mais uma manifestação do artefato de telemetria que o Capítulo 15 identificou.

17.4 O laço humano

17.4.1 Três papéis distintos

Operador de turno.

Recebe alertas graduados, decide se investiga, registra o desfecho. Precisa de latência baixa e de baixa taxa de falso alarme.

Especialista de disciplina.

Valida agrupamentos, nomeia classes virtuais, corrige perfis. Atua em escala de dias, não de minutos.

Responsável pelo modelo.

Monitora deriva, decide retreinamentos, versiona modelos e prompts.

Confundir esses papéis é um erro comum. A interface do operador não deve expor controles de validação de agrupamento; a do especialista não precisa de latência de segundos.

17.4.2 Governança de classes virtuais

Um sistema que promove classes virtuais indefinidamente acumula categorias mal definidas. A Tabela 17.2 propõe uma política.

Tabela 17.2: Política de governança de classes virtuais.

Decisão	Critério
Promover a virtual	Grupo aprovado nos três índices internos; ao menos trinta segmentos; convergência de nomes acima de um limiar
Encaminhar a revisão	Toda classe virtual, dentro de um prazo definido, com o nome e a justificativa do agente
Fundir	Dois grupos cujas descrições convergem para o mesmo nome e cujos centroides distam menos que um limiar
Descartar	Grupo cuja dispersão de nomes indica confabulação; grupo dominado por artefato de instrumentação
Promover a real	Confirmação do especialista, com definição por mecanismo e não por sintoma

A última linha é a mais importante

“Definição por mecanismo e não por sintoma” é a lição que as classes 4 e 5 ensinaram ao longo de todo o livro. Uma política de governança que não a incorpore reproduzirá o problema em cada nova classe.

17.5 Deriva

17.5.1 Três formas

Deriva de dados.

A distribuição das entradas muda — o poço envelhece, o BSW sobe, a pressão de reservatório cai. O modelo continua correto sobre o passado e progressivamente irrelevante sobre o presente.

Deriva de conceito.

A relação entre entrada e rótulo muda. Um mesmo padrão de sensores passa a significar outra coisa, por exemplo após uma intervenção que altera a completção.

Deriva induzida pelo próprio sistema.

O caso mais insidioso: o modelo se retreina sobre dados que ele mesmo classificou como normais e, gradualmente, aprende a considerar normal uma degradação progressiva.

A salvaguarda do Capítulo 7, revisitada

A regra de excluir dados anômalos do conjunto de retreinamento existe precisamente para impedir a terceira forma. Sem ela, uma incrustação que se desenvolve ao longo de meses seria progressivamente absorvida como normalidade, e o alarme se extinguiria sozinho — sem que nenhuma métrica indicasse falha. É o modo de falha mais perigoso de sistemas auto-adaptativos, porque é silencioso.

17.5.2 O que monitorar

- **Distribuição do escore de Mahalanobis** sobre dados classificados como normais. Um deslocamento sistemático indica deriva de dados.
- **Taxa de rejeição.** Um aumento sustentado pode indicar deriva ou o surgimento de um fenômeno novo — e distinguir os dois é trabalho do especialista.
- **Taxa de confirmação do agente.** Queda na fração de decisões validadas sugere que os perfis de classe estão desatualizados.
- **Convergência de nomes.** Aumento de dispersão indica que o agente está confabulando com mais frequência.
- **Desfecho registrado pelo operador.** A única fonte de rótulo verdadeiro em operação, e a mais valiosa.

Quatro dos cinco indicadores não exigem rótulo

Isso é essencial. Um esquema de monitoramento que dependesse de rótulos seria inútil exatamente onde é mais necessário — em operação contínua, sem anotação. O quinto indicador, o desfecho registrado, exige disciplina operacional e é o mais difícil de obter. Vale investir nele: é o que permite avaliar o sistema de verdade.

17.6 Custo

Tabela 17.3: Estrutura de custo por camada, em ordem de grandeza.

Camada	Custo de inferência	Observação
Diagrama de decisão	Desprezível	Regras
U-Net	Milissegundos por sensor	GPU opcional
Ensemble binário	405 ms; 21 MB	Por poço
Mahalanobis	Desprezível	Inversão de matriz 64×64 pré-computada
Agente de linguagem	Segundos; custo por chamada	Somente sobre segmentos anômalos

Uma estimativa de custo total de propriedade precisa fixar um horizonte H e separar custos fixos, computação, chamadas e revisão humana. Um modelo mínimo é

$$C_{\text{TCO}}(H) = C_{\text{implantação}} + C_{\text{infra}}(H) + \frac{N(H)}{10^6} (T_{\text{in}} p_{\text{in}} + T_{\text{out}} p_{\text{out}}) + N(H) r t_h c_h + C_{\text{armazenamento}}(H), \quad (17.1)$$

onde $N(H)$ é o número de segmentos enviados ao agente, T_{in} e T_{out} são os *tokens* médios por chamada, p_{in} e p_{out} são os preços contratados por milhão de *tokens*, r é a fração encaminhada à revisão, t_h é o tempo de revisão em horas e c_h é o custo da hora do especialista.

Exemplo 17.1 — Dimensionamento mensal sem congelar preços comerciais

Com cinquenta segmentos por dia durante trinta dias, 6.000 *tokens* de entrada e 1.000 de saída por segmento, o consumo mensal é de nove milhões de *tokens* de entrada e 1,5 milhão de saída. O custo da API é, portanto, $9p_{\text{in}} + 1,5p_{\text{out}}$. Se 41 % dos casos exigirem dez minutos de revisão, serão 102,5 horas de especialista, com custo $102,5c_h$. Substituir na Equação (17.1) os preços do contrato, a infraestrutura e o armazenamento produz a estimativa mensal; variar N , r e t_h revela qual termo domina.

A decisão de custo que viabiliza a camada de linguagem

Acionar o agente a cada janela, em duzentos e cinquenta poços, seria proibitivo em custo e desnecessário: a esmagadora maioria das janelas é normal. Acioná-lo apenas sobre segmentos que a camada 4 sinalizou reduz o volume em ordens de grandeza — de milhões de janelas por dia para dezenas de segmentos. É por isso que a arquitetura do Capítulo 16 coloca o agente na posição seis, e não na posição um. Generalizando: em sistemas com componentes de custo muito assimétrico, a arquitetura deve garantir que o componente caro só seja acionado quando o barato já filtrou.

17.6.1 Custos que não aparecem na tabela

- **Tempo do especialista** na validação de classes virtuais. É o custo dominante do ciclo de mundo aberto, e a razão pela qual as descrições geradas pelo agente têm valor econômico direto.
- **Versionamento de modelos e prompts.** Um prompt é código; deve ser versionado, revisado e testado.
- **Dependência de serviço externo.** Disponibilidade, latência de rede, mudança de modelo sem aviso.

- **Governança de dados.** Enviar dados operacionais a um serviço de terceiros exige avaliação de conformidade.

17.7 Uma lista de verificação

1. O sistema funciona no primeiro segundo, antes de qualquer treinamento?
2. Ele informa explicitamente quando não sabe?
3. Ele degrada graciosamente quando um sensor falha?
4. Manobras deliberadas geram alarme?
5. O desempenho foi reportado com desvio padrão entre poços?
6. Cada afirmação do sistema pode ser rastreada a um número verificável?
7. Indicadores discordantes são apresentados separadamente?
8. Existe caminho para o operador registrar o desfecho?
9. Existe política escrita de governança de classes novas?
10. O monitoramento de deriva dispensa rótulos?
11. O componente caro só é acionado após filtragem pelo barato?
12. Prompts e modelos estão versionados?

Resumo do capítulo

A distância entre um protótipo e um sistema implantado é feita de requisitos não funcionais que nenhuma métrica captura: disponibilidade desde o primeiro segundo, operação sem rotulação contínua, robustez a falha de sensor e a manobra deliberada, auditabilidade e extensibilidade. A interface deve apresentar separadamente a delimitação, a decisão conhecido/novidade, a classe e as hipóteses do agente — fundir indicadores é aceitável quando concordam e inaceitável quando discordam, e como não se sabe de antemão, não se funde. O laço humano envolve três papéis com necessidades distintas: operador de turno, especialista de disciplina e responsável pelo modelo. A governança de classes virtuais define quando promover, fundir, descartar e — crucialmente — exige que a promoção a classe real seja feita por mecanismo, não por sintoma. Das três formas de deriva, a mais perigosa é a induzida pelo próprio sistema, contra a qual a exclusão de dados anômalos do retreinamento é a salvaguarda. Quatro dos cinco indicadores de deriva propostos dispensam rótulos. Por fim, a camada de linguagem só é economicamente viável porque é acionada apenas sobre segmentos já filtrados: em sistemas com custos assimétricos, o componente caro deve vir depois do barato.

Exercícios

1. Estime o volume diário de janelas processadas em duzentos e cinquenta poços com inferência a cada minuto, e o número esperado de segmentos anômalos com taxa de falso alarme de 5 %. Quantas chamadas ao agente isso representa por dia?
2. Projete a interface do operador de turno com os quatro objetos produzidos pelo sistema. Justifique cada elemento visual em termos de carga cognitiva e de risco de fadiga de alarme.

3. Implemente os cinco indicadores de deriva propostos. Simule uma deriva de dados lenta sobre um poço do 3W e verifique quais indicadores a detectam e com quanta antecedência.
4. Construa um cenário concreto de deriva induzida pelo próprio sistema e demonstre, por simulação, que a salvaguarda de exclusão de dados anômalos a impede. O que acontece se a salvaguarda tiver falsos negativos?
5. A Figura 17.1 exibe uma variação percentual de mais de quinze mil por cento. Proponha três formas de apresentar esse valor ao especialista — exibir sem tratamento, limitar a uma faixa, ou substituir por uma marca de artefato — e discuta os riscos de cada uma.
6. Redija a política de governança de classes virtuais como documento operacional, com critérios numéricos concretos, prazos e responsáveis. Aplique-a retrospectivamente aos agrupamentos do Capítulo 9.
7. Percorra a lista de verificação para um sistema de aprendizado de máquina com que você tenha trabalhado. Quantos itens ele satisfaz? Para cada item não satisfeito, estime o custo de corrigi-lo.

Leituras recomendadas

- Aranha et al. (2024a) e Aranha et al. (2024b) — descrições de sistemas de monitoramento em operação real.
- Lopes (2025) — o contexto operacional completo do sistema dual.
- Node-RED (2019) — a ferramenta de orquestração usada na implantação.
- Gatta et al. (2022) e Soriano-Vargas et al. (2021) — aspectos operacionais e de visualização em monitoramento de poços.

Capítulo 18

O que ainda não sabemos

Objetivos de aprendizagem

Ao final deste capítulo, você será capaz de:

- enunciar com precisão as limitações que atravessam todo o trabalho apresentado;
- distinguir limitações de dados, de método e de avaliação;
- formular questões de pesquisa a partir de resultados negativos e de artefatos identificados;
- avaliar criticamente afirmações sobre sistemas de detecção de anomalias em contextos industriais;
- planejar uma agenda de trabalho que ataque os gargalos na ordem correta.

18.1 Uma advertência sobre o que foi medido

Este livro apresentou muitos números. Antes de propor o que vem depois, é necessário delimitar o que esses números sustentam.

A ressalva que atravessa tudo

Quatro classes receberam, do agente, nomes contendo “perda de telemetria” (Capítulo 15). Isso revelou que, no 3W, o início de muitas anomalias coincide com sensores de fundo reportando valores ausentes ou zerados.

A implicação é desconfortável: **parte do desempenho reportado nos experimentos com o 3W pode decorrer da detecção de falha de instrumentação, e não da detecção da anomalia.** Não há como quantificar essa fração com os experimentos realizados.

As análises por matriz de confusão apresentadas não evidenciaram esse padrão; as descrições em linguagem natural o tornaram visível e motivam um teste controlado.

Essa ressalva não invalida automaticamente os resultados — o Capítulo 7 reporta estudos de caso de campo com dados reais e eventos verificados — mas define a primeira prioridade da agenda: *medir o confundimento antes de perseguir mais acurácia.*

18.2 Limitações de dados

1. **Possível confundimento de telemetria.** Descrito acima. Testável por um protocolo que remova instâncias em que a anomalia coincide com valores ausentes, e repita toda a avaliação. A diferença de desempenho pareada, com intervalo de confiança, estimará a contribuição desse sinal; a remoção também pode alterar a composição e a dificuldade da amostra.
2. **Um único conjunto de dados.** Quase tudo foi avaliado no 3W. A exceção — o sistema dual, avaliado em poços reais de um operador — é justamente a que não permite publicação dos dados.
3. **Amostras pequenas por classe.** A classe 9 tem $n = 11$ no estudo de novidade e $n = 14$ no de classificação. Intervalos de confiança de Wilson com essas amostras são largos o bastante para tornar várias comparações inconclusivas.
4. **Rótulos de qualidade heterogênea.** A análise do poço A3 no Capítulo 11 mostrou que a discordância entre modelo e anotação podia ser atribuída à anotação. Não se sabe quantos outros casos assim existem.
5. **Classes definidas por sintoma.** As classes 4 e 5, discutidas em quatro capítulos. Não é um problema de método.
6. **Possível contaminação.** O 3W é público desde 2019 e pode ter integrado corpora de pré-treinamento. O Capítulo 15 apresentou três argumentos contra essa explicação, nenhum deles conclusivo.

Cinco das seis limitações são do conjunto de dados, não do método

Isso é característico da área. A comunidade de detecção de anomalias industriais dispõe de poucos conjuntos públicos, e o 3W — apesar de todas as ressalvas — é um dos melhores existentes.

Avançar exige mais dados públicos de qualidade, com anotação por especialista e taxonomia por mecanismo. É trabalho menos glamouroso que propor arquiteturas, e provavelmente mais impactante.

18.3 Limitações de método

18.3.1 Segmentação

A U-Net exige anotação por amostra, muito mais cara que anotação por janela. O Capítulo 11 obteve 0,863 de acurácia com esse custo. Não se sabe qual seria o desempenho de abordagens fracamente supervisionadas, que aprendem a segmentar a partir de rótulos de janela.

A revocação SoftED de 0,678 significa que cerca de um terço dos eventos não é detectado dentro da tolerância temporal. A detecção antecipada de 0,222 indica que o modelo raramente antecipa o especialista — e antecipar é o que teria valor operacional.

18.3.2 Novidade

A média μ e a covariância Σ do Mahalanobis são estimadas uma vez, e não acompanham deriva. Um esquema de atualização incremental é necessário, mas introduz o risco de absorver degradação progressiva — o modo de falha silencioso do Capítulo 17.

O limiar no percentil 95 é uma escolha, não uma derivação. A justificativa dada no Capítulo 12 — que a hipótese de normalidade multivariada não se sustenta — explica por que não se usa χ^2 , mas não estabelece que 95 seja ótimo.

A classe 7 permanece em 52,3 %. O diagnóstico é claro: a janela de duzentos passos não comporta um fenômeno de semanas. A solução exige representação multiescala.

18.3.3 Agente

- **Sem ablação.** Não se sabe quais das treze métricas importam. Um estudo de ablação é o experimento de menor custo e maior retorno informativo pendente.
- **Sem comparação com atribuição.** SHAP e gradientes integrados produzem explicações de natureza diferente; não foram comparados.
- **Sem ajuste fino, sem exemplos, sem múltiplas passagens, sem ferramentas.** Como o Capítulo 14 registrou, os resultados devem ser lidos como piso.
- **Sem calibração.** A confiança declarada pelo agente não foi verificada contra frequências empíricas.
- **Sem informação de localização.** A confusão entre as classes 8 e 9 decorre disso, e é corrigível.

18.3.4 Reprodutibilidade do modelo de linguagem

O Capítulo 13 prometeu que este capítulo discutiria alternativas. A questão é séria: o modelo é servido por interface de programação de terceiros, pode ser atualizado ou descontinuado sem aviso, e a temperatura de 0,2 reduz mas não elimina a estocasticidade. Os resultados não são estritamente reproduzíveis.

Tabela 18.1: Alternativas para reprodutibilidade da camada de linguagem.

Alternativa	Ganho	Custo
Modelo aberto local, versão fixa	Reprodutibilidade estrita; dados não saem do perímetro	Infraestrutura de GPU; desempenho tipicamente inferior
Ajuste fino sobre modelo aberto menor	Adaptação ao domínio; modelo próprio e versionável	Exige dados rotulados — o que o sistema procura evitar
Registro completo de entradas e saídas	Auditoria posterior; permite reanálise	Não permite repetir o experimento
Amostragem múltipla com agregação	Reduz variância; mede consistência	Multiplica o custo por chamada

Não há escolha dominante

Cada linha da Tabela 18.1 troca uma propriedade desejável por outra. A recomendação prática é combinar a terceira linha — registro completo, que é barata e compatível com qualquer das outras — com a alternativa que o contexto de governança exigir. Em ambiente industrial com restrição de dados, a primeira linha tende a ser mandatária, e o custo de desempenho deve ser aceito.

18.4 Limitações de avaliação

1. **Nenhuma avaliação com operadores.** Todas as afirmações sobre carga cognitiva, fadiga de alarme e utilidade das justificativas são argumentadas, não medidas. A política de triagem do Capítulo 15 — que reduziria à metade o volume de revisão — é uma projeção.
2. **Nenhuma avaliação fim-a-fim.** Os componentes foram medidos isoladamente. A arquitetura de referência do Capítulo 16 nunca foi executada como um todo.
3. **Ausência de linha de base humana.** Não se sabe qual é a acurácia de um especialista sobre os mesmos segmentos, o que impede afirmar que o sistema é útil e não apenas mensurável.
4. **Comparações com a literatura são aproximadas.** Como o Capítulo 8 registrou, protocolos, partições e definições de classe diferem entre trabalhos.

A limitação mais séria é a terceira

Sem linha de base humana, “89,7% de detecção de novidade” é um número sem referencial. Pode ser excelente ou trivial.

Estabelecer essa linha de base é caro — exige tempo de especialista — e é a lacuna que mais compromete a interpretação de todo o trabalho.

18.5 Uma agenda

18.5.1 Ordenada por razão informação/custo

Tabela 18.2: Agenda de trabalho, ordenada por razão entre informação obtida e custo.

Experimento	Custo	Informação obtida
Remoção do confundimento de telemetria	Baixo	Quantifica quanto do desempenho é artefato
Ablação das treze métricas	Baixo	Quais métricas importam; guia para adicionar novas
Métricas de localização por sensor	Baixo	Testa a hipótese sobre a confusão entre classes 8 e 9
Calibração da confiança declarada	Baixo	Viabiliza uso da confiança na política de triagem
Múltiplas passagens com agregação	Médio	Mede consistência; provável ganho em top-1
Representação multiescala	Médio	Ataca a classe 7 diretamente
Avaliação fim-a-fim da arquitetura	Médio	Único número que descreve o sistema real
Segmentação fracamente supervisionada	Alto	Elimina o custo de anotação por amostra
Linha de base humana	Alto	Referencial para todos os números do livro
Redefinição das classes sintomáticas	Alto	Corrige a taxonomia; beneficia toda a comunidade

18.5.2 Quatro questões de pesquisa

A assimetria é universal?

Métodos geométricos e modelos de linguagem, sistemas de natureza completamente distinta, exibem a mesma assimetria entre afirmar identidade e reconhecer incompatibilidade. Ela se manifesta em outros domínios? Existe uma formulação teórica que a preveja?

A convergência de nomes é uma métrica de confiança válida?

O Capítulo 15 propôs medir a concentração das descrições geradas como indicador não supervisionado de confiabilidade. A proposta é plausível e não foi validada. Se funcionar, resolve o problema de estimar confiança sem rótulos.

Quanto da vantagem do latente supervisionado é transferível?

O Capítulo 12 mostrou que representar com um classificador em vez de um autoencoder eleva a detecção de novidade em quarenta e seis pontos. Isso depende de haver classes conhecidas suficientes. Qual é o mínimo? A vantagem persiste com três classes? Com duas?

Sistemas que descrevem auditam melhor os dados?

O artefato de telemetria do 3W só se tornou visível pela descrição em linguagem natural. Isso sugere um uso não previsto de modelos de linguagem: auditoria automática de conjuntos de dados. A hipótese pode ser testada injetando artefatos conhecidos e verificando se são descritos.

18.6 Encerramento

O que este livro sustenta

Um sistema de monitoramento pode — e deve — dizer “não sei”.

Dizer isso corretamente é mais fácil do que dizer o que algo é: 95,4 % contra 87 % nos métodos numéricos, 89,7 % contra 35,1 % na camada de linguagem.

O espaço em que a pergunta é feita importa mais que o método: a mesma distância detecta 67,5 % ou 98,2 % da mesma anomalia.

E um sistema que descreve o que vê, em linguagem que o especialista lê, transforma um grupo anônimo em uma hipótese verificável — além de revelar problemas nos dados que nenhuma métrica agregada exporia.

Nada disso substitui o especialista. Tudo isso muda o que ele recebe no início do turno.

Resumo do capítulo

Os resultados deste livro devem ser lidos sob uma ressalva que atravessa todos os capítulos: no 3W, o início de muitas anomalias coincide com falha de telemetria, e parte do desempenho reportado pode decorrer da detecção desse artefato — fração que os experimentos realizados não permitem quantificar. Cinco das seis limitações de dados são do conjunto, não do método, o que aponta a escassez de dados públicos de qualidade como gargalo da área. Entre as limitações de método, destacam-se a revocação SoftED de 0,678 e a detecção antecipada de 0,222 na segmentação; a estimação estática de μ e Σ no Mahalanobis; a classe 7 presa em 52,3 % por insuficiência de escala temporal; e, no agente, a ausência de ablação, de calibração e de métricas de localização. A reprodutibilidade da camada de linguagem não tem solução dominante: cada alternativa troca uma propriedade desejável por outra, e o registro completo de entradas e saídas é a única compatível com todas as demais. A limitação de avaliação mais séria é a ausência de linha de base humana, sem a qual os números do livro carecem

de referencial. A agenda proposta ordena dez experimentos por razão entre informação e custo, com a avaliação do possível confundimento de telemetria em primeiro lugar, e formula quatro questões de pesquisa — entre elas, se a assimetria entre reconhecer incompatibilidade e afirmar identidade é uma propriedade universal.

Projetos de pesquisa

1. Projete e execute o estudo de ablação das treze métricas do Capítulo 14. Ordene-as por contribuição marginal. O resultado é consistente com a intuição física?
2. Implemente o protocolo de remoção do confundimento de telemetria e reavalie os resultados dos Capítulos 8, 12 e 15. Quanta acurácia se perde em cada um? A ordenação entre métodos se mantém?
3. Verifique a calibração da confiança declarada pelo agente construindo um diagrama de confiabilidade. Se ela estiver mal calibrada, proponha e avalie uma correção.
4. Ataque a classe 7 com uma representação multiescala — por exemplo, concatenando latentes de janelas de duzentos, dois mil e vinte mil passos. Quanto se ganha? O que se perde nas demais classes?
5. Estime experimentalmente o número mínimo de classes conhecidas necessário para que o latente supervisionado supere o latente do autoencoder na detecção de novidade.
6. Teste a hipótese de auditoria automática: injete um artefato conhecido em um conjunto de dados limpo e verifique se o agente o descreve. Varie a intensidade do artefato e determine o limiar de detecção.
7. Projete o protocolo de uma avaliação com operadores que meça, e não apenas argumente, a redução de carga de revisão prometida pela política de triagem do Capítulo 15. Que ameaças à validade ele precisa controlar?

Leituras recomendadas

- Pimentel et al. (2014) — levantamento que contextualiza as limitações discutidas neste capítulo.
- Salles et al. (2024) — a métrica cujos valores de revocação e detecção antecipada apontam as lacunas da segmentação.
- Vaz Vargas et al. (2026) — a evolução do 3W, e o caminho pelo qual várias das limitações de dados podem ser atacadas.
- Sharma and Mehta (2025), Belay et al. (2026) e Zhang and Jain (2026) — direções contemporâneas para a camada de linguagem.

Apêndice A

Glossário

Este apêndice reúne os termos técnicos empregados no livro, com a definição usada aqui e o original em inglês. A lista de siglas encontra-se nas páginas pré-textuais.

A.1 Operação de poços e escoamento

Anomalia

Comportamento do poço que se desvia do regime operacional esperado. Não é sinônimo de falha: uma anomalia pode ser benigna, e uma falha pode ocorrer sem anomalia detectável nos sensores disponíveis.

Árvore de natal molhada (*wet christmas tree*)

Conjunto de válvulas instalado na cabeça do poço submarino, que controla o fluxo entre o poço e as linhas de produção.

Completação inteligente (*intelligent completion*)

Arranjo de poço com válvulas de controle de intervalo operáveis remotamente, que permite regular a contribuição de cada zona produtora sem intervenção física.

Curva de formação de hidrato

Fronteira no plano pressão-temperatura que separa a região onde hidratos de gás são termodinamicamente estáveis da região onde não são.

Elevação por gás (*gas lift*)

Técnica de elevação artificial em que gás é injetado na coluna de produção para reduzir a densidade da mistura e restabelecer o fluxo.

Golfada (*slugging*)

Regime de escoamento intermitente em que bolsões de gás e de líquido alternam-se, produzindo oscilações de pressão e vazão.

Hidrato de gás

Sólido cristalino formado por moléculas de gás aprisionadas em uma estrutura de água, estável a alta pressão e baixa temperatura. Pode obstruir linhas de produção.

Incrustação (*scaling*)

Deposição progressiva de sais ou parafinas nas paredes da tubulação ou na válvula reguladora, que restringe o fluxo ao longo de semanas ou meses.

Intervenção

Operação física sobre o poço, geralmente com embarcação dedicada, de custo elevado. Reduzir intervenções não programadas é um dos objetivos do monitoramento.

Linha de serviço

Linha secundária, distinta da linha de produção, usada para injeção de químicos, gás de elevação ou operações auxiliares.

Perda de produtividade

Redução sustentada da vazão produzida sob condições operacionais equivalentes.

Poço injetor

Poço destinado a injetar fluido no reservatório, para manutenção de pressão ou varrido, em oposição ao poço produtor.

Pré-sal

Província petrolífera brasileira situada abaixo de uma camada de sal, em lâminas d'água tipicamente superiores a dois mil metros.

Regime permanente (*steady state*)

Condição em que as variáveis do processo permanecem aproximadamente constantes, em oposição ao transiente.

Tempo não produtivo

Período em que o poço não produz por razão não programada.

Transiente

Período de variação rápida das variáveis do processo, tipicamente após uma manobra deliberada, durante o qual os modelos de regime permanente não se aplicam.

Válvula de controle de intervalo

Válvula de fundo que regula a contribuição de uma zona produtora específica.

Válvula de segurança de subsuperfície

Válvula de fundo que fecha automaticamente em condição de emergência, isolando o poço.

Válvula reguladora de produção (*production choke*)

Válvula que controla a vazão do poço para a linha de produção.

A.2 Aprendizado de máquina

Acurácia balanceada

Média das revocações por classe. Usada quando as classes são desbalanceadas, situação em que a acurácia simples é enganosa.

Agrupamento (*clustering*)

Tarefa não supervisionada de particionar um conjunto de dados em grupos de elementos semelhantes.

Aprendizado de mundo aberto (*open-world learning*)

Paradigma em que o modelo deve reconhecer que uma amostra não pertence a nenhuma classe conhecida, organizar as amostras rejeitadas e incorporá-las como novas classes.

Aprendizado de mundo fechado (*closed-world learning*)

Paradigma que pressupõe que todas as classes que ocorrerão em operação estavam presentes no treinamento.

Atenção (*attention*)

Mecanismo que pondera dinamicamente a contribuição de cada posição de uma sequência, permitindo caminho de comprimento constante entre posições distantes.

Autoencoder

Rede treinada para reconstruir a própria entrada através de um gargalo, aprendendo uma representação comprimida sem supervisão.

Classe virtual

Agrupamento de amostras rejeitadas que satisfaz critérios de coesão e é tratado provisoriamente como classe, até validação por especialista.

Classe sintomática

Classe definida pelo sintoma observável e não pelo mecanismo físico subjacente. Instâncias de uma mesma classe sintomática podem ter causas distintas, o que compromete a coerência interna do rótulo.

Deriva (*drift*)

Mudança, ao longo do tempo, da distribuição dos dados (deriva de dados) ou da relação entre entrada e rótulo (deriva de conceito).

Detecção de novidade (*novelty detection*)

Tarefa de identificar amostras que não pertencem a nenhuma classe conhecida.

Distância de Mahalanobis

Distância entre um ponto e uma distribuição, normalizada pela covariância. É invariante a escala e sensível à correlação entre variáveis.

Ensemble

Conjunto de modelos cujas saídas são combinadas. Neste livro, designa sobretudo o conjunto de classificadores binários um-contra-todos.

Época (*epoch*)

Uma passagem completa pelo conjunto de treinamento.

Escore- z (*z-score*)

Padronização que subtrai a média e divide pelo desvio padrão.

Espaço latente

Espaço de representação intermediária aprendido por um modelo. Sua geometria determina o que métodos baseados em distância conseguem detectar.

Índice de Calinski-Harabasz

Razão entre dispersão entre grupos e dispersão dentro dos grupos. Valores maiores indicam melhor separação.

Índice de Davies-Bouldin

Média da similaridade de cada grupo com seu vizinho mais próximo. Valores menores indicam melhor separação.

Interseção sobre união

Razão entre a interseção e a união de duas regiões. Usada para avaliar a qualidade de segmentações.

Janela deslizante (*sliding window*)

Recorte de comprimento fixo que avança sobre a série temporal com passo definido.

Mistura de especialistas

Arquitetura em que apenas um subconjunto dos parâmetros é ativado por entrada, permitindo modelos de grande capacidade com custo de inferência reduzido.

Parada antecipada (*early stopping*)

Interrupção do treinamento quando a métrica de validação deixa de melhorar por um número definido de épocas.

Perceptron de múltiplas camadas

Rede neural composta por camadas densas sucessivas com não linearidades.

Rede recorrente

Rede que processa sequências mantendo um estado interno atualizado a cada passo.

Regularização por abandono (*dropout*)

Técnica que desativa aleatoriamente unidades durante o treinamento, reduzindo sobreajuste.

Reconhecimento em conjunto aberto (*open-set recognition*)

Formulação em que o modelo pode recusar-se a atribuir uma classe, mas não organiza nem incorpora as amostras recusadas.

Risco de espaço aberto

Formalização do risco de classificar como conhecida uma região do espaço de características arbitrariamente distante dos dados de treinamento.

Segmentação de séries temporais

Tarefa de atribuir um rótulo a cada instante da série, em oposição a atribuir um rótulo a uma janela inteira.

Silhueta

Medida, por amostra, de quão bem ela se ajusta ao próprio grupo em comparação ao grupo mais próximo. Varia em $[-1, 1]$.

Sobreajuste (*overfitting*)

Ajuste excessivo aos dados de treinamento, com perda de desempenho em dados novos.

Um-contra-todos (*one-vs-all*)

Estratégia que decompõe um problema multiclasse em vários problemas binários independentes.

Validação cruzada estratificada

Partição em dobras que preserva a proporção das classes em cada dobra.

A.3 Modelos de linguagem

Alucinação (*hallucination*)

Produção de afirmação fluente e plausível que não é sustentada pela entrada nem por fato verificável.

Cadeia de raciocínio (*chain-of-thought*)

Texto intermediário produzido antes da resposta final. Não deve ser confundido com explicação do processo computacional efetivo.

Calibração

Grau de correspondência entre a confiança declarada por um modelo e a frequência empírica de acerto.

Contaminação de dados

Presença, no corpus de pré-treinamento, de dados usados na avaliação, o que invalida a interpretação dos resultados como generalização.

Instrução de sistema (*system prompt*)

Instrução que define papel, restrições e formato de saída, aplicada antes da entrada específica.

Prompt

Entrada textual fornecida ao modelo de linguagem, incluindo instrução, contexto e dados.

Saída estruturada

Resposta em formato especificado, tipicamente JSON, que pode ser validada programaticamente.

Temperatura

Parâmetro que controla a aleatoriedade da amostragem. Valores baixos tornam a saída mais determinística.

Transformador (*transformer*)

Arquitetura baseada em atenção, sem recorrência, que permite paralelização do processamento da sequência.

A.4 Métricas e avaliação

Deteção antecipada

Fração de eventos detectados antes do instante anotado pelo especialista. Métrica da família SoftED.

Erro percentual absoluto médio simétrico

Métrica de erro de reconstrução limitada e simétrica em relação a sobre e subestimação.

Especificidade

Fração de negativos corretamente identificados.

Intervalo de Wilson

Intervalo de confiança para proporção binomial, adequado a amostras pequenas e a proporções próximas de zero ou um.

Medida F_1

Média harmônica entre precisão e revocação.

Precisão

Fração de predições positivas que estão corretas.

Revocação

Fração de positivos reais que foram detectados. Também chamada de sensibilidade.

SoftED

Família de métricas de detecção de eventos com tolerância temporal, que credita parcialmente detecções próximas ao instante anotado.

Top- k

Métrica que considera acerto se a resposta correta está entre as k primeiras posições de uma lista ordenada.

Apêndice B

Correspondência de notação

A notação do livro foi harmonizada. Este apêndice registra a correspondência com os símbolos dos trabalhos originais, para que o leitor possa transitar entre as fontes sem ambiguidade. A tabela de símbolos propriamente dita encontra-se nas páginas pré-textuais.

B.1 Séries temporais e janelas

Tabela B.1: Correspondência de notação para dados e janelas.

Neste livro	Significado	Nos trabalhos originais
T	Passos de tempo da janela	<i>window size, sequence length, n_{steps}</i> ; valores 200, 500 e a varredura de 150 a 7500 do Capítulo 10
S	Número de sensores	<i>n_{features}, channels</i> ; valores 4 e 5 conforme o capítulo
$\mathbf{X} \in \mathbb{R}^{T \times S}$	Janela multivariada	X , <i>input tensor</i> , com forma (T, S) na notação de <i>frameworks</i>
b, e	Janelas de linha de base e de evento	<i>baseline window</i> e <i>event window</i> no Capítulo 14
y	Rótulo de classe	<i>class, label</i> ; no 3W, o código de 0 a 9

Uma diferença de convenção que confunde

Bibliotecas de aprendizado profundo descrevem a entrada como *(batch, timesteps, features)*. Este livro omite a dimensão de lote e escreve $\mathbf{X} \in \mathbb{R}^{T \times S}$.

Assim, a camada descrita nos trabalhos originais como *Input(500, 5)* corresponde aqui a $T = 500$ e $S = 5$.

Tabela B.2: Correspondência de notação para modelos.

Neste livro	Significado	Nos trabalhos originais
g_ϕ, h_ψ	Codificador e decodificador	<i>encoder</i> e <i>decoder</i> ; frequentemente sem símbolo, apenas nomeados
z	Representação latente	<i>latent vector</i> , <i>embedding</i> , <i>bottleneck</i> , <i>latent representation</i>
d	Dimensão do latente	<i>latent dim</i> ; valores 4, 16, 64 e 128 conforme o capítulo
c_k, s_k	Classificador binário da classe k e seu escore	<i>binary classifier k</i> , <i>sigmoid output</i> , <i>score</i>
τ	Limiar de decisão	<i>threshold</i> ; valores 0,3, 0,5 e 0,65 conforme o contexto

B.2 Modelos e representações

Três latentes distintos, um mesmo símbolo

O símbolo z designa, em capítulos diferentes, objetos com propriedades muito distintas: no Capítulo 9, o latente de dimensão 16 de um autoencoder; no Capítulo 12, o latente de dimensão 128 de um autoencoder maior e a penúltima camada de dimensão 64 de um classificador multiclasse. A tese central do Capítulo 12 é justamente que esses espaços não são intercambiáveis, apesar de receberem o mesmo símbolo. Quando a distinção importa, o texto a explicita.

B.3 Estatística e limiares

Tabela B.3: Correspondência de notação para estatística e limiares.

Neste livro	Significado	Nos trabalhos originais
$\mu + k\sigma$	Limiar de reconstrução	<i>mean + 3 std</i> ; no Capítulo 7, $k = 3$
d_M	Distância de Mahalanobis	<i>Mahalanobis distance</i> , D^2 quando elevada ao quadrado
λ	Regularização da covariância	<i>shrinkage</i> , <i>regularization term</i> somado à diagonal
K	Número de agrupamentos	k minúsculo em <i>k-means</i> ; aqui maiúsculo, para evitar colisão
$R = \mu/\sigma$	Razão do limiar adaptativo	<i>ratio</i> no Capítulo 9
$\delta = \bar{e} - \bar{b}$	Variação absoluta	<i>delta</i> , <i>absolute change</i> no Capítulo 14

Tabela B.4: Correspondência de notação para métricas de avaliação.

Neste livro	Significado	Nos trabalhos originais
ACC	Acurácia	<i>accuracy, acc</i>
ACC _b	Acurácia balanceada	<i>balanced accuracy</i>
REC	Revocação	<i>recall, sensitivity, true positive rate</i>
PR	Precisão	<i>precision, positive predictive value</i>
SP	Especificidade	<i>specificity, true negative rate</i>
F ₁	Medida F1	<i>F1-score, F-measure</i>
IoU	Interseção sobre união	<i>IoU, Jaccard index</i>

B.4 Métricas

Duas armadilhas de tradução

“**Precisão**” traduz *precision* neste livro, e nunca *accuracy*. Em português técnico corrente, “precisão” é usada às vezes para acurácia, o que gera confusão. Aqui, acurácia é ACC e precisão é PR.

“**Sensibilidade**” e “**revocação**” são o mesmo objeto. O livro usa revocação uniformemente, mas a literatura médica e de sinais prefere sensibilidade.

B.5 Nomenclatura de classes

Tabela B.5: Correspondência entre a numeração de classes do 3W e a designação usada no livro.

Código	Designação no livro	Denominação no 3W
0	Normal	<i>Normal</i>
1	Aumento de BSW	<i>Abrupt Increase of BSW</i>
2	Fechamento de DHSV	<i>Spurious Closure of DHSV</i>
3	Golfadas severas	<i>Severe Slugging</i>
4	Instabilidade de fluxo	<i>Flow Instability</i>
5	Perda de produtividade	<i>Rapid Productivity Loss</i>
6	Restrição rápida no PCK	<i>Quick Restriction in PCK</i>
7	Incrustação no PCK	<i>Scaling in PCK</i>
8	Hidrato na produção	<i>Hydrate in Production Line</i>
9	Hidrato no serviço	<i>Hydrate in Service Line</i>

Deslocamento de índice

Alguns dos trabalhos originais indexam as nove classes anômalas de 1 a 9; outros indexam de 0 a 8, tratando a classe normal separadamente. Este livro segue estritamente a numeração do 3W, de 0 a 9, com a classe 0 correspondendo ao regime normal.

Ao comparar tabelas com as fontes originais, verifique a convenção antes de alinhar linhas.

Apêndice C

Formulário

Este apêndice reúne, em um só lugar, as expressões usadas ao longo do livro. Cada uma remete ao capítulo em que foi introduzida e discutida.

C.1 Métricas de classificação

Com VP, VN, FP e FN denotando verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos (Capítulo 4):

$$\text{ACC} = \frac{\text{VP} + \text{VN}}{\text{VP} + \text{VN} + \text{FP} + \text{FN}} \quad (\text{C.1})$$

$$\text{REC} = \frac{\text{VP}}{\text{VP} + \text{FN}} \quad (\text{C.2})$$

$$\text{SP} = \frac{\text{VN}}{\text{VN} + \text{FP}} \quad (\text{C.3})$$

$$\text{PR} = \frac{\text{VP}}{\text{VP} + \text{FP}} \quad (\text{C.4})$$

$$F_1 = 2 \cdot \frac{\text{PR} \cdot \text{REC}}{\text{PR} + \text{REC}} \quad (\text{C.5})$$

$$\text{ACC}_b = \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \text{REC}_k \quad (\text{C.6})$$

Para segmentação, com A e B os conjuntos de instantes preditos e anotados:

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (\text{C.7})$$

Para listas ordenadas de N segmentos, com ρ_i a posição da classe correta:

$$\text{top-}k = \frac{1}{N} \sum_{i=1}^N \mathbb{1}[\rho_i \leq k] \quad (\text{C.8})$$

C.2 Erro de reconstrução e limiar

Erro percentual absoluto médio simétrico, usado como perda e como escore de anomalia (Capítulo 7):

$$\text{SMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{|\hat{x}_i - x_i|}{(|x_i| + |\hat{x}_i|)/2} \quad (\text{C.9})$$

Limiar sobre o erro de reconstrução, com μ e σ estimados no conjunto de treinamento e $k = 3$:

$$\tau = \mu + k \sigma \quad (\text{C.10})$$

C.3 Detecção de novidade

Distância de Mahalanobis de um ponto $\mathbf{x}$ à distribuição de média $\boldsymbol{\mu}$ e covariância $\boldsymbol{\Sigma}$ (Capítulo 12):

$$d_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})} \quad (\text{C.11})$$

Regularização da covariância, necessária quando a dimensão é comparável ao número de amostras:

$$\boldsymbol{\Sigma}_{\text{reg}} = \boldsymbol{\Sigma} + \lambda \mathbf{I} \quad (\text{C.12})$$

Decisão de novidade, com τ_{95} o percentil 95 das distâncias no conjunto de referência:

$$\text{novidade}(\mathbf{x}) = \begin{cases} 1, & d_M(\mathbf{x}) > \tau_{95} \\ 0, & \text{caso contrário} \end{cases} \quad (\text{C.13})$$

Rejeição por ensemble binário (Capítulo 8), com s_k o escore do classificador da classe k :

$$\text{rejeitar} \iff \max_{k \in \mathcal{K}} s_k < \tau \quad (\text{C.14})$$

Voto ponderado entre classificador latente e OCSVM (Capítulo 9):

$$v = w_{\text{bin}} s_{\text{bin}} + w_{\text{ocsvm}} s_{\text{ocsvm}}, \quad w_{\text{bin}} + w_{\text{ocsvm}} = 1 \quad (\text{C.15})$$

C.4 Agrupamento

Objetivo do K -médias:

$$\min_{\{C_j\}} \sum_{j=1}^K \sum_{\mathbf{x} \in C_j} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \quad (\text{C.16})$$

Silhueta de uma amostra, com a a distância média ao próprio grupo e b a distância média ao grupo vizinho mais próximo:

$$s = \frac{b - a}{\max(a, b)} \quad (\text{C.17})$$

Índice de Calinski-Harabasz, com B e W as dispersões entre e dentro dos grupos e n o número de amostras:

$$\text{CH} = \frac{\text{tr}(B)}{\text{tr}(W)} \cdot \frac{n - K}{K - 1} \quad (\text{C.18})$$

Índice de Davies-Bouldin, com σ_j a dispersão do grupo j e d_{ij} a distância entre centroides:

$$DB = \frac{1}{K} \sum_{i=1}^K \max_{j \neq i} \frac{\sigma_i + \sigma_j}{d_{ij}} \quad (C.19)$$

Limiar adaptativo do ciclo de mundo aberto, com $R = \mu/\sigma$ das distâncias intragrupo (Capítulo 9):

$$k(R) = \begin{cases} 2, & R \geq 4 \\ 1 + \frac{R-2}{2}, & 2 \leq R < 4 \\ 0, & R < 2 \end{cases} \quad (C.20)$$

C.5 Formação de hidrato

Temperatura de formação de hidrato pela correlação de Motiee, com $x = \log_{10}(P/\text{psia})$, saída em graus Fahrenheit e γ a densidade relativa do gás (Capítulo 10):

$$T_{\text{hid}} = -238,24469 + 78,99667x - 5,352544x^2 + 349,473877\gamma - 150,854675\gamma^2 - 27,604065x\gamma \quad (C.21)$$

Margem térmica percentual, com T e T_{hid} na mesma escala de temperatura:

$$C_{\text{hid}} = 100 \frac{T - T_{\text{hid}}}{T} \quad (C.22)$$

C.6 As treze métricas do agente

Com $\mathbf{b}$ a janela de linha de base e $\mathbf{e}$ a janela de evento (Capítulo 14), para cada sensor:

$$\delta = \bar{e} - \bar{b} \quad (C.23)$$

$$\text{pct} = 100 \cdot \frac{\delta}{|\bar{b}|} \quad (C.24)$$

$$z = \frac{|\delta|}{\max(\sigma_b, 10^{-6})} \quad (C.25)$$

$$\text{noise_ratio} = \frac{\sigma_e}{\sigma_b} \quad (C.26)$$

Categorizações derivadas:

Métricas restantes: inclinação, comportamento, razão de oscilação, amplitude do evento, média da linha de base, média do evento, relação entre P-PDG e P-TPT, e sensor mais afetado.

C.7 Intervalo de confiança

Intervalo de Wilson para uma proporção $\hat{p}$ observada em n ensaios, com $z_{\alpha/2} = 1,96$ para 95 % (Capítulo 4):

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}} \quad (C.27)$$

Tabela C.1: Categorizações das métricas do agente.

Métrica	Valor	Condição
Direção	aumento	$\delta > 0,5 \sigma_b$
	redução	$\delta < -0,5 \sigma_b$
	estável	caso contrário
Magnitude	pequena	$z < 1$
	moderada	$1 \leq z < 3$
	grande	$z \geq 3$
Taxa	súbita	$ \text{inclinação} > 0,01$
	rápida	$ \text{inclinação} > 0,002$
	gradual	caso contrário

Por que Wilson e não a aproximação normal

Vários resultados do livro envolvem amostras pequenas — $n = 11$ para a classe 9 no estudo de novidade — e proporções próximas de 1, como os 100 % da classe 2. A aproximação normal produz, nesses casos, intervalos que ultrapassam os limites $[0, 1]$ ou colapsam a largura zero. O intervalo de Wilson permanece válido em ambos os regimes, e por isso foi usado uniformemente.

C.8 Normalizações

Padronização por escore- z :

$$x' = \frac{x - \mu}{\sigma} \quad (\text{C.28})$$

Normalização Min-Max para o intervalo $[0, 1]$:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (\text{C.29})$$

Apêndice D

Reprodução dos experimentos

Este apêndice reúne as informações disponíveis para reconstruir os experimentos descritos no livro: origem dos dados, ambiente computacional, hiperparâmetros e protocolos de avaliação. Ele não equivale a um pacote de reprodução completo.

D.1 Dados

D.1.1 O 3W

O conjunto 3W é público e mantido pela Petrobras. Contém instâncias reais, simuladas e desenhadas de eventos indesejáveis em poços de petróleo, rotuladas em dez classes (Tabela B.5).

Tabela D.1: Procedência das instâncias do 3W e uso neste livro.

Tipo	Origem	Uso
<i>WELL</i>	Poços reais	Sempre incluído. Base de todos os resultados
<i>SIMULATED</i>	Simulador de escoamento	Incluído apenas quando a classe tem menos de trinta instâncias reais
<i>DRAWN</i>	Traçado manualmente por especialista	Sempre excluído

Por que excluir as instâncias desenhadas

Instâncias *DRAWN* são construções idealizadas do especialista. Elas representam o que o evento *deveria* parecer, não o que os sensores registraram. Incluí-las eleva artificialmente as métricas, porque o modelo aprende a reconhecer a idealização em vez do fenômeno. A exclusão é uma decisão de honestidade metodológica, e custa desempenho reportado.

D.1.2 Dados operacionais

Os resultados do Capítulo 7 foram obtidos sobre dados de poços reais de um operador, não públicos. Os três poços caracterizados naquele capítulo — dois produtores e um injetor com injeção alternada de água e gás, em lâminas d'água entre 1.946 e 2.125 metros — não podem ser disponibilizados.

As demais informações do capítulo — arquitetura, hiperparâmetros, limiares e protocolo — são suficientes para reproduzir o método sobre outro conjunto.

D.2 Ambiente computacional

Tabela D.2: Ambiente computacional utilizado.

Componente	Especificação
Processador	Intel Xeon, 2 vCPU
Memória	13 GB
Aceleração	NVIDIA T4
Linguagem	Python 3.7 (sistema em operação) e 3.10 (experimentos)
Aprendizado profundo	Keras sobre TensorFlow
Aprendizado clássico	scikit-learn
Orquestração em operação	Node-RED
Camada de linguagem	Qwen3.5-397B-A17B via NVIDIA NIM

O hardware é modesto de propósito

Duas vCPU, treze gigabytes e uma T4 não constituem uma configuração de pesquisa ambiciosa. É deliberado: um sistema destinado a operar em unidade flutuante precisa caber em infraestrutura disponível a bordo ou em nuvem de custo controlado. O ensemble completo ocupa 21 MB e responde em 405 ms (Capítulo 10). Nenhum resultado do livro depende de escala computacional.

D.3 Hiperparâmetros

D.3.1 Sistema dual (Capítulo 7)

Tabela D.3: Configuração do autoencoder do sistema dual.

Item	Valor
Entrada	(500, 5)
Arquitetura	LSTM 16 $\rightarrow$ LSTM 4 $\rightarrow$ RepeatVector(500) $\rightarrow$ LSTM 16 $\rightarrow$ TimeDistributed Dense(5)
Compressão	2500 $\rightarrow$ 4, fator 625
Perda	SMAPE
Otimizador	Adam
Épocas	500
Tamanho de lote	100
Ativação	ReLU
Normalização	Min-Max
Ruído de aumento	0 a 0,5 %
Amostras de treinamento	$\approx$ 500 janelas normais ($\approx$ 5.000 s)
Limiar	$\mu + 3\sigma$ sobre o SMAPE de treinamento
Níveis de risco	baixo < 30 %; médio 30–70 %; alto > 70 %

Tabela D.4: Configuração dos classificadores binários um-contra-todos.

Item	Valor
Arquitetura	Entrada (T, S) $\rightarrow$ LSTM 32–128 $\rightarrow$ Dropout 0,1–0,5 $\rightarrow$ Dense 32–64 ReLU $\rightarrow$ Dense 1 sigmoide
Busca de hiperparâmetros	Busca aleatória, 100 combinações por classe
Épocas	25, com parada antecipada e paciência 5
Tamanho de lote	64
Otimizador	Adam
Perda	Entropia cruzada binária
Partição	Temporal, 80/20

D.3.2 Ensemble binário (Capítulo 8)

A partição temporal não é detalhe

Partição aleatória sobre janelas deslizantes vaza informação: janelas consecutivas se sobrepõem, e uma janela do conjunto de teste pode compartilhar amostras com uma de treinamento.

A partição temporal — primeiros 80 % para treinamento, últimos 20 % para teste — elimina o vazamento e produz números menores e honestos. Comparações com trabalhos que usam partição aleatória são, por isso, desfavoráveis a este.

D.3.3 Ciclo de mundo aberto (Capítulo 9)

Tabela D.5: Configuração do ciclo de mundo aberto.

Item	Valor
Autoencoder	Entrada (200, 4) $\rightarrow$ LSTM 32 $\rightarrow$ LSTM 8 $\rightarrow$ Dense 16 (latente) $\rightarrow$ LSTM 8 $\rightarrow$ LSTM 32 $\rightarrow$ Dense(4 $\times$ 200)
Compressão	800 $\rightarrow$ 16, fator 50
Classificador latente	Dense 64 $\rightarrow$ Dropout 0,3 $\rightarrow$ Dense 32 $\rightarrow$ Dropout 0,2 $\rightarrow$ Dense 1 sigmoide
Limiar do voto	$\tau = 0,65$
Estimador de K	Floresta aleatória com oito atributos
Salvaguarda	Dois terços

D.3.4 Segmentação (Capítulo 11)

D.3.5 Representação e Mahalanobis (Capítulo 12)

D.3.6 Camada de linguagem (Capítulos 13 e 14)

O que não foi feito

Sem ajuste fino. Sem exemplos no prompt. Sem múltiplas passagens com agregação. Sem acesso a ferramentas externas.

Essas técnicas alterariam custo e desempenho em direções que precisam ser medidas; os resultados do Capítulo 15 descrevem apenas a configuração documentada.

Tabela D.6: Configuração da U-Net unidimensional.

Item	Valor
Entrada	$(L, 1)$, um modelo por sensor
Codificador 1	Conv1D(32,5) + BN, $\times 2$; MaxPool(2); Dropout 0,2
Codificador 2	Conv1D(64,5) + BN, $\times 2$; MaxPool(2); Dropout 0,2
Gargalo	Conv1D(128,5) + BN, $\times 2$
Decodificador 1	UpSampling(2); concatenação com 64; Conv1D(64,5) + BN, $\times 2$
Decodificador 2	UpSampling(2); concatenação com 32; Conv1D(32,5) + BN, $\times 2$
Saída	Conv1D(1,1) sigmoide; limiar 0,5
Janela	200 passos $\times$ 4 variáveis; deslizamento de 100 passos, passo 5 s
Pré-processamento	Imputação; padronização; remoção de ruído por ondaletas
Validação	Cruzada estratificada, cinco dobras
Otimizador	Adam; 30 a 50 épocas

Tabela D.7: Configuração dos espaços de representação avaliados.

Espaço	Definição
Bruto	800 dimensões (200 passos $\times$ 4 variáveis)
Latente do autoencoder	128 dimensões; Entrada $\rightarrow$ LSTM 256 $\rightarrow$ LSTM 128 $\rightarrow$ Dense 128
Latente do multiclasse	64 dimensões; penúltima camada do classificador
Cabeça binária	Latente(128) $\rightarrow$ Dense 64 ReLU $\rightarrow$ Dense 32 ReLU $\rightarrow$ Dense 2 <i>softmax</i>
Limiar de novidade	Percentil 95 das distâncias de referência
Limiar binário	0,3

Tabela D.8: Configuração da camada de linguagem.

Item	Valor
Modelo	Qwen3.5-397B-A17B (mistura de especialistas)
Serviço	NVIDIA NIM
Modo de raciocínio	Ativado
Temperatura	0,2
Top- p	0,7
Máximo de <i>tokens</i>	4096
Formato de saída	JSON validado
Candidatas por consulta	3, ordenadas
Pré-processamento	Escore- z ; Min-Max $[0, 1]$; ondaleta db4 nível 3, limiar suave; tratamento de ausentes
Perfis de classe	Remoção de discrepantes por IQR em duas passagens, $k = 3,0$ e depois $k = 1,5$

Limites de reprodução desta edição

O repositório desta edição não contém os scripts de treinamento e avaliação, as tabelas derivadas em formato legível por máquina, as sementes das execuções, os ambientes congelados nem os registros completos das chamadas ao serviço de linguagem. O identificador exato do endpoint NIM e sua revisão também não estão documentados nas fontes disponíveis. Assim, os parâmetros abaixo permitem reconstrução aproximada, mas não repetição bit a bit nem auditoria independente de todos os números. Esses itens são lacunas de evidência, não valores a serem inferidos.

D.4 Protocolos de avaliação**Classe escondida (Capítulo 10).**

Treina-se o sistema com $|\mathcal{K}| - 1$ classes, omitindo uma. Avaliam-se as instâncias da classe omitida: acerto significa rejeição. Repete-se para cada classe.

Comparação de arquiteturas (Capítulo 9).

Mesma partição, mesmo protocolo, mesma métrica; varia-se apenas o gerador da representação.

Varredura de janela (Capítulo 10).

Repete-se o protocolo de classe escondida para comprimentos de janela de 150 a 7500 passos.

Validação (Capítulo 15).

Apresentam-se ao agente decisões corretas e incorretas de um classificador; mede-se precisão e revocação no julgamento.

Novidade com agente (Capítulo 15).

Apresentam-se os perfis de todas as classes exceto a do segmento; acerto significa declarar incompatibilidade.

Intervalos de confiança.

Wilson a 95 % (Equação (C.27)) quando as contagens necessárias estão disponíveis; tabelas herdadas sem n não permitem reconstruí-los.

Desvio entre poços.

Sempre que a avaliação é por poço, reporta-se média e desvio padrão entre poços, e não apenas a média agregada.

O item mais fácil de esquecer

Reportar o desvio padrão entre poços foi o que tornou visível o principal ganho do Capítulo 11: a acurácia subiu de 0,500 para 0,863, mas o desvio caiu de 0,187 para 0,082.

Um sistema com desvio de 0,187 entre poços exige investigação por poço antes de uma decisão de implantação, ainda que sua média seja aceitável.

D.5 Lista de verificação para reprodução

1. Obter o 3W e verificar a versão utilizada.
2. Excluir instâncias *DRAWN*; incluir *SIMULATED* apenas nas classes com menos de trinta instâncias reais.

3. Usar partição temporal, nunca aleatória, sobre janelas deslizantes.
4. Normalizar por poço, não globalmente.
5. Fixar sementes e registrá-las.
6. Reportar métricas por classe, não apenas a média global.
7. Reportar desvio padrão entre poços.
8. Usar intervalo de Wilson para todas as proporções.
9. Registrar entradas e saídas da camada de linguagem, dado que o modelo servido por interface externa não é estritamente reproduzível.
10. Documentar o prompt como código versionado.
11. Exportar previsões pareadas, contagens e tabelas derivadas em formato legível por máquina, junto ao script que gera cada tabela do livro.
12. Congelar versões de dependências, identificador do modelo/endpoint e data de execução; registrar *top-k*, semente e política de atualização quando o serviço os expuser.

Apêndice E

Roteiro prático com o repositório 3W

Todos os conceitos da Parte I podem ser exercitados sobre o próprio 3W, com código público. Este apêndice descreve o recurso *Introduction to Machine Learning Applied to Multivariate Time Series* (Lopes, 2026), disponível no repositório oficial do projeto (Petróleo Brasileiro S.A. (Petrobras), 2026), e mapeia cada um de seus cadernos aos capítulos do livro.

O recurso foi apresentado no 4º Workshop on 3W e é destinado a ensino: cursos, oficinas e disciplinas de aprendizado de máquina aplicado a séries temporais multivariadas.

O que este apêndice é e o que não é

Não é uma reprodução dos experimentos do livro — esses estão no Capítulo D. É um *roteiro de aprendizagem*: um caminho executável que leva o leitor dos dados brutos do 3W até um autoencoder LSTM, um conjunto de classificadores e três algoritmos de agrupamento, com configurações deliberadamente reduzidas para caber no tempo de uma aula.

As diferenças em relação às configurações do livro são intencionais e estão listadas na Seção E.9.

E.1 Estrutura do recurso

O código de apoio fica em `src/`, com treze módulos. Toda a parametrização está centralizada em `src/config.py`, o que permite alterar o experimento sem tocar nos cadernos.

E.2 Instalação

```
conda env create -f environment.yml
conda activate 3W-ml-mts
jupyter notebook
```

O arquivo `environment.yml` local, dentro da pasta do recurso, fixa as versões dos pacotes. Usá-lo é o que garante que os resultados sejam consistentes entre execuções e entre máquinas.

Verificação de que os dados foram preparados:

```
from src.data_persistence import DataPersistence
from src import config
```

Tabela E.1: Cadernos do recurso e sua correspondência com os capítulos do livro.

Caderno	Conteúdo	Capítulos
1_data_treatment	Carga, escalonamento, janelamento e validação cruzada	Capítulo 3
2_visualization_techniques	Redução de dimensionalidade e separabilidade de classes	Capítulos 3 e 6
3_introduction_to_unsupervised_learning	Autoencoder LSTM, limiar de reconstrução e OCSVM	Capítulos 5 a 7
4_introduction_to_supervised_learning	Árvores, florestas, SVM e redes densas	Capítulos 4 e 8
5_clustering_methods	K -médiãs, DBSCAN e MeanShift, com índices de qualidade	Capítulos 6 e 9

```

persistence = DataPersistence(base_dir=config.PROCESSED_DATA_DIR)
print(persistence.check_windowed_data())
print(persistence.check_raw_data())

```

E.3 Configuração central

```

TARGET_FEATURES = ["P-PDG", "P-TPT", "T-TPT", "class"]
MAX_FILES_PER_CLASS = 50 # ~4 a 5 GB de RAM
DEFAULT_SCALING_METHOD = "minmax" # standard | minmax | robust | normalizer
RANDOM_SEED = 42

ENABLE_DATA_SAMPLING = True
SAMPLING_RATE = 5 # mantém 1 linha a cada 5

N_FOLDS = 3
WINDOW_SIZE = 300
WINDOW_STRIDE = 150 # janelas com 50% de sobreposicao
MIN_WINDOW_SIZE = 300 # descarta janelas incompletas

```

Três parâmetros que mudam a natureza do experimento

SAMPLING_RATE = 5 reduz a frequência efetiva de amostragem em cinco vezes. Uma janela de 300 pontos passa a cobrir 1.500s de operação, e não 300s. Ao comparar com os números do livro, é esse tempo coberto — e não a contagem de pontos — que deve ser confrontado.

WINDOW_STRIDE = 150 produz sobreposição de 50%. Com partição aleatória, isso vazaria informação entre treino e teste; o recurso evita o problema particionando por instância, e não por janela.

MAX_FILES_PER_CLASS = 50 é o parâmetro que controla o consumo de memória. É o primeiro a ajustar quando o caderno 1 falha.

E.4 Caderno 1: tratamento de dados

Corresponde ao Capítulo 3. Executa quatro etapas.

1. **Carga** dos arquivos Parquet do 3W, com limite por classe.
2. **Comparação de escalonamentos** — padronização, Min-Max, robusto e normalizador — sobre as mesmas séries.
3. **Validação cruzada com separação entre real e simulado.**
4. **Janelamento** para modelos de sequência, produzindo tensores de forma $(n_{\text{janelas}}, 300, 3)$.

E.4.1 A separação entre real e simulado

A classe `CrossValidator` implementa uma política explícita:

o treinamento usa todos os dados disponíveis — reais e simulados — e o teste usa apenas dados reais.

Uma política diferente da adotada no livro

O Capítulo D descreve outra escolha: incluir instâncias simuladas apenas nas classes com menos de trinta instâncias reais, e excluir sempre as desenhadas.

As duas políticas são defensáveis e respondem a preocupações distintas. A do recurso maximiza o volume de treinamento e preserva a honestidade da avaliação; a do livro minimiza a contaminação do treinamento por idealizações.

O que *não* é defensável — e é comum na literatura — é misturar as três procedências sem declarar. Comparar as duas políticas sobre o mesmo conjunto é um exercício instrutivo, e está proposto ao final deste apêndice.

E.5 Caderno 2: técnicas de visualização

Corresponde às discussões de projeção do Capítulo 6. As janelas são achatadas — de $(300, 3)$ para um vetor — e projetadas em duas dimensões por t-SNE e UMAP, com quatro configurações cada:

Tabela E.2: Configurações de projeção avaliadas no caderno 2.

Método	Parâmetros	Efeito pretendido
t-SNE	perplexidade 30, taxa 200	Configuração padrão
t-SNE	perplexidade 10, taxa 100	Ênfase na estrutura local
t-SNE	perplexidade 50, taxa 300	Ênfase na estrutura global
t-SNE	perplexidade 30, taxa 500	Convergência rápida
UMAP	15 vizinhos, dist. mín. 0,1	Configuração padrão
UMAP	5 vizinhos, dist. mín. 0,0	Agrupamentos compactos
UMAP	50 vizinhos, dist. mín. 0,5, métrica cosseno	Estrutura global
UMAP	30 vizinhos, dist. mín. 0,25, métrica Manhattan	Configuração robusta

Por que quatro configurações, e não uma

Este é o ponto pedagógico do caderno. Ao ver a mesma nuvem de pontos organizada de quatro maneiras diferentes conforme a perplexidade, o leitor internaliza que **a projeção é uma escolha, não uma medida**.

Todas as ressalvas do Capítulo 6 sobre interpretar distâncias em projeções não lineares ficam concretas aqui, e é bem mais eficaz vê-las do que lê-las. A mesma cautela se aplica às figuras de espaço latente dos Capítulos 9 e 12.

E.6 Caderno 3: aprendizado não supervisionado

Corresponde aos Capítulos 5 e 7. Treina um autoencoder LSTM sobre janelas da classe 0 e usa o erro de reconstrução como escore de anomalia.

E.6.1 A arquitetura

```
from src.autoencoder_models import StableLSTMAutoencoder

ae = StableLSTMAutoencoder(
    time_steps=300,
    n_features=3,
    latent_dim=16,
    lstm_units=64,
)
ae.build_model()
```

Tabela E.3: Decisões de estabilidade numérica no autoencoder do caderno 3.

Decisão	Motivo
Ativação <code>tanh</code> nas LSTM	Mais estável que ReLU em recorrentes; evita divergência do estado interno
Inicialização ortogonal nos pesos recorrentes	Preserva a norma do estado ao longo dos 300 passos
Recorte de gradiente (<code>clipnorm=1,0</code>)	Contém o gradiente explosivo típico de sequências longas
Taxa de aprendizado 0,0005	Conservadora; troca velocidade por convergência confiável
Saída sigmoide	Casa com o intervalo $[0, 1]$ produzido pelo escalonamento Min-Max
Sementes fixas nos inicializadores	Reprodutibilidade entre execuções

Estabilidade não é detalhe de implementação

Todas as linhas da Tabela E.3 existem porque a alternativa falha. Um autoencoder LSTM sobre 300 passos com ativação ReLU e sem recorte de gradiente diverge com frequência, e a falha se manifesta como perda que vira NaN no meio do treinamento — sintoma que o iniciante costuma atribuir aos dados.

O sistema do Capítulo 7, que opera em campo, adotou ReLU e funcionou por trabalhar com um gargalo muito mais estreito, de apenas quatro dimensões. A lição é que essas escolhas interagem, e nenhuma delas é universalmente correta.

E.6.2 O limiar

```
from src.anomaly_detection import AnomalyDetector

detector = AnomalyDetector()
detector.compute_reconstruction_errors(ae, normal_data, anomaly_data)
detector.determine_threshold(method="percentile", percentile=95)
metrics = detector.evaluate_detection()
```

Duas políticas estão implementadas: percentil dos erros normais, e $\mu + 2\sigma$. São exatamente as duas alternativas discutidas nos Capítulos 7 e 12 — ali com $k = 3$ e com o percentil 95, respectivamente. Comparar as duas sobre os mesmos erros é uma forma direta de ver que a escolha do limiar move o compromisso entre detecção e alarme falso muito mais do que a escolha da arquitetura.

E.6.3 A alternativa geométrica

O módulo `unsupervised_preprocessing` traz a máquina de vetores de suporte de uma classe como comparação:

```
from src.unsupervised_preprocessing import DistanceAnomalyDetector

ocsvm = DistanceAnomalyDetector(nu=0.05, gamma="scale", kernel="rbf")
ocsvm.fit(normal_data)
```

A implementação achata a janela para um vetor de 300×3 posições e encadeia padronização e OCSVM. É a mesma família de método que, no Capítulo 8, obteve 0,65 de acurácia contra 0,87 do ensemble binário — e a razão desse desempenho fica evidente ao inspecionar a dimensão do vetor achatado.

E.7 Caderno 4: aprendizado supervisionado

Corresponde ao Capítulo 4. Treina e compara seis modelos clássicos.

Tabela E.4: Modelos supervisionados do caderno 4.

Família	Modelo	Configuração
Árvores	Árvore de decisão	profundidade 10; mínimo de 20 para dividir, 10 por folha
	Floresta aleatória	100 árvores; profundidade 15; mínimo de 10 e 5
SVM	Núcleo linear	$C = 1,0$
	Núcleo RBF	$C = 1,0$; γ automático
Redes densas	Rasa	uma camada de 100 unidades
	Profunda	camadas de 200, 100 e 50
	Regularizada	camadas de 150 e 100

O experimento padrão usa as classes $\{0, 3, 4, 8\}$ — normal, golfadas severas, instabilidade de fluxo e hidrato na linha de produção. O balanceamento do treinamento é feito por estratégia combinada de sobre e subamostragem, com teto de mil amostras por classe; o conjunto de teste não é balanceado.

Balancear o treino e não balancear o teste

Essa assimetria é deliberada e frequentemente invertida por engano.

Balancear o treino ajuda o modelo a aprender as classes raras. Balancear o teste *altera a pergunta*: passa-se a medir o desempenho sob uma distribuição que não existe em operação. Como o Capítulo 4 argumenta, é a acurácia balanceada — e não a reamostragem do teste — o instrumento correto para lidar com desbalanceamento na avaliação.

Note ainda que a classe 4 está entre as selecionadas. É a classe sintomática que aparece no fundo de todas as tabelas do livro. Ver isso acontecer com uma floresta aleatória, em uma execução de poucos minutos, é a forma mais econômica de entender o argumento do Capítulo 16 sobre taxonomia.

E.8 Caderno 5: métodos de agrupamento

Corresponde aos Capítulos 6 e 9. Opera sobre as séries brutas, redimensionadas para 500 pontos, e aplica três algoritmos.

Tabela E.5: Algoritmos de agrupamento do caderno 5.

Algoritmo	Seleção de parâmetros	Observação
K -médiãs	Cotovelo e silhueta sobre uma faixa de K	Comparado em espaço escalonado e em 50 componentes principais
MeanShift	Largura de banda estimada dos dados	Produz o número de grupos sem que ele seja informado
DBSCAN	Varredura de ϵ com curva de k -distância, $k = 4$	Único que rotula pontos como ruído

A avaliação usa silhueta e índice de Rand ajustado, além de uma rotina de interpretação que associa cada grupo à classe dominante e produz uma leitura operacional.

Reconhecendo o Capítulo 9 em escala reduzida

O caderno 5 é o ciclo de mundo aberto sem a etapa de rejeição: agrupa, avalia a coesão e tenta interpretar cada grupo.

Ao executá-lo, o leitor encontra — em minutos, e por conta própria — os dois achados que estruturam o Capítulo 9: a silhueta é baixa no espaço bruto, e o número de grupos que os índices sugerem raramente coincide com o número de classes.

O Capítulo 12 explica por quê. Executar antes de ler torna a explicação bem mais convincente.

Tabela E.6: Principais diferenças entre o recurso didático e os experimentos do livro.

Aspecto	Recurso	Livro
Sensores	Três (P-PDG, P-TPT, T-TPT)	Quatro ou cinco, conforme o capítulo
Janela	300 pontos, subamostrados a 1:5	200 a 500 pontos na frequência original
Instâncias por classe	Até 50 arquivos	Todas as disponíveis
Partição	Três dobras; treino com real e simulado, teste só com real	Partição temporal 80/20; simulado só em classes escassas
Latente do autoencoder	16 dimensões, 64 unidades LSTM	4 a 128 dimensões, conforme o capítulo
Classes	Subconjunto $\{0, 3, 4, 8\}$	Todas as dez

E.9 Diferenças em relação às configurações do livro

As diferenças são o próprio material didático

Cada linha da Tabela E.6 é uma decisão que o leitor pode reverter alterando `src/config.py` e reexecutando.

Medir o efeito de cada reversão — quanto se ganha ao passar de três para cinco sensores, quanto se perde ao subamostrar — ensina mais sobre séries temporais multivariadas do que qualquer tabela de resultados prontos. É por isso que o recurso centraliza a parametrização em um único arquivo.

E.10 Exercícios guiados

Exercícios

1. Execute o caderno 1 com os quatro métodos de escalonamento disponíveis e compare a distribuição resultante de cada sensor. Qual método preserva melhor os valores extremos que caracterizam as anomalias?
2. Altere `SAMPLING_RATE` de 5 para 1 e reexecute o caderno 3. O erro de reconstrução melhora ou piora? Separe o efeito do aumento de resolução do efeito da mudança no tempo coberto pela janela.
3. Implemente, no caderno 1, a política de procedência adotada no Capítulo D — excluir instâncias desenhadas e incluir simuladas apenas nas classes escassas — e compare os resultados do caderno 4 sob as duas políticas.
4. Compare, no caderno 3, o limiar por percentil 95 e o limiar $\mu + 2\sigma$ sobre os mesmos erros de reconstrução. Construa a curva ROC e localize os dois limiares sobre ela.
5. Execute o caderno 4 com `selected_classes = None` e compare o desempenho das classes 4 e 5 com o das demais. O padrão descrito no Capítulo 16 se reproduz?
6. Substitua, no caderno 5, o espaço de entrada pelo espaço latente do autoencoder treinado no caderno 3, e recalcule silhueta e índice de Rand ajustado. Compare com os valores da

Tabela 12.3.

7. Estenda o caderno 3 para extrair a penúltima camada de um dos classificadores do caderno 4 e calcular a distância de Mahalanobis nesse espaço. Você consegue reproduzir, em escala reduzida, o salto descrito no Capítulo 12?

Leituras recomendadas

- Lopes (2026) — o recurso descrito neste apêndice, com os cinco cadernos e a gravação do workshop.
- Petróleo Brasileiro S.A. (Petrobras) (2026) — o repositório oficial, com o conjunto de dados, o 3W Toolkit e os demais recursos da comunidade.
- Vaz Vargas et al. (2026) — a descrição formal da versão 2.0.0 do conjunto.

Referências Bibliográficas

- Aranha, P., Gouveia Omena Lopes, L., Paranhos Sobrinho, E., Oliveira, I., de Araújo, J., Santos, B., Lima Junior, E., Silva, T., Vieira, T., Lira, W., Policarpo, N., and Pinto, M. A. (2024a). A system to detect oilwell anomalies using deep learning and decision diagram dual approach. *SPE Journal*, 29:1540–1553.
- Aranha, P. E., Policarpo, N. A., and Sampaio, M. A. (2024b). Unsupervised machine learning model for predicting anomalies in subsurface safety valves and application in offshore wells during oil production. *Journal of Petroleum Exploration and Production Technology*, 14:567–581.
- Belay, M. A., Haghipour, A., Rasheed, A., and Salvo Rossi, P. (2026). Agentic and LLM-based multimodal anomaly detection: Architectures, challenges, and prospects. *Sensors*, 26(8):2330.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Brønstad, C., Netto, S. L., and Ramos, A. L. (2021). Data-driven detection and identification of undesirable events in subsea oil wells. In *Proceedings of the International Conference on Advances in Condition-Based Monitoring*, pages 1–6, Athens, Greece. IARIA.
- Caliński, T. and Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1):1–27.
- Carvalho, B. G., Vaz Vargas, R. E., Salgado, R. M., Munaro, C. J., and Varejão, F. M. (2021). Flow instability detection in offshore oil wells with multivariate time series machine learning classifiers.
- Chebbi, A. and Kolade, B. (2025). Towards EnergyGPT: A large language model specialized for the energy sector.
- Chollet, F. (2015). Keras. <https://github.com/fchollet/keras>.
- Comaniciu, D. and Meer, P. (2002). Mean shift: a robust approach toward feature space analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(5):603–619.
- Deng, D. (2020). DbSCAN clustering algorithm based on density. In *2020 7th International Forum on Electrical Engineering and Automation (IFEEA)*, pages 949–953.
- Gatta, F., Giampaolo, F., Chiaro, D., and Piccialli, F. (2022). Predictive maintenance for offshore oil wells by means of deep learning features extraction. *Expert Systems*.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Jafarzadeh, M., Dhamija, A. R., Cruz, S., Li, C., Ahmad, T., and Boulton, T. E. (2022). A review of open-world learning and steps toward open-world learning without labels.

- Jones, E., Oliphant, T., Peterson, P., et al. (2001). SciPy: Open source scientific tools for Python.
- Kingma, D. P. and Ba, J. (2014). Adam: A method for stochastic optimization. arXiv preprint, last revised 30 January 2017.
- Liu, H., Ren, Y., Li, X., Deng, Y., Wang, Y., Cao, Q., Du, J., Lin, Z., and Wang, W. (2024). Research status and application of artificial intelligence large models in the oil and gas industry. *Petroleum Exploration and Development*, 51(4):1049–1065.
- Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2):129–137.
- Lopes, L. G. O. (2025). *Open-World Learning Applied to Oil Wells Using Autoencoder-Based Clustering*. PhD thesis, Universidade Federal de Alagoas, Programa de Pos-Graduacao em Engenharia Civil, Maceio, Brasil.
- Lopes, L. G. O. (2026). Introduction to machine learning applied to multivariate time series. Recurso da comunidade 3W, https://github.com/petrobras/3W/tree/main/resources/introduction_to_ml_applied_to_mts. Apresentado no 4th Workshop on 3W.
- Lopes, L. G. O., Vieira, T. M. d. A., Aranha, P. E., Lima Junior, E. T. d., and Lira, W. W. M. (2025). Detection and classification of anomalies in oil well production using Open-World Learning. *Engineering Applications of Artificial Intelligence*, 159:111514.
- Lopes, L. G. O., Vieira, T. M. d. A., Aranha, P. E., Lima Junior, E. T. d., and Lira, W. W. M. (2026a). Real-time recognition of operational events in oil wells using U-Net segmentation and distance-based classification. In *Offshore Technology Conference*. OTC-36929-MS.
- Lopes, L. G. O., Vieira, T. M. d. A., Lima Junior, E. T. d., and Lira, W. W. M. (2026b). An explainable LLM agent layer for open-world anomaly detection in oil wells. Preprint.
- Lopes, L. G. O., Vieira, T. M. d. A., Lima Junior, E. T. d., and Lira, W. W. M. (2026c). Overcoming the closed-world assumption with binary classifier ensembles for anomaly classification in oil wells. *Petroleum Science and Technology*.
- Ma, Z., Santos, J. E., Lackey, G., Viswanathan, H., and O'Malley, D. (2024). Information extraction from historical well records using a large language model. *Scientific Reports*, 14:31702.
- Machado, A. P. F., Vargas, R. E. V., Ciarelli, P. M., and Munaro, C. J. (2022). Improving performance of one-class classifiers applied to anomaly detection in oil wells. *Journal of Petroleum Science and Engineering*, 218.
- Mahalanobis, P. C. (1936). On the generalised distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1):49–55.
- Malhotra, P., Vig, L., Shroff, G., and Agarwal, P. (2015). Long short term memory networks for anomaly detection in time series. In *ESANN*. "ESANN 2015".
- Marins, M. A., Barros, B. D., Santos, I. H., Barrionuevo, D. C., Vargas, R. E., Prego, T. M., Lima, A. A., Campos, M. L., Silva, E. A., and Netto, S. L. (2021a). Fault detection and classification in oil wells and production/service lines using random forest. *Journal of Petroleum Science and Engineering*, 197.

- Marins, M. A., Barros, B. D., Santos, I. H., et al. (2021b). Fault detection and classification in oil wells and production/service lines using random forest. *Journal of Petroleum Science and Engineering*.
- Motiee, M. (1991). Estimate possibility of hydrates. *Hydrocarbon Processing*, 70:98–99.
- Node-RED (2019). Node-red: Documentation.
- Parmar, J., Chouhan, S. S., Raychoudhury, V., and Rathore, S. S. (2022). Open-world machine learning: Applications, challenges, and opportunities.
- Petróleo Brasileiro S.A. (Petrobras) (2026). The 3W project. <https://github.com/petrobras/3W>. Repositorio publico do conjunto de dados 3W, do 3W Toolkit e dos recursos da comunidade.
- Pimentel, M. A., Clifton, D. A., Clifton, L., and Tarassenko, L. (2014). A review of novelty detection. *Signal Processing*, 99:215–249.
- Qwen Team (2025). Qwen3 technical report.
- Qwen Team (2026). Qwen3.5-397B-A17B model card. Hugging Face, <https://huggingface.co/Qwen/Qwen3.5-397B-A17B>. Acesso em 3 set. 2026.
- Ren, Y., Pu, J., Yang, Z., Xu, J., Li, G., Pu, X., Yu, P. S., and He, L. (2022). Deep clustering: A comprehensive survey.
- Ronneberger, O., Fischer, P., and Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65.
- Safamirzaei, M. (2015). Predict gas hydrate formation temperature with a simple correlation. <http://www.gasprocessingnews.com/features/201508/predict-gas-hydrate-formation-temperature-with-a-simple-correlation.aspx>.
- Salles, R., Lima, J., Reis, M., Coutinho, R., Pacitti, E., Maseglia, F., Akbarinia, R., Chen, C., Garibaldi, J., Porto, F., and Ogasawara, E. (2024). SoftED: Metrics for soft evaluation of time series event detection. *Computers and Industrial Engineering*, 198:110728.
- Scheirer, W. J., Rocha, A. d. R., Sapkota, A., and Boulton, T. E. (2013). Toward open set recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(7):1757–1772.
- Schmidhuber, J. (2015). Deep learning in neural networks: An overview. *Neural Networks*, 61:85 – 117.
- Sharma, R. and Mehta, M. (2025). Adaptive and explainable AI agents for anomaly detection in critical IoT infrastructure using LLM-enhanced contextual reasoning.
- Smola, A. and Scholkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, 14(3).
- Soriano-Vargas, A., Werneck, R., Moura, R., Mendes Júnior, P., Prates, R., Castro, M., Gonçalves, M., Hossain, M., Zampieri, M., Ferreira, A., Davólio, A., Hamann, B., Schiozer, D. J., and Rocha, A. (2021). A visual analytics approach to anomaly detection in hydrocarbon reservoir time series data. *Journal of Petroleum Science and Engineering*.

- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958.
- Turan, E. M. and Jaschke, J. (2021). Classification of undesirable events in oil well operation. In *23rd International Conference on Process Control (PC)*, Strbske Pleso, Slovakia.
- van der Maaten, L. and Hinton, G. (2008). Visualizing data using t-sne. *Journal of Machine Learning Research*, 9(11):2579–2605.
- Vargas, R. E. V., Munaro, C. J., Ciarelli, P. M., Medeiros, A. G., do Amaral, B. G., Barrionuevo, D. C., de Araújo, J. C. D., Ribeiro, J. L., and aes, L. P. M. (2019). A realistic and public dataset with rare undesirable real events in oil wells. *Journal of Petroleum Science and Engineering*, 181:106223.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30.
- Vaz Vargas, R. E., de Melo Junior, A. J., de Campos Lima, C. B., de Araújo, J. C. D., de Araujo Fernandes, M., Alves Pinto, R. L., Barbosa Jr., J. R., Munaro, C. J., Ciarelli, P. M., Varejão, F. M., Barrocas, F. M., Carneiro, J. N. E., Scramignon, M. L., Castello Branco, R., Sequeira, T. P., de Lima Junior, E. T., de Melo Nery Oliveira, I., Lopes, L. G. O., de Gouveia, L. P., Peixer, G. F., and Lozano Cadena, J. A. (2026). 3W dataset 2.0.0: A realistic and public dataset with rare undesirable real events in oil wells. *Scientific Data*, 13(1):949.
- Wei, Q., Sun, H., Xu, Y., Pang, Z., and Gao, F. (2024). Exploring the application of large language models based AI agents in leakage detection of natural gas valve chambers. *Energies*, 17(22):5633.
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212.
- Xu, H., Chen, W., Zhao, N., Li, Z., Bu, J., Li, Z., Liu, Y., Zhao, Y., Pei, D., Feng, Y., Chen, J., Wang, Z., and Qiao, H. (2018). Unsupervised anomaly detection via variational auto-encoder for seasonal kpis in web applications. In *Proceedings of the 2018 World Wide Web Conference, WWW '18*, page 187–196, Republic and Canton of Geneva, CHE. International World Wide Web Conferences Steering Committee.
- Zhang, H. and Jain, S. (2026). LLM-assisted logic rule learning: Scaling human expertise for time series anomaly detection.
- Zhang, Q., Xu, C., Li, J., Sun, Y., Bao, J., and Zhang, D. (2025). LLM-TSFD: An industrial time series human-in-the-loop fault diagnosis method based on a large language model. *Expert Systems with Applications*, 264:125861.
- Zhu, F., Ma, S., Cheng, Z., Zhang, X.-Y., Zhang, Z., and Liu, C.-L. (2024). Open-world machine learning: A review and new outlooks.

Índice Remissivo

aprendizado de mundo aberto, 6
atenção, 44
autoencoder, 40
autoencoder variacional, 42

busca aleatória, 77

chaves, 128
coluna de produção, 11
completação, 12
completação inteligente, 12
conexões de atalho, 110
consulta, 128
custo de credibilidade, 5

hipótese de mundo fechado, iii, 6

janela deslizante, 21

medidor permanente de fundo, 14
memória de curto prazo longa, 38

perceptron de múltiplas camadas, 37
problema do gradiente evanescente, 38

reconhecimento em conjunto aberto, 6
rede de agrupamento profundo, 42
regime de base, 137
regime do evento, 137
representação latente, 40
risco de espaço aberto, 48

tempo não produtivo, 4
teor de água e sedimentos, 15
token, 128
transdutor de temperatura e pressão, 14

unidade recorrente com portas, 39

valores, 128

árvore de natal molhada, 12